

解答解説集

大学基礎から大学院入試への橋渡し — 全19章・159問の詳解

本書は『問題集』の姉妹編です。問題番号は完全に対応しています(問 3.4 の解説は 解 3.4)。

PDF版 2026-09-02 生成

目次

- 第1章 関数と極限 解 1.1～1.9
- 第2章 微分の基礎 解 2.1～2.9
- 第3章 微分で関数を読む 解 3.1～3.9
- 第4章 テイラー展開 解 4.1～4.8
- 第5章 積分の基礎 解 5.1～5.8
- 第6章 積分の技法と広義積分 解 6.1～6.9
- 第7章 偏微分と勾配 解 7.1～7.9
- 第8章 ヘッセ行列と2次近似 解 8.1～8.8
- 第9章 多変数関数の極値 解 9.1～9.8
- 第10章 重積分 解 10.1～10.8
- 第11章 最適化問題の定式化 解 11.1～11.8
- 第12章 凸集合と凸関数 解 12.1～12.9
- 第13章 勾配降下法 解 13.1～13.9
- 第14章 ニュートン法 解 14.1～14.8
- 第15章 等式制約とラグランジュ乗数 解 15.1～15.8

第17章 双対性 解 17.1～17.8

第18章 機械学習と最適化 解 18.1～18.8

第19章 ε - δ 論法 解 19.1～19.8

解説の読み方

各解説は次の3段構成です。

- **方針** — 解き始める前の見取り図。詰まったときは、まずここだけを読んでもう一度自力で挑戦してください(段階的ヒントとして使えます)。
- **解答** — 答案として書ける形の完全な解。途中計算も省略せずに示します。
- **ポイント** — その問題が教えてくれる本質、よくある誤り、先の章や応用とのつながり。

読んで「わかった」で止めず、翌日、何も見ずにノートへ再現できて初めて身についたと判定してください。証明問題は、論理の流れを自分の言葉で言い直せるかが基準です。

第1章

関数と極限 — 解答解説

「限りなく近づく」を扱う言葉

解 1.1 ★ 関数と合成

方針

$f(x)$ の x の位置に、指定されたもの(数・式・別の関数)をそのまま入れる。合成 $f \circ g$ は「先に g 、あとに f 」の順で作用させる。

解答

(1) $f(0) = 0 - 0 + 3 = 3$ 、 $f(2) = 4 - 4 + 3 = 3$ 。また

$$f(a+1) = (a+1)^2 - 2(a+1) + 3 = a^2 + 2a + 1 - 2a - 2 + 3 = a^2 + 2$$

(2) f の x に $g(x) = 2x - 1$ を代入して

$$\begin{aligned}(f \circ g)(x) &= (2x - 1)^2 - 2(2x - 1) + 3 \\ &= 4x^2 - 4x + 1 - 4x + 2 + 3 = 4x^2 - 8x + 6\end{aligned}$$

逆に g の x に $f(x)$ を代入して

$$(g \circ f)(x) = 2(x^2 - 2x + 3) - 1 = 2x^2 - 4x + 5$$

たとえば $x = 0$ で前者は 6、後者は 5 なので、確かに $(f \circ g) \neq (g \circ f)$ 。

ポイント

合成の順序で結果が変わる — 関数はプログラムの関数と同じで、「適用の順番」が本質です。第2章の連鎖律(合成関数の微分)、第7章の多変数の連鎖律、そして深層学習の誤差逆伝播は、すべて「合成関数をどう扱うか」という一つの物語です。 $f(a+1)$ のような「式の代入」に慣れておくと、微分の定義に出てくる $f(a+h)$ が怖くなくなります。

解 1.2 ★ 数列の極限

方針

$\frac{\infty}{\infty}$ 型は「最高次の項で割る」、 $\infty - \infty$ 型は「有理化して1つの分数にまとめる」。不定形は式変形で情報を引き出してから極限をとる。

解答

(1) 分母分子を n^2 で割ると

$$\frac{3n^2 + 2n}{n^2 + 1} = \frac{3 + \frac{2}{n}}{1 + \frac{1}{n^2}} \longrightarrow \frac{3 + 0}{1 + 0} = 3$$

(2) $\sqrt{n+1} + \sqrt{n}$ を掛けて割る(有理化)と

$$\sqrt{n+1} - \sqrt{n} = \frac{(n+1) - n}{\sqrt{n+1} + \sqrt{n}} = \frac{1}{\sqrt{n+1} + \sqrt{n}} \longrightarrow 0$$

(分母は $2\sqrt{n}$ より大きく、限りなく大きくなる。)

(3) $1 + 2 + \cdots + n = \frac{n(n+1)}{2}$ だから

$$\frac{1 + 2 + \cdots + n}{n^2} = \frac{n(n+1)}{2n^2} = \frac{1}{2} \left(1 + \frac{1}{n}\right) \longrightarrow \frac{1}{2}$$

ポイント

(1) は「 n が大きいとき、多項式は最高次の項で決まる」という増大度の感覚そのもの — 計算量で $3n^2 + 2n$ を $O(n^2)$ と書くのと同じ思想です。(3) は「1 から n までの平均 $\frac{1+\cdots+n}{n}$ はおよそ $\frac{n}{2}$ 」と読み、ループの平均実行回数の見積もりなどで頻出します。

解 1.3 ★ 関数の極限 — 不定形の解消

方針

$\frac{0}{0}$ になる原因は「分母分子に共通のゼロ因子が隠れている」こと。因数分解や有理化で共通因子を見つけて約分すれば、不定形が解消される。

解答

(1) $x \rightarrow 2$ で分母分子とも 0 (不定形)。 $x^2 - 4 = (x - 2)(x + 2)$ と因数分解し、 $x \neq 2$ で約分して

$$\lim_{x \rightarrow 2} \frac{(x - 2)(x + 2)}{x - 2} = \lim_{x \rightarrow 2} (x + 2) = 4$$

(2) $x \rightarrow 0$ で $\frac{0}{0}$ 。分子を有理化すると

$$\frac{\sqrt{1+x} - 1}{x} = \frac{(1+x) - 1}{x(\sqrt{1+x} + 1)} = \frac{1}{\sqrt{1+x} + 1} \longrightarrow \frac{1}{1+1} = \frac{1}{2}$$

(3) $x \rightarrow 3$ で $\frac{0}{0}$ 。因数分解して約分すると

$$\frac{x^2 - 2x - 3}{x^2 - 9} = \frac{(x - 3)(x + 1)}{(x - 3)(x + 3)} = \frac{x + 1}{x + 3} \longrightarrow \frac{4}{6} = \frac{2}{3}$$

ポイント

極限の計算で「 $x \neq 2$ だから約分してよい」と言えるのが急所です。極限は「 $x = 2$ での値」ではなく「 $x = 2$ に近づくときの値」を問うので、途中の式変形では $x \neq 2$ と仮定して構いません。実は (1) は $g(x) = x^2$ の $x = 2$ における微分係数 $\lim_{x \rightarrow 2} \frac{g(x) - g(2)}{x - 2}$ そのもの — 第2章で定義する微分は、この型の極限の名前です。

解 1.4 ★ 片側極限と極限の不存在

方針

$|x|$ は $x > 0$ なら x 、 $x < 0$ なら $-x$ 。右から近づく場合と左から近づく場合を別々に計算する。

解答

$x > 0$ のとき $f(x) = \frac{x}{x} = 1$ 、 $x < 0$ のとき $f(x) = \frac{-x}{x} = -1$ 。よって

$$\lim_{x \rightarrow 0+} f(x) = 1, \quad \lim_{x \rightarrow 0-} f(x) = -1$$

右極限と左極限が異なる ($1 \neq -1$) ので、 $\lim_{x \rightarrow 0} f(x)$ は存在しない。極限が存在するとは、どちら側から近づいても同じ1つの値に落ち着くことだからである。

ポイント

この f は符号関数 $\text{sgn}(x)$ で、プログラムの `if x > 0` による場合分けに対応する「段差」を持ちます。段差の位置では極限が壊れ、したがって連続でも微分可能でもありません。深層学習で使うステップ関数や ReLU の「角」の議論(問2.9)の最初の例です。

解 1.5 ★★ はさみうちの原理

方針

振動する因子($\sin$ の部分)は極限を持たないが、 $|\sin(\cdot)| \leq 1$ で大きさは抑えられる。振動部分を ± 1 で挟み、両側が同じ極限を持つことを確かめる。

解答

(1) すべての $x \neq 0$ で $-1 \leq \sin \frac{1}{x} \leq 1$ だから、 $x^2 \geq 0$ を掛けて

$$-x^2 \leq x^2 \sin \frac{1}{x} \leq x^2$$

$x \rightarrow 0$ で両端はともに 0 に収束するので、はさみうちの原理より

$$\lim_{x \rightarrow 0} x^2 \sin \frac{1}{x} = 0$$

(2) すべての n で $-1 \leq \sin n \leq 1$ だから、 $n > 0$ で割って

$$-\frac{1}{n} \leq \frac{\sin n}{n} \leq \frac{1}{n}$$

$n \rightarrow \infty$ で両端は 0 に収束するので、 $\lim_{n \rightarrow \infty} \frac{\sin n}{n} = 0$ 。

よくある誤り:「 $\lim x^2 \sin \frac{1}{x} = \lim x^2 \times \lim \sin \frac{1}{x}$ 」と積に分解すること。 $\lim \sin \frac{1}{x}$ は存在しないため、「積の極限=極限の積」という定理の前提(各因子の極限が存在すること)が満たされず、この分解は使えません。

ポイント

「有界なもの $\times 0$ に向かうもの $= 0$ に向かう」という型は、誤差評価の基本形です。ノイズ(有界)を含む信号を n 個平均すればノイズの影響が $\frac{1}{n}$ のオーダーで消えていく、という直感((2) の形)は、確率・統計の大数の法則にもつながります。

解 1.6 ★★ 重要極限 $\sin x/x$

方針

単位円で中心角 x (ラジアン) の扇形を、内側の三角形と外側の三角形で挟む。面積の大小がそのまま $\sin x < x < \tan x$ になり、逆数をとって $\sin x$ を掛ければはさみうちの形が現れる。

解答

(1) 単位円の中心を O 、円周上に $A = (1, 0)$ 、中心角 x ($0 < x < \frac{\pi}{2}$) の点 $B = (\cos x, \sin x)$ をとる。さらに A を通る鉛直線と直線 OB の交点を $T = (1, \tan x)$ とする。このとき

$$\triangle OAB \subset \text{扇形 } OAB \subset \triangle OAT$$

だから面積を比べて

$$\frac{1}{2} \sin x < \frac{1}{2} x < \frac{1}{2} \tan x$$

(扇形の面積は 半径² × 中心角 ÷ 2 = $\frac{x}{2}$ 。中心角をラジアンで測っているからこの式になる。) 各辺を 2 倍して $\sin x < x < \tan x$ 。

(2) (1) の各辺を $\sin x$ (> 0) で割ると $1 < \frac{x}{\sin x} < \frac{1}{\cos x}$ 、逆数をとって

$$\cos x < \frac{\sin x}{x} < 1$$

$x \rightarrow 0+$ のとき $\cos x \rightarrow 1$ だから、はさみうちの原理より $\frac{\sin x}{x} \rightarrow 1$ 。また $\frac{\sin x}{x}$ は偶関数 (x を $-x$ に変えても値が同じ) なので、 $x \rightarrow 0-$ でも同じ値 1 に収束する。よって

$$\lim_{x \rightarrow 0} \frac{\sin x}{x} = 1$$

(3) $1 - \cos x$ に $1 + \cos x$ を掛けて割ると $1 - \cos^2 x = \sin^2 x$ が現れて

$$\frac{1 - \cos x}{x^2} = \frac{\sin^2 x}{x^2(1 + \cos x)} = \left(\frac{\sin x}{x}\right)^2 \cdot \frac{1}{1 + \cos x} \longrightarrow 1^2 \cdot \frac{1}{2} = \frac{1}{2}$$

また

$$\frac{\tan x}{x} = \frac{\sin x}{x} \cdot \frac{1}{\cos x} \longrightarrow 1 \cdot 1 = 1$$

ポイント

この極限は「 x が小さいとき $\sin x \approx x$, $\cos x \approx 1 - \frac{x^2}{2}$, $\tan x \approx x$ 」という近似の正当化です(第4章のテイラー展開で系統化されます)。物理シミュレーションで微小角の回転を線形化するときの根拠もこれ。なお角を度で測るとこの極限は $\frac{\pi}{180}$ になってしまいます — 数学・工学でラジアンを使う理由は「sin の微分をきれいにするため」です(問2.3)。

解 1.7 ★★ ネイピア数 e と関連する極限

方針

すべて $\lim_{t \rightarrow 0} (1 + t)^{1/t} = e$ に「形を合わせる」。(1) は指数の作り替え、(2) は $\log$ の中に押し込む、(3) は置換で (2) に帰着。

解答

(1) $t = \frac{2}{n}$ とおくと $n = \frac{2}{t}$ で、 $n \rightarrow \infty$ のとき $t \rightarrow 0+$ 。よって

$$\left(1 + \frac{2}{n}\right)^n = (1 + t)^{2/t} = \left\{(1 + t)^{1/t}\right\}^2 \longrightarrow e^2$$

(2) 対数の性質 $a \log b = \log b^a$ より

$$\frac{\log(1 + x)}{x} = \log\left((1 + x)^{1/x}\right)$$

$x \rightarrow 0$ で $(1+x)^{1/x} \rightarrow e$ であり、 $\log$ は連続関数だから中身の極限をそのまま渡せて

$$\lim_{x \rightarrow 0} \frac{\log(1+x)}{x} = \log e = 1$$

(3) $t = e^x - 1$ とおくと $x = \log(1+t)$ で、 $x \rightarrow 0$ のとき $t \rightarrow 0$ 。よって

$$\frac{e^x - 1}{x} = \frac{t}{\log(1+t)} = \frac{1}{\frac{\log(1+t)}{t}} \rightarrow \frac{1}{1} = 1$$

ポイント

(2)(3) は「 x が小さいとき $\log(1+x) \approx x$ 、 $e^x \approx 1+x$ 」という、実務で最頻出の近似です。 e がわざわざ底に選ばれるのは、この近似の係数が 1 になる(= e^x の微分が自分自身になる。問2.3)から。複利計算 $(1 + \frac{r}{n})^n \rightarrow e^r$ ($r=2$ の場合)、情報理論の $\log$ 、機械学習のソフトマックスやロジスティック関数 — e は情報系の至る所の「自然な底」です。

解 1.8 ★★ 中間値の定理と二分法

方針

端点での符号が異なれば、連続関数は途中で必ず 0 を横切る(中間値の定理)。二分法は「符号が異なる区間を半分に縮め続ける」アルゴリズムで、各ステップの正しさをこの定理が保証する。

解答

(1) $f(x) = x^3 + x - 1$ は多項式なので連続。端点の値は

$$f(0) = -1 < 0, \quad f(1) = 1 + 1 - 1 = 1 > 0$$

符号が異なるから、中間値の定理より $f(c) = 0$ となる c が区間 $(0, 1)$ に少なくとも1つ存在する。

(2) 中点 $x = \frac{1}{2}$ で

$$f\left(\frac{1}{2}\right) = \frac{1}{8} + \frac{1}{2} - 1 = -\frac{3}{8} < 0$$

$f\left(\frac{1}{2}\right) < 0 < f(1)$ だから解は $\left(\frac{1}{2}, 1\right)$ にある。次に中点 $x = \frac{3}{4}$ で

$$f\left(\frac{3}{4}\right) = \frac{27}{64} + \frac{3}{4} - 1 = \frac{27}{64} - \frac{16}{64} = \frac{11}{64} > 0$$

$f\left(\frac{1}{2}\right) < 0 < f\left(\frac{3}{4}\right)$ だから、解は幅 $\frac{1}{4}$ の区間 $\left(\frac{1}{2}, \frac{3}{4}\right)$ にある。(実際の解は $c = 0.6823\dots$ で、確かにこの区間内。)

(3) $a < b$ とすると、 x^3 も x も狭義単調増加だから $a^3 < b^3$ かつ $a < b$ 。辺々加えて1を引くと $f(a) < f(b)$ 。つまり f は狭義単調増加であり、同じ値0を2度とることはできない。よって実数解はただ1つ。(微分を使うなら: $f'(x) = 3x^2 + 1 \geq 1 > 0$ が常に成り立つので狭義単調増加、としてもよい。)

ポイント

二分法は1回の反復で解の存在区間が半分になるので、 k 回で幅 2^{-k} — 10回で約 $\frac{1}{1000}$ の精度です。これはソート済み配列の二分探索と同じ $O(\log \frac{1}{\epsilon})$ の発想で、「連続版の二分探索」と言えます。中間値の定理は「解が存在すること」を保証する定理であり、アルゴリズムの停止性・正当性の証明に使われる、実は極めて計算機科学的な定理です。より速い求根法(ニュートン法)は第14章で扱います。

解 1.9 ★★★ 増大度の比較(計算量の階層)

方針

比 $\frac{a_{n+1}}{a_n}$ が 1 未満の値に収束するなら、途中から数列は「毎回 s 倍 ($s < 1$) される」等比数列で上から抑えられる。等比数列 $s^k \rightarrow 0$ とはさみうちで結論が出る。

解答

(1) 比の補題の証明: $r < s < 1$ となる s を 1 つとる (たとえば $s = \frac{r+1}{2}$)。 $\frac{a_{n+1}}{a_n} \rightarrow r < s$ だから、ある番号 N 以降のすべての n で $\frac{a_{n+1}}{a_n} \leq s$ 、すなわち $a_{n+1} \leq s a_n$ が成り立つ。これを繰り返し使うと、 $n > N$ に対して

$$0 < a_n \leq s a_{n-1} \leq s^2 a_{n-2} \leq \cdots \leq s^{n-N} a_N = \frac{a_N}{s^N} \cdot s^n$$

$0 < s < 1$ より $s^n \rightarrow 0$ だから、右辺は 0 に収束する。はさみうちの原理より $a_n \rightarrow 0$ 。
(証明終)

(2) $a_n = \frac{n^{100}}{2^n}$ とおくと

$$\frac{a_{n+1}}{a_n} = \frac{(n+1)^{100}}{2^{n+1}} \cdot \frac{2^n}{n^{100}} = \frac{1}{2} \left(1 + \frac{1}{n}\right)^{100} \longrightarrow \frac{1}{2} \cdot 1 = \frac{1}{2} < 1$$

よって比の補題より $\frac{n^{100}}{2^n} \rightarrow 0$ 。

(3) $b_n = \frac{2^n}{n!}$ とおくと

$$\frac{b_{n+1}}{b_n} = \frac{2^{n+1}}{(n+1)!} \cdot \frac{n!}{2^n} = \frac{2}{n+1} \longrightarrow 0 < 1$$

よって比の補題より $\frac{2^n}{n!} \rightarrow 0$ 。

(4) (2) は、実行時間が $\Theta(n^{100})$ で増大するアルゴリズムは、 $\Theta(2^n)$ で増大するものに比べ、入力サイズ n が大きいとき比が 0 になるほど遅く増大することを意味する。(3) は、

$\Theta(n!)$ で増大する全順列列挙などが $\Theta(2^n)$ よりさらに速く増大することを意味する。ここで Θ を使うのは、 O が上界しか表さず、たとえば n も $O(2^n)$ に含まれるためである。

ポイント

増大度の階層 $\log n \ll n^a \ll c^n \ll n! (a > 0, c > 1)$ は、アルゴリズム設計の羅針盤です。残る「 $\log n \ll n^a$ 」($\frac{\log n}{n^a} \rightarrow 0$) は、ロピタルの定理を手に入れる問3.8で証明します。比の補題は、第4章で e^x の級数の収束を保証するときにも同じ形で再登場する — 「隣の比を見る」のは無限を手なずける常套手段です。

第2章

微分の基礎 — 解答解説

瞬間の変化率と一次近似

解 2.1 ★ 定義から微分する

方針

差分商 $\frac{f(x+h)-f(x)}{h}$ を作り、 $\frac{0}{0}$ の不定形を第1章の技術(展開・通分・有理化)で解消してから $h \rightarrow 0$ とする。

解答

(1)

$$\frac{(x+h)^2 - x^2}{h} = \frac{2xh + h^2}{h} = 2x + h \xrightarrow{h \rightarrow 0} 2x \quad \therefore (x^2)' = 2x$$

(2) 通分して

$$\begin{aligned} \frac{\frac{1}{x+h} - \frac{1}{x}}{h} &= \frac{x - (x+h)}{h x(x+h)} = \frac{-1}{x(x+h)} \xrightarrow{h \rightarrow 0} -\frac{1}{x^2} \\ \therefore \left(\frac{1}{x}\right)' &= -\frac{1}{x^2} \end{aligned}$$

(3) 分子を有理化して

$$\begin{aligned} \frac{\sqrt{x+h} - \sqrt{x}}{h} &= \frac{(x+h) - x}{h(\sqrt{x+h} + \sqrt{x})} = \frac{1}{\sqrt{x+h} + \sqrt{x}} \xrightarrow{h \rightarrow 0} \frac{1}{2\sqrt{x}} \\ \therefore (\sqrt{x})' &= \frac{1}{2\sqrt{x}} \end{aligned}$$

ポイント

3問とも $(x^\alpha)' = \alpha x^{\alpha-1}$ ($\alpha = 2, -1, \frac{1}{2}$) の実例になっていることを確認してください。定義からの計算は面倒ですが、「微分とは差分商の極限である」という体感は、数値微分(コンピュータで $\frac{f(x+h)-f(x)}{h}$ を小さい h で計算して微分の近似にする手法)を理解する土台になります。

解 2.2 ★ べき乗の微分と線形性

方針

項ごとに $(x^\alpha)' = \alpha x^{\alpha-1}$ を適用し、係数はそのまま前に出す(線形性)。負のべきもそのまま公式に乘る。

解答

(1)

$$f'(x) = 3 \cdot 4x^3 - 5 \cdot 2x + 2 - 0 = 12x^3 - 10x + 2$$

(2) $g(x) = x^{-3}$ だから

$$g'(x) = -3x^{-4} = -\frac{3}{x^4}$$

ポイント

「微分は線形な操作」— つまり $(af + bg)' = af' + bg'$ — であることは、これから何百回も暗黙に使う性質です。線形代数の言葉で言えば、微分は関数の空間の上の**線形写像**です(『線形代数』第6章)。なお任意の実数 α でも、 $x > 0$ では $(x^\alpha)' = \alpha x^{\alpha-1}$ が成り立ちます。一般の場合の証明は $x^\alpha = e^{\alpha \log x}$ と書き直して連鎖律を使えばよく、問2.7のあとに各自確かめられます。整数指数などでは定義域をさらに広げられます。

解 2.3 ★★ $\sin$ と e^x の微分の導出

方針

差分商を作り、加法定理(または指数法則)で「 x の部分」と「 h の部分」を分離する。残った h だけの極限が、第1章で準備した重要極限そのもの。

解答

(1) まず $\lim_{h \rightarrow 0} \frac{\cos h - 1}{h} = \lim_{h \rightarrow 0} \left(-\frac{1 - \cos h}{h^2} \cdot h \right) = -\frac{1}{2} \cdot 0 = 0$ (問1.6(3)の結果 $\times h \rightarrow 0$)。加法定理 $\sin(x + h) = \sin x \cos h + \cos x \sin h$ より

$$\begin{aligned} \frac{\sin(x + h) - \sin x}{h} &= \sin x \cdot \frac{\cos h - 1}{h} + \cos x \cdot \frac{\sin h}{h} \\ &\xrightarrow{h \rightarrow 0} \sin x \cdot 0 + \cos x \cdot 1 = \cos x \end{aligned}$$

よって $(\sin x)' = \cos x$ 。(同様に $\cos(x + h) = \cos x \cos h - \sin x \sin h$ から $(\cos x)' = -\sin x$ も出る。)

(2) 指数法則 $e^{x+h} = e^x e^h$ より

$$\frac{e^{x+h} - e^x}{h} = e^x \cdot \frac{e^h - 1}{h} \xrightarrow{h \rightarrow 0} e^x \cdot 1 = e^x$$

(問1.7(3)を使った。)よって $(e^x)' = e^x$ 。

ポイント

どちらの証明も構造は同じで、「 $f(x + h)$ を $f(x) \times (h \text{ だけの式}) + \dots$ に分解できる」ことが効いています。 $(e^x)' = e^x$ — 微分しても形が変わらない — は指数関数の最重要性質で、微分方程式 $y' = y$ (成長・減衰のモデル) の解であり、第4章のテイラー展開 $e^x = 1 + x + \frac{x^2}{2!} + \dots$ の美しさの源泉です。角度をラジアンで測るのは、まさに (1) の $\frac{\sin h}{h} \rightarrow 1$ を成立させ、 $(\sin x)' = \cos x$ と余計な定数なしで書くためです。

解 2.4 ★★ 積の公式の証明と適用

方針

差分商の分子 $f(x+h)g(x+h) - f(x)g(x)$ に、中間項 $f(x+h)g(x)$ を「引いて足す」。2つの差分商に分かれ、それぞれが f' 、 g' を生む。

解答

(1)

$$\begin{aligned} & \frac{f(x+h)g(x+h) - f(x)g(x)}{h} \\ &= \frac{f(x+h)g(x+h) - f(x+h)g(x)}{h} + \frac{f(x+h)g(x) - f(x)g(x)}{h} \\ &= f(x+h) \cdot \frac{g(x+h) - g(x)}{h} + \frac{f(x+h) - f(x)}{h} \cdot g(x) \end{aligned}$$

$h \rightarrow 0$ のとき、 f は微分可能ゆえ連続なので $f(x+h) \rightarrow f(x)$ 。各差分商はそれぞれ $g'(x)$ 、 $f'(x)$ に収束するから

$$(fg)'(x) = f(x)g'(x) + f'(x)g(x)$$

(証明終)

(2) $f = x^2$ 、 $g = e^x$ として

$$y' = (x^2)'e^x + x^2(e^x)' = 2xe^x + x^2e^x = (x^2 + 2x)e^x$$

よくある誤り: $(fg)' = f'g'$ としてしまうこと。実際、 $f = g = x$ なら $(x \cdot x)' = (x^2)' = 2x$ ですが $f'g' = 1 \cdot 1 = 1$ で一致しません。積の微分は「片方ずつ微分して足す」です。

ポイント

「引いて足す」は解析学で最も多用される証明技法です。直感的には、長方形の面積 fg の増分を「縦の増分 $\times$ 横」+「縦 $\times$ 横の増分」に分けている(微小量どうしの積 $\Delta f \Delta g$ は高次の微小として消える)、と見ることができます。

解 2.5 ★ 商の公式

方針

$\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2}$ 。「分子を微分 $\times$ 分母 $-$ 分子 $\times$ 分母を微分、全体を分母の2乗で割る」。分子の順番(引き算の向き)に注意。

解答

(1) $f = \sin x, g = \cos x$ として

$$(\tan x)' = \frac{\cos x \cdot \cos x - \sin x \cdot (-\sin x)}{\cos^2 x} = \frac{\cos^2 x + \sin^2 x}{\cos^2 x} = \frac{1}{\cos^2 x}$$

(2) $f = x, g = x^2 + 1$ として

$$y' = \frac{1 \cdot (x^2 + 1) - x \cdot 2x}{(x^2 + 1)^2} = \frac{1 - x^2}{(x^2 + 1)^2}$$

ポイント

$(\tan x)' = \frac{1}{\cos^2 x} = 1 + \tan^2 x \geq 1 > 0$ — $\tan$ が各区間で狭義単調増加である理由がここから読めます(第3章)。(2) の関数は $x = \pm 1$ で導関数の符号が変わる、極値問題(問3.3)の題材として再登場します。

解 2.6 ★★ 連鎖律(合成関数の微分)

方針

$y = f(u)$ 、 $u = g(x)$ と分解し、 $\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$ (外の微分 $\times$ 中の微分)。「外側から一枚ずつ皮をむく」感覚で。

解答

(1) 外 u^5 、中 $u = 3x^2 + 1$:

$$y' = 5u^4 \cdot (3x^2 + 1)' = 5(3x^2 + 1)^4 \cdot 6x = 30x(3x^2 + 1)^4$$

(2) 外 e^u 、中 $u = -x^2$:

$$y' = e^{-x^2} \cdot (-2x) = -2x e^{-x^2}$$

(3) 外 $\log u$ 、中 $u = x^2 + 1$:

$$y' = \frac{1}{x^2 + 1} \cdot 2x = \frac{2x}{x^2 + 1}$$

(4) 外 $\sin u$ 、中 $u = 2x$:

$$y' = \cos 2x \cdot 2 = 2 \cos 2x$$

ポイント

連鎖律は本書で最も「稼ぐ」公式です。深層学習の損失 L は「入力 $\rightarrow$ 層1 $\rightarrow$ 層2 $\rightarrow \dots \rightarrow$ 損失」という長い合成関数で、その勾配は連鎖律で外側(損失側)から順に掛け算して求めます — これが誤差逆伝播法。(2) の e^{-x^2} は正規分布の密度の心臓部で、第6章(ガウス積分)・第9章で再登場します。

解 2.7 ★★ 逆関数の微分

方針

局所逆関数が存在して微分可能であり $f'(y) \neq 0$ とする。 $y = f^{-1}(x)$ は $f(y) = x$ と同じこと。両辺を x で微分すると連鎖律から $f'(y)y' = 1$ 、よって $y' = \frac{1}{f'(y)}$ 。最後に y を x の式に戻す。

解答

(1) $y = \log x$ は $e^y = x$ と同値。両辺を x で微分すると(左辺は連鎖律で)

$$e^y \cdot \frac{dy}{dx} = 1 \quad \therefore \frac{dy}{dx} = \frac{1}{e^y} = \frac{1}{x}$$

(最後に $e^y = x$ を使って x の式に戻した。)

(2) $y = \arctan x$ は $\tan y = x$ と同値。両辺を x で微分すると、問2.5(1)より

$$\frac{1}{\cos^2 y} \cdot \frac{dy}{dx} = 1 \quad \therefore \frac{dy}{dx} = \cos^2 y$$

ここで $\frac{1}{\cos^2 y} = 1 + \tan^2 y = 1 + x^2$ だから

$$\frac{dy}{dx} = \frac{1}{1+x^2}$$

ポイント

「逆関数の傾きは、元の関数の傾きの逆数」— グラフを直線 $y = x$ で折り返す図を思い浮かべれば自然です。 $(\arctan x)' = \frac{1}{1+x^2}$ は第6章で「有理関数の積分に突然 $\arctan$ が現れる」理由になります。また $\log$ の微分が $\frac{1}{x}$ という単純な有理式になることが、対数微分

法(log をとってから微分する技法: $y = x^x$ なら $\log y = x \log x$ を微分して $\frac{y'}{y} = \log x + 1, y' = x^x(\log x + 1)$)を強力にしています。

解 2.8 ★★ 一次近似で数を見積もる

方針

接線 $L(x) = f(a) + f'(a)(x - a)$ は、 a の近くで f の代役を務める最良の一次関数。基準点 a には「値と微分が簡単に求まる点」を選ぶ。

解答

(1) $f(x) = \sqrt{x}, f'(x) = \frac{1}{2\sqrt{x}}$ より、 $a = 100$ で $f(100) = 10, f'(100) = \frac{1}{20}$ 。接線は

$$L(x) = 10 + \frac{x - 100}{20}$$

$x = 101$ を代入して

$$\sqrt{101} \approx L(101) = 10 + \frac{1}{20} = 10.05$$

真の値は $10.049875\dots$ なので、誤差は約 1.2×10^{-4} — 4桁目まで正しい。

(2) $f(x) = (1 + x)^\alpha$ とすると $f'(x) = \alpha(1 + x)^{\alpha-1}, f(0) = 1, f'(0) = \alpha, a = 0$ での一次近似は

$$(1 + x)^\alpha \approx 1 + \alpha x$$

$\alpha = 10, x = 0.02$ として $1.02^{10} \approx 1 + 10 \times 0.02 = 1.2$ 。真の値は $1.218994\dots$ なので誤差は約 0.019 — (1) より桁違いに大きい。理由: 一次近似の誤差は f'' の大きさと $|x - a|^2$ に比例する(第4章で定式化)。(1) は a からのずれが相対的に 1%、しかも $\sqrt{x}$ は

$x = 100$ 付近ではほぼ直線なのに対し、(2) は $\alpha = 10$ の高次のべきで曲がり強く $(f''(0) = \alpha(\alpha - 1) = 90)$ 、2次の項 $\frac{90}{2}x^2 = 0.018$ が誤差の主部としてそのまま現れているからである。

ポイント

「近似する」と「誤差を見積もる」はワンセットです。(2) の考察がそのまま第4章のテイラーの定理(誤差 $= \frac{f''}{2}h^2 + \dots$)への入口になっています。一次近似は、浮動小数点演算の誤差伝播解析(入力の誤差 δ が出力で約 $f'(a)\delta$ になる)や、勾配降下法(第13章:損失を一次近似して下る)の思想的な原点です。

解 2.9 ★★★ 微分可能性 — 連続だが微分できない関数

方針

微分可能性は「差分商の極限が(左右どちらから近づいても同じ値で)存在するか」。(1) は左右で傾きが食い違う例、(2)(3) は「振動を x^2 で押さえ込むと原点では微分できるが、導関数は原点で暴れる」精密な例。

解答

(1) 連続性: $\lim_{x \rightarrow 0} |x| = 0 = |0|$ より $x = 0$ で連続。微分可能性: 差分商は $\frac{|0 + h| - |0|}{h} = \frac{|h|}{h}$ で、問1.4より

$$\lim_{h \rightarrow 0+} \frac{|h|}{h} = 1, \quad \lim_{h \rightarrow 0-} \frac{|h|}{h} = -1$$

左右の極限が一致しないので差分商の極限は存在せず、 $x = 0$ で微分可能でない。(グラフの「角」では接線が定まらない。)

(2) 定義より

$$g'(0) = \lim_{h \rightarrow 0} \frac{g(h) - g(0)}{h} = \lim_{h \rightarrow 0} \frac{h^2 \sin \frac{1}{h} - 0}{h} = \lim_{h \rightarrow 0} h \sin \frac{1}{h}$$

$\left| h \sin \frac{1}{h} \right| \leq |h| \rightarrow 0$ だから、はさみうちの原理よりこの極限は 0。よって g は $x = 0$ で微分可能で $g'(0) = 0$ 。

(3) $x \neq 0$ では積と連鎖律で

$$g'(x) = 2x \sin \frac{1}{x} + x^2 \cos \frac{1}{x} \cdot \left(-\frac{1}{x^2} \right) = 2x \sin \frac{1}{x} - \cos \frac{1}{x}$$

第1項は $x \rightarrow 0$ で 0 に収束する(はさみうち)が、第2項 $-\cos \frac{1}{x}$ は振動する。実際、 $x_n = \frac{1}{2n\pi} \rightarrow 0$ では $g'(x_n) = 0 - \cos(2n\pi) = -1$ 、 $y_n = \frac{1}{(2n+1)\pi} \rightarrow 0$ では $g'(y_n) = 0 - \cos((2n+1)\pi) = +1$ 。0 にいくらでも近い点で g' が -1 と $+1$ の両方の値をとり続けるので、 $\lim_{x \rightarrow 0} g'(x)$ は存在しない。したがって g' は $x = 0$ で不連続である。

ポイント

(1) の $|x|$ の親戚が、深層学習の活性化関数 $\text{ReLU} = \max(0, x)$ です。 $x = 0$ で微分できないにもかかわらず実務で問題なく使われるのは、「角にちょうど当たる確率は実質ゼロ」で、当たった場合は劣勾配(第12章のポイントで触れます)として $[0, 1]$ の任意の値を割り当てればよいから。(2)(3) は「微分可能 $\Rightarrow$ 導関数が連続(C^1)」が偽であることを示す標準反例で、関数のクラス $C^0 \supset (\text{微分可能}) \supset C^1 \supset C^2 \supset \dots$ という階層(第8章・第19章)を意識するきっかけになります。

補足:「角に当たる確率が0」と言えるのは、入力連続分布に従う理想化の下です。離散入力や有限精度計算では0に当たることがあるため、実装は0での微分値を規約として明示します。

第3章

微分で関数を読む — 解答解説

増減・極値・凸性

解 3.1 ★ 増減表と極値

方針

$f' = 0$ の点で数直線を区切り、各区間での f' の符号を調べる。符号が $+$ $\rightarrow$ $-$ と変わる点が極大、 $-$ $\rightarrow$ $+$ が極小。

解答

$f'(x) = 3x^2 - 3 = 3(x+1)(x-1)$ 。 $f'(x) = 0$ となるのは $x = \pm 1$ 。増減表は

x	...	-1	...	1	...
$f'(x)$	+	0	-	0	+
$f(x)$	増加	極大 2	減少	極小 -2	増加

よって $x = -1$ で極大値 $f(-1) = -1 + 3 = 2$ 、 $x = 1$ で極小値 $f(1) = 1 - 3 = -2$ 。

2階条件による確認: $f''(x) = 6x$ より $f''(-1) = -6 < 0$ (極大)、 $f''(1) = 6 > 0$ (極小)。増減表と一致する。

ポイント

「微分してゼロ」だけでは極大・極小・どちらでもない(例: x^3 の $x = 0$)の区別がつきません。
 $f' = 0$ は候補を絞る条件で、判定は符号変化(または2階条件)で行う — この2段構えは、多変数(第9章:勾配ゼロ+ヘッセ行列の判定)でもまったく同じ構図で現れます。

解 3.2 ★ 閉区間での最大・最小

方針

閉区間上の連続関数は必ず最大・最小を持つ(最大値の定理)。その達成点は「内部の停留点」か「端点」のどちらかしかないので、候補をすべて挙げて値を比較する。

解答

$f'(x) = 3x^2 - 12x + 9 = 3(x-1)(x-3)$ 。区間 $[0, 4]$ の内部で $f' = 0$ となるのは $x = 1, 3$ 。候補4点の値は

$$f(0) = 1, \quad f(1) = 1 - 6 + 9 + 1 = 5, \quad f(3) = 27 - 54 + 27 + 1 = 1, \\ f(4) = 64 - 96 + 36 + 1 = 5$$

比較して、**最大値** 5($x = 1$ と $x = 4$ で達成)、**最小値** 1($x = 0$ と $x = 3$ で達成)。

よくある誤り:停留点だけを比べて端点を忘れること。この問題では端点 $x = 4$ が最大値タイに入っており、端点を落とすと「最大値を与える点」を取りこぼします。

ポイント

「連続関数は**有界閉区間上**で必ず最大・最小をとる」(ワイエルシュトラスの最大値定理)は、最適化で「解が存在すること」を保証する基本定理です(第11章で主役になります)。定義域が開区間や無限区間だと最大・最小は存在しないことがある — その場合の扱いが次の問3.3です。

解 3.3 ★ 実数全体での最大・最小

方針

実数全体では最大値の定理が使えないので、「極値」と「遠方($x \rightarrow \pm\infty$)での挙動」を合わせて大域的な最大・最小を判断する。

解答

(1) 問2.5(2)より $f'(x) = \frac{1-x^2}{(x^2+1)^2}$ 。分母は常に正なので符号は $1-x^2$ で決まり、 $x < -1$ で負、 $-1 < x < 1$ で正、 $x > 1$ で負。よって $x = -1$ で極小値 $f(-1) = -\frac{1}{2}$ 、 $x = 1$ で極大値 $f(1) = \frac{1}{2}$ 。

(2) 分母が2次、分子が1次なので

$$\lim_{x \rightarrow \infty} \frac{x}{x^2+1} = \lim_{x \rightarrow \infty} \frac{1/x}{1+1/x^2} = 0, \quad \lim_{x \rightarrow -\infty} \frac{x}{x^2+1} = 0$$

増減とあわせると、 f は $x \leq -1$ で $-\frac{1}{2}$ まで下がり折り返し、 $x \geq 1$ で $\frac{1}{2}$ から 0 へ向かって減少する。したがって f の値域は $\left[-\frac{1}{2}, \frac{1}{2}\right]$ に含まれ、両端の値は実際に達成されるから、最大値 $\frac{1}{2}$ ($x = 1$)、最小値 $-\frac{1}{2}$ ($x = -1$)。遠方で 0 に近づく(=極値より内側に戻る)ことが、極値がそのまま大域的な最大・最小になる理由である。

ポイント

非有界領域での最適化では「遠方で目的関数がどうなるか」の確認が必須です。機械学習でも、損失が遠方で下がり続けるなら最小解は存在しません(発散)。「遠方で値が大きくなる(coercive)なら最小解が存在する」という形の存在定理を第11章で扱います。

解 3.4 ★★ 平均値の定理

方針

「両端を結ぶ割線」を f から引き算した関数 φ を作ると、両端で φ の値が等しくなり、ロルの定理が使える形になる。

解答

(1) 割線の傾きを $k = \frac{f(b) - f(a)}{b - a}$ とおき、

$$\varphi(x) = f(x) - \{f(a) + k(x - a)\}$$

と定める。 φ は $[a, b]$ で連続、 (a, b) で微分可能で、

$$\begin{aligned}\varphi(a) &= f(a) - f(a) = 0, \\ \varphi(b) &= f(b) - \{f(a) + k(b - a)\} = f(b) - f(b) = 0\end{aligned}$$

よって $\varphi(a) = \varphi(b)$ となり、ロルの定理より $\varphi'(c) = 0$ を満たす $c \in (a, b)$ が存在する。

$\varphi'(x) = f'(x) - k$ だから、この c で

$$f'(c) = k = \frac{f(b) - f(a)}{b - a}$$

(証明終)

(2) $f(x) = x^3$ 、 $[a, b] = [0, 2]$ では $\frac{f(2) - f(0)}{2 - 0} = \frac{8}{2} = 4$ 。 $f'(c) = 3c^2 = 4$ を $c \in (0, 2)$ で解いて

$$c = \frac{2}{\sqrt{3}} = \frac{2\sqrt{3}}{3} \approx 1.155$$

確かに $0 < c < 2$ にある。

ポイント

平均値の定理は「平均の変化率と同じ瞬間変化率が、途中のどこかで必ず実現している」という主張です(平均時速 60 kmで走ったなら、どこかの瞬間にちょうど時速 60 kmだった)。理論上の役割は絶大で、「 $f' > 0$ なら増加」も「テイラーの定理の剰余項」(第4章)も、この定理から導かれます。証明の「補助関数を引いてロルに帰着」という型は、解析学の証明の定番手筋です。

解 3.5 ★★ 微分による不等式の証明

方針

「差をとって g とおき、 g の最小値が 0 以上であることを増減で示す」— 不等式証明の基本フォーム。最小値をとる点が等号成立点になる。

解答

(1) $g(x) = e^x - 1 - x$ とおく。 $g'(x) = e^x - 1$ は、 $x < 0$ で負、 $x = 0$ で 0、 $x > 0$ で正(e^x は単調増加で $e^0 = 1$)。よって g は $(-\infty, 0]$ で減少し $[0, \infty)$ で増加するから、 $x = 0$ で最小値 $g(0) = e^0 - 1 - 0 = 0$ をとる。したがってすべての x で

$$g(x) \geq g(0) = 0 \quad \Longleftrightarrow \quad e^x \geq 1 + x$$

等号は最小点 $x = 0$ のときに限る。(証明終)

(2) $h(x) = x - 1 - \log x (x > 0)$ とおく。 $h'(x) = 1 - \frac{1}{x}$ は $0 < x < 1$ で負、 $x > 1$ で正なので、 h は $x = 1$ で最小値 $h(1) = 1 - 1 - 0 = 0$ をとる。よって $x > 0$ で $h(x) \geq 0$ 、すなわち

$$\log x \leq x - 1$$

で、等号は $x = 1$ のときに限る。(証明終)

2つの関係:(1) で x を $\log t (t > 0)$ に置き換えると $e^{\log t} \geq 1 + \log t$ 、つまり $t \geq 1 + \log t$ となり (2) が得られる。逆も $x = \log t$ の逆置換で戻れるので、両者は同じ不等式の「指数の世界」と「対数の世界」での表現である。

ポイント

幾何的には、(1) は「 $y = e^x$ のグラフが $x = 0$ での接線 $y = 1 + x$ の常に上にある」、(2) は「 $y = \log x$ が $x = 1$ での接線 $y = x - 1$ の常に下にある」— つまり凸関数はどの接線よりも上、凹関数は下(第12章で一般化)という事実の実例です。 $\log x \leq x - 1$ は情報理論で「KLダイバージェンス ≥ 0 (ギブスの不等式)」を証明する際の急所であり、EMアルゴリズムや変分推論の導出でも繰り返し使われます。1本の不等式が現代の機械学習理論を下支えしています。

解 3.6 ★★ ロピタルの定理

方針

「 $\frac{0}{0}$ か $\frac{\infty}{\infty}$ であること」を毎回確認してから分母分子を別々に微分する。1回で不定形が解消しなければ、条件を確認してもう一度。

解答

(1) $x \rightarrow 0$ で分子 $\rightarrow e^0 - 1 = 0$ 、分母 $\rightarrow 0$: $\frac{0}{0}$ 型。分母分子を微分して

$$\lim_{x \rightarrow 0} \frac{e^x - 1}{2x}$$

これも $\frac{0}{0}$ 型なので、もう一度微分して

$$\lim_{x \rightarrow 0} \frac{e^x}{2} = \frac{1}{2}$$

これが存在するので、逆向きにたどって元の極限も $\frac{1}{2}$ 。(問1.7(3) を使い $\frac{e^x-1}{2x} \rightarrow \frac{1}{2}$ と1回で締めてもよい。)

(2) $x \rightarrow \infty$ で $\frac{\infty}{\infty}$ 型。微分して

$$\lim_{x \rightarrow \infty} \frac{1/x}{1} = 0 \quad \therefore \lim_{x \rightarrow \infty} \frac{\log x}{x} = 0$$

(3) $0 \cdot (-\infty)$ 型なので、まず商に直す: $x \log x = \frac{\log x}{1/x}$ は $x \rightarrow 0+$ で $\frac{-\infty}{\infty}$ 型。微分して

$$\lim_{x \rightarrow 0+} \frac{1/x}{-1/x^2} = \lim_{x \rightarrow 0+} (-x) = 0 \quad \therefore \lim_{x \rightarrow 0+} x \log x = 0$$

よくある誤り:不定形でないのにロピタルを使うこと。たとえば $\lim_{x \rightarrow 0} \frac{\cos x}{1+x} = 1$ は代入で終わりですが、機械的に微分すると $\frac{-\sin x}{1} \rightarrow 0$ と誤答します。「まず型の確認」を習慣に。

ポイント

(1) は $e^x \approx 1 + x + \frac{x^2}{2}$ の2次の係数を取り出した計算で、第4章のテイラー展開の予告編です。(3) の $x \log x \rightarrow 0$ は、情報理論でエントロピー $-\sum p \log p$ を定義するとき「 $p = 0$ の項は 0 と約束してよい」根拠になる、実用上たいへん重要な極限です。

解 3.7 ★★ 凸性・変曲点とグラフの概形

方針

f' の符号で増減、 f'' の符号で凹凸、遠方の極限で「両端の逃げ先」を押さえる。3点セットで概形は一意に定まる。

解答

(1) 積の微分で

$$f'(x) = 1 \cdot e^{-x} + x \cdot (-e^{-x}) = (1 - x)e^{-x}$$

$e^{-x} > 0$ なので符号は $1 - x$ と同じ: $x < 1$ で増加、 $x > 1$ で減少。 $x = 1$ で**極大値**
 $f(1) = e^{-1} = \frac{1}{e} \approx 0.368$ 。極小はない。

(2)

$$f''(x) = (-1)e^{-x} + (1 - x)(-e^{-x}) = (x - 2)e^{-x}$$

符号は $x - 2$ と同じ: $x < 2$ で $f'' < 0$ (上に凸)、 $x > 2$ で $f'' > 0$ (下に凸)。 $x = 2$ で凹
 凸が切り替わるので**変曲点** $(2, 2e^{-2})$ ($2e^{-2} \approx 0.271$)。

(3) $x \rightarrow \infty$ では、問3.8(2) ($k = 1$) より $\frac{x}{e^x} \rightarrow 0$ 、すなわち $f(x) \rightarrow 0+$ (x 軸が漸近
 線)。 $x \rightarrow -\infty$ では $x \rightarrow -\infty$ 、 $e^{-x} \rightarrow +\infty$ なので $f(x) \rightarrow -\infty$ 。まとめると

x	$-\infty$	...	1	...	2	...	∞
f'		+	0	−	−	−	
f''		−	−	−	0	+	
f	$-\infty$	増加・上に凸	極大 $\frac{1}{e}$	減少・上に凸	変曲点	減少・下に凸	$\rightarrow 0+$

グラフは、左下から立ち上がって原点を通り、 $x = 1$ で山の頂上 $\frac{1}{e}$ に達し、その後 $x = 2$
 で反り方を変えながら x 軸へ滑り込んでいく形になる。

ポイント

xe^{-x} の形(急に立ち上がり、緩やかに減衰する山)は、待ち行列・信頼性工学のガンマ分布
 (形状2)の密度や、システムのインパルス応答など、情報系のモデルに頻繁に現れます。「多項

式 × 指数減衰」は必ず遠方で指数が勝つ(問3.8) — この感覚はアルゴリズムの解析でも応答の解析でも共通です。

解 3.8 ★★★★★ 増大度の階層の完成

方針

$\frac{\infty}{\infty}$ 型にロピタル。(2) は「1回微分するたびに分子の次数が1下がる」ので k 回で決着 — 帰納法の形で書く。

解答

(1) $\frac{\infty}{\infty}$ 型。ロピタルの定理より

$$\lim_{x \rightarrow \infty} \frac{\log x}{x^a} = \lim_{x \rightarrow \infty} \frac{1/x}{a x^{a-1}} = \lim_{x \rightarrow \infty} \frac{1}{a x^a} = 0$$

(2) k についての帰納法。 $k = 0$ では $\frac{1}{e^x} \rightarrow 0$ で成立。 $k - 1$ で成立すると仮定すると、 $\frac{x^k}{e^x}$ は $\frac{\infty}{\infty}$ 型で、ロピタルより

$$\lim_{x \rightarrow \infty} \frac{x^k}{e^x} = \lim_{x \rightarrow \infty} \frac{k x^{k-1}}{e^x} = k \cdot 0 = 0$$

(帰納法の仮定を使った。)よってすべての自然数 k で成立。(証明終)

(3) $\frac{n \log n}{n^{1.1}} = \frac{\log n}{n^{0.1}}$ であり、(1) を $a = 0.1$ で使えば $\rightarrow 0$ 。意味: 実行時間が

$\Theta(n \log n)$ で増大するアルゴリズムは、 $\Theta(n^{1.1})$ で増大するものより漸近的に速い。一般に任意の固定した $\varepsilon > 0$ について $n \log n = o(n^{1+\varepsilon})$ であり、 $\log$ 因子は多項式の指数を正の定数だけ増やすより軽い。 O は上界だけを表すため、 $O(n \log n)$ と $O(n^{1+\varepsilon})$ という情報だけでは個々のアルゴリズムの厳密な優劣までは決まらない。

ポイント

これで階層 $\log n \ll n^a \ll c^n \ll n! (a > 0, c > 1)$ が全部証明されました(問 1.9+本問)。「比較したい2つの増大度の比の極限をとる」— アルゴリズムの優劣判定は、突き詰めればこの1つの操作です。なお (2) は「指数関数はどんな多項式よりも最終的に速く増える」ことの厳密化で、暗号(総当たり攻撃の非現実性)からニューラルネットの表現力の議論まで、情報系のあらゆる漸近論の共通言語です。

解 3.9 ★★★★ 2乗誤差は平均、絶対誤差は中央値

方針

(1) は滑らかな関数なので「微分ゼロ+2階条件」。(2)(3) は角のある区分的一次関数なので、微分の代わりに各区間での傾きの符号を数える。

解答

(1) $f(\theta) = \sum_i (\theta - x_i)^2$ を θ で微分して

$$f'(\theta) = \sum_{i=1}^n 2(\theta - x_i) = 2\left(n\theta - \sum_{i=1}^n x_i\right)$$

$f'(\theta) = 0$ を解くと $\theta = \frac{1}{n} \sum_i x_i = \bar{x}$ 。さらに $f''(\theta) = 2n > 0$ が常に成り立つので

f は下に凸であり、唯一の停留点 $\bar{x}$ が大域的な最小点である。(証明終)

(2) 絶対値の折れ目 $\theta = 1, 2, 4$ で区切り、各区間で g を一次式に直す:

区間	$g(\theta)$	傾き
$\theta \leq 1$	$(1 - \theta) + (2 - \theta) + (4 - \theta) = 7 - 3\theta$	-3
$1 \leq \theta \leq 2$	$(\theta - 1) + (2 - \theta) + (4 - \theta) = 5 - \theta$	-1
$2 \leq \theta \leq 4$	$(\theta - 1) + (\theta - 2) + (4 - \theta) = \theta + 1$	$+1$
$\theta \geq 4$	$3\theta - 7$	$+3$

傾きが負から正へ切り替わるのは $\theta = 2$ 。よって g は $\theta = 2$ (データの中央値) で最小になり、**最小値** $g(2) = 1 + 0 + 2 = 3$ 。

(3) n を奇数、データを相異なるとして小さい順に $x_{(1)} < \cdots < x_{(n)}$ と並べ、中央値を $m = x_{((n+1)/2)}$ とする。データ点以外の θ では g は微分可能で、 $|\theta - x_i|$ の微分が $\theta > x_i$ なら $+1$ 、 $\theta < x_i$ なら -1 であることから

$$g'(\theta) = \#\{i : x_i < \theta\} - \#\{i : x_i > \theta\}$$

(「左にあるデータの個数 - 右にあるデータの個数」)。 $\theta < m$ なら左側は高々 $\frac{n-1}{2}$ 個・右側は少なくとも $\frac{n+1}{2}$ 個なので $g'(\theta) \leq -1 < 0$ 。 $\theta > m$ なら対称に $g'(\theta) \geq +1 > 0$ 。よって連続関数 g は m の左で減少・右で増加し、 $\theta = m$ で最小となる。(証明終)

ポイント

「損失関数を替えると最適な代表値が変わる」— 2乗誤差(L2損失)なら平均、絶対誤差(L1損失)なら中央値。L1が外れ値に強い(ロバストな)理由は、 g' が「個数の差」しか見ておらず、外れ値がどれほど遠くても票は1票分しか持たないからです。これは回帰で二乗損失と絶対損失を使い分ける実務感覚の数学的根拠であり、「最適化問題の設計(何を最小化するか)がモデルの性質を決める」という第11章以降の中心思想の、最初の具体例です。 n が偶数の場合

は、中央の2点の間のどの θ でも傾き 0 となり、最小点は区間全体になります(一意でない最適解の例)。

重複値があっても結論は同じです。 $n=2r-1$ とし、重複を許して $x(1) \leq \dots \leq x(n)$ 、中央値 $m=x(r)$ と並べます。 $\theta < m$ では右側のデータが少なくとも r 個、左側が高々 $r-1$ 個なので、データ点の間での傾きは負です。 $\theta > m$ では逆に正です。データ点では左右の傾きで解釈すれば、連続な区分的一次関数 g は m まで減少し、その後増加するため、重複があっても中央値が最小点です。

第4章

テイラー展開 — 解答解説

多項式で関数を近似する

解 4.1 ★ テイラー多項式の計算

方針

係数は $\frac{f^{(k)}(0)}{k!}$ 。 e^x は何回微分しても e^x なので、微分係数はすべて $e^0 = 1$ 。

解答

(1) $f = f' = f'' = f''' = e^x$ だから $f(0) = f'(0) = f''(0) = f'''(0) = 1$ 。よって

$$T_3(x) = 1 + x + \frac{x^2}{2} + \frac{x^3}{6}$$

(2) $x = 0.1$ を代入して

$$T_3(0.1) = 1 + 0.1 + 0.005 + \frac{0.001}{6} = 1.1051666\dots$$

真の値 $1.1051709\dots$ との誤差は約 4.3×10^{-6} — わずか4項の多項式で小数第5位まで一致する。(なお剰余項による事前保証は $R_4 = \frac{e^c}{4!}(0.1)^4 \leq \frac{e^{0.1}}{24} \times 10^{-4} \approx 4.6 \times 10^{-6}$ で、実誤差はきちんとこの範囲に収まっている。)

ポイント

係数が $\frac{f^{(k)}(0)}{k!}$ である理由: T_n を k 回微分して $x = 0$ を代入すると、 x^k の項だけが $k! \times$ 係数 $= f^{(k)}(0)$ を残し、他は消えるからです。つまりテイラー多項式は「 $x = a$ での値と n

階までの微分係数がすべて f と一致する、ただ1つの n 次多項式」— 一次近似(接線)の完全上位互換です。

解 4.2 ★ 主要なマクローリン展開の導出

方針

(1)(2) は微分係数の周期性・規則性を見つけて $\frac{f^{(k)}(0)}{k!}$ を並べる。(3) は「有限和の公式 → 極限」の2段構え。

解答

(1) $f = \sin x$ の導関数は $\cos x, -\sin x, -\cos x, \sin x, \cos x, \dots$ と周期4で巡回する。 $x = 0$ での値は順に

$$f(0) = 0, f'(0) = 1, f''(0) = 0, f'''(0) = -1, f^{(4)}(0) = 0, f^{(5)}(0) = 1$$

よって

$$\sin x = 0 + 1 \cdot x + 0 - \frac{1}{3!}x^3 + 0 + \frac{1}{5!}x^5 - \dots = x - \frac{x^3}{6} + \frac{x^5}{120} - \dots$$

(2) $f = \log(1+x)$ について $f' = (1+x)^{-1}, f'' = -(1+x)^{-2}, f''' = 2(1+x)^{-3}, f^{(4)} = -6(1+x)^{-4}$ 。一般に $f^{(k)}(0) = (-1)^{k-1}(k-1)!(k \geq 1)$ 。

よって係数は $\frac{(-1)^{k-1}(k-1)!}{k!} = \frac{(-1)^{k-1}}{k}$ となり

$$\log(1+x) = x - \frac{x^2}{2} + \frac{x^3}{3} - \frac{x^4}{4} + \dots$$

(3) 等比数列の和の公式より、 $x \neq 1$ で

$$1 + x + x^2 + \dots + x^n = \frac{1 - x^{n+1}}{1 - x}$$

$|x| < 1$ のとき $x^{n+1} \rightarrow 0 (n \rightarrow \infty)$ だから、右辺は $\frac{1}{1-x}$ に収束する。すなわち

$$\frac{1}{1-x} = \sum_{k=0}^{\infty} x^k (|x| < 1)。$$

ポイント

(3) の等比級数は「すべての級数の母」で、収束範囲 $|x| < 1$ が明示的に見える貴重な例です。 $\log(1+x)$ の展開も実は $|x| \leq 1, x \neq -1$ でしか成り立ちません($x=2$ を代入すると右辺は発散します) — **展開には有効範囲がある** という意識を持ってください。一方 $e^x, \sin, \cos$ は全実数で収束します(問4.7)。

解 4.3 ★ ランダウ記号に慣れる

方針

すべて定義に戻る: $f = o(g)$ は「比 $\frac{f}{g}$ が 0 に収束」、 $f = O(g)$ は「比が 0 の近くで有界」。

解答

(1) $\frac{x^3}{x^2} = x \rightarrow 0 (x \rightarrow 0)$ 。よって定義より $x^3 = o(x^2)$ 。

(2) 示すべきは $\sin x - x = o(x)$ 、すなわち $\frac{\sin x - x}{x} \rightarrow 0$ 。実際

$$\frac{\sin x - x}{x} = \frac{\sin x}{x} - 1 \rightarrow 1 - 1 = 0$$

(問1.6の重要極限)。よって $\sin x = x + o(x)$ 。

(3) $\left| \frac{x^2 + 3x^3}{x^2} \right| = |1 + 3x|$ は $x \rightarrow 0$ で 1 に収束するから、0 の近くで有界(たとえば $|x| < 1$ なら 4 以下)。よって $x^2 + 3x^3 = O(x^2)$ 。一方この比は $1 \neq 0$ に収束するので $o(x^2)$ ではない。

ポイント

o は「無視できるほど小さい」、 O は「同程度以下」。テイラー展開の文末に付く $o(x^n) \cdot O(x^{n+1})$ は「書いた項より高位の誤差」という約束記号です。アルゴリズム解析の $O(n^2)$ ($n \rightarrow \infty$) と同じ記号を $x \rightarrow 0$ の文脈で使っている — 「どこへ向かう極限か」を常に意識するのがコツです。

解 4.4 ★★ テイラーの定理(2次の場合)の証明

方針

平均値の定理の証明(問3.4)の上位版。「両端でゼロになる補助関数を作ってロルの定理」という型は同じで、補助関数を t の関数として設計するのが工夫。

解答

(1) $x \neq a$ だから $(x - a)^2 \neq 0$ で、 $M = \frac{2\{f(x) - f(a) - f'(a)(x - a)\}}{(x - a)^2}$ と定めれば指定の等式が成り立つ。この M に対し

$$\varphi(t) = f(x) - f(t) - f'(t)(x - t) - \frac{M}{2}(x - t)^2$$

とおくと、 $t = x$ では全項が 0 になり $\varphi(x) = 0$ 。 $t = a$ では M の定め方(指定の等式)がちょうど $\varphi(a) = 0$ を意味する。

(2) φ は $[a, x]$ で連続、 (a, x) で微分可能、 $\varphi(a) = \varphi(x) = 0$ 。よってロルの定理より $\varphi'(c) = 0$ となる $c \in (a, x)$ が存在する。微分を計算すると(積の微分に注意)

$$\begin{aligned}\varphi'(t) &= -f'(t) - \left\{ f''(t)(x - t) - f'(t) \right\} + M(x - t) \\ &= -f''(t)(x - t) + M(x - t) = (x - t) \left\{ M - f''(t) \right\}\end{aligned}$$

$c < x$ より $x - c \neq 0$ だから、 $\varphi'(c) = 0$ は $M = f''(c)$ を意味する。これを (1) の等式に戻せば

$$f(x) = f(a) + f'(a)(x - a) + \frac{f''(c)}{2}(x - a)^2$$

(証明終。 $x < a$ の場合も区間 $[x, a]$ で同様。)

(3) $f = e^x$ 、 $a = 0$ 、 $x = 1$ では、定理は $e = 1 + 1 + \frac{e^c}{2}$ となる $c \in (0, 1)$ の存在を主張する。解くと $e^c = 2(e - 2) = 1.43656\dots$ 、すなわち

$$c = \log(2(e - 2)) = 0.36225\dots$$

確かに $0 < c < 1$ にある。

ポイント

$n = 0$ の場合がちょうど平均値の定理($f(x) = f(a) + f'(c)(x - a)$)であることを確認してください — テイラーの定理は平均値の定理の高次版です。同じ補助関数の設計で一般の n 次剰余 $R_{n+1} = \frac{f^{(n+1)}(c)}{(n+1)!}(x - a)^{n+1}$ も証明できます。剰余項の存在意義は「誤差が不等式で保証できる」こと: $|f^{(n+1)}|$ の上界さえ分かれば、近似の信頼区間が計算前に手に入ります(問4.5)。

解 4.5 ★★ 剰余項による誤差保証

方針

剰余項の中の未知の c は特定できないが、 $|f^{(n+1)}(c)|$ を「最悪ケース」で上から抑えれば誤差の保証が出る。 $\sin$ 系は $|f^{(k)}| \leq 1$ 、 e^x 系は区間の右端で評価。

解答

(1) 近似値は

$$0.5 - \frac{0.5^3}{6} = 0.5 - \frac{0.125}{6} = 0.4791666\dots$$

$\sin x$ の3次テイラー多項式は4次の項の係数が 0 なので、4次多項式としても正しい。したがって剰余は5次で書けて

$$R_5 = \frac{f^{(5)}(c)}{5!}(0.5)^5 = \frac{\cos c}{120}(0.5)^5$$

$|\cos c| \leq 1$ より

$$|R_5| \leq \frac{0.5^5}{120} = \frac{0.03125}{120} = 2.604 \times 10^{-4}$$

実際の誤差は $0.4794255\dots - 0.4791666\dots = 2.59 \times 10^{-4}$ で、確かに保証の範囲内(しかもほぼ上界に近い)。

(2) e^x の $x = 1$ での剰余は $R = \frac{e^c}{(n+1)!}$ ($0 < c < 1$)。 $e^c < e < 3$ だから

$$0 < R < \frac{3}{(n+1)!}$$

$\frac{3}{(n+1)!} < 10^{-6}$ すなわち $(n+1)! > 3 \times 10^6$ が必要。 $9! = 362880 < 3 \times 10^6 < 10! = 3628800$ なので $n+1 = 10$ 、すなわち $n = 9$ ($\frac{1}{0!}$ から $\frac{1}{9!}$ までの10項)で十分。実際、10項の和の誤差は $3.03 \times 10^{-7} < 10^{-6}$ 、9項では $3.06 \times 10^{-6} > 10^{-6}$ なので、この項数はほぼぎりぎり最適である。

ポイント

「答えを出す前に誤差の上界が言える」—これが数値計算を工学として成立させている思想です。ライブラリの $\exp$ や $\sin$ が「最終桁まで信用できる」のは、この種の解析で必要項数・

必要精度が事前に設計されているから。階乗 $n!$ の急成長(問1.9(3))が、テイラー級数の実用性(少ない項数で高精度)の源泉であることも見て取れます。

解 4.6 ★★ テイラー展開による極限計算

方針

分母のべき x^n に合わせて、分子を n 次まで展開する。消える項は消し、最初に生き残る項が答えを決める。

解答

$$(1) \sin x = x - \frac{x^3}{6} + o(x^3) \text{ より}$$

$$\frac{x - \sin x}{x^3} = \frac{\frac{x^3}{6} + o(x^3)}{x^3} = \frac{1}{6} + \frac{o(x^3)}{x^3} \longrightarrow \frac{1}{6}$$

(2) それぞれ4次まで展開する:

$$\begin{aligned} \cos x &= 1 - \frac{x^2}{2} + \frac{x^4}{24} + o(x^4), \\ e^{-x^2/2} &= 1 + \left(-\frac{x^2}{2}\right) + \frac{1}{2}\left(-\frac{x^2}{2}\right)^2 + o(x^4) = 1 - \frac{x^2}{2} + \frac{x^4}{8} + o(x^4) \end{aligned}$$

($e^u = 1 + u + \frac{u^2}{2} + \dots$ に $u = -\frac{x^2}{2}$ を代入した。)差をとると 1 と $-\frac{x^2}{2}$ の項が打ち消し合い

$$\cos x - e^{-x^2/2} = \left(\frac{1}{24} - \frac{1}{8}\right)x^4 + o(x^4) = -\frac{x^4}{12} + o(x^4)$$

よって

$$\lim_{x \rightarrow 0} \frac{\cos x - e^{-x^2/2}}{x^4} = -\frac{1}{12}$$

ポイント

(2) は「 $\cos x$ と $e^{-x^2/2}$ は2次まで完全に一致し、4次で初めてずれる」ことを示しています — だからこそ両者のグラフは原点付近で見分けがつきません。この「ガウス型 $e^{-x^2/2}$ との高次一致」は、確率論の中心極限定理の証明(特性関数の展開)の核心部分に現れる計算です。展開に $u = -\frac{x^2}{2}$ を「代入」してよいのは、合成のテイラー展開の一致性による — 機械的に使ってよい強力な技です。

解 4.7 ★★★ テイラー級数の収束と、その限界

方針

(1) 剰余項の e^c を最悪値 $e^{|x|}$ で抑えれば、残るのは $\frac{|x|^{n+1}}{(n+1)!}$ — 「階乗はべきに勝つ」(問1.9)で 0 へ。(2) は定義通り差分商を作り、増大度の階層で潰す。

解答

(1) テイラーの定理より $R_{n+1} = \frac{e^c}{(n+1)!} x^{n+1}$ (c は 0 と x の間)。 $|c| \leq |x|$ だから $e^c \leq e^{|x|}$ であり

$$|R_{n+1}| \leq e^{|x|} \frac{|x|^{n+1}}{(n+1)!}$$

ここで $a_n = \frac{|x|^n}{n!}$ とおくと $\frac{a_{n+1}}{a_n} = \frac{|x|}{n+1} \rightarrow 0 < 1$ なので、比の補題(問1.9)より $a_n \rightarrow 0$ 。 $e^{|x|}$ は n に依らない定数だから $|R_{n+1}| \rightarrow 0$ 。したがって部分和 $T_n(x) = e^x - R_{n+1}$ は e^x に収束する。 x は任意だったので、級数はすべての実数で e^x に収束する。(証明終)

(2) 定義より

$$f'(0) = \lim_{h \rightarrow 0} \frac{e^{-1/h^2} - 0}{h}$$

$t = \frac{1}{h^2} \rightarrow \infty (h \rightarrow 0)$ と置換すると $\frac{e^{-1/h^2}}{|h|} = \frac{\sqrt{t}}{e^t}$ であり、問3.8(2)の階層 $(t^{1/2} \ll e^t)$ より $\rightarrow 0$ 。符号を含めても挟まれて 0 なので $f'(0) = 0$ 。次に $x \neq 0$ で $f'(x)$
 $= \frac{2}{x^3} e^{-1/x^2}$ だから

$$f''(0) = \lim_{h \rightarrow 0} \frac{f'(h) - 0}{h} = \lim_{h \rightarrow 0} \frac{2e^{-1/h^2}}{h^4} = \lim_{t \rightarrow \infty} \frac{2t^2}{e^t} = 0$$

(同じ置換と階層による。) によって $f''(0) = 0$ 。同様の計算を繰り返すと、任意の n で

$f^{(n)}(0) = 0$ が示される(各導関数が「 $\frac{1}{x}$ の多項式 $\times e^{-1/x^2}$ 」の形になり、指数減衰がべきの発散を常に打ち消す)。

(3) 教訓: テイラー級数は「原点での微分係数の情報」しか使っておらず、この関数は原点であまりに平坦なため、微分係数からは関数の情報が一切取り出せない。「無限回微分可能」と「テイラー級数が関数を表す(解析的)」は別の概念であり、展開を使うときは収束と一致の両方を確認する必要がある。

ポイント

(2) の関数は「滑らかだが解析的でない」標準反例で、この性質を逆手に取ると「ある区間の外で完全に 0 の滑らかな関数(バンプ関数)」が作れます — 信号処理の窓関数や偏微分方程式の理論で活躍する道具です。(1) と (2) の対比は、「 e^x 側の世界(解析的: 局所の情報が大域を決める)」と「一般の滑らかな関数の世界」の違いを示す、解析学で最も教育的なペアです。

解 4.8 ★★★ 数値微分の誤差次数(勾配チェックの原理)

方針

中心差分の $O(h^4)$ までを正当化するには、3次ではなく5次項まで展開します。対称な引き算で偶数次項が消えることが要点です。

解答

(1) 前進側を展開して h で割ると、 $D_f = f'(x) + f''(x)h/2 + O(h^2)$ 。誤差の主部は h に比例するため1次精度です。

中心差分では、 $f(x+h)$ と $f(x-h)$ を5次項まで展開して引きます。偶数次項が消え、差は $2f'(x)h + f'''(x)h^3/3 + f^{(5)}(x)h^5/60 + O(h^6)$ 。これを $2h$ で割ると、 $D_c = f'(x) + f'''(x)h^2/6 + f^{(5)}(x)h^4/120 + O(h^5) = f'(x) + f'''(x)h^2/6 + O(h^4)$ 。したがって2次精度です。

(2) 真値は $\cos 1 = 0.5403023\dots$ 。前進差分は $0.4973638\dots$ で誤差は約 -4.29×10^{-2} 、中心差分は $0.5394023\dots$ で誤差は約 -9.00×10^{-4} です。それぞれの主項 $-\sin(1)h/2$ と $-\cos(1)h^2/6$ と整合します。

(3) h を $1/10$ にすると、主項から前進差分の誤差は約 $1/10$ 、中心差分の誤差は約 $1/100$ になります。

ポイント

中心差分は対称性によって打ち切り誤差を小さくできます。ただし h を小さくしすぎると丸め誤差が増えるため、実際の勾配チェックでは打ち切り誤差と丸め誤差の両方を考えて h を選びます。固定の最適値は関数の尺度や浮動小数点形式に依存します。

第5章

積分の基礎 — 解答解説

足し合わせの極限と微積分学の基本定理

解 5.1 ★ リーマン和から定積分へ

方針

和を n の式(閉じた形)に直してから $n \rightarrow \infty$ 。「長方形の面積の合計 $\rightarrow$ 曲線の下面積」を式で追体験する。

解答

$$\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6} \text{ を使うと}$$

$$\sum_{k=1}^n \left(\frac{k}{n}\right)^2 \cdot \frac{1}{n} = \frac{1}{n^3} \sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6n^3} = \frac{1}{6} \left(1 + \frac{1}{n}\right) \left(2 + \frac{1}{n}\right)$$

$$n \rightarrow \infty \text{ とすれば } \frac{1}{6} \cdot 1 \cdot 2 = \frac{1}{3} \text{。よって}$$

$$\int_0^1 x^2 dx = \frac{1}{3}$$

ポイント

この計算が「積分の定義通りの計算は、 x^2 ですらこんなに大変」だと教えてくれます。だからこそ次の基本定理(微分の逆演算として一撃で計算する)がありがたい。一方で、定義そのもの(細分して足す)は数値積分 — 解析的に積分できない関数をコンピュータで積分する方法 — としてそのまま生きています。モンテカルロ積分も「足し合わせの近似」という同じ思想の確率版です。

解 5.2 ★ 原始関数(不定積分)

方針

「微分すると被積分関数に戻る関数」を探す。微分公式表を右から左に読む。定数 C を忘れない。

解答

$$(1) \int x^3 dx = \frac{x^4}{4} + C \text{ (検算: } \left(\frac{x^4}{4}\right)' = x^3 \text{)}$$

$$(2) \int \frac{dx}{x} = \log x + C \text{ (} x > 0 \text{。検算: } (\log x)' = \frac{1}{x} \text{。一般には } \log |x| + C \text{)}$$

$$(3) \int e^{2x} dx = \frac{e^{2x}}{2} + C \text{ (検算: 連鎖律で } \left(\frac{e^{2x}}{2}\right)' = e^{2x} \cdot \frac{1}{2} \text{ を忘れると微分で } 2e^{2x} \text{ になってしまう)}$$

$$(4) \int \cos 3x dx = \frac{\sin 3x}{3} + C$$

$$(5) \int \frac{dx}{1+x^2} = \arctan x + C \text{ (問2.7(2)の逆読み)}$$

ポイント

$\int x^\alpha dx = \frac{x^{\alpha+1}}{\alpha+1}$ の唯一の例外が $\alpha = -1$ で、そこに $\log$ が現れる — べき乗の世界の「穴」を対数が埋めるという美しい構図です。(5) のように「多項式の逆数を積分すると逆三角関数が出てくる」現象は、第6章の有理関数の積分で主役になります。**積分の検算は微分**。5秒でできる検算を習慣にすれば、積分の計算ミスはほぼ根絶できます。

解 5.3 ★ 定積分の計算

方針

原始関数 F を1つ見つけて $F(b) - F(a)$ 。記号 $\left[F(x)\right]_a^b$ で整理する。

解答

(1)

$$\begin{aligned} \int_1^2 (x^2 - 2x + 3) dx &= \left[\frac{x^3}{3} - x^2 + 3x \right]_1^2 \\ &= \left(\frac{8}{3} - 4 + 6 \right) - \left(\frac{1}{3} - 1 + 3 \right) = \frac{14}{3} - \frac{7}{3} = \frac{7}{3} \end{aligned}$$

(2)

$$\int_0^\pi \sin x \, dx = \left[-\cos x \right]_0^\pi = (-\cos \pi) - (-\cos 0) = 1 + 1 = 2$$

図形的には「 $\sin$ の山1つ分の面積がちょうど 2」という意味である。曲線 $y = \sin x$ は高さ最大 1・幅 $\pi \approx 3.14$ の山だから、面積が外接長方形 π より小さい 2 であることは直感とも合う。

ポイント

定積分の値が出たら、(2) のように「大きさの妥当性」を一度見積もる習慣をつけてください（外接・内接する長方形との比較で十分）。この検算感覚は、数値計算の結果やシミュレーション出力の妥当性チェック（サニティチェック）にそのまま通じます。

解 5.4 ★★ 微積分学の基本定理の証明

方針

面積関数 S の増分 $S(x+h) - S(x)$ は「幅 h の細長い帯の面積」。帯を最小値・最大値の長方形で挟み、 $h \rightarrow 0$ で連続性がとどめを刺す — はさみうち(問1.5)の再演。

解答

(1) 区間加法性 $\int_a^{x+h} = \int_a^x + \int_x^{x+h}$ より

$$S(x+h) - S(x) = \int_a^{x+h} f(t) dt - \int_a^x f(t) dt = \int_x^{x+h} f(t) dt$$

(2) $[x, x+h]$ 上で $m_h \leq f(t) \leq M_h$ だから、単調性より

$$m_h \cdot h = \int_x^{x+h} m_h dt \leq \int_x^{x+h} f(t) dt \leq \int_x^{x+h} M_h dt = M_h \cdot h$$

$h > 0$ で割れば $m_h \leq \frac{S(x+h) - S(x)}{h} \leq M_h$ 。

(3) $h \rightarrow 0+$ のとき区間 $[x, x+h]$ は点 x に潰れ、 f の連続性から $m_h \rightarrow f(x)$ 、 $M_h \rightarrow f(x)$ 。はさみうちの原理より

$$\lim_{h \rightarrow 0+} \frac{S(x+h) - S(x)}{h} = f(x)$$

$h < 0$ 側も同様なので $S'(x) = f(x)$ 。(証明終)

後半: F を f の任意の原始関数とすると、 $(S - F)' = f - f = 0$ より $S - F$ は定数(平均値の定理の帰結)。よって $S(x) = F(x) + C$ 。 $S(a) = 0$ から $C = -F(a)$ で、

$$\int_a^b f(x) dx = S(b) = F(b) - F(a)$$

(4) $S(x) = \int_0^x t^2 dt = \frac{x^3}{3}$ (問5.1の一般化、または後述の公式)。微分すると $S'(x) = x^2 = f(x)$ 。確かに成立。

ポイント

面積を上端 x の関数として微分すると端点の高さが現れます。微積分学の基本定理は、リーマン和で定義された積分を原始関数の端点値の差で評価できることを保証します。これは計

算量の等式ではなく、極限で定義された量を有限の式で計算できるという数学的な対応です。

解 5.5 ★★ 計算しない積分 — 不等式と対称性

方針

(1) 被積分関数を区間上で定数で挟む。(2) 左半分と右半分の面積が符号つきで打ち消し合う。

解答

(1) $0 \leq x \leq 1$ では $1 \leq 1 + x^2 \leq 2$ だから、逆数と平方根をとって(どちらも順序を保つ・逆転する向きに注意)

$$\frac{1}{\sqrt{2}} \leq \frac{1}{\sqrt{1+x^2}} \leq 1$$

各辺を $[0, 1]$ で積分すると、単調性より

$$\frac{1}{\sqrt{2}} = \int_0^1 \frac{dx}{\sqrt{2}} \leq \int_0^1 \frac{dx}{\sqrt{1+x^2}} \leq \int_0^1 1 dx = 1$$

(証明終。実際の値 $0.8814\dots$ は確かに $0.7071\dots$ と 1 の間にある。)

(2) 置換 $x \rightarrow -x$ を考えると、奇関数では左半分 $[-a, 0]$ の積分が右半分 $[0, a]$ の積分の -1 倍になる:

$$\int_{-a}^0 f(x) dx = \int_0^a f(-u) du = - \int_0^a f(u) du$$

よって足すと 0 。与式では $x^3 e^{x^2}$ が奇関数(奇 $\times$ 偶 = 奇)、 $3x^2$ が偶関数なので

$$\int_{-1}^1 (3x^2 + x^3 e^{x^2}) dx = \underbrace{\int_{-1}^1 x^3 e^{x^2} dx}_{=0} + 2 \int_0^1 3x^2 dx = 0 + 2 \left[x^3 \right]_0^1 = 2$$

ポイント

「積分は、計算する前に評価・簡約できないか考える」— (1) の挟み込みは、閉じた式で積分できない関数(統計学の正規分布の累積分布関数など)の値を見積もる基本手段です。(2) の対称性は、確率論で「対称な分布の奇数次モーメントは 0」として毎日のように使われます。腕力の前に構造を見る — 数学でもプログラミングでも同じです。

解 5.6 ★★ 置換積分の基礎

方針

「中身 $g(x)$ の微分 $g'(x)$ が外に掛かっている形」を見つけたら $u = g(x)$ 。 $du = g'(x) dx$ の対応で機械的に書き換わる — 連鎖律の逆再生。

解答

(1) $u = x^2$ とおくと $du = 2x dx$ 。ちょうど $2x dx$ がそのまま du に置き換わり

$$\int 2x e^{x^2} dx = \int e^u du = e^u + C = e^{x^2} + C$$

(2) $u = 1 + x^2$ 、 $du = 2x dx$ すなわち $x dx = \frac{du}{2}$ 。区間は $x : 0 \rightarrow 1$ が $u : 1 \rightarrow 2$ に対応して

$$\int_0^1 \frac{x}{1+x^2} dx = \int_1^2 \frac{1}{u} \cdot \frac{du}{2} = \frac{1}{2} \left[\log u \right]_1^2 = \frac{\log 2}{2}$$

(3) $u = \cos x$ 、 $du = -\sin x dx$ より

$$\int \tan x \, dx = \int \frac{\sin x}{\cos x} dx = \int \frac{-du}{u} = -\log |u| + C = -\log |\cos x| + C$$

ポイント

(2)(3) はどちらも「 $\int \frac{g'(x)}{g(x)} dx = \log |g(x)| + C$ 」という頻出パターンの実例です(分子が分母の微分)。この形は一瞬で見抜けるようにしておくと、第6章以降の計算速度が段違いになります。定積分の置換では「区間も一緒に変換する」— 変換を忘れて x の区間のまま u の式に代入するのが最頻出のミスです。

解 5.7 ★★ 部分積分の基礎

方針

$\int f'g = fg - \int fg'$ 。「微分すると簡単になる方(多項式・log)」を g (微分される側)に、「積分しても複雑にならない方(e^x ・三角)」を f' (積分される側)に選ぶ。

解答

(1) $f' = e^x$ (積分側)、 $g = x$ (微分側)と選ぶ:

$$\int xe^x dx = xe^x - \int 1 \cdot e^x dx = xe^x - e^x + C = (x-1)e^x + C$$

(2) $f' = \sin x$ 、 $g = x$:

$$\begin{aligned} \int_0^\pi x \sin x \, dx &= \left[-x \cos x \right]_0^\pi + \int_0^\pi \cos x \, dx \\ &= (-\pi \cos \pi - 0) + \left[\sin x \right]_0^\pi = \pi + 0 = \pi \end{aligned}$$

(3) $\log x = 1 \cdot \log x$ と見て、 $f' = 1$ 、 $g = \log x$:

$$\int \log x \, dx = x \log x - \int x \cdot \frac{1}{x} dx = x \log x - x + C$$

ポイント

部分積分は積の微分公式 $(fg)' = f'g + fg'$ を移項して積分しただけのもの — つまり「積の微分の逆」です。役割分担の指針は「LIATE」(Log・逆三角・代数式・三角・指数の順に微分側へ)という語呂で覚える流儀もありますが、本質は「 $\int fg'$ が元より簡単になる分担を選ぶ」こと。(3) の「1 を掛けて無理やり部分積分」は、log や arctan 単体の積分での定番トリックです。部分積分は第6章(繰り返し適用・漸化式)や第17章の双対性の計算でも活躍します。

解 5.8 ★★★ 和を積分で評価する — 調和数と $O(\log n)$

方針

$y = \frac{1}{x}$ は減少関数なので、幅1の長方形の列は、左端の高さで作れば曲線の上、右端の高さで作れば曲線の下に来る。この2通りの比較から上下の評価が1本ずつ出る。

解答

(1) 下からの評価: 区間 $[k, k+1]$ 上で $\frac{1}{x} \leq \frac{1}{k}$ ($\frac{1}{x}$ は減少)だから

$$\int_k^{k+1} \frac{dx}{x} \leq \int_k^{k+1} \frac{dx}{k} = \frac{1}{k}$$

$k = 1, \dots, n$ で足し合わせると、左辺は区間がつながって

$$\int_1^{n+1} \frac{dx}{x} = \log(n+1) \leq \sum_{k=1}^n \frac{1}{k} = H_n$$

上からの評価: 区間 $[k-1, k]$ 上では $\frac{1}{x} \geq \frac{1}{k}$ だから $\frac{1}{k} \leq \int_{k-1}^k \frac{dx}{x}$ 。これを $k = 2, \dots, n$ で足すと

$$H_n - 1 = \sum_{k=2}^n \frac{1}{k} \leq \int_1^n \frac{dx}{x} = \log n \quad \therefore H_n \leq 1 + \log n$$

合わせて $\log(n+1) \leq H_n \leq 1 + \log n$ 。(証明終)

(2) (1) の各辺を $\log n$ で割ると

$$\frac{\log(n+1)}{\log n} \leq \frac{H_n}{\log n} \leq \frac{1}{\log n} + 1$$

左辺は $\frac{\log n + \log(1 + 1/n)}{\log n} = 1 + \frac{\log(1 + 1/n)}{\log n} \rightarrow 1$ 、右辺も $\rightarrow 1$ 。はさみうちより $\frac{H_n}{\log n} \rightarrow 1$ 。特に $H_n = \Theta(\log n)$ 。

(3) $n = 100$: 下界 $\log 101 = 4.615\dots$ 、上界 $1 + \log 100 = 5.605\dots$ 。実際 $H_{100} = 5.187\dots$ は確かにこの間にある。

ポイント

「和は積分で挟める」— 離散(アルゴリズムの世界)と連続(解析の世界)をつなぐ、情報系にとって最重要級の技法です。クイックソートの平均比較回数 $2(n+1)H_n - 4n \approx 1.39$

$n \log_2 n$ 、クーポンコレクターの期待試行回数 nH_n 、ハッシュ表の解析 — $H_n \approx \log n$ はあらゆる場所で顔を出します。より精密には $H_n = \log n + \gamma + O(1/n)$ (γ

$= 0.5772\dots$ はオイラー定数)が知られており、本問の挟み込みはその第一歩です。同じ手法で $\sum k^a \approx \frac{n^{a+1}}{a+1}$ や $\log(n!) = \Theta(n \log n)$ (スターリングの公式の入口、比較ソートの下界 $\Omega(n \log n)$ の証明に使う)も評価できます。

クイックソートの比較回数の式は、相異なる要素をランダムなピボット規則で処理する標準モデルに対する期待値です。実装の分割規則、重複要素の扱い、ピボット選択によって定数項や厳密式は変わりますが、標準的な平均次数が $\Theta(n \log n)$ である点は共通です。

第6章

積分の技法と広義積分 — 解答解説

部分分数・漸化式から ∞ の積分へ

解 6.1 ★ 部分分数分解による積分

方針

(1) 分母を因数分解して未定係数法。(2) 分子を「分母の微分」+「定数」に分けると、前者は $\log$ 型(問5.6)、後者は $\arctan$ 型に分かれる。

解答

(1) $\frac{1}{(x-1)(x+1)} = \frac{A}{x-1} + \frac{B}{x+1}$ とおき、両辺に $(x-1)(x+1)$ を掛けると
 $1 = A(x+1) + B(x-1)$ 。 $x=1$ を代入して $A = \frac{1}{2}$ 、 $x=-1$ を代入して $B = -\frac{1}{2}$ 。よって

$$\int \frac{dx}{x^2-1} = \frac{1}{2} \int \left(\frac{1}{x-1} - \frac{1}{x+1} \right) dx = \frac{1}{2} \log \left| \frac{x-1}{x+1} \right| + C$$

(2) $2x+3 = (2x) + 3$ と分けて

$$\int \frac{2x+3}{x^2+1} dx = \int \frac{2x}{x^2+1} dx + 3 \int \frac{dx}{x^2+1} = \log(x^2+1) + 3 \arctan x + C$$

(第1項は $\frac{g'}{g}$ 型、第2項は基本積分。)

ポイント

まず仮分数なら多項式除法を行う。次に、実係数の分母多項式は「1次式」と「実数解を持たない2次式」の積に因数分解でき、重複因子には $(x-a)^{-j}$ や $(x^2+px+q)^{-j}$ の各次数

を並べて部分分数分解する。 $j \geq 2$ の項を積分すると有理関数残り、 $j = 1$ の項から $\log$ と $\arctan$ が現れる。したがって実係数有理関数の原始関数は原理的にいつでも「有理関数 + $\log$ + $\arctan$ 」で書けます。数式処理システムが有理関数を確実に積分できるのは、この構造定理があるからです。

解 6.2 ★ 三角関数の積分

方針

三角関数の偶数べきは半角(次数下げ)の公式で1次式に落とすのが定石。奇数べきや積は置換が効く。

解答

(1)

$$\int \sin^2 x \, dx = \int \frac{1 - \cos 2x}{2} \, dx = \frac{x}{2} - \frac{\sin 2x}{4} + C$$

(2) (1) の結果に区間の端を代入して

$$\int_0^{2\pi} \sin^2 x \, dx = \left[\frac{x}{2} - \frac{\sin 2x}{4} \right]_0^{2\pi} = \pi - 0 = \pi$$

(1周期にわたる $\sin^2$ の平均値が $\frac{\pi}{2\pi} = \frac{1}{2}$ であることを意味する。)

(3) $u = \sin x$ 、 $du = \cos x \, dx$ と置換して

$$\int \sin x \cos x \, dx = \int u \, du = \frac{u^2}{2} + C = \frac{\sin^2 x}{2} + C$$

(倍角 $\sin x \cos x = \frac{\sin 2x}{2}$ を使って $-\frac{\cos 2x}{4} + C$ としてもよい。2つの答えは定数差 $\frac{1}{4}$ しか変わらず、どちらも正解である。)

ポイント

(2) の「 $\sin^2$ の1周期平均 $= \frac{1}{2}$ 」は、交流電圧の実効値(最大値の $\frac{1}{\sqrt{2}}$ 倍)や信号の平均パワーの計算の根拠で、フーリエ解析(信号処理)では $\int \sin mx \sin nx$ 型の直交性計算として無数に繰り返されます。(3) のように不定積分の答えは定数差を除いて一意 — 見た目が違ってても微分して一致すれば同じ答えです。

解 6.3 ★★ 置換の定石 — 三角置換

方針

$\sqrt{1-x^2}$ には $x = \sin \theta$ ($1 - \sin^2 \theta = \cos^2 \theta$ で根号が外れる)。 $\sqrt{1+x^2}$ 型は答えの候補を微分して確かめるのが実戦的。

解答

(1) $x = \sin \theta$ ($-\frac{\pi}{2} < \theta < \frac{\pi}{2}$) とおくと $dx = \cos \theta d\theta$ 、 $\sqrt{1-x^2} = \cos \theta > 0$ 。よって

$$\int \frac{dx}{\sqrt{1-x^2}} = \int \frac{\cos \theta}{\cos \theta} d\theta = \int d\theta = \theta + C = \arcsin x + C$$

(2) 同じ置換で、 $x : 0 \rightarrow 1$ は $\theta : 0 \rightarrow \frac{\pi}{2}$ に対応し

$$\begin{aligned} \int_0^1 \sqrt{1-x^2} dx &= \int_0^{\pi/2} \cos^2 \theta d\theta = \int_0^{\pi/2} \frac{1 + \cos 2\theta}{2} d\theta \\ &= \left[\frac{\theta}{2} + \frac{\sin 2\theta}{4} \right]_0^{\pi/2} = \frac{\pi}{4} \end{aligned}$$

これは単位円の第1象限部分(四分円、面積 $\frac{\pi \cdot 1^2}{4}$)の面積と一致する。

(3) $F(x) = \log(x + \sqrt{1+x^2})$ を微分すると

$$F'(x) = \frac{1 + \frac{x}{\sqrt{1+x^2}}}{x + \sqrt{1+x^2}} = \frac{\frac{\sqrt{1+x^2} + x}{\sqrt{1+x^2}}}{x + \sqrt{1+x^2}} = \frac{1}{\sqrt{1+x^2}}$$

よって F は原始関数であり

$$\int_0^1 \frac{dx}{\sqrt{1+x^2}} = \left[\log(x + \sqrt{1+x^2}) \right]_0^1 = \log(1 + \sqrt{2}) = 0.8814 \dots$$

問5.5(1)の挟み込み $\frac{1}{\sqrt{2}} = 0.707 \dots \leq 0.881 \dots \leq 1$ と確かに整合する。

ポイント

三角置換の選び方は「 $\sqrt{1-x^2} \rightarrow x = \sin \theta$ 」「 $\sqrt{1+x^2} \rightarrow x = \tan \theta$ 」「 $\sqrt{x^2-1} \rightarrow x = \frac{1}{\cos \theta}$ 」— いずれも三角恒等式で根号を外す設計です。(3) の $\log(x + \sqrt{1+x^2})$ は双曲線関数の逆関数 $\operatorname{arsinh} x$ にほかならず、 $\sinh, \cosh$ を学ぶと $\sqrt{1+x^2}$ 型は $x = \sinh t$ の置換で機械的に処理できるようになります。「まず挟んで見積もり(第5章)、その後厳密値(本問)」という2段階は、数値計算で近似値を出してから解析解を検証する実務の流れと同じです。

解 6.4 ★★ 漸化式 — ウォリスの積分

方針

$\sin^n x = \sin^{n-1} x \cdot \sin x$ と分け、 $\sin x$ を積分して部分積分。出てきた $\cos^2 = 1 - \sin^2$ を書き換えると、右辺に I_n 自身が現れて方程式になる — 「自分自身に帰着させる」漸化式の定石。

解答

$$(1) I_0 = \int_0^{\pi/2} dx = \frac{\pi}{2}, I_1 = \int_0^{\pi/2} \sin x dx = \left[-\cos x \right]_0^{\pi/2} = 1.$$

(2) 部分積分($f' = \sin x \rightarrow f = -\cos x, g = \sin^{n-1} x$)で

$$I_n = \left[-\cos x \sin^{n-1} x \right]_0^{\pi/2} + (n-1) \int_0^{\pi/2} \cos^2 x \sin^{n-2} x dx$$

境界項は $x = \frac{\pi}{2}$ で $\cos = 0, x = 0$ で $\sin^{n-1} = 0 (n \geq 2)$ だから消える。 $\cos^2 x = 1 - \sin^2 x$ を代入して

$$I_n = (n-1) \int_0^{\pi/2} (\sin^{n-2} x - \sin^n x) dx = (n-1) I_{n-2} - (n-1) I_n$$

I_n について解くと $n I_n = (n-1) I_{n-2}$ 、すなわち

$$I_n = \frac{n-1}{n} I_{n-2}$$

(3) 漸化式を回して

$$I_2 = \frac{1}{2} I_0 = \frac{\pi}{4}, \quad I_3 = \frac{2}{3} I_1 = \frac{2}{3}, \quad I_4 = \frac{3}{4} I_2 = \frac{3\pi}{16}$$

ポイント

「 n の問題を $n-2$ の問題に帰着させる」— これは分割統治法(再帰アルゴリズム)そのものの発想で、漸化式は積分計算における再帰呼び出しです。ウォリスの積分は、 $n \rightarrow \infty$ の挙動から円周率の無限積表示(ウォリスの公式)や、二項係数の漸近評価・スターリングの公式の証明に接続する、みかけ以上に奥の深い対象です。偶数なら最後は $I_0 = \frac{\pi}{2}$ (答えに π が残る)、奇数なら $I_1 = 1$ に落ちる、という偶奇の分岐にも注意。

解 6.5 ★ 広義積分の定義と p 積分

解答

(1) $\int_1^R x^{-2} dx = 1 - 1/R$ より、極限は 1 で収束する。

(2) $\int_1^R dx/x = \log R \rightarrow \infty$ なので発散する。

(3) $\int_\varepsilon^1 x^{-1/2} dx = 2 - 2\sqrt{\varepsilon} \rightarrow 2$ なので収束し、値は 2。

(4) $\int_1^\infty x^{-p} dx$ は $p > 1$ のときだけ収束し、 $\int_0^1 x^{-p} dx$ は $p < 1$ のときだけ収束する。境界の $p = 1$ は対数発散である。

ポイント

密度の裾が x^{-p} と同程度なら、期待値の収束条件は $p > 2$ です。標準的なパレート分布の形状母数を α と書く流儀では密度の裾は $x^{-(\alpha+1)}$ なので、期待値が有限なのは $\alpha > 1$ のときです。2種類の指数を混同しないようにしましょう。

解 6.6 ★★ 比較判定法

方針

原始関数を求めるのではなく、被積分関数を「収束が既知の関数」で上から(収束を言うとき)、「発散が既知の関数」で下から(発散を言うとき)挟む。

解答

(1) $x \geq 1$ なら $x^2 \geq x$ なので $-x^2 \leq -x$ 、指数関数の単調性より $e^{-x^2} \leq e^{-x}$ 。優関数の積分は

$$\int_1^\infty e^{-x} dx = \left[-e^{-x} \right]_1^\infty = e^{-1} < \infty$$

で収束するから、比較判定法より $\int_1^\infty e^{-x^2} dx$ も収束する。(証明終)

(2) $x \geq 1$ で $0 \leq \frac{1}{1+x^3} \leq \frac{1}{x^3}$ 。 $p = 3 > 1$ の p 積分は収束するから、収束。

(3) $x \geq 1$ で $x^2 + 1 \leq 2x^2$ だから $\frac{1}{\sqrt{x^2 + 1}} \geq \frac{1}{\sqrt{2}x}$ 。劣関数の積分 $\frac{1}{\sqrt{2}} \int_1^\infty \frac{dx}{x}$ は発散する($p = 1$)から、**発散**。

ポイント

比較判定の実戦手順は「 $x \rightarrow \infty$ での主要項を見抜く $\rightarrow$ その p 積分(または指数)と比べる」の2手です:(2) は $\frac{1}{1+x^3} \sim \frac{1}{x^3}$ 、(3) は $\frac{1}{\sqrt{x^2+1}} \sim \frac{1}{x}$ 。(1) はこの後ガウス積分(問6.8)・正規分布のあらゆる積率の収束を支える基礎です。プログラムの停止性を「既知の減少量と比較して」示す議論と、構造はよく似ています。

解 6.7 ★★ ガンマ関数 — 階乗の連続化

解答

$$(1) \Gamma(1) = \int_0^\infty e^{-x} dx = 1.$$

(2) 部分積分により、 $s > 0$ では

$$\Gamma(s+1) = \left[-x^s e^{-x} \right]_0^\infty + s \int_0^\infty x^{s-1} e^{-x} dx = s\Gamma(s).$$

境界項は、 $x \rightarrow \infty$ では指数関数がべき関数より速く増大し、 $x \rightarrow 0+$ では $s > 0$ なので、いずれも 0 となる。

(3) $n = 1$ では $\Gamma(2) = 1\Gamma(1) = 1 = 1!$ 。 $\Gamma(n+1) = n!$ を仮定すると

$$\Gamma(n+2) = (n+1)\Gamma(n+1) = (n+1)n! = (n+1)!$$

したがって、すべての自然数 $n \geq 1$ で $\Gamma(n+1) = n!$ が成り立つ。

解 6.8 ★★★ ガウス積分と正規分布

方針

(1) 収束(存在)と (2)(3) 値の変換は独立の作業。収束は比較、変換は置換 — 使う道具を切り分ける。

解答

(1) 偶関数性より $\int_{-\infty}^{\infty} = 2 \int_0^{\infty}$ を調べれば十分。 $[0, 1]$ 上は連続関数の普通の積分で有限。 $[1, \infty)$ 上は問6.6(1)で収束を示した。有限区間の値と収束する広義積分の和なので、全体も収束する。(証明終)

(2) $u = x^2$ とおくと $du = 2x dx$ 、すなわち $dx = \frac{du}{2\sqrt{u}}$ 。 $x : 0 \rightarrow \infty$ は $u : 0 \rightarrow \infty$ に対応し

$$\int_0^{\infty} e^{-x^2} dx = \int_0^{\infty} e^{-u} \frac{du}{2\sqrt{u}} = \frac{1}{2} \int_0^{\infty} u^{-1/2} e^{-u} du = \frac{1}{2} \Gamma\left(\frac{1}{2}\right)$$

(最後は $\Gamma(s) = \int_0^{\infty} u^{s-1} e^{-u} du$ の $s = \frac{1}{2}$ 。)一方、対称性より $\int_0^{\infty} e^{-x^2} dx = \frac{I}{2} = \frac{\sqrt{\pi}}{2}$ 。両者を比べて

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

(3) $x = \sqrt{2}t$ と置換すると $dx = \sqrt{2}dt$ で

$$\int_{-\infty}^{\infty} e^{-x^2/2} dx = \int_{-\infty}^{\infty} e^{-t^2} \sqrt{2} dt = \sqrt{2} \cdot \sqrt{\pi} = \sqrt{2\pi}$$

両辺を $\sqrt{2\pi}$ で割れば

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 1$$

ポイント

正規分布の密度に付く謎の係数 $\frac{1}{\sqrt{2\pi}}$ の正体は「ガウス積分の値で割って全確率を 1 にするための規格化定数」でした。 $\Gamma(\frac{1}{2}) = \sqrt{\pi}$ は「 $(-\frac{1}{2})! = \sqrt{\pi}$ 」とも読め、階乗の世界に突然 π が現れる名場面です (χ^2 分布や n 次元球の体積公式の π はすべてここから来ます)。値 $I = \sqrt{\pi}$ 自体の証明は「2乗して2次元の積分に直し、極座標で回す」— 第10章のハイライトとして予告しておきます。

解 6.9 ★★★ 指数分布 — サーバ応答時間のモデル

方針

すべて $\int_0^\infty (\text{多項式}) \times e^{-\lambda x} dx$ 型。部分積分を素直に回すか、 $u = \lambda x$ の置換でガンマ関数に帰着させるか — 両方できるようにする。

解答

$$(1) \int_0^\infty \lambda e^{-\lambda x} dx = \left[-e^{-\lambda x} \right]_0^\infty = 0 - (-1) = 1. \text{密度として正しい。}$$

(2) 部分積分 ($f' = \lambda e^{-\lambda x} \rightarrow f = -e^{-\lambda x}$, $g = x$):

$$E[X] = \left[-xe^{-\lambda x} \right]_0^\infty + \int_0^\infty e^{-\lambda x} dx = 0 + \left[-\frac{e^{-\lambda x}}{\lambda} \right]_0^\infty = \frac{1}{\lambda}$$

(境界項は増大度の階層 $x \ll e^{\lambda x}$ で消える。)

(3) 置換 $u = \lambda x$ でガンマ関数に帰着させる:

$$E[X^2] = \int_0^\infty x^2 \lambda e^{-\lambda x} dx = \frac{1}{\lambda^2} \int_0^\infty u^2 e^{-u} du = \frac{\Gamma(3)}{\lambda^2} = \frac{2!}{\lambda^2} = \frac{2}{\lambda^2}$$

よって分散は

$$V[X] = E[X^2] - (E[X])^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

(同じ置換で $E[X] = \frac{\Gamma(2)}{\lambda} = \frac{1}{\lambda}$ も一瞬で再現できる。)

ポイント

「平均到着率 λ (件/秒)のとき、平均待ち時間は $\frac{1}{\lambda}$ 秒」— 単位の対応まで含めて腑に落としてください。標準偏差も $\frac{1}{\lambda}$ で平均と同じ大きさ、つまり指数分布は「ばらつきが平均並みに大きい」分布です。指数分布はポアソン過程(ランダムな到着)の待ち時間分布であり、待ち行列理論(M/M/1 モデル)・信頼性工学・強化学習の環境モデルなどで基本部品になります。一般に $E[X^n] = \frac{n!}{\lambda^n}$ — 「モーメントの計算はガンマ関数の索引引き」という感覚が身につけば、この章は卒業です。

モデル化上の注意: 指数分布が到着間隔になるのは、一定率で独立に到着する斉次ポアソン過程を仮定した場合です。故障時間として使う場合も、一定の故障率、すなわち無記憶性を仮定しています。

第7章

偏微分と勾配 — 解答解説

多変数の世界への第一歩

解 7.1 ★ 偏微分の計算

方針

x で偏微分するときは y をただの定数(3 や a と同じ)と思って1変数の微分をするだけ。連鎖律もそのまま使える。

解答

- (1) $f_x = 2xy^3$ (y^3 は係数扱い)、 $f_y = 3x^2y^2$ 。
 (2) $f_x = ye^{xy}$ (x で見ると $e^{(\text{定数})x}$ の形)、 $f_y = xe^{xy}$ 。
 (3) 連鎖律で $f_x = \frac{2x}{x^2 + y^2}$ 、 $f_y = \frac{2y}{x^2 + y^2}$ 。

ポイント

偏微分の図形的意味: $f_x(a, b)$ は、曲面 $z = f(x, y)$ を平面 $y = b$ で切った断面の曲線の、 $x = a$ での傾きです。「他を全部固定して1方向だけ動かす」— プログラムで1つの引数だけ変えて挙動を見るデバッグと同じ発想で、多変数の複雑さを1変数の問題の束に分解しています。

解 7.2 ★ 勾配ベクトル

方針

各変数での偏微分を順に並べてベクトルにするだけ。ただしこのベクトルが持つ意味(問7.6・7.7)がこの章の核心。

解答

(1) $\nabla f = (f_x, f_y) = (2x, 4y)$ 。点 $(1, 1)$ では

$$\nabla f(1, 1) = (2, 4)$$

(2) $\nabla f = (yz, xz, xy)$ 。

ポイント

変数が n 個なら勾配は n 次元ベクトル — 深層学習では「パラメータと同じ形をした配列」として実装されます(PyTorch の `param.grad`)。(1) の $f = x^2 + 2y^2$ は等高線が楕円になる「異方的な谷」で、この章と第13章(勾配降下法の挙動)を貫く主役例です。 $(1, 1)$ で勾配が y 成分に偏っている($4 > 2$)こと — 係数の大きい y 方向ほど関数が敏感 — を覚えておいてください。

解 7.3 ★ 高階偏導関数と順序交換

方針

2通りの順序で愚直に計算して突き合わせる。

解答

x から: $f_x = 3x^2y^2 + \sin y$ 、これを y で微分して

$$f_{xy} = 6x^2y + \cos y$$

y から: $f_y = 2x^3y + x \cos y$, これを x で微分して

$$f_{yx} = 6x^2y + \cos y$$

確かに $f_{xy} = f_{yx}$ 。一般に、**シュワルツの定理**: f の2階偏導関数がすべて存在して連続(f が C^2 級)ならば、偏微分の順序は交換できる。

ポイント

順序交換のおかげで、 n 変数関数の2階偏導関数を並べた行列(ヘッセ行列、第8章)は**対称行列**になります。対称行列は実固有値を持ち直交対角化できる(『線形代数』第9章)—— この事実が第9章の極値判定・第14章のニュートン法の土台になるので、「 C^2 なら順序交換 → ヘッセ行列は対称」という連鎖はぜひ意識してください。なお連続性を欠くと交換が破れる病的な例も知られています(本書では扱わないが、条件が飾りでないことは心に留めておくこと)。

解 7.4 ★★ 接平面と1次近似

方針

1変数の接線 $y = f(a) + f'(a)(x - a)$ の素直な拡張: 傾きが x 方向と y 方向の2つになる。

解答

(1) $f(1, 2) = 1 + 4 = 5$, $f_x = 2x$, $f_y = 2y$ より $f_x(1, 2) = 2$, $f_y(1, 2) = 4$ 。接平面は

$$z = 5 + 2(x - 1) + 4(y - 2)$$

(2) $(x, y) = (1.1, 1.9)$ を接平面に代入して

$$f(1.1, 1.9) \approx 5 + 2(0.1) + 4(-0.1) = 5 + 0.2 - 0.4 = 4.8$$

真の値は $1.1^2 + 1.9^2 = 1.21 + 3.61 = 4.82$ 。誤差は 0.02 — 変位の大きさ 0.1 の2乗のオーダーで、1変数のとき(問2.8)と同じく「1次近似の誤差は2次」になっている。

ポイント

接平面の式は $f(\mathbf{a} + \mathbf{h}) \approx f(\mathbf{a}) + \nabla f(\mathbf{a}) \cdot \mathbf{h}$ と1本で書けます — 1変数の $f(a)$ + $f'(a)h$ の f' が ∇f に、積が内積に置き換わっただけ。この形は第8章で2次の項(ヘッセ行列)を足した多変数テイラー展開へ、さらに勾配降下法の1ステップの解析(第13章)へと育っていきます。

解 7.5 ★★ 多変数の連鎖律

方針

「 t が動く $\rightarrow x, y$ が動く $\rightarrow z$ が動く」という影響の伝播を、経路ごとの寄与の和として書く。

解答

$$(1) \frac{\partial z}{\partial x} = 2xy, \frac{\partial z}{\partial y} = x^2, \frac{dx}{dt} = -\sin t, \frac{dy}{dt} = \cos t \text{ より}$$

$$\frac{dz}{dt} = 2xy \cdot (-\sin t) + x^2 \cdot \cos t = -2 \cos t \sin^2 t + \cos^3 t$$

(最後に $x = \cos t, y = \sin t$ を代入した。)

(2) $z = \cos^2 t \sin t$ を直接微分すると、積の微分で

$$\frac{dz}{dt} = 2 \cos t (-\sin t) \sin t + \cos^2 t \cos t = -2 \cos t \sin^2 t + \cos^3 t$$

(1) と一致する。

(3) $\nabla z = (2xy, x^2)$ 、 $\mathbf{r}'(t) = (-\sin t, \cos t)$ だから、(1) の式はまさに内積

$$\frac{dz}{dt} = \nabla z \cdot \mathbf{r}'(t)$$

である。

ポイント

多変数連鎖律は「複数の経路を通して伝わる影響を全部足す」— 計算グラフの言葉で言えば、 $t \rightarrow x \rightarrow z$ と $t \rightarrow y \rightarrow z$ の2経路の寄与の和です。深層学習の誤差逆伝播は、この「経路ごとの偏微分の積を足す」計算を、何層にも重なったグラフの上で出力側から効率よく実行するアルゴリズムにほかなりません。内積形 $\nabla f \cdot \mathbf{r}'$ は次の2問(方向微分・等高線)の証明道具としてすぐ使います。

解 7.6 ★★ 方向微分と最急上昇方向

解答

(1) $\nabla f(1, 1) = (2, 4)$ なので、 $D_{(1,0)}f = 2$ 、 $D_{(1,1)/\sqrt{2}}f = 3\sqrt{2}$ 。

(2) 単位ベクトル $\mathbf{u}$ に対して、コーシー・シュワルツの不等式から

$$D_{\mathbf{u}}f = \nabla f \cdot \mathbf{u} \leq \|\nabla f\|.$$

$\nabla f \neq \mathbf{0}$ なら等号は $\mathbf{u} = \nabla f / \|\nabla f\|$ のときに限る。 $\nabla f = \mathbf{0}$ なら全方向の方向微分が 0 で、最大方向は一意でない。

(3) 最急上昇方向は $(1/\sqrt{5}, 2/\sqrt{5})$ 、最大増加率は $2\sqrt{5}$ 。

解 7.7 ★★ 勾配は等高線と直交する

解答

(1) 等高線を $\mathbf{r}(t)$ で表し、 $f(\mathbf{r}(t)) = c$ を微分すると

$$\nabla f(\mathbf{r}(t)) \cdot \mathbf{r}'(t) = 0.$$

$\mathbf{r}'(t) \neq \mathbf{0}$ の正則点では、これは勾配と接ベクトルの直交を表す。 $\mathbf{r}'(t) = \mathbf{0}$ の媒介表示からは接方向を読み取れない。

(2) $x^2 + 2y^2 = 3$ を暗黙微分すると $2x + 4yy' = 0$ 。点 $(1, 1)$ では $y' = -1/2$ だから接ベクトルを $(2, -1)$ と取れる。 $(2, -1) \cdot (2, 4) = 0$ で、勾配と直交する。

解 7.8 ★★★ 偏微分可能でも連続とは限らない

方針

偏微分は軸方向の差分商しか見ない。ところがこの関数は軸上で恒等的に 0、対角線上で恒等的に $\frac{1}{2}$ へ近づく経路で値が変わる。

解答

(1) x 軸上では $f(h, 0) = \frac{h \cdot 0}{h^2 + 0} = 0$ 。よって

$$f_x(0, 0) = \lim_{h \rightarrow 0} \frac{f(h, 0) - f(0, 0)}{h} = \lim_{h \rightarrow 0} \frac{0 - 0}{h} = 0$$

対称性より $f_y(0, 0) = 0$ 。どちらも存在する。

(2) 直線 $y = 0$ に沿えば $f(x, 0) = 0 \rightarrow 0$ 。一方、直線 $y = x$ に沿えば

$$f(x, x) = \frac{x \cdot x}{x^2 + x^2} = \frac{1}{2} \quad (\text{恒等的に}) \longrightarrow \frac{1}{2}$$

近づく経路によって極限值が 0 と $\frac{1}{2}$ で異なるので、 $\lim_{(x,y) \rightarrow (0,0)} f(x,y)$ は存在せず、 f は原点で連続でない。(2変数の極限は「あらゆる近づき方で同じ値」を要求することに注意。)

(3) 偏微分係数は x 軸・ y 軸という2本の直線に沿った情報しか使っていない。この関数は、ちょうどその2本の上でだけ行儀よく 0 で、軸から外れた方向(対角線)では $\frac{1}{2}$ に張り付いている — 偏微分は「軸の隙間」で起きていることを一切検知できないのである。多変数関数のクラスの階層は

$$C^1 \implies \text{全微分可能} \implies \text{連続かつ偏微分可能}$$

であり、逆はいずれも成り立たない(本問は「偏微分可能だが連続でない」の反例)。実用上は「 C^1 を確認すれば全微分可能(接平面が正しく機能する)」と覚えておけばよい。

ポイント

1変数の常識「微分可能 $\implies$ 連続」が多変数の「偏微分可能」では崩れる — 次元が上がると**近づき方の自由度**が爆発的に増えるからです。正しい微分可能性の概念は「接平面による1次近似が全方向で成り立つ」こと(全微分可能性)で、その手軽な十分条件が C^1 。本書で扱う関数は基本的に C^1 (あるいは C^2)なので安心して接平面・テイラー展開を使えますが、「なめらかさの確認は無料ではない」という感覚は、理論の証明を読むときの注意力になります。

解 7.9 ★★★★★ 線形モデルの学習 — 損失の勾配と正規方程式

解答

残差を $r_i = wx_i + b - y_i$ とおくと

$$\frac{\partial L}{\partial w} = 2 \sum_i r_i x_i, \quad \frac{\partial L}{\partial b} = 2 \sum_i r_i.$$

したがって正規方程式は

$$\begin{cases} (\sum x_i^2)w + (\sum x_i)b = \sum x_i y_i, \\ (\sum x_i)w + nb = \sum y_i. \end{cases}$$

データ $(1, 2), (2, 3), (3, 5)$ では $14w + 6b = 23, 6w + 3b = 10$ なので、 $w = 3/2, b = 1/3$ 。

このとき残差は順に $-1/6, 1/3, -1/6$ であり、最小損失は $1/36 + 1/9 + 1/36 = 1/6$ となる。

ここで得た停留点が最適点であることは、 L が残差の2乗和で凸な2次関数であることから従う。このデータでは設計行列の2列が一次独立なのでヘッセ行列は正定値となり、停留点は唯一の大域的最小点である(問9.6で詳しく確認する)。

第8章

ヘッセ行列と2次近似 — 解答解説

曲がり方を行列で捉える

解 8.1 ★ ヘッセ行列の計算

方針

1階偏導関数を求め、それぞれをもう一度 x, y で偏微分して 2×2 に並べる。

解答

$f_x = 3x^2 - 3y, f_y = 3y^2 - 3x$ 。さらに偏微分して $f_{xx} = 6x, f_{xy} = -3, f_{yx} = -3, f_{yy} = 6y$ 。よって

$$H(x, y) = \begin{pmatrix} 6x & -3 \\ -3 & 6y \end{pmatrix}, \quad H(1, 1) = \begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix}$$

$f_{xy} = f_{yx} = -3$ で確かに対称である (f は多項式なので C^2 、シュワルツの定理の適用範囲)。

ポイント

ヘッセ行列は「勾配ベクトル $\nabla f = (3x^2 - 3y, 3y^2 - 3x)$ のヤコビ行列」、つまり**勾配の変化率**です。1変数の f'' (傾きの変化率) の行列版という位置づけを押さえておくと、この後の議論がすべて1変数の焼き直しに見えてきます。この関数は $(1, 1)$ と $(0, 0)$ に停留点を持ち、片方だけが極値 — 判定は問9.2のお楽しみです。

解 8.2 ★ 2次形式と対称行列

方針

$ax^2 + 2bxy + cy^2 \longleftrightarrow \begin{pmatrix} a & b \\ b & c \end{pmatrix}$: 交差項の係数を半分ずつ非対角に振り分ける。

解答

(1) $x^2 + 4xy + y^2$ の交差項係数は $4 = 2 \times 2$ なので

$$Q(x, y) = \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

(2) 固有方程式 $\det(A - \lambda I) = (1 - \lambda)^2 - 4 = 0$ より $1 - \lambda = \pm 2$ 、すなわち

$$\lambda = 3, -1$$

正負の固有値が混在するので Q は不定値。実際、 $(x, y) = (1, 1)$ (固有値 3 の固有ベクトル方向) では $Q = 1 + 4 + 1 = 6 > 0$ 、 $(x, y) = (1, -1)$ (固有値 -1 の方向) では $Q = 1 - 4 + 1 = -2 < 0$ 。

ポイント

2次形式の値の符号のパターンは固有値の符号が完全に決めます(直交対角化して $Q = \lambda_1 u_1^2 + \lambda_2 u_2^2$ と書けるから — 『線形代数』第9章)。 $Q > 0 \cdot Q < 0$ の実例として固有ベクトル方向を選ぶのが最短手 — 「固有ベクトル方向では2次形式は $\lambda \|u\|^2$ になる」からです。この行列は問8.3(2)にも登場します。

解 8.3 ★★ 正定値性の判定

方針

首座小行列式(左上から $1 \times 1, 2 \times 2, \dots$ の行列式)がすべて正 $\iff$ 正定値。固有値でも裏を取る。

解答

(1) 首座小行列式: $\Delta_1 = 2 > 0, \Delta_2 = \det A = 6 - 1 = 5 > 0$ 。よって**正定値**。固有値は $\det(A - \lambda I) = \lambda^2 - 5\lambda + 5 = 0$ より

$$\lambda = \frac{5 \pm \sqrt{5}}{2} \approx 3.62, 1.38$$

ともに正で、判定と整合する。

(2) $\Delta_1 = 1 > 0, \Delta_2 = 1 - 4 = -3 < 0$ 。正定値の条件が破れ、 $\det B = \lambda_1 \lambda_2 = -3 < 0$ から固有値は正と負が1つずつ(実際 $3, -1$ 、問8.2)。よって**不定値**。

(3) $\Delta_1 = 2, \Delta_2 = \det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} = 3, \Delta_3 = \det C = 2(4 - 1) - (-1)(-2 - 0) + 0 = 6 - 2 = 4$ 。すべて正なので**正定値**。固有値は $2 - \sqrt{2} \approx 0.59, 2, 2 + \sqrt{2} \approx 3.41$ ですべて正。

ポイント

(3) の三重対角行列は、2階微分の差分近似(問4.8の中心差分を並べたもの)やグラフ・ラプラシアンとして数値計算・ネットワーク解析の至る所に現れる有名行列です。実務上の正定値判定は「コレスキー分解が成功するか試す」のが最速($O(n^3/3)$ 、失敗したら正定値でない)で、シルベスターの判定法はその理論的背景 — 手計算の $2 \times 2 \cdot 3 \times 3$ では首座小行列式が便利、と使い分けます。**不定値の判定には「首座」以外の情報(行列式の符号や固有値)も併用すること**: 首座小行列式が正でないと分かった時点で言えるのは「正定値でない」ことです。

解 8.4 ★★ 多変数の2次テイラー展開

解答

$f = e^x \cos y$ について、原点では

$$f(0,0) = 1, \quad \nabla f(0,0) = (1,0)^\top, \quad H(0,0) = \text{diag}(1, -1).$$

よって2次近似は $1 + x + x^2/2 - y^2/2$ 。1変数展開の積からも同じ結果を得る。

ヘッセ行列の固有値の符号は異なるが、勾配は $(1,0) \neq \mathbf{0}$ である。したがって原点は停留点でも鞍点でもなく、ここで読めるのは2方向の2次曲率の符号が異なることだけである。

解 8.5 ★★ 2次関数 — 最適化の「水素原子」

方針

成分でゴリゴリ計算して $\nabla f = A\mathbf{x} - \mathbf{b}$ を確立すれば、あとは連立1次方程式と正定値性(問8.3)の合わせ技。

解答

(1) 2変数で書き下すと

$$f = \frac{1}{2} (a_{11}x^2 + 2a_{12}xy + a_{22}y^2) - b_1x - b_2y$$

偏微分して $f_x = a_{11}x + a_{12}y - b_1$ 、 $f_y = a_{12}x + a_{22}y - b_2$ 。並べると

$$\nabla f = \begin{pmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} - \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = A\mathbf{x} - \mathbf{b}$$

もう一度微分すればヘッセ行列は A 自身(n 変数でも同じ計算が通る)。

(2) $\nabla f = \mathbf{0} \iff A\mathbf{x} = \mathbf{b}$, すなわち

$$2x + y = 1, \quad x + 3y = 2$$

第1式 $\times 3$ - 第2式: $5x = 1$ より $x = \frac{1}{5}$, $y = 1 - \frac{2}{5} = \frac{3}{5}$ 。よって $\mathbf{x}^* = \left(\frac{1}{5}, \frac{3}{5}\right)$ 。 A は問8.3(1)で正定値と判定済みなので、 f は狭義凸関数であり(第12章で一般論を学ぶが、2次関数では「ヘッセ行列が正定値 $\Rightarrow$ お椀型」)、停留点 $\mathbf{x}^*$ は唯一の大域的最小点である。

(3) 一般に $A\mathbf{x}^* = \mathbf{b}$ を使うと

$$f(\mathbf{x}^*) = \frac{1}{2} \mathbf{x}^{*\top} A \mathbf{x}^* - \mathbf{b}^\top \mathbf{x}^* = \frac{1}{2} \mathbf{x}^{*\top} \mathbf{b} - \mathbf{b}^\top \mathbf{x}^* = -\frac{1}{2} \mathbf{b}^\top \mathbf{x}^*$$

本問の数値では

$$f(\mathbf{x}^*) = -\frac{1}{2} \left(1 \cdot \frac{1}{5} + 2 \cdot \frac{3}{5} \right) = -\frac{1}{2} \cdot \frac{7}{5} = -\frac{7}{10}$$

ポイント

「2次関数の最小化 = 連立1次方程式 $A\mathbf{x} = \mathbf{b}$ を解くこと」— この対応は最適化と数値線形代数を結ぶ大動脈です。最小二乗法の正規方程式(問7.9)はまさにこの形($A = X^\top X$, $\mathbf{b} = X^\top \mathbf{y}$)でしたし、逆に「大規模な $A\mathbf{x} = \mathbf{b}$ を2次関数の最小化とみなして反復法(共役勾配法)で解く」のが現代の数値計算の定石です。2次関数を「水素原子」(すべてが厳密に解ける教科書模型)として完全に手の内に入れておくと、一般の関数の最適化はすべて「局所的にこの模型で近似する話」として見通せます。

解 8.6 ★★ 2次モデルの最小化 — ニュートン法の1歩

方針

2次モデル $m(\mathbf{h})$ は問8.5の2次関数そのもの($A = H$ 、 $\mathbf{b} = -\mathbf{g}$ の対応)。よって最小点は連立1次方程式 $H\mathbf{h} = -\mathbf{g}$ の解。

解答

$$(1) \nabla f = (4x^3 - 2, 2y) \text{ より } \mathbf{g} = \nabla f(1, 1) = (2, 2)^\top. \text{ヘッセ行列は } \nabla^2 f = \begin{pmatrix} 12x^2 & 0 \\ 0 & 2 \end{pmatrix} \text{ より}$$

$$H = \begin{pmatrix} 12 & 0 \\ 0 & 2 \end{pmatrix}$$

(2) $m(\mathbf{h}) = f(\mathbf{x}_0) + \mathbf{g}^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top H \mathbf{h}$ は変数 $\mathbf{h}$ の2次関数で、問8.5(1) の形($A = H$ 、 $\mathbf{b} = -\mathbf{g}$ 、定数項付き)。よって $\nabla_{\mathbf{h}} m = H\mathbf{h} + \mathbf{g} = \mathbf{0}$ 、すなわち $\mathbf{h}^* = -H^{-1}\mathbf{g}$ (H は対角成分正の対角行列で正定値だから、これが最小点)。具体的には

$$\mathbf{h}^* = - \begin{pmatrix} \frac{1}{12} & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} -\frac{1}{6} \\ -1 \end{pmatrix}$$

(3) 新しい点は

$$\mathbf{x}_1 = (1, 1) + \left(-\frac{1}{6}, -1\right) = \left(\frac{5}{6}, 0\right)$$

真の最小点: $\nabla f = \mathbf{0} \iff 4x^3 = 2 \text{ かつ } y = 0$ 、つまり $\mathbf{x}^\dagger = (2^{-1/3}, 0) \approx (0.794, 0)$ 。 y 座標は $1 \rightarrow 0$ で一撃で厳密に到達(f が y について純粋な2次だから、2次モデルが厳密)。 x 座標は $1 \rightarrow \frac{5}{6} \approx 0.833$ で、真の値 0.794 までの距離が $0.206 \rightarrow 0.040$ と大きく縮んだ。もう1歩繰り返せばさらに急速に近づく — これがニュートン法(第14章)である。

ポイント

ニュートン法 の思想は「本物の関数は難しい。ならば、いま居る場所での2次近似(お椀)を作り、そのお椀の底へジャンプせよ。着地点でまたお椀を作り直せ」— 近似モデルの厳密解で

本物を攻める、数値計算の王道パターンです。2次モデルが厳密な方向(y)では1歩で終わり、そうでない方向(x)でも誤差が急減する(2次収束、第14章で証明)。1変数のニュートン法 $x_1 = x_0 - f'(x_0)/f''(x_0)$ の分数が、多変数では「 H^{-1} を掛ける = 連立1次方程式を解く」に化けることも覚えておいてください。

解 8.7 ★★★ 固有値・等高線・条件数

解答

(1) $x^2 + 9y^2 = 2c$ の半軸長は $\sqrt{2c}$ と $\sqrt{2c}/3$ 。軸比は $3 = \sqrt{\kappa}$ で、 $\kappa = 9$ 。

(2) $A = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$ の固有値は 9, 1、対応方向はそれぞれ $(1, 1)$ 、 $(1, -1)$ 。等高線は後者を長軸とする楕円である。

(3) $A = P\Lambda P^\top$ 、 $\mathbf{u} = P^\top \mathbf{x}$ とすると、2次形式は $\frac{1}{2} \sum_i \lambda_i u_i^2$ 。したがって半軸長は $\sqrt{2c/\lambda_i}$ である。

ポイント

特徴量の標準化や適切な前処理は、座標尺度の不揃いによる悪条件性を緩和できます。バッチ正規化や Adam も学習を安定・高速化する場合がありますが、一般の非凸問題でヘッセ行列の条件数を 1 にする保証があるわけではありません。

解 8.8 ★★★ log-sum-exp — ソフトマックスの数学

方針

合成関数の微分を丁寧に。ヘッセ行列は p が x, y の関数であることに注意して連鎖律をもう一段。ランク1構造 $\propto (1, -1)(1, -1)^\top$ が見えると計算が締まる。

解答

(1) $f_x = \frac{e^x}{e^x + e^y} = p, f_y = \frac{e^y}{e^x + e^y} = 1 - p$ 。よって $\nabla f = (p, 1 - p)$ 。(証明終)

(2) p を x で微分する。商の微分より

$$\frac{\partial p}{\partial x} = \frac{e^x(e^x + e^y) - e^x \cdot e^x}{(e^x + e^y)^2} = \frac{e^x e^y}{(e^x + e^y)^2} = p(1 - p)$$

同様に $\frac{\partial p}{\partial y} = -p(1 - p)$ 。したがって $f_{xx} = p(1 - p), f_{xy} = -p(1 - p), f_{yy}$
 $= \frac{\partial(1 - p)}{\partial y} = p(1 - p)$ で

$$H = p(1 - p) \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

行列 $\begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$ の固有値は 0(固有ベクトル $(1, 1)$)と 2(固有ベクトル $(1, -1)$)なの
 で、 H の固有値は

$$0 \quad \text{と} \quad 2p(1 - p)$$

(3) $0 < p < 1$ より $2p(1 - p) > 0$: 固有値は 0 と正で、 H は半正定値だが正定値ではない(固有値に 0 がある)。実際 $\mathbf{v} = (1, 1)$ に対して $\mathbf{v}^\top H \mathbf{v} = 0$ 。この方向の意味: 両方の入力に同じ定数 c を足すと

$$f(x + c, y + c) = \log(e^c(e^x + e^y)) = f(x, y) + c$$

— $(1, 1)$ 方向に沿って f は1次式(まっすぐ)で、曲がりがない。ヘッセ行列の零固有値方向は、関数が「平ら(アフィン)になっている方向」を正確に検出しているのである。

ポイント

log-sum-exp は「 $\max(x, y)$ のなめらか版」($\max \leq f \leq \max + \log 2$)で、ソフトマックス分類・アテンション・強化学習の soft value など現代機械学習の中核部品です。(1) の「勾配 = ソフトマックス確率」は、交差エントロピー損失の勾配が「予測確率 − 正解」という綺麗

な形になる理由の半分を担っています。(3) の退化方向は「ロジットに定数を足しても確率が変わらない」という実装上の常識(オーバーフロー対策で **max** を引く技法)の幾何学的な正体。凸だが強凸でない関数の典型例として、第12章でも再登場します。

第9章

多変数関数の極値 — 解答解説

勾配ゼロ+ヘッセ行列で地形を分類する

解 9.1 ★ 停留点と平方完成

方針

定石(勾配ゼロ → ヘッセ判定)と、初等的な平方完成の両方で解いて突き合わせる。

解答

(1) $\nabla f = (2x - 2, 2y + 4) = \mathbf{0}$ より $(x, y) = (1, -2)$ 。停留点はこの1点。

(2) $H = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = 2I$ 。固有値 $2, 2$ はともに正で正定値。よって $(1, -2)$ は極小点で、
極小値は $f(1, -2) = 1 + 4 - 2 + (-8) + 5 = 0$ 。

(3) 平方完成すると

$$f(x, y) = (x - 1)^2 + (y + 2)^2$$

2乗の和なので常に $f \geq 0$ 、等号は $(x, y) = (1, -2)$ のときのみ。よって極小どころか大域的な最小(最小値 0)である。

ポイント

ヘッセ判定が教えてくれるのはあくまで局所の情報(その点の近くで谷底)です。「地球全体で一番低いか」(大域性)には、平方完成・2乗和・凸性(第12章)といった大域的な構造の根拠が

別途必要 — この区別が本章の通奏低音です。なお f はグラフが回転放物面で、等高線は同心円:ヘッセ行列 $2I$ の条件数は 1、最適化にとって最も「素直」な地形です(問9.8と対極)。

解 9.2 ★★ 停留点の分類 — 問8.1の続き

解答

$\nabla f = (3x^2 - 3y, 3y^2 - 3x) = \mathbf{0}$ から、停留点は $(0, 0)$ と $(1, 1)$ 。

ヘッセ行列は $H = \begin{pmatrix} 6x & -3 \\ -3 & 6y \end{pmatrix}$ 。原点での固有値は ± 3 なので鞍点である。 $(1, 1)$ での固有値は $3, 9$ なので局所的極小点で、値は -1 。

ただし $f(x, 0) = x^3 \rightarrow -\infty$ だから、 $(1, 1)$ は大域的最小点ではない。高次元の非凸最適化でも鞍点は重要になり得るが、その頻度やアルゴリズムへの影響は問題の構造に依存する。

解 9.3 ★ 凸2次関数の極値

方針

D 判定法で片づけたあと、問8.5の一般公式に載せ替えて二重検算する。

解答

$\nabla f = (2x + y - 3, x + 2y) = \mathbf{0}$ 。第2式から $x = -2y$ 、第1式に代入して $-4y + y = 3$ 、 $y = -1$ 、 $x = 2$ 。停留点は $(2, -1)$ 。

2階偏導関数は $f_{xx} = 2$ 、 $f_{yy} = 2$ 、 $f_{xy} = 1$ で

$$D = f_{xx}f_{yy} - f_{xy}^2 = 4 - 1 = 3 > 0, \quad f_{xx} = 2 > 0$$

よって**極小**。極小値は $f(2, -1) = 4 + (2)(-1) + 1 - 6 = -3$ 。

問8.5の形では $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 、 $\mathbf{b} = \begin{pmatrix} 3 \\ 0 \end{pmatrix}$ ($\frac{1}{2}\mathbf{x}^\top A\mathbf{x} = x^2 + xy + y^2$ に注意)。 $A\mathbf{x} = \mathbf{b}$ を解くと

$$\mathbf{x}^* = \frac{1}{3} \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} 3 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \end{pmatrix},$$

$$f(\mathbf{x}^*) = -\frac{1}{2}\mathbf{b}^\top \mathbf{x}^* = -\frac{1}{2}(3 \cdot 2 + 0) = -3$$

で完全に一致。 A は正定値(首座小行列式 $2, 3$)なので、この極小は大域的最小でもある。

ポイント

D 判定法は「 2×2 対称行列の定値性をシルベスターの判定法で見る」ことの言い換えです: $D = \det H$ 、 $f_{xx} =$ 首座 1×1 。3変数以上では D 一発では済まないの、固有値か首座小行列式の一般形(問8.3)に戻ること。1つの問題を2つの流儀(成分計算と行列公式)で解いて一致させる — この「自己検算」の習慣は、テストコードを書いてから実装する開発スタイルと同じ安心感を数学にもたらしめます。

解 9.4 ★★ 鞍点の解剖

方針

判定(固有値)と実感(軸への制限・等高線)の両面から、鞍点という地形を立体的に掴む。

解答

(1) $\nabla f = (2x, -2y)$ は原点で **0**:停留点である。 $H = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$ の固有値は 2 と -2 で正負混在 — **鞍点**。

(2) x 軸上では $f(x, 0) = x^2$:原点は**極小**(谷)。 y 軸上では $f(0, y) = -y^2$:原点は**極大**(尾根)。方向によって山にも谷にも見える — 馬の鞍(サドル)の形そのものである。

(3) $c > 0: x^2 - y^2 = c$ は x 軸方向に開く双曲線。 $c < 0: y$ 軸方向に開く双曲線。 $c = 0: y = \pm x$ の2直線(双曲線の漸近線であり、「山側」と「谷側」の境界)。鞍点のまわりの等高線は「双曲線の族が、交差する2直線を境に向きを変える」パターンで、閉じた輪(極値点のまわりの楕円状の等高線)にならないのが特徴である。

ポイント

等高線を見るだけで極値か鞍点かはほぼ判別できます: 閉じた輪が同心状に並べば極値、X字に交差すれば鞍点。ヘッセ行列の固有ベクトル $(1, 0)$ 、 $(0, 1)$ がちょうど「谷の方向」「尾根の方向」を与えていることにも注目 — 問8.7(固有ベクトル = 地形の主軸)の再演です。鞍点では勾配降下法は固有値正の方向では引き込まれ、負の方向では(わずかでもずれていれば)逃げ出す — この「不安定な均衡」の力学は第13章で再訪します。

解 9.5 ★★ 判定不能なとき — $D=0$ の世界

方針

2次の情報(ヘッセ行列)が消えているので、4次の項が直接勝負を決める。関数の符号を原点の近傍で調べる。

解答

3つとも $\nabla = \mathbf{0}$ 、 $H(0, 0) = O$ (零行列)は容易に確かめられる(4次式の2階微分は2次式で、原点で消える)。

(1) $f = x^4 + y^4 \geq 0$ で、等号は原点のみ。よって原点は**極小**(それどころか大域的最小)。

(2) $g = -f \leq 0$ で等号は原点のみ:**極大**(大域的最大)。

(3) $h = x^4 - y^4$ は x 軸上($h(x, 0) = x^4 > 0$)で正、 y 軸上($h(0, y) = -y^4 < 0$)で負。原点のどんな近傍でも両符号の値をとるので、極値ではない:**鞍点**である。

ポイント

$D = 0$ (退化)は「2次近似では平らに見える」状態で、勝敗はより高次の項に持ち越されます。3つの関数は2次の情報が完全に同一(全部ゼロ)なのに結末が三者三様 — **判定法が沈黙したら、定義(近傍での符号)に立ち返る**という原則の演習です。実際の機械学習でも、平坦な(ヘッセ行列がほぼ退化した)領域は損失地形に広く存在し、「平坦な最小はよく汎化する」といった研究テーマにつながっています。

解 9.6 ★★ 最小二乗は本当に「最小」か — 問7.9の完結

解答

(1) ヘッセ行列は

$$\nabla^2 L = 2 \begin{pmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & n \end{pmatrix}.$$

(2) 本問のデータでは $\nabla^2 L = \begin{pmatrix} 28 & 12 \\ 12 & 6 \end{pmatrix}$ 。首座小行列式は $28 > 0$ と $24 > 0$ なので正定値であり、 $(w, b) = (3/2, 1/3)$ は唯一の大域的最小点である。

(3) 行列式は $4\{n \sum x_i^2 - (\sum x_i)^2\}$ 。コーシー・シュワルツの等号条件から、これは全 x_i が等しいときだけ 0 となる。その場合、傾きと切片を別々に識別できず、正規方程式は特異で解が一意に定まらない。方程式が「不定」なのではない。

解 9.7 ★★★ 有界閉領域での最大・最小

方針

「内部は微分、境界はパラメータ表示して1変数問題に落とす」— 2段構えの標準手順。最後に候補を並べて表彰式。

解答

(1) $\nabla f = (2x - 2, 2y) = \mathbf{0}$ より停留点は $(1, 0)$ 。 $1^2 + 0^2 = 1 < 4$ なので D の内部にある。値は $f(1, 0) = 1 - 2 = -1$ 。

(2) 境界上では $x = 2 \cos \theta, y = 2 \sin \theta (0 \leq \theta < 2\pi)$ として

$$f = 4 \cos^2 \theta + 4 \sin^2 \theta - 4 \cos \theta = 4 - 4 \cos \theta$$

$\cos \theta \in [-1, 1]$ より $f \in [0, 8]$: 境界上の最小は $\theta = 0$ 、点 $(2, 0)$ で 0、最大は $\theta = \pi$ 、点 $(-2, 0)$ で 8。

(3) 候補は内部の -1 (点 $(1, 0)$) と境界の $0, 8$ 。比較して

$$\min_D f = -1 \left((1, 0) \text{ で達成} \right), \quad \max_D f = 8 \left((-2, 0) \text{ で達成} \right)$$

ワイエルシュトラスの定理(第1章・第3章の1変数版の多変数版)は「 D が有界閉集合で f が連続なら最大・最小が必ず**存在する**」ことを保証する。存在が保証されているからこそ、「内部にあるなら停留点、境界にあるなら境界上の最適点」という候補の総当たりで最大・最小を**確定**できる — 存在定理は候補リスト方式の正当性の土台である。

ポイント

内部では $\nabla f = \mathbf{0}$ が必要条件ですが、**境界上ではその限りではない**(境界に沿った方向の微分だけがゼロになればよい)。実際 $(-2, 0)$ では $\nabla f = (-6, 0) \neq \mathbf{0}$ です。この「境界上の最適性条件」を系統的に扱う道具こそがラグランジュ乗数法(第15章)・KKT条件(第16章) — 本問はその手前の、素朴だが確実なパラメータ表示作戦でした。制約つき最適化の原風景として覚えておいてください。

解 9.8 ★★★★ ローゼンブロック関数 — 最適化のベンチマーク

方針

(2) は「2乗和 ≥ 0 、ゼロにできるか?」だけで大域最小が出る — ヘッセ行列より強い議論。

(3) は数値も込みで地形を測量する。

解答

(1) 偏微分して

$$f_x = -2(1-x) - 400x(y-x^2), \quad f_y = 200(y-x^2)$$

$f_y = 0$ より $y = x^2$ 。これを $f_x = 0$ に入れると第2項が消えて $-2(1-x) = 0$ 、すなわち $x = 1, y = 1$ 。停留点は $(1, 1)$ のみ。

(2) f は2つの2乗の和なので常に $f \geq 0$ 。 $f = 0$ となるのは $1-x = 0$ かつ $y-x^2 = 0$ 、すなわち $(1, 1)$ のときだけ。よって $(1, 1)$ は大域的最小点で最小値は 0。(ヘッセ行列を見るまでもなく大域性まで確定する。)

(3) 2階偏導関数は $f_{xx} = 2 - 400y + 1200x^2$ 、 $f_{xy} = -400x$ 、 $f_{yy} = 200$ 。 $(1, 1)$ で

$$H = \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix}, \quad \det H = 802 \cdot 200 - 400^2 = 400, \quad \text{tr } H = 1002$$

固有値は $\lambda^2 - 1002\lambda + 400 = 0$ の解で

$$\lambda = \frac{1002 \pm \sqrt{1002^2 - 1600}}{2} \approx 1001.60, \quad 0.3994$$

条件数は

$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}} \approx \frac{1001.60}{0.3994} \approx 2508$$

問8.7より、最小点付近の等高線は軸比 $\sqrt{\kappa} \approx 50$ の極端に細長い楕円 — 実際この関数の等高線は放物線 $y = x^2$ に沿って曲がった細い谷(バナナ)になる。勾配降下法は、谷を横切

る急な方向($\lambda \approx 1000$)では少しの歩幅でも振動し、谷底に沿う緩い方向($\lambda \approx 0.4$)ではほとんど進めない:歩幅をどちらに合わせても不幸になる、という板挟みが「意地悪」の正体である(定量的な解析は第13章)。

ポイント

ローゼンブロック関数は1960年提案以来の最適化ベンチマークの古典で、「勾配降下法は苦しみ、ニュートン法や準ニュートン法(曲率情報を使う方法)は快走する」という教科書的な対比を体感させてくれます。(2) の「2乗和構造から大域最小を直接読む」議論は、最小二乗・非線形最小二乗(ガウス・ニュートン法)で常用する見方。ヘッセ行列は局所の顕微鏡、関数の構造(2乗和・凸性)は大域の望遠鏡 — 両方を使い分けるのが解析の作法です。

第10章

重積分 — 解答解説

面で足し合わせる・座標を取り替える

解 10.1 ★ 長方形領域の累次積分

方針

内側の積分では外側の変数を定数扱い — 二重ループの内側で外側のループ変数が固定されているのと同じ。

解答

(a) y から先に:

$$\begin{aligned}\int_0^1 \left(\int_0^2 (x + y^2) dy \right) dx &= \int_0^1 \left[xy + \frac{y^3}{3} \right]_{y=0}^{y=2} dx \\ &= \int_0^1 \left(2x + \frac{8}{3} \right) dx = 1 + \frac{8}{3} = \frac{11}{3}\end{aligned}$$

(b) x から先に:

$$\int_0^2 \left(\int_0^1 (x + y^2) dx \right) dy = \int_0^2 \left(\frac{1}{2} + y^2 \right) dy = 1 + \frac{8}{3} = \frac{11}{3}$$

両順序で $\frac{11}{3}$ と一致する。

ポイント

プログラムの二重ループ `for x: for y: s += f(x, y)*dA` はループの入れ子順を替えても総和が変わらない — フビニの定理はその連続版です(連続関数なら無条件で交換可)。「内

側の積分結果は外側の変数だけの関数になる」という型の感覚(内側: y が消えて $2x + \frac{8}{3}$)を、変数の消し込みチェックとして毎回行う癖をつけると、多重積分の計算ミスは激減します。

解 10.2 ★ 三角形領域の累次積分

方針

領域を「 x を固定すると y はどこからどこまで動けるか」と読み替える。図では、縦の走査線が領域を切り取る区間が $[0, x]$ 。

解答

x を $[0, 1]$ で固定すると y は 0 から x まで動くので

$$\iint_D xy \, dA = \int_0^1 \left(\int_0^x xy \, dy \right) dx = \int_0^1 x \cdot \frac{x^2}{2} dx = \int_0^1 \frac{x^3}{2} dx = \frac{1}{8}$$

ポイント

一般領域の累次積分は「外側:走査する範囲、内側:走査線が領域と交わる区間」というスキャンライン(走査線)アルゴリズムの発想そのものです。内側の上限に外側の変数 x が入る — ここが長方形との違いで、順序を替えると区間の記述も変わります(次問)。計算前に必ず領域の絵を描く:重積分の事故のほとんどは絵を省略したときに起こります。

解 10.3 ★★ 積分順序の交換

方針

不等式 $0 \leq y \leq 1, y \leq x \leq 1$ を領域の絵に翻訳 → 同じ領域を「 x 固定で y が動く」向きに読み直す。

解答

(1) 条件は $0 \leq y \leq x \leq 1$: 頂点 $(0, 0), (1, 0), (1, 1)$ の三角形(問10.2と同じ領域)である。直線 $y = x$ の下側・ $x \leq 1$ の範囲。

(2) 同じ三角形を「 x を $[0, 1]$ で固定すると y は 0 から x 」と読み替えて

$$\int_0^1 \int_y^1 e^{x^2} dx dy = \int_0^1 \int_0^x e^{x^2} dy dx = \int_0^1 e^{x^2} [y]_0^x dx = \int_0^1 x e^{x^2} dx$$

最後の積分は $u = x^2$ の置換(問5.6)で

$$\int_0^1 x e^{x^2} dx = \left[\frac{e^{x^2}}{2} \right]_0^1 = \frac{e - 1}{2}$$

ポイント

順序交換の御利益は「内側の積分で被積分関数に掛け算の相棒が生まれる」こと: 交換後、内側の dy 積分が長さ x を吐き出し、 $x e^{x^2}$ という置換可能な形が出現しました。**片方の順序で詰んだら、もう片方を試す** — 探索の枝を張り替える定石です。交換は必ず領域の絵を経由すること: 不等式の機械的な入れ替え($\int_y^1 \rightarrow \int_1^y$ のような)は事故のもとです。

解 10.4 ★★ 極座標変換

方針

ヤコビ行列は偏微分を並べるだけ。面積要素の r は「行列式」と「微小扇形の面積」の2通りで納得しておく。

解答

(1) $x = r \cos \theta, y = r \sin \theta$ より

$$\frac{\partial(x, y)}{\partial(r, \theta)} = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}, \quad \det = r \cos^2 \theta + r \sin^2 \theta = r$$

よって $dA = |\det| dr d\theta = r dr d\theta$ 。(幾何的にも:半径 r 、幅 dr 、角 $d\theta$ の微小片は、ほぼ縦 dr ・横 $r d\theta$ の長方形で面積 $r dr d\theta$ 。)

(2)

$$\iint_{D_R} dA = \int_0^{2\pi} \int_0^R r dr d\theta = 2\pi \cdot \frac{R^2}{2} = \pi R^2$$

(3) $x^2 + y^2 = r^2$ なので

$$\iint_{D_R} (x^2 + y^2) dA = \int_0^{2\pi} \int_0^R r^2 \cdot r dr d\theta = 2\pi \cdot \frac{R^4}{4} = \frac{\pi R^4}{2}$$

ポイント

極座標が効くサイン:被積分関数か領域に $x^2 + y^2$ が現れたとき(円対称)。 r の掛け忘れは重積分の最頻出バグで、「外側ほど同じ $d\theta$ が広い面積を掃く(半径に比例)」という絵で体に入れてください。(3) は回転体の慣性モーメント、画像処理なら円形フィルタの重みの正規化に相当する計算です。

解 10.5 ★★★ ガウス積分 $\sqrt{\pi}$ の証明 — 第6章の宿題

方針

1次元で解けないなら次元を上げる: I^2 を2重積分と見ると $e^{-x^2} e^{-y^2} = e^{-(x^2+y^2)}$ が円対称になり、極座標では $r dr$ が置換の相棒(問5.6の $g'e^g$ 型)を務めて一撃で積分できる。

解答

(1) I を2回書いて(積分変数名は自由なので片方を y に)、 x の積分にとって e^{-y^2} は定数、という順で入れ子にすると

$$\begin{aligned} I^2 &= \left(\int_{-\infty}^{\infty} e^{-x^2} dx \right) \left(\int_{-\infty}^{\infty} e^{-y^2} dy \right) \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-x^2} e^{-y^2} dx dy = \iint_{\mathbb{R}^2} e^{-(x^2+y^2)} dA \end{aligned}$$

(2) 極座標に移ると $x^2 + y^2 = r^2$ 、 $dA = r dr d\theta$ で

$$I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-r^2} r dr d\theta = 2\pi \left[-\frac{e^{-r^2}}{2} \right]_0^{\infty} = 2\pi \cdot \frac{1}{2} = \pi$$

(内側は $u = r^2$ の置換で片づく — 1次元で不可能だった積分が、ヤコビアン r を得て初めて可能になった。)

(3) $I > 0$ (正の関数の積分) なので $I = \sqrt{\pi}$ 。(証明終)

厳密性の補足: 無限領域の2重積分は「有限領域で積分して極限」で定義される。正の被積分関数では、円板 $D_R \subset$ 正方形 $[-R, R]^2 \subset$ 円板 $D_{\sqrt{2}R}$ という領域の入れ子から

$$\iint_{D_R} e^{-(x^2+y^2)} dA \leq \left(\int_{-R}^R e^{-x^2} dx \right)^2 \leq \iint_{D_{\sqrt{2}R}} e^{-(x^2+y^2)} dA$$

が成り立つ。両端は極座標計算で $\pi(1 - e^{-R^2})$ と $\pi(1 - e^{-2R^2})$ で、 $R \rightarrow \infty$ でともに π に収束する。はさみうちにより中央(正方形上の積分の極限 $= I^2$)も π — 「円板の極限と正方形の極限が同じ値か」という細部まで、第1章のはさみうちが締めてくれる。

ポイント

「解けない問題は、より対称性の高い世界に埋め込むと解けることがある」— この証明が教える一般教訓です。 e^{-x^2} 単体は非対称的に難しいが、2つ掛けると回転対称が出現し、対称性に合った座標(極座標)が計算を溶かす。結果の $\sqrt{\pi}$ は正規分布の規格化(問6.8)、 $\Gamma(\frac{1}{2})$ 、スターリングの公式、 n 次元球の体積と、この先何度でも再会する定数です。はさみうち(第1

章)→ 広義積分(第6章)→ 重積分(本章)と、本書の道具が一本の証明に合流したことも味わってください。

解 10.6 ★★ 重心 — 一様分布の期待値

方針

「積分して面積で割る」= 平均。積分は問10.2と同じ三角形上の累次積分。

解答

$$(1) |D| = \int_0^1 \int_0^x dy dx = \int_0^1 x dx = \frac{1}{2}.$$

(2)

$$\iint_D x dA = \int_0^1 \int_0^x x dy dx = \int_0^1 x^2 dx = \frac{1}{3}, \quad \bar{x} = \frac{1/3}{1/2} = \frac{2}{3}$$

$$\iint_D y dA = \int_0^1 \int_0^x y dy dx = \int_0^1 \frac{x^2}{2} dx = \frac{1}{6}, \quad \bar{y} = \frac{1/6}{1/2} = \frac{1}{3}$$

よって重心は $\left(\frac{2}{3}, \frac{1}{3}\right)$ 。

(3) 3頂点の平均は $\left(\frac{0+1+1}{3}, \frac{0+0+1}{3}\right) = \left(\frac{2}{3}, \frac{1}{3}\right)$ で一致する(三角形の重心は頂点の平均、という初等幾何の事実の積分による再証明)。

ポイント

確率の言葉に訳すと: D 上の一様分布の密度は $f = \frac{1}{|D|} = 2$ で、 $\bar{x} = E[X] = \iint x f dA$ 。「重心 = 期待値」の同一視は、物理(質量分布)と確率(確率分布)が同じ数学(測度と積分)の上に立っていることの現れです。モンテカルロ法で「領域内の一様乱数の座標平均」を取ればこの値に収束する — 実装して確かめられる検算法も覚えておくとう便利です(本書の解答の数値も一部この方法で二重チェックしています)。

解 10.7 ★★ 一般の変数変換とヤコビアン

方針

線形写像なのでヤコビ行列は定数行列 = 写像の行列そのもの。積分は uv 側で実行するのが変数変換の御利益。

解答

(1) $x = 2u + v, y = u + v$ より

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad \det J = 2 - 1 = 1$$

面積拡大率が $|\det J| = 1$ なので、 P の面積は単位正方形と同じ 1。

(2) $x - y = (2u + v) - (u + v) = u$ 。変数変換公式より

$$\iint_P (x - y) dA = \int_0^1 \int_0^1 u \cdot |\det J| du dv = \int_0^1 \int_0^1 u du dv = \frac{1}{2}$$

(本書の検証では、この値を xy 平面での直接のモンテカルロ積分でも独立に確認している:
面積 ≈ 1.00 、積分 ≈ 0.50 。)

(3) 線形写像 T は面積を一律に $|\det J|$ 倍する — 『線形代数』の「行列式 = 体積(面積)拡大率」がそのまま積分の換算率になっている。一般の(非線形な)変数変換公式は、「写像を各点で1次近似(ヤコビ行列)すれば局所的には線形写像 $\rightarrow$ 微小タイルの面積が

$|\det J(u, v)|$ 倍」という、この事実の各点版である。

ポイント

変数変換公式 $dA = |\det J| du dv$ は「微分(1次近似) + 行列式(面積拡大率)」の合体で、本書と『線形代数』の交差点に立つ定理です。極座標(問10.4)はその特別な場合($\det = r$)でした。確率論では、変数変換した確率密度に $|\det J|^{-1}$ が付く公式として毎日使われ、機

機械学習の正規化流(normalizing flow:可逆変換で分布を変形する生成モデル)は、まさにこのヤコビアン計算を学習可能にしたものです。

解 10.8 ★★★ 2次元標準正規分布 — 原点からの距離

方針

円対称な密度 $\times$ 円板領域 = 極座標の独壇場。ガウス積分の計算(問10.5)と同じ $re^{-r^2/2}$ 型が続けて現れる。

解答

(1) 累次積分に分けると1次元の規格化(問6.8(3))の積になる:

$$\iint_{\mathbb{R}^2} f dA = \left(\int_{-\infty}^{\infty} \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx \right) \left(\int_{-\infty}^{\infty} \frac{e^{-y^2/2}}{\sqrt{2\pi}} dy \right) = 1 \cdot 1 = 1$$

(2) 極座標で

$$\begin{aligned} P(X^2 + Y^2 \leq R^2) &= \int_0^{2\pi} \int_0^R \frac{1}{2\pi} e^{-r^2/2} r dr d\theta = \int_0^R e^{-r^2/2} r dr \\ &= \left[-e^{-r^2/2} \right]_0^R = 1 - e^{-R^2/2} \end{aligned}$$

$R = 1$ なら $1 - e^{-1/2} = 0.3935 \dots$ — 標準正規の2次元の点が単位円板に入る確率は約 39% である。

(3)

$$E[X^2 + Y^2] = \int_0^{2\pi} \int_0^{\infty} r^2 \cdot \frac{1}{2\pi} e^{-r^2/2} r dr d\theta = \int_0^{\infty} r^3 e^{-r^2/2} dr$$

$u = r^2/2 (du = r dr, r^2 = 2u)$ と置換して

$$\int_0^{\infty} 2u e^{-u} du = 2 \Gamma(2) = 2 \cdot 1! = 2$$

確かに $E[X^2] + E[Y^2] = 1 + 1 = 2$ (各座標の分散 1 の和) と一致する。

ポイント

距離の2乗 $X^2 + Y^2$ の分布(自由度2の χ^2 分布 = 平均2の指数分布:(2) の式がその累積分布関数)は、統計検定・信頼領域・誤差楕円の基礎です。(2) の計算は「2次元正規乱数を (r, θ) で生成する」ボックス・ミュラー法の裏づけそのもの: θ は一様、 $r^2/2$ は指数分布に従う、と読めます。1次元の道具(ガンマ関数・置換)と2次元の道具(極座標・ヤコビアン)が滑らかに接続して確率の実務計算になる — 第II部の到達点です。

第 11 章

最適化問題の定式化 — 解答解説

「よい」を数式にする技術

解 11.1 ★ min・argmin・inf の使い分け

方針

値(スカラー)と点(集合)を峻別する。達成されるかどうかは $\min$ と $\inf$ の分かれ目。

解答

(1) $(x - 2)^2 \geq 0$ より $f(x) \geq 1$ 、等号は $x = 2$ 。よって $\min f = 1$ 、 $\operatorname{argmin} f = \{2\}$ 。(値は 1、点は 2 — 混同しないこと。)

(2) $x > 0$ で $g(x) = \frac{1}{x} > 0$ であり、 $x \rightarrow \infty$ で $g \rightarrow 0$ ：いくらでも 0 に近い値をとるが 0 自体には決して到達しない。よって $\inf g = 0$ だが、 $g(x) = 0$ となる x は存在しないので $\min g$ は存在しない。

(3) アルゴリズムが「最小点に到達したら停止」という設計だと、最小点が存在しない問題では永遠に停止しない(値は下限に近づき続けるのに)。だから実用の停止条件は「勾配が十分小さい」「値の改善が閾値以下」のような達成可能な条件で書く — $\inf$ と $\min$ の区別は、停止性を考える工学的な感覚と直結している。

ポイント

論文や教科書で $\hat{\theta} \in \operatorname{argmin}_{\theta} L(\theta)$ と「 $\in$ 」で書かれるのは、 argmin が一般には**集合**(複数点や空集合もありうる)だからです。この記法の作法を守るだけで、答案の解像度が一段上がります。

解 11.2 ★ 最大化・最小化・対数変換

方針

直接法と対数法で同じ答えが出ることを見て、変換の正当性を体感する。

解答

(1) $f'(x) = e^{-x} - xe^{-x} = (1-x)e^{-x} = 0$ より $x = 1$ 。 $f''(x) = (x-2)e^{-x}$ から $f''(1) = -e^{-1} < 0$ で極大。 $x \rightarrow 0+$ で $f \rightarrow 0$ 、 $x \rightarrow \infty$ で $f \rightarrow 0$ (増大度の階層)だから、 $x = 1$ が大域的最大点(最大値 e^{-1})。

(2) $-\log f(x) = -\log x + x$ 。微分して $-\frac{1}{x} + 1 = 0$ 、すなわち $x = 1$ — 同じ点が得られる(こちらは最小化として)。

(3) φ が狭義単調増加なら「 $f(a) > f(b) \iff \varphi(f(a)) > \varphi(f(b))$ 」 — 大小関係が完全に保存されるので、最大を与える点も変わらない(変わるのは最大の**値**だけ)。積の形 $f = \prod_i f_i$ は対数で和 $\sum_i \log f_i$ に変わり、(i) 微分が「積の微分の連鎖」から「和の微分」に単純化し、(ii) 数値計算上も微小な確率の積によるアンダーフローを回避できる。

ポイント

「尤度の最大化 = 負の対数尤度の最小化」という機械学習の常套句は、本問の (3) がすべてです。交差エントロピー損失は負の対数尤度そのもの。**目的関数は最適点を変えない範囲**

で化粧してよい — 定数加算、正の定数倍、狭義単調増加変換は argmax を保つ(負の定数倍なら最大化と最小化が反転する)ので、計算しやすさのために使えます(問11.8で実戦投入)。

解 11.3 ★★ 実行可能集合と線形計画の顔見せ

方針

線形の目的関数の等高線は平行な直線群。実行可能集合(多角形)の上をどこまで押せるかを図で読む。

解答

(1) S は頂点 $(0, 0)$ 、 $(1, 0)$ 、 $(0, 1)$ の三角形(直角二等辺三角形、斜辺は直線 $x + y = 1$ 上)。

(2) 目的関数の等高線 $x + y = c$ は傾き -1 の平行線で、 c を大きくする方向(右上)へ押していくと、 S と交わる限界は $c = 1$ 、そのとき交わりは斜辺全体。よって最大値は 1 、それを与える点は線分 $\{(x, y) \mid x + y = 1, 0 \leq x \leq 1\}$ 上のすべての点(頂点 $(1, 0)$ と $(0, 1)$ を含む)。 argmax が無限個の点からなる例である。

(3) $x \leq 0$ と $x \geq 1$ を同時に満たす x は存在しないので、実行可能集合は空集合。制約を満たす点が1つもない問題を**実行不能(infeasible)**という。実行不能な問題には最適解も最適値もそもそも定義されない — 定式化の段階で制約同士が矛盾していないか(モデルのバグがないか)を確かめることが、解くことと同じくらい重要である。

ポイント

(2) は線形計画(LP)の基本現象の縮図です:非定数の線形目的関数を、内部をもつ多面体上で最適化して最適解が存在すれば、最適点は境界にあります。また、線形計画が有限の最適値をもち、実行可能多面体に極点がある標準的な状況では、少なくとも1つの最適な極点(頂点)を選べます。等高線が辺と平行なら、本問のように辺全体が最適になることもあります。定

数目的関数なら内部も含む全実行可能点が最適なので、「必ず境界」という無条件な言い方はできません。単体法が頂点を渡り歩くのはこの極点構造を利用するためです。

解 11.4 ★★ 最小値の存在 — coercivity(第3章の宿題)

方針

coercivity は「遠方はすべて高い」という保証。だから探索を有界閉区間に閉じ込めてよく、あとはワイエルシュトラスに引き渡す。

解答

(1) $f(x) = x^4 - 3x = x^4 \left(1 - \frac{3}{x^3}\right)$ で、 $|x| \rightarrow \infty$ のとき $x^4 \rightarrow \infty$ ・括弧 $\rightarrow 1$ だから $f \rightarrow +\infty$ (coercive)。

存在の証明:基準点 $x = 0$ の値 $f(0) = 0$ をとる。coercivity より、ある $R > 0$ が存在して $|x| > R$ なら $f(x) > f(0) = 0$ 。一方、有界閉区間 $[-R, R]$ 上では連続関数 f はワイエルシュトラスの定理により最小値を達成する:その点を $x^* \in [-R, R]$ とすると $f(x^*) \leq f(0) = 0$ 。すると任意の $x \in \mathbb{R}$ に対して、 $|x| \leq R$ なら $f(x) \geq f(x^*)$ (区間内の最小性)、 $|x| > R$ なら $f(x) > 0 \geq f(x^*)$ 。よって x^* は $\mathbb{R}$ 全体での最小点である。(証明終)

(2) $f'(x) = 4x^3 - 3 = 0$ より $x^* = \left(\frac{3}{4}\right)^{1/3} = 0.909$ (小数第3位)。 $f'' = 12x^2 > 0$ で極小、(1) より大域的最小。最小値は

$$f(x^*) = x^* \left((x^*)^3 - 3 \right) = \left(\frac{3}{4}\right)^{1/3} \left(\frac{3}{4} - 3\right) = -\frac{9}{4} \left(\frac{3}{4}\right)^{1/3} = -2.044$$

(3) $g(x) = e^x$:下に有界($g > 0$)で $\inf g = 0$ だが、 $x \rightarrow -\infty$ の「無限の彼方」でしか近づけず達成されない — **coercivity の欠如**(片側で $f \rightarrow \infty$ にならない)により最小値が存

在しないタイプ。 $h(x) = x^3: x \rightarrow -\infty$ で $h \rightarrow -\infty$ 、そもそも下に有界でない($\inf h = -\infty$)タイプ。同じ「最小値なし」でも病理が異なる。

ポイント

(1) の証明パターン「遠方を coercivity で切り捨て、残った有界閉集合でワイエルシュトラス」は多変数でもそのまま通用します。たとえば元の損失が下に有界で、 $\lambda > 0$ の L2 項 $\lambda \|w\|^2$ がすべての非有界な変数方向を罰するなら、目的関数は coercive になり最小点の存在が保証されます。一部の変数を罰しない場合は、その方向をデータ項などが抑えるかを別に確認する必要があります(問11.6では残差項が切片方向を抑える)。解く前に存在を確認することが重要です。

解 11.5 ★ argmin は1点とは限らない

方針

偶関数の対称性に注意しながら、停留点3つを2次判定で仕分ける。

解答

$f'(x) = 4x^3 - 4x = 4x(x-1)(x+1) = 0$ より停留点は $x = -1, 0, 1$ 。 $f''(x) = 12x^2 - 4$ を使うと、 $f''(\pm 1) = 8 > 0$ (極小)、 $f''(0) = -4 < 0$ (極大)。値は $f(\pm 1) = 1 - 2 = -1$ 、 $f(0) = 0$ 。 $x \rightarrow \pm\infty$ で $f \rightarrow \infty$ (coercive)なので最小値は存在し、

$$\min f = -1, \quad \operatorname{argmin} f = \{-1, +1\}$$

— 大域的最小点が2つある(W字型の二重井戸)。機械学習での対応例:ニューラルネットワークの損失は、隠れユニットの並べ替えや符号の反転で値が変わらない対称性を持つため、同じ最小値を与えるパラメータが組合せ的に大量に存在する(解の非一意性)。「どの最小点に落ちるかは初期値次第」という現象の最小モデルが本問である。

ポイント

非一意性そのものは悪ではありません(どの解でも損失は同じ)。ただし「解が一意」を前提にした議論(解の連続性・安定性・解釈)は崩れるので、一意性が欲しい場面では狭義凸性(第12章)や正則化で担保します。二重井戸は物理(相転移)・分子計算・GAN の解析まで登場する、非凸性の最小教材です。

解 11.6 ★★ 正則化 — 目的関数を設計する

方針

正則化項 λw^2 は損失に足された2次のバネ。正規方程式の w の係数だけが $+\lambda$ されることを見抜く。

解答

(1) $\frac{\partial L_\lambda}{\partial w} = 2 \sum (wx_i + b - y_i)x_i + 2\lambda w$, $\frac{\partial L_\lambda}{\partial b} = 2 \sum (wx_i + b - y_i)$ 。ゼロと置くと(問7.9の正規方程式の第1式だけ w の係数が λ 増えて)

$$(14 + \lambda)w + 6b = 23, \quad 6w + 3b = 10$$

$\lambda = 1$: $15w + 6b = 23$ と $6w + 3b = 10$ 。第2式から $b = \frac{10-6w}{3}$ 、代入して $15w + 20 - 12w = 23$, $3w = 3$ 。よって

$$w = 1, \quad b = \frac{4}{3}$$

無正則化の $w = \frac{3}{2}$ より傾きが 0 側へ縮小した(その分 b が $\frac{1}{3} \rightarrow \frac{4}{3}$ と調整されている)。

(2) 一般の λ で同じ消去をすると $(14 + \lambda)w + 2(10 - 6w) = 23$ 、すなわち $(\lambda + 2)w = 3$ で

$$w(\lambda) = \frac{3}{\lambda + 2}$$

$\lambda \rightarrow 0$ で $w \rightarrow \frac{3}{2}$ (通常の最小二乗に復帰)、 $\lambda \rightarrow \infty$ で $w \rightarrow 0$ (データを無視してでも係数を小さく)。 λ は「残差を小さくしたい」と「係数を小さく保ちたい」という2つの願いの混合比を連続的に調整するツマミであり、その効果が $w(\lambda) = \frac{3}{\lambda+2}$ という単調減少の閉じた式で完全に見える。

ポイント

リッジ正則化の実務的な効能は3つ: (i) 過学習の抑制(係数の暴れを罰する)、(ii) ヘッセ行列を $+2\lambda I$ (の該当ブロック) だけ持ち上げて正定値性・解の一意性を保証(問9.6の退化への処方箋)、(iii) coercivity の付与による存在保証(問11.4)。「目的関数に項を1つ足す」だけでこれだけの解析的性質が買える — **目的関数は所与ではなく設計するもの**、というこの章のメッセージの代表例です。

解 11.7 ★★★ 変形して解く — 代入と不等式

方針

(1) は制約の消去(次元削減)、(2) は最適値を直接下から押さえる評価 — 最適化の二大戦略を1つの問題で対決させる。

解答

(1) $y = \frac{1}{x}$ を代入して $g(x) = x + \frac{1}{x} (x > 0)$ 。 $g'(x) = 1 - \frac{1}{x^2} = 0$ より $x = 1 (x > 0 \text{ の範囲で})$ 。 $g''(x) = \frac{2}{x^3} > 0$ で極小、さらに $x \rightarrow 0+$ と $x \rightarrow \infty$ の両端で $g \rightarrow \infty$ (coercive) なので大域的最小。最小値は $g(1) = 2$ 、このとき $y = 1$ 。

(2) 相加相乗平均の不等式より、 $x, y > 0$ に対して

$$\frac{x+y}{2} \geq \sqrt{xy} = \sqrt{1} = 1 \quad \therefore x+y \geq 2$$

等号成立は $x = y$ のとき。制約 $xy = 1$ と合わせて $x = y = 1$ 。下界 2 が実際に達成されるので、最小値は 2。(微分不要・大域性も同時に確定。)

(3) **代入法**の長所:機械的で汎用(制約が複雑でも変数が消せれば使える)。短所:得られるのは局所的な情報で、大域性には別途議論(coercivity 等)が要る。**不等式法**の長所:下界と達成を同時に示すので**大域的な最適性が一撃で確定**し、計算も軽い。短所:使える不等式が見つかる問題にしか適用できない(職人芸的)。実務では「まず代入・数値計算であたりをつけ、構造(不等式・凸性)が見えたら大域性を固める」という併用が定石である。

ポイント

不等式法は「最適値の証明書(certificate)を提示する」発想で、第17章の双対性 — 最小化問題の下界を系統的に作る理論 — の原点です。相加相乗平均はイェンゼンの不等式(凸性、第12章)の特別な場合でもあり、 $x + \frac{1}{x} \geq 2$ はキャッシュサイズとミス率、並列度とオーバーヘッドのようなトレードオフの雛形として応用面でも頻出します。

解 11.8 ★★★ 最尤推定 — 統計を最適化として解く

解答

(1) 対数尤度は $\ell(p) = 7 \log p + 3 \log(1-p)$ 。 $\ell'(p) = 7/p - 3/(1-p) = 0$ から $\hat{p} = 7/10$ 。

(2) $\ell''(p) = -7/p^2 - 3/(1-p)^2 < 0$ なので、 ℓ は $(0, 1)$ で狭義凹である。境界では尤度が 0、内部の $p = 0.7$ では正なので、これが $[0, 1]$ 上の唯一の大域的最大点である。

(3) 一般に n 回中 k 回が表なら、 $0 < k < n$ では同じ計算から $\hat{p} = k/n$ 。 $k = 0$ と $k = n$ では、それぞれ境界解 0 と 1 となる。

ポイント

自然パラメータで表した正則な指数型分布族では、対数分配関数の凸性から負の対数尤度が凸になるという有用な構造があります。任意のパラメータ化や任意の統計モデルで自動的に凸になるわけではありません。

第12章

凸集合と凸関数 — 解答解説

「解ける最適化」の共通言語

解 12.1 ★ 凸集合の判定

方針

凸性の証明はワンパターン:2点を取り、凸結合 $t\mathbf{x} + (1-t)\mathbf{y}$ が条件を満たすことを線形性や三角不等式で確かめる。反例は「はみ出す1点」を挙げれば終わり。

解答

(1) $(x_1, y_1), (x_2, y_2) \in S, t \in [0, 1]$ とする。凸結合での左辺は線形性より

$$\begin{aligned} & a(tx_1 + (1-t)x_2) + b(ty_1 + (1-t)y_2) \\ &= t(ax_1 + by_1) + (1-t)(ax_2 + by_2) \leq tc + (1-t)c = c \end{aligned}$$

よって凸結合も S に属し、 S は凸。(証明終)

(2) $\|\mathbf{x}\| \leq 1, \|\mathbf{y}\| \leq 1$ とすると、三角不等式と斉次性より

$$\|t\mathbf{x} + (1-t)\mathbf{y}\| \leq t\|\mathbf{x}\| + (1-t)\|\mathbf{y}\| \leq t + (1-t) = 1$$

よって凸。(証明終)

(3) $1 \in [0, 1], 2 \in [2, 3]$ の中点 $\frac{1+2}{2} = 1.5$ は $[0, 1]$ にも $[2, 3]$ にも属さない。線分がはみ出すので凸でない。

ポイント

実は「凸集合どうしの共通部分は凸」も同じ1行証明で出ます(各集合で条件が保たれるから)。したがって連立の線形不等式で書かれる領域(多面体) — 線形計画の実行可能集合(問11.3) — は半平面の交わりとして自動的に凸。逆に合併は(3)の通り凸性を壊すのが普通です。「制約を足す(交わり)のは安全、場合分けで貼り合わせる(合併)のは危険」という定式化の感覚として持っておいてください。

解 12.2 ★ 弦の不等式による判定

方針

弦の不等式は「右辺 - 左辺 ≥ 0 」を直接展開して示すのが基本。反例は具体的な数値で1発。

解答

(1) 右辺 - 左辺を展開すると

$$\begin{aligned} tx^2 + (1-t)y^2 - (tx + (1-t)y)^2 &= t(1-t)x^2 - 2t(1-t)xy + t(1-t)y^2 \\ &= t(1-t)(x-y)^2 \geq 0 \end{aligned}$$

よって弦の不等式が成り立ち、 x^2 は凸。しかも $x \neq y, t \in (0, 1)$ では真に正なので**狭義凸**である。

(2) 三角不等式 $|a+b| \leq |a| + |b|$ と $|ca| = |c||a|$ より

$$|tx + (1-t)y| \leq |tx| + |(1-t)y| = t|x| + (1-t)|y|$$

これはまさに $f = |x|$ の弦の不等式である。(証明終)

(3) $x = -2, y = 1, t = \frac{1}{2}$: 中点は $-\frac{1}{2}$ で $f(-\frac{1}{2}) = -\frac{1}{8}$ 。弦の側は $\frac{f(-2)+f(1)}{2} = \frac{-8+1}{2} = -\frac{7}{2}$ 。 $-\frac{1}{8} > -\frac{7}{2}$ なので「グラフが弦の上」に出てしまい、凸性が破れている。

ポイント

(2) の $|x|$ は「凸だが微分不可能」の代表例で、問2.9で予告した劣微分(subgradient)の主役です: $x = 0$ では接線の傾きとして $[-1, 1]$ のどの値も許され、その集合を劣微分と呼びます。L1正則化(Lasso)が重みをちょうど 0 に落とせるのは、この 0 での「傾きの遊び」のおかげ — 微分不可能性が機能として役立つ好例です。凸性は微分より根源的な概念であり、微分できない点を持つ関数にもそのまま通用します。

解 12.3 ★ 2階条件による判定

方針

実務の判定はほぼこれ:2階微分(ヘッセ行列)の符号(半正定値性)を見る。

解答

(1) $(e^x)'' = e^x > 0$:凸(狭義凸)。

(2) $(-\log x)'' = \frac{1}{x^2} > 0 (x > 0)$:凸(狭義凸)。

(3) $(x^4)'' = 12x^2 \geq 0$:凸(なお $x = 0$ で2階微分は 0 だが、弦の不等式は満たす — 半正定値で十分)。 $(x^3)'' = 6x$ は $x < 0$ で負:2階条件が破れ、凸でない(問12.2(3)の反例と整合)。

(4) $\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = 2I$ は正定値:凸(狭義凸)。

ポイント

暗記推奨の凸関数リスト: $e^{ax} (x \in \mathbb{R})$ 、 $-\log x (x > 0)$ 、 $x \log x (x > 0)$ 、または $0 \log 0 = 0$ と連続拡張して $x \geq 0$ 、 $|x|^p (p \geq 1)$ 、 $\frac{1}{2} \mathbf{x}^\top A \mathbf{x} (A \succeq O)$ 、log-sum-exp。凹関数(

- f が凸)側の代表は $\log x (x > 0)$ 、 $\sqrt{x} (x \geq 0)$ 、確率単体上のエントロピー
- $-\sum p_i \log p_i$ です。凸性は必ず凸な定義域と組にして述べます。

解 12.4 ★★ 1階条件 — 接線はいつもグラフの下

方針

1階条件は「接線(接平面)による1次近似が、常に真の値の過小評価になる」という大域的な不等式。既出の不等式 $e^t \geq 1 + t$ がその実例だったことを見抜く。

解答

(1) 右辺 $f(x) + f'(x)(y - x)$ は「点 x で引いた接線の、位置 y での高さ」。不等式は凸関数のグラフはどの接線よりも上にある(接線が大域的な下界になる)ことを主張している。

(2) $f = e^x$ では $f'(x) = e^x$ なので1階条件は $e^y \geq e^x + e^x(y - x) = e^x(1 + y - x)$ 。両辺を $e^x > 0$ で割り、 $t = y - x$ と置けば

$$e^t \geq 1 + t$$

— 問3.5で平均値の定理から証明した不等式そのものである。逆にこの不等式から任意の x, y の1階条件が復元できるので、両者は同値。

(3) 1階条件を2本書く:

$$f(y) \geq f(x) + f'(x)(y - x), \quad f(x) \geq f(y) + f'(y)(x - y)$$

辺々足すと $f(x) + f(y) \geq f(x) + f(y) + (f'(x) - f'(y))(y - x)$ 、整理して

$$(f'(y) - f'(x))(y - x) \geq 0$$

すなわち f' は(広義)単調増加である。(証明終)

ポイント

凸性の3特徴づけの使い分け: **弦**は定義そのもの(微分可能性不要・理論の出発点)、**1階**は「接線 = 大域下界」でアルゴリズム解析の主戦力(第13章の収束証明で酷使します)、**2階**は判定の実務用。(3) の「勾配の単調性」は、多変数では $(\nabla f(\mathbf{y}) - \nabla f(\mathbf{x}))^\top (\mathbf{y} - \mathbf{x}) \geq 0$ となり、単調作用素という現代最適化のキーワードにつながります。第1部でバラバラに証明した不等式群が「凸性」という1語に統一される — 数学の圧縮力の見せ場です。

解 12.5 ★★ イェンゼンの不等式とその応用

方針

(1) は「3点を2点にまとめて2点版を2回使う」再帰。(2)(3) は凸関数の選び方が芸の見せどころ。

解答

(1) $\lambda_1 = 1$ なら自明なので $\lambda_1 < 1$ とし、 $s = \lambda_2 + \lambda_3 = 1 - \lambda_1 > 0$ 、 $z = \frac{\lambda_2 x_2 + \lambda_3 x_3}{s}$ とおく($\frac{\lambda_2}{s} + \frac{\lambda_3}{s} = 1$ なので z は x_2, x_3 の凸結合)。まず2点版を x_1 と z に:

$$f(\lambda_1 x_1 + s z) \leq \lambda_1 f(x_1) + s f(z)$$

次に2点版を z の内部に: $f(z) \leq \frac{\lambda_2}{s} f(x_2) + \frac{\lambda_3}{s} f(x_3)$ 。代入して

$$f(\lambda_1 x_1 + \lambda_2 x_2 + \lambda_3 x_3) \leq \lambda_1 f(x_1) + \lambda_2 f(x_2) + \lambda_3 f(x_3)$$

(同じ手順の繰り返しで任意個の n 点版が帰納法で従う。)

(2) $f = -\log$ (凸、問12.3) に2点版($\lambda = \frac{1}{2}$)を適用:

$$-\log \frac{x+y}{2} \leq \frac{-\log x - \log y}{2} = -\log \sqrt{xy}$$

両辺に -1 を掛けて $\log$ の単調性を使えば $\frac{x+y}{2} \geq \sqrt{xy}$ 。(証明終 — 問11.7の道具が凸性から正式に導出された。)

(3) $f(x) = x^2$ で $f(E[X]) \leq E[f(X)]$ は $(E[X])^2 \leq E[X^2]$ 、すなわち

$$V[X] = E[X^2] - (E[X])^2 \geq 0$$

— 分散の非負性。イエンゼンの等号条件(狭義凸なら X がほとんど確実に定数のときに限る)は「分散 $0 \iff$ ある定数 c が存在して $P(X = c) = 1$ 」に対応する。零確率の事象上で値が異なっても分散には影響しないため、「各標本点で定数」とは限らない。

ポイント

イエンゼンの不等式は情報系の理論のいたるところに顔を出します:KLダイバージェンスの非負性($-\log$ に適用)、エントロピーの上界 $H \leq \log n$ 、EMアルゴリズムの下界構成(変分推論のELBO)、金融の「期待効用 $\leq$ 効用の期待」…。「平均してから関数」と「関数してから平均」の大小を、凸性が一律に決める — この1行を体に入れると、確率まわりの不等式の半分は自力で再構成できます。

解 12.6 ★★ 凸性を保つ演算 — 部品から組み立てる

方針

いずれも弦の不等式を書いて、係数の非負性・アフィン性・ $\max$ の性質で締めるだけの「1行証明」3連発。

解答

(1) $z = tx + (1-t)y$ とおくと、 f, g の弦の不等式に $\alpha, \beta \geq 0$ を掛けて足し

$$\alpha f(z) + \beta g(z) \leq t(\alpha f(x) + \beta g(x)) + (1-t)(\alpha f(y) + \beta g(y))$$

これは $\alpha f + \beta g$ の弦の不等式である。(証明終)

(2) $\varphi(x) = f(ax + b)$ とすると、アフィン写像は凸結合を保つ $a(tx + (1-t)y) + b = t(ax + b) + (1-t)(ay + b)$ ので

$$\varphi(tx + (1-t)y) = f(t(ax + b) + (1-t)(ay + b)) \leq t\varphi(x) + (1-t)\varphi(y)$$

よって凸。最小二乗損失は「凸関数 u^2 にアフィン式 $u = a_i w - b_i$ を合成(各項が凸)し、非負和をとる((1))」ので凸 — 2階微分を計算するまでもなく、構造だけで凸性が確定する。

(3) $h = \max(f, g)$ とする。 $f(z) \leq tf(x) + (1-t)f(y) \leq th(x) + (1-t)h(y)$ ($f \leq h$ を使った)。 g についても同じ上界が成り立つので、両者の $\max$ をとって

$$h(z) = \max\{f(z), g(z)\} \leq th(x) + (1-t)h(y)$$

(証明終)

ポイント

この「演算規則」の思想は型システムに似ています:基本部品(問12.3のリスト)の凸性と、合成規則(非負和・アフィン合成・ $\max$ ・さらに上限 $\sup$ 、非減少凸関数との合成など)を組み合わせれば、複雑な目的関数の凸性がコンパイル時チェックのように機械的に検証できる。実際、凸最適化モデリング言語 CVXPY はまさにこの規則集(DCP ルール)で式の凸性を自動判定しています。(3) の $\max$ 則は、SVM のヒンジ損失 $\max(0, 1 - yz)$ やReLU $\max(0, x)$ の凸性を一撃で保証する重要則です。

解 12.7 ★★ 凸なら局所=大域 — この章の主定理

方針

弦の不等式は「よい点 $\mathbf{y}$ に向かう線分上では、値が線形補間以下」— つまり良い点があれば、その方向にほんの少し動くだけで改善できてしまう。これが局所最小性と衝突する。

解答

(1) $\mathbf{x}^*$ を局所的最小点とし、仮に $f(\mathbf{y}) < f(\mathbf{x}^*)$ なる $\mathbf{y}$ が存在したとする。 $t \in (0, 1]$ に対し $\mathbf{z}_t = t\mathbf{y} + (1-t)\mathbf{x}^*$ とおくと、弦の不等式より

$$f(\mathbf{z}_t) \leq t f(\mathbf{y}) + (1-t) f(\mathbf{x}^*) < t f(\mathbf{x}^*) + (1-t) f(\mathbf{x}^*) = f(\mathbf{x}^*)$$

$t \rightarrow 0+$ で $\mathbf{z}_t \rightarrow \mathbf{x}^*$ だから、 $\mathbf{x}^*$ のどんな近傍にも f の値が $f(\mathbf{x}^*)$ より真に小さい点 $\mathbf{z}_t$ が存在する — これは局所的最小性(近傍で $f \geq f(\mathbf{x}^*)$)に矛盾。よってそのような $\mathbf{y}$ は存在せず、 $\mathbf{x}^*$ は大域的最小点。(証明終)

(2) 大域的最小点が2つ $\mathbf{x}_1 \neq \mathbf{x}_2$ (値 m) あったとすると、狭義凸性より中点で

$$f\left(\frac{\mathbf{x}_1 + \mathbf{x}_2}{2}\right) < \frac{f(\mathbf{x}_1) + f(\mathbf{x}_2)}{2} = m$$

— 最小値 m より小さい値が出てしまい矛盾。よって最小点は高々1つ。(証明終)

(3) $\nabla f(\mathbf{x}^*) = \mathbf{0}$ とすると、1階条件より任意の $\mathbf{y}$ で

$$f(\mathbf{y}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^\top (\mathbf{y} - \mathbf{x}^*) = f(\mathbf{x}^*)$$

すなわち $\mathbf{x}^*$ は大域的最小点。(証明終)

ポイント

この定理が凸最適化の「無敵感」の源泉です:凸なら、勾配ゼロの点を1つ見つけた瞬間に大域的最適性の**証明書**が手に入り((3))、鞍点や偽の谷(問9.2)への不安が消える。深層学習の損失は非凸なのでこの保証はありませんが、「凸な部分問題に落とす」「凸な代理損失で置き

換える」など、凸性は非凸の世界でも設計の羅針盤であり続けます。3つの証明がすべて数行 — 凸性という仮定の強力さを味わってください。

解 12.8 ★★★ log-sum-exp — なめらかな max(問8.8の完結)

方針

(2) は $e^x + e^y$ を $e^{\max}$ で挟んで $\log$ をとるだけ。(3) はスケーリングで (2) を再利用。

解答

(1) 問8.8で $\nabla^2 f = p(1-p) \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$ 、固有値 0 と $2p(1-p) \geq 0$ を確かめた:

ヘッセ行列は至る所で半正定値なので、2階条件により f は凸。ただし固有値 0 の方向

$(1, 1)$ に沿って f はアフィン($f(x+c, y+c) = f+c$)であり、弦の不等式が等号で成立するため狭義凸ではない。

(2) $m = \max(x, y)$ とおく。 $e^m \leq e^x + e^y \leq e^m + e^m = 2e^m$ (左は大きい方の項だけで、右は両項を e^m で上から)。各辺の $\log$ をとって(単調性)

$$m \leq \log(e^x + e^y) \leq m + \log 2$$

(証明終)

(3) (2) を引数 $x/\tau, y/\tau$ に適用し、全体を $\tau > 0$ 倍すると($\max(x/\tau, y/\tau) = m/\tau$ に注意)

$$m \leq \tau \log(e^{x/\tau} + e^{y/\tau}) \leq m + \tau \log 2$$

$\tau \rightarrow 0+$ で右端 $\rightarrow m$: はさみうちにより $f_\tau \rightarrow \max(x, y)$ 。ありがたさ: $\max$ は角(微分不可能点)を持つが、 f_τ はすべての $\tau > 0$ で C^∞ かつ凸 — 勾配計算(誤差逆伝播)と相性のよい、精度調整可能な $\max$ の代用品になる。

ポイント

τ はソフトマックスの「温度」そのもの: 高温では平均的(なだらか)、低温では $\max(\arg\max$ の one-hot) に鋭くなる — 注意機構や強化学習の方策、知識蒸留で毎日調整されているパラメータです。誤差上界が $\tau \log 2(n$ 択なら $\tau \log n)$ と定量的に抑えられている点の実務上の安心材料。「微分不可能な演算を、凸性を保ったままなめらかに置き換える(smoothing)」は現代最適化の常套手段で、log-sum-exp はその教科書第1号です。

解 12.9 ★★★ 強凸性 — 凸性に「底の硬さ」を足す

解答

(1) x^2 の2階微分は 2 なので、最大の強凸定数は 2。一方、 $(e^x)'' = e^x$ は正だが $x \rightarrow -\infty$ で 0 に近づくため、正の一樣な下限を持たず強凸ではない。

(2) 2乗損失を L_0 とすると

$$\nabla^2 L_\lambda = \nabla^2 L_0 + 2\lambda I.$$

$\nabla^2 L_0 \succeq 0$ だから、 $\lambda > 0$ では $\nabla^2 L_\lambda \succeq 2\lambda I$ で、 2λ -強凸である。 $\lambda = 0$ では、もとの設計行列が退化していれば強凸性も一意性も保証されない。

(3) $g(\mathbf{x}) = f(\mathbf{x}) - \mu \|\mathbf{x}\|^2/2$ に凸関数の1階条件を適用し、 $\nabla f(\mathbf{x}^*) = 0$ を使って整理すると

$$f(\mathbf{y}) \geq f(\mathbf{x}^*) + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}^*\|^2.$$

$\mathbf{y} \neq \mathbf{x}^*$ なら右辺の第2項は正なので、最小点は一意である。

ポイント

正しい包含関係は「強凸 $\subset$ 狭義凸 $\subset$ 凸」です。逆向きの含意は一般には成り立ちません。

第13章

勾配降下法 — 解答解説

最急降下の力学と収束理論

解 13.1 ★ 更新式を手で回す

方針

$\nabla f = (2x, 4y)$ を評価して引くだけ。手計算の感触が後の理論の土台になる。

解答

$\nabla f(1, 1) = (2, 4)$ より

$$\boldsymbol{x}_1 = (1, 1) - 0.1 (2, 4) = (0.8, 0.6)$$

$\nabla f(0.8, 0.6) = (1.6, 2.4)$ より

$$\boldsymbol{x}_2 = (0.8, 0.6) - 0.1 (1.6, 2.4) = (0.64, 0.36)$$

値は $f(\boldsymbol{x}_0) = 3$ 、 $f(\boldsymbol{x}_1) = 0.64 + 0.72 = 1.36$ 、 $f(\boldsymbol{x}_2) = 0.4096 + 0.2592$
 $= 0.6688$ — 確かに単調減少している。

ポイント

係数の大きい y 方向(勾配成分 $4 > 2$)が最初は速く減る一方、更新係数を見ると x は毎歩 0.8 倍、 y は 0.6 倍 — 「感度の高い方向から先に片づく」構造がすでに顔を出しています。数歩の手計算は、実装のバグ(符号ミス・学習率の掛け忘れ)を見つける最強の単体テストでもあります。

解 13.2 ★ 1次元2次関数 — 完全に解ける場合

解答

$f'(x) = ax$ だから $x_{k+1} = (1 - \eta a)x_k$ 、従って $x_k = (1 - \eta a)^k x_0$ 。

$x_0 \neq 0$ のとき収束の必要十分条件は $|1 - \eta a| < 1$ 、すなわち $0 < \eta < 2/a$ 。係数が正なら単調に、負なら符号を交互に変えて収束する。

$\eta = 1/a$ では係数が 0 なので1歩で解に着く。 $\eta = 2/a$ では係数が -1 で、 $x_0 \neq 0$ なら振動して収束しない。 $\eta > 2/a$ では係数の絶対値が 1 より大きく発散する。

解 13.3 ★★ 異方性とジグザグ — 条件数の呪い

方針

対角的な2次関数では各座標が独立の1次元問題(問13.2)に分離する。共通の η を両方の曲率(1 と 9)が取り合う綱引きが本質。

解答

(1) $\nabla f = (x, 9y)$ なので更新は成分ごとに $x_{k+1} = (1 - \eta)x_k$ 、 $y_{k+1} = (1 - 9\eta)y_k$ 。収束条件は両方の公比が絶対値 1 未満: $|1 - \eta| < 1$ かつ $|1 - 9\eta| < 1$ 、すなわち $0 < \eta < \frac{2}{9}$ (厳しい方 = 大きい曲率が支配)。

(2) $|1 - \eta|$ は η の増加とともに減り、 $|1 - 9\eta|$ は ($\eta > \frac{1}{9}$ で) 増える。最小はつり合う点: $1 - \eta = 9\eta - 1$ 、すなわち

$$\eta^* = \frac{2}{1+9} = \frac{2}{\mu+L} = 0.2, \quad \rho^* = |1 - \eta^*| = 0.8 = \frac{9-1}{9+1} = \frac{\kappa-1}{\kappa+1}$$

(3) 実測(検証済み): $(1, 1) \rightarrow (0.8, -0.8) \rightarrow (0.64, 0.64) \rightarrow (0.512, -0.512)$ 。距離は毎歩ちょうど 0.8 倍。 y の公比は $1 - 9\eta^* = -0.8$ と負なので、 y 座標は谷($y = 0$)を毎歩飛び越えて符号反転する — 等高線図で見ると、細長い楕円の谷を左右に横切りながら進むジグザグ軌道になる。急な方向(y)は「飛び越えすれすれ」、緩い方向(x)は「もどかしいすり足」 — 共通の η が両者の板挟みになった姿である。

ポイント

レート $\frac{\kappa-1}{\kappa+1}$ は $\kappa = 1$ (等方的な円い谷)で 0(1歩で到達)、 $\kappa \rightarrow \infty$ で 1(進まない)。勾配降下法の速度は関数の「細長さ」で決まる — 第8章で条件数を「地形の測量値」として導入した回収がここです。特徴量の標準化が学習を速くするのは、 κ を下げて谷を丸くする操作だから、という実務直結の結論も出ます。

解 13.4 ★★ 降下補題 — 1歩でどれだけ下がるか

方針

「値の増分 = 勾配の線積分」(微積分学の基本定理+連鎖律)に、勾配のリプシッツ性を流し込む。第5章の道具がそのまま最適化理論の証明部品になる。

解答

(1) $\varphi(t) = f(\mathbf{x} + t\mathbf{d})$ ($\mathbf{d} = \mathbf{y} - \mathbf{x}$)とおくと、連鎖律より $\varphi'(t) = \nabla f(\mathbf{x} + t\mathbf{d})^\top \mathbf{d}$ 。微積分学の基本定理で

$$f(\mathbf{y}) - f(\mathbf{x}) = \varphi(1) - \varphi(0) = \int_0^1 \nabla f(\mathbf{x} + t\mathbf{d})^\top \mathbf{d} dt$$

両辺から $\nabla f(\mathbf{x})^\top \mathbf{d} = \int_0^1 \nabla f(\mathbf{x})^\top \mathbf{d} dt$ を引くと問題文の等式を得る。右辺の被積分関数をコーシー・シュワルツと L -平滑性で評価:

$$\left(\nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x})\right)^\top \mathbf{d} \leq \|\nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x})\| \|\mathbf{d}\| \leq L t \|\mathbf{d}\|^2$$

よって

$$f(\mathbf{y}) - f(\mathbf{x}) - \nabla f(\mathbf{x})^\top \mathbf{d} \leq \int_0^1 L t \|\mathbf{d}\|^2 dt = \frac{L}{2} \|\mathbf{d}\|^2$$

(証明終)

(2) $\mathbf{d} = -\eta \nabla f(\mathbf{x})$ を代入すると $\nabla f^\top \mathbf{d} = -\eta \|\nabla f\|^2$ 、 $\|\mathbf{d}\|^2 = \eta^2 \|\nabla f\|^2$ なので

$$\begin{aligned} f(\mathbf{x}_{k+1}) &\leq f(\mathbf{x}_k) - \eta \|\nabla f(\mathbf{x}_k)\|^2 + \frac{L\eta^2}{2} \|\nabla f(\mathbf{x}_k)\|^2 \\ &= f(\mathbf{x}_k) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(\mathbf{x}_k)\|^2 \end{aligned}$$

$\eta = \frac{1}{L}$ なら係数は $\frac{1}{L} \left(1 - \frac{1}{2}\right) = \frac{1}{2L}$: $f(\mathbf{x}_{k+1}) \leq f(\mathbf{x}_k) - \frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2$ 。

(3) $f = \frac{a}{2}x^2, f' = ax (L = a)$: $f(y) - f(x) - f'(x)(y - x) = \frac{a}{2}(y^2 - x^2) - ax(y - x) = \frac{a}{2}(y - x)^2$ — 上界 $\frac{L}{2}(y - x)^2$ と厳密に一致(等号)。2次関数は降下補題の「最悪ケースを常に実現する」関数である。

ポイント

降下補題は「 L -平滑関数は、各点で上から放物線(曲率 L)で押さえられる」と読めます — 凸性の1階条件(接線が下から支える: 問12.4)と対をなす挟み撃ちです。勾配降下の1歩は「この上側放物線の最小化」にほかならず($\eta = \frac{1}{L}$ がその放物線の底)、だから確実に $\frac{1}{2L} \|\nabla f\|^2$ 以上下がる。「勾配が大きいうちは大きく下がり、下がらなくなったら勾配が小さい」 — 次問の収束保証の心臓部です。

解 13.5 ★★ 凸性なしで言えること — 勾配ノルムの収束

方針

1歩の減少量を全歩ぶん足すと左辺が望遠鏡式に潰れる — 問5.8(和の評価)と同じ「足して構造を出す」型。

解答

(1) 問13.4(2) を移項した $\frac{1}{2L} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})$ を $k = 0, \dots, K-1$ で足すと、右辺は隣どうしが打ち消し合って(望遠鏡和)

$$\frac{1}{2L} \sum_{k=0}^{K-1} \|\nabla f(\mathbf{x}_k)\|^2 \leq f(\mathbf{x}_0) - f(\mathbf{x}_K) \leq f(\mathbf{x}_0) - f^*$$

(最後は $f(\mathbf{x}_K) \geq f^*$ 。)

(2) 和の中の最小項は平均以下だから

$$\min_{0 \leq k < K} \|\nabla f(\mathbf{x}_k)\|^2 \leq \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(\mathbf{x}_k)\|^2 \leq \frac{2L(f(\mathbf{x}_0) - f^*)}{K}$$

すなわち K 歩あれば勾配ノルムを $O(1/\sqrt{K})$ まで小さくできる — 凸性ゼロの仮定でこの保証が出る。ただし得られるのは「勾配の小さい点(停留点の近く)」であって、それが極小か鞍点か(第9章)、ましてや大域的最小かは何も言えない — 非凸最適化の理論保証は原理的に「1次の停留性」止まりであり、深層学習で「学習が収束した = 最良のモデル」とは限らない理由の一端がここにある。

ポイント

この定理は深層学習の収束解析の出発点そのもので、SGD 版(勾配にノイズが乗る場合)や適応学習率版など、現代の収束証明はほぼすべて「降下補題 → 望遠鏡和」という同じ骨格の変奏です。証明の部品は微積分学の基本定理・コーシー・シュワルツ・望遠鏡和だけ — 第I・II部で積んだ基礎がそのまま最前線の道具であることを実感してください。

解 13.6 ★★ 強凸なら直線的に速い — 線形収束

方針

2次関数では固有成分ごとの等比数列なので、収束レートを厳密に計算して一般理論の予言と突き合わせる。

解答

(1) $\eta = \frac{1}{9}$ のとき、座標ごとの係数は $1 - \frac{1}{9} = \frac{8}{9}(x)$ と $1 - \frac{9}{9} = 0(y)$ 。値は $f(\mathbf{x}_k) = \frac{1}{2}x_k^2 + \frac{9}{2}y_k^2$ で、各項がそれぞれ $(\frac{8}{9})^2 = \frac{64}{81}$ 倍・0 倍になるから

$$f(\mathbf{x}_{k+1}) = \left(\frac{8}{9}\right)^2 \cdot \frac{1}{2}x_k^2 + 0 \leq \frac{8}{9} \left(\frac{1}{2}x_k^2 + \frac{9}{2}y_k^2\right) = \left(1 - \frac{\mu}{L}\right) f(\mathbf{x}_k)$$

($(\frac{8}{9})^2 \leq \frac{8}{9}$ を使った。) よって $f(\mathbf{x}_k) \leq (\frac{8}{9})^k f(\mathbf{x}_0)$ — 幾何級数的(線形)収束。

(2) 問13.3(3) の実測で、距離の比は毎歩ちょうど $0.8 = \frac{\kappa-1}{\kappa+1}$ だった(両座標の係数がともに絶対値 0.8 なので、この2次関数では上界が毎歩等号で達成される)。一般の μ -強凸・ L -平滑関数でも $\eta = \frac{2}{\mu+L}$ で $\|\mathbf{x}_k - \mathbf{x}^*\| \leq \left(\frac{\kappa-1}{\kappa+1}\right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|$ が成り立つ(2次関数はその最悪ケース)。

(3) $0.8^k \leq 10^{-6} \iff k \geq \frac{6 \log 10}{\log(1/0.8)} = \frac{13.816}{0.2231} \approx 62$ 歩。一般に必要な歩数は $\frac{\log(1/\varepsilon)}{\log \frac{\kappa+1}{\kappa-1}}$ で、 κ が大きいとき $\log \frac{\kappa+1}{\kappa-1} = \log\left(1 + \frac{2}{\kappa-1}\right) \approx \frac{2}{\kappa}$ (問4.2の $\log(1+x) \approx x$) だから、歩数 $\approx \frac{\kappa}{2} \log \frac{1}{\varepsilon} = O\left(\kappa \log \frac{1}{\varepsilon}\right)$ — 条件数に比例して遅くなる。

ポイント

「線形収束」という名前は紛らわしいですが、誤差が指数関数的に減る(片対数プロットで直線)という意味の業界用語です。歩数の κ 比例則は、問13.8のローゼンブロック($\kappa \approx 2500$)

での苦戦、そして前処理・正規化・二次手法(第14章)の存在意義を1行で説明します。テイラー近似 $\log(1+x) \approx x$ が収束理論の歩数見積りに直結する — 第4章の再利用です。

解 13.7 ★★ 学習率を上げすぎると

解答

$\eta = 0.25 > 2/9$ 。 y の係数は -1.25 なので、 $y_k = (-1.25)^k$ と振動発散し、 $|y_6| = 1.25^6 \approx 3.815$ 。一方、 $x_k = 0.75^k$ は収束する。

バックトラッキングは十分減少条件を満たすまで試行ステップを縮小する。 L -平滑なら十分小さいステップで必ず受理される。ただし「受理値が必ず $1/(2L)$ 以上」という下限には、初期試行値が $1/L$ より大きく、一定比で縮小するなどの条件が必要である。最初から非常に小さい値を試せば、そのまま受理され得る。

解 13.8 ★★★ ローゼンブロックの谷での苦闘

解答

(1) 急な横断方向では初期に損失が大きく下がるが、谷底に入ると曲率の小さい接線方向だけが残し、共通の小さな学習率では進行が遅くなる。

(2) $\kappa \approx 2508$ なら最適固定ステップの率は $(\kappa - 1)/(\kappa + 1) \approx 0.9992$ で、1桁に約 2900 歩。これは $\eta \approx 2/(\mu + L) \approx 0.001996$ のベンチマークである。実際の $\eta = 0.001$ では緩い固有方向の率は $1 - 0.001\mu \approx 0.9996006$ で、1桁に約 5760 歩となる。5000歩後にも距離 0.133890 が残ることと整合する。

(3) 急な方向の安定条件はおおよそ $\eta < 2/1000 = 0.002$ 。このため緩い方向に合わせて共通学習率を大きくできない。前処理、座標別ステップ、モメンタム、準ニュートン法やニュートン

ン法が打開策となる。

解 13.9 ★★★ モメンタム — 正定値2次関数での加速

解答

固有値 1 の方向では特性方程式が $r^2 - r + 1/4 = (r - 1/2)^2$ 、固有値 9 の方向では $r^2 + r + 1/4 = (r + 1/2)^2$ 。初期条件から

$$x_k = (1 + k/2)2^{-k}, \quad y_k = (1 + 3k/2)(-2)^{-k}.$$

したがって指数部分の漸近率は 0.5 だが、重根による一次の多項式因子が付く。有限歩の誤差を単純に 0.5^k と置くことはできない。

$k = 60$ では距離は 8.338×10^{-17} 。素の勾配降下法では $\sqrt{2} \cdot 0.8^{60} = 2.167 \times 10^{-6}$ 。60歩目付近の距離比は約 0.508 で、漸近率 0.5 に近づく。

この $\sqrt{\kappa}$ 依存の改善は、ここで扱う正定値2次関数と適切なパラメータのもとでの結論である。一般の滑らかな凸関数には加速勾配法の別の保証があり、任意の非凸問題に同じ保証がそのまま成立するわけではない。

第14章

ニュートン法 — 解答解説

曲率を使って一気に踏み込む

解 14.1 ★ $\sqrt{2}$ を手で求める

方針

「接線が x 軸と交わる点へ移る」を式にするだけ。分数のまま計算すると収束の速さが桁の伸びで見える。

解答

(1) $g(x) = x^2 - 2, g'(x) = 2x$ より

$$x_{k+1} = x_k - \frac{x_k^2 - 2}{2x_k} = \frac{x_k}{2} + \frac{1}{x_k}$$

(2) $x_0 = 1$ から:

$$\begin{aligned} x_1 &= \frac{1}{2} + 1 = \frac{3}{2}, & x_2 &= \frac{3}{4} + \frac{2}{3} = \frac{17}{12}, \\ x_3 &= \frac{17}{24} + \frac{12}{17} = \frac{289 + 288}{408} = \frac{577}{408} \end{aligned}$$

$x_3 = 1.414215\dots$ で、 $\sqrt{2} = 1.4142135\dots$ との差は約 2.1×10^{-6} — たった3歩で6桁が合った。

ポイント

この更新式は「現在の見積もり x と、割り算で得た $2/x$ の平均をとる」— 古代バビロニアの開平法として知られ、いまでも数値ライブラリの平方根計算の骨格です。誤差の推移 0.41

→ 0.086 → 0.0025 → 0.0000021 を眺めると、正しい桁数がほぼ倍々に増えている:これが次問以降で証明する**2次収束**の手触りです。

解 14.2 ★ 最適化版の1歩 — 除算のいらぬ逆数計算

方針

最適化のニュートン法は「 $f' = 0$ に方程式版を適用」。分母の $f'' = 1/x^2$ が逆数なので、割り算が掛け算に化ける。

解答

(1) $f'(x) = 1 - \frac{1}{x}$ 、 $f''(x) = \frac{1}{x^2}$ 。更新式は

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} = x_k - \left(1 - \frac{1}{x_k}\right)x_k^2 = x_k - x_k^2 + x_k = 2x_k - x_k^2$$

— 加減算と乗算だけで、割り算が消えた。

(2) $x_0 = 0.5$ から:

$$0.75 \rightarrow 0.9375 \rightarrow 0.99609375 \rightarrow 0.9999847412109375$$

(3) $e_k = 1 - x_k$ とおくと

$$e_{k+1} = 1 - (2x_k - x_k^2) = (1 - x_k)^2 = e_k^2$$

— 近似ではなく**厳密な恒等式**である。実際 $e_0 = \frac{1}{2}$ から $e_k = (1/2)^{2^k}$: $0.25 \rightarrow 0.0625 \rightarrow 0.0039 \rightarrow 0.0000153$ で、(2) の数値(小数部の 9 の個数が $1 \rightarrow 2 \rightarrow 4 \rightarrow$ 約 8 個)と完全に整合する。

ポイント

一般化すると「 $1/a$ を求める」更新は $x_{k+1} = x_k(2 - ax_k)$ — 除算命令を使わずに逆数を計算するこの反復は、CPU/GPU の除算・平方根ユニットや任意精度演算ライブラリで実際に使われている現役のアルゴリズムです(初期値をテーブル参照で数桁当てておき、2~3回反復して倍精度に到達させる)。「最適化のニュートン法」が「ハードウェアの割り算」とつながる — 情報系ならではの景色です。

解 14.3 ★★ 2次収束の証明

方針

更新後の誤差を過大に平方完成 — 実は展開一発で厳密な恒等式が出る、気持ちのよい計算。

解答

(1) 更新式 $x_{k+1} = \frac{x_k}{2} + \frac{1}{x_k} = \frac{x_k^2 + 2}{2x_k}$ から

$$x_{k+1} - \sqrt{2} = \frac{x_k^2 + 2 - 2\sqrt{2}x_k}{2x_k} = \frac{(x_k - \sqrt{2})^2}{2x_k}$$

(証明終)。誤差は毎歩「2乗して $2x_k$ で割った」値になる — 符号は常に正(1歩目以降は必ず $\sqrt{2}$ の上側から近づく)ことも読み取れる。一般の g では、 g を根 x^* のまわりでテイラー展開して同様に $e_{k+1} \approx \frac{g''(x^*)}{2g'(x^*)} e_k^2$ 。分母に $g'(x^*)$ が現れるため、単根($g'(x^*) \neq 0$)という仮定が効いている(破れると問14.5(1))。

(2) 実測の誤差 $e_0 \approx 0.4142$ 、 $e_1 \approx 0.0858$ 、 $e_2 \approx 0.00245$ 、 $e_3 \approx 2.1 \times 10^{-6}$ から

$$\frac{e_1}{e_0^2} \approx 0.500, \quad \frac{e_2}{e_1^2} \approx 0.333, \quad \frac{e_3}{e_2^2} \approx 0.354$$

— (1) の係数 $\frac{1}{2x_k} \rightarrow \frac{1}{2\sqrt{2}} = 0.3536$ に収束していく様子が見える。

(3) $e_k = 10^{-d}$ (正しい小数が約 d 桁) なら $e_{k+1} \approx Ce_k^2 = C \cdot 10^{-2d}$: 定数 C の影響は 1 桁未満なので、**正しい桁数がほぼ倍増**する。1 桁 $\rightarrow 2 \rightarrow 4 \rightarrow 8 \rightarrow 16$ 桁 — 適当な初期値から倍精度(約16桁)までわずか**4~5歩**。歩数が $\log \log(1/\varepsilon)$ でしか増えない、事実上「定数歩」のアルゴリズムである。

ポイント

収束スピードの語彙を整理しておきましょう:**線形収束**(勾配降下法: 誤差が毎歩 ρ 倍、桁数が毎歩一定量ずつ増える) vs **2次収束**(ニュートン法: 桁数が毎歩倍増)。片対数プロットで前者は直線、後者は下に折れ曲がる崖になります。ただし2次収束は「十分近く」に入ってからの話 — 遠方の挙動は無保証(問14.5・14.7)という条件付きの無敵です。

解 14.4 ★★ 多変数ニュートン法 — 問8.6の完結

解答

$(5/6, 0)$ では勾配が $(17/54, 0)$ 、ヘッセ行列が $\text{diag}(25/3, 2)$ 。従って方向は $(-17/450, 0)$ 、2歩目は $(179/225, 0)$ 。

$2^{-1/3} \approx 0.793701$ に対し、誤差は約 0.03963 から 0.001855 へ下がり、比 $e_2/e_1^2 \approx 1.18$ で2次収束の局所挙動と整合する。

密なヘッセ行列を明示的に扱う直接法では、保存が $O(n^2)$ 、一般の密な連立方程式が $O(n^3)$ 。これは最悪時の密行列モデルであり、疎性や特殊構造、反復解法、ヘッセベクトル積を使う手法にはそのまま当てはまらない。

解 14.5 ★★ 失敗モードのカatalog

方針

どの反例も1～2行の計算で確かめられる。壊れた仮定を特定するところまでがワンセット。

解答

(1) $g = x^3, g' = 3x^2$ より

$$x_{k+1} = x_k - \frac{x_k^3}{3x_k^2} = \frac{2}{3}x_k$$

— 公比 $\frac{2}{3}$ の等比数列で、収束はするが**線形**(勾配降下法と同格)に退化する。破れた仮定は**単根性**: $x^* = 0$ は3重根で $g'(x^*) = 0$ 、2次収束の誤差係数 $\frac{g''}{2g'}$ の分母が消えている(接線がほぼ水平になり、1歩で根を捉えきれない)。

(2) $g(x) = x^3 - 2x + 2, g'(x) = 3x^2 - 2, x_0 = 0: x_1 = 0 - \frac{2}{-2} = 1, x_1 = 1: g(1) = 1, g'(1) = 1$ で $x_2 = 1 - 1 = 0$ 。以後 $0 \rightarrow 1 \rightarrow 0 \rightarrow 1 \rightarrow \dots$ の2周期を永久に往復し、実根($x \approx -1.77$)には決して到達しない。初期値がこの周期の「吸引域」に入ると脱出できない — ニュートン法の大域挙動は初期値に敏感で、複素平面で見ると吸引域はフラクタル(ニュートン・フラクタル)になることで有名。

(3) $f = -x^2: f' = -2x, f'' = -2$ で

$$x_{k+1} = x_k - \frac{-2x_k}{-2} = x_k - x_k = 0$$

— どこから出発しても1歩で $x = 0$ 、すなわち**最大点**に着地する。ニュートン法が本質的に解いているのは方程式 $\nabla f = \mathbf{0}$ (停留条件)であり、これは最小点・最大点・鞍点(第9章)が等しく満たす**1次の条件**にすぎない。ヘッセ行列の符号(2次の情報)を「歩幅の換算」にしか使わず「向きの検査」に使っていないため、最小と最大を区別できないのである。

ポイント

3つの失敗はそれぞれ処方箋があります:(1) 重根 → 更新を m 倍する(重複度既知のとき)か減速を検知して切替、(2) 周期・発散 → 直線探索や信頼領域で歩幅を制御(問14.7)、(3) 鞍点・最大点行き → ヘッセ修正で降下方向を強制(問14.6)。「**純粋ニュートン法は理論の骨格、実用コードは必ず安全装置つき**」 — `scipy.optimize.minimize` の Newton-CG や `trust-ncg` が単純な更新式の何倍ものコードを持つ理由です。

解 14.6 ★★ ヘッセ修正 — 鞍点行きを阻止する

解答

$(1, 1)$ で $\mathbf{g} = (2, -2)$ 、 $H = \text{diag}(2, -2)$ 。純粋ニュートン方向は $(-1, -1)$ で、内積は 0、行き先は鞍点の原点である。

$H + 3I = \text{diag}(5, 1)$ は正定値で、修正方向は $(-2/5, 2)$ 。勾配との内積は -4.8 で、実際に目的値は 0 から -8.64 へ下がる。

$H + \lambda I$ が正定値で、かつ $\mathbf{g} \neq 0$ なら、修正方向は厳密な降下方向となる。これは減衰ニュートン法の基本的な考え方である。非線形最小二乗におけるレーベンバーグ・マーカート法は近縁だが、通常はヤコビ行列から作るガウス・ニュートン行列を減衰させる手法であり、任意のヘッセ修正と同一ではない。

解 14.7 ★★★ ローゼンブロック7歩踏破

解答

純粋ニュートン法は2歩目で $f \approx 1411.845$ まで一時悪化するが、5歩目で約 1.85×10^{-11} 、6歩目で約 3.43×10^{-20} 、7歩目で倍精度上の $(1, 1)$ に到達する。

遠方では2次モデルが不正確で、純粋ニュートン法は目的値の単調減少を保証しない。直線探索や信頼領域法で大域化するのが標準的である。

密な直接法では1歩が高価だが、実際のコストはヘッセ行列の疎性・構造、線形ソルバー、要求精度に依存する。歩数だけでなく総計算量で比較する。

解 14.8 ★★★ ロジスティック回帰をニュートン法で解く

解答

各項の2階微分は $x_i^2 \sigma(y_i w x_i) (1 - \sigma(y_i w x_i))$ で非負である。少なくとも1つの x_i が非零なら、有限の w で総和は正になる。

分離可能な3点では損失は単調減少して 0 に近づくが有限の w では達成しない。 $L(10) = 9.07999 \times 10^{-5}$ 。

非分離データでは $w_1 = 6/7$ となり、反復は $w^* = 1.0457268824$ 、 $L^* = 2.06568613$ に収束する。標準的なロジスティック回帰では、ニュートン更新は重みつき最小二乗を反復する IRLS の形に書ける。

第15章

等式制約とラグランジュ乗数 — 解答解説

制約の上での最適化と、勾配の平行条件

解 15.1 ★ 代入法とラグランジュ法の顔合わせ

方針

同じ答えを2つの道で。ラグランジュ法は「連立を立てて解くだけ」の機械的手順であることを体感する。

解答

(1) $y = 10 - x$ を代入して $h(x) = x(10 - x) = 10x - x^2$ 。 $h'(x) = 10 - 2x = 0$ より $x = 5$ 、 $h'' = -2 < 0$ で最大。よって $x = y = 5$ 、最大値 25。

(2) $\nabla f = (y, x)$ 、 $\nabla g = (1, 1)$ 。条件 $\nabla f = \lambda \nabla g$ と制約を連立:

$$y = \lambda, \quad x = \lambda, \quad x + y = 10$$

前2式から $x = y$ 、制約から $x = y = 5$ 、 $\lambda = 5$ 。最大値 $xy = 25$ — 代入法と完全に一致する。

ポイント

「 $x = y$ で最大」は正方形が同周長の長方形の中で面積最大、という古典の再演です。 $\lambda = 5$ の意味は問15.4で回収します(周長を1増やすと面積が約5増える、の「5」)。代入法は変数が消せるとき最速・ラグランジュ法は消せないとき(制約が複雑・変数が多い)の汎用路線 — 両刀を持ち、可能なら両方で解いて検算するのが本書流です。

解 15.2 ★★ 等高線の接触 — 問7.7の伏線回収

方針

計算は連立3本。主役は (2)(3) の幾何 — ラグランジュ条件の「なぜ」を等高線の絵で腹落ちさせる。

解答

(1) $\nabla f = (1, 1)$ 、 $\nabla g = (2x, 2y)$ より連立

$$1 = 2\lambda x, \quad 1 = 2\lambda y, \quad x^2 + y^2 = 1$$

前2式から $x = y = \frac{1}{2\lambda}$ 。制約に入れて $\frac{2}{4\lambda^2} = 1$ 、 $\lambda = \pm \frac{1}{\sqrt{2}}$ 。停留点は $\pm \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right)$ の2つで、 f の値は $\pm \sqrt{2}$ 。円周は有界閉集合なので最大・最小は存在し (ワイエルシュトラス)、候補の比較から **最大** $\sqrt{2}$ (点 $\frac{1}{\sqrt{2}}(1, 1)$)、**最小** $-\sqrt{2}$ (点 $-\frac{1}{\sqrt{2}}(1, 1)$)。

(2) f の等高線は傾き -1 の平行な直線群 $x + y = c$ 。 c を増やしながらか平行移動すると、円と交わる最後の瞬間 — $c = \sqrt{2}$ — に直線は円に**接する**。問7.7より、 ∇f は f の等高線に垂直、 ∇g は制約曲線(g の等高線)に垂直。接触点では2つの曲線が共通の接線を持つ → 垂直方向も共通 → ∇f と ∇g は**平行** — これが $\nabla f = \lambda \nabla g$ の幾何的な正体である。

(3) もし最適点で等高線が制約曲線を横切っていたら、その点の近くで制約曲線は等高線の「 c が大きい側」と「小さい側」の両方に足を踏み入れている。つまり制約を守ったまま少し動くだけで f を増やすことも減らすこともできる — その点は最大でも最小でもありえない。対偶をとれば「最適点では横切れない = 接するしかない」：これがラグランジュ条件(1次の必要条件)の直感的証明である。

ポイント

「等高線を c の増える向きに押していき、実行可能集合と触れ合う最後の位置が最適」— この絵は線形計画(問11.3)で頂点解が出た理由と同一で、第16章の KKT 条件でも主役を続けます。ラグランジュ乗数法は暗記する公式ではなく、問7.7(勾配 $\perp$ 等高線)から毎回その場で再導出できる幾何 — 院試の記述でこの導出を書ければ、理解の深さは十分に伝わります。

解 15.3 ★ 直線への最近点

方針

連立を解いたら、初等幾何の公式で答え合わせ。「最近点で ∇f (= 位置ベクトルの2倍) が直線の法線と平行」という絵も確認する。

解答

$\nabla f = (2x, 2y)$ 、 $\nabla g = (1, 2)$ 。連立

$$2x = \lambda, \quad 2y = 2\lambda, \quad x + 2y = 5$$

から $x = \frac{\lambda}{2}$ 、 $y = \lambda$ 。制約に代入して $\frac{\lambda}{2} + 2\lambda = 5$ 、 $\frac{5\lambda}{2} = 5$ 、 $\lambda = 2$ 。よって最近点は

$(1, 2)$ 、最短距離の2乗は $1 + 4 = 5$ 、距離は $\sqrt{5}$ 。検算: 点と直線の距離の公式で $d = \frac{|0 + 2 \cdot 0 - 5|}{\sqrt{1^2 + 2^2}} = \frac{5}{\sqrt{5}} = \sqrt{5}$ — 一致。(なお最近点 $(1, 2)$ は法線ベクトル $(1, 2)$ の方向にあり、「原点から直線へ下ろした垂線の足」という初等幾何の描像とも整合する。)

ポイント

「距離の最小化 = 垂線」は射影の理論(『線形代数』の正射影・最小二乗)とラグランジュ法が同じ答えに合流する交差点です。距離そのものでなく2乗を最小化したのは、平方根の微分を避けて計算を軽くする定石(単調変換は argmin を変えない: 問11.2)。この小技は最小二乗法の「二乗」の理由の1つでもあります。

解 15.4 ★★ 乗数の正体 — 感度・シャドープライス

解答

停留条件から $2x - \lambda = 0, 2y - 2\lambda = 0$ 。制約と合わせて $x = c/5, y = 2c/5, \lambda = 2c/5$ 。

従って $V(c) = c^2/5$ で、 $V'(c) = 2c/5 = \lambda(c)$ 。

これは $\mathcal{L} = f + \lambda(c - x - 2y)$ という符号規約での式である。本例で $c > 0$ を増やすと直線が原点から遠ざかり、最小距離の2乗は増える。「資源を増やして目的が改善する」という説明は、資源制約の向きと最大化・最小化の設定を別途確認して初めて使える。

解 15.5 ★★ 複数の候補を仕分ける

方針

連立の解を「全部」出す(取りこぼしが最頻出ミス)。存在保証+候補比較で締め、不等式の別解でダブルチェック。

解答

(1) $\nabla f = (y, x), \nabla g = (2x, 2y)$ より

$$y = 2\lambda x, \quad x = 2\lambda y, \quad x^2 + y^2 = 2$$

第1式を第2式に代入: $x = 4\lambda^2 x$ 。 $x = 0$ とすると第1式から $y = 0$ となり制約に反するので $x \neq 0$ 、よって $\lambda^2 = \frac{1}{4}$ 、 $\lambda = \pm \frac{1}{2}$ 。
 $\lambda = \frac{1}{2}$: $y = x$ 、制約から $2x^2 = 2$ 、 $(1, 1)$ と $(-1, -1)$ (ともに $f = 1$)。
 $\lambda = -\frac{1}{2}$: $y = -x$ から $(1, -1)$ と $(-1, 1)$ (ともに $f = -1$)。候補4点の値は $1, 1, -1, -1$ 。

(2) 円周は有界閉集合、 f は連続なので最大・最小は必ず存在する(ワイエルシュトラス)。最適点は必ずラグランジュ条件を満たす(必要条件)から、存在する最大・最小は候補4点のどれかで達成されるしかない。よって**最大値** $1(\pm(1, 1))$ 、**最小値** $-1(\pm(1, -1))$ と確定する。

(3) $(x - y)^2 \geq 0$ を開いて $xy \leq \frac{x^2 + y^2}{2}$ 。円上では右辺 $= 1$ なので $xy \leq 1$ 、等号は $x = y$ のとき — 制約と合わせて $(\pm 1, \pm 1)$ (同符号)、ラグランジュ法の最大点と一致する(最小側は $(x + y)^2 \geq 0$ から $xy \geq -1$ 、等号 $x = -y$)。下界・上界が達成されるので値も確定 — 不等式法(問11.7)による独立検算が成立した。

ポイント

径数表示 $x = \sqrt{2} \cos \theta, y = \sqrt{2} \sin \theta$ なら $xy = \sin 2\theta$ — 第3の解法でも $[-1, 1]$ が即出ます。1つの問題を連立(ラグランジュ)・不等式・径数表示の3路線で解いて一致させる: 答えの信頼性が上がるだけでなく、各方法の得手不得手(汎用性 vs 大域保証 vs 具体性)が体で分かります。 $\lambda = \pm \frac{1}{2}$ が「最大側と最小側で符号が変わる」ことにも注目 — 感度(問15.4)の符号として自然な現象です。

解 15.6 ★★ 最大エントロピー分布

方針

停留条件が「 $-\log p_i$ が全部同じ値」— 対称性が答え(一様分布)を強制する構図を見る。最大性は凹性(第12章)で締める。

解答

(1) $\frac{\partial \mathcal{L}}{\partial p_i} = -\log p_i - 1 + \lambda = 0$ より $\log p_i = \lambda - 1$ 、すなわち

$$p_i = e^{\lambda-1} \quad (i = 1, 2, 3)$$

— 右辺は i によらないのですべての p_i が等しい。制約 $\sum p_i = 1$ から $p_i = \frac{1}{3}$ 。最大値は

$$H = -3 \cdot \frac{1}{3} \log \frac{1}{3} = \log 3$$

(2) 各項 $-p \log p$ の2階微分は $-\frac{1}{p} < 0$: 各項が凹なので、和 H も凹(問12.6の凸性保存則の凹版)。凹関数の(制約がアフィンな集合上での)停留点は大域的最大である(問12.7の $-f$ 版)。よって一様分布が唯一の最大点(狭義凹なので一意)。

(3) 「 $H \leq \log n$ 、等号は一様分布」の使用例: **符号化の限界** — n 記号の情報源はエントロピーが最大 $\log_2 n$ ビットで、一様なとき圧縮の余地がゼロになる(ハフマン符号・算術符号の理論限界)。ほかにも、事前知識がないときに一様事前分布を選ぶ最大エントロピー原理、分類器の予測分布を平滑化するラベルスムージングやエントロピー正則化(強化学習の探索促進)など、「わからないことは断定しない = エントロピーを高く保つ」という設計原理として遍在する。

ポイント

制約を「平均値の指定 $\sum p_i x_i = m$ 」に増やして同じ計算をすると、解は $p_i \propto e^{-\beta x_i}$ — 統計力学のボルツマン分布・機械学習の指数型分布族・ソフトマックス(問8.8)が一斉に導出されます。「**最大エントロピー+線形制約 = 指数型分布**」という1行は、情報理論・統計・物理を貫く背骨です。ここではその最初の1段(制約が正規化だけ)を厳密に登りました。

解 15.7 ★★★ 2次形式の最大最小 = 固有値 — レイリー商

方針

ラグランジュ条件を書いた瞬間に固有値方程式が出現する — 『線形代数』の主演が最適化から再導出される瞬間を味わう。

解答

(1) $f = \mathbf{x}^\top A \mathbf{x}$ (A 対称) の勾配は $\nabla f = 2A\mathbf{x}$ 、制約 $g = \|\mathbf{x}\|^2 - 1$ の勾配は $\nabla g = 2\mathbf{x}$ 。ラグランジュ条件 $\nabla f = \lambda \nabla g$ は

$$2A\mathbf{x} = 2\lambda\mathbf{x} \iff A\mathbf{x} = \lambda\mathbf{x}$$

— 停留点は A の単位固有ベクトル、乗数是对应する固有値にほかならない。さらに停留点での値は $f = \mathbf{x}^\top A \mathbf{x} = \mathbf{x}^\top (\lambda \mathbf{x}) = \lambda \|\mathbf{x}\|^2 = \lambda$: 値そのものも固有値である。

(2) $A = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$ の固有値は 9 (固有ベクトル $\propto (1, 1)$) と 1 ($\propto (1, -1)$) (問8.7)。単位化して停留点は $\pm \frac{1}{\sqrt{2}}(1, 1)$ ($f = 9$) と $\pm \frac{1}{\sqrt{2}}(1, -1)$ ($f = 1$) の4点。円周上で最大・最小は存在する(ワイエルシュトラス)ので、**最大値 9・最小値 1**。検証では単位円上の200個のランダム点で $f \in [1, 9]$ に収まることも数値確認済み。問8.7の等高線($(1, 1)$ 方向に急 = その方向で2次形式の値が大きい)とも整合する。

(3) 例: PCA (主成分分析) — データの分散共分散行列 Σ に対し、射影方向 $\mathbf{w}$ ($\|\mathbf{w}\| = 1$) での分散は $\mathbf{w}^\top \Sigma \mathbf{w}$ 。これを最大化する第1主成分は、本問の原理そのままに「 Σ の最大固有値の固有ベクトル」になる。ほかにもスペクトラルグラフ理論(グラフの分割とラプラシアン)の第2固有値)、行列ノルム $\|A\|_2 = \sqrt{\lambda_{\max}(A^\top A)}$ 、物理の振動モードなど、レイリー商は「対称行列 × 最適化」の交差点すべてに現れる。

ポイント

『線形代数』では固有値を「 $\det(A - \lambda I) = 0$ の解」として学びましたが、本問はもう1つの顔 — 「球面上の2次形式の最適化の停留値」— を与えます。この変分的な特徴づけこそ、べき乗法や Lanczos 法(勾配で固有ベクトルを探す数値解法)、そして「最適化としてのPCA」観の出発点。2冊の教科書がラグランジュ乗数という蝶番で接合される、本書屈指の合流地点です。

解 15.8

★★★

問9.7の再訪と、方法が黙る場所

方針

(1) は場合分けの練習(y の式が積の形になる)。(2) は「必要条件の前提が破れると候補リストから漏れる」ことの実地見学。

解答

(1) $\nabla f = (2x - 2, 2y)$ 、 $\nabla g = (2x, 2y)$ 。連立

$$2x - 2 = 2\lambda x, \quad 2y = 2\lambda y, \quad x^2 + y^2 = 4$$

第2式は $y(1 - \lambda) = 0$: 場合 (i) $y = 0$ — 制約から $x = \pm 2$ 。 $x = 2$ なら第1式 $2 = 4\lambda$ で $\lambda = \frac{1}{2}$ 、 $x = -2$ なら $-6 = -4\lambda$ で $\lambda = \frac{3}{2}$ (いずれも整合)。場合 (ii) $\lambda = 1$ — 第1式が $2x - 2 = 2x$ 、すなわち $-2 = 0$ で矛盾、解なし。よって境界候補は $(2, 0)$ ($f = 0$) と $(-2, 0)$ ($f = 8$) のみ — 問9.7の径数表示で得た結果と完全に一致する。内部の停留点 $(1, 0)$ ($f = -1$) と合わせ、大域的最小 -1 ($(1, 0)$)、最大 8 ($(-2, 0)$)。

(2) 曲線 $x^3 = y^2$ は (t^2, t^3) と表せ ($(t^2)^3 = (t^3)^2$)、その上で $f = x = t^2 \geq 0$: 最小値 0 は $t = 0$ 、つまり原点で達成される。ところがラグランジュ系

$$1 = 3\lambda x^2, \quad 0 = -2\lambda y, \quad x^3 = y^2$$

は、第2式から $\lambda = 0$ または $y = 0$ だが、 $\lambda = 0$ は第1式 $1 = 0$ と矛盾、 $y = 0$ は制約から $x = 0$ となりやはり第1式 $1 = 0$ と矛盾 — 実数解が存在しない(検証済み)。原点では $\nabla g = (3x^2, -2y) = (0, 0)$: 曲線が尖点(カスプ)でつぶれ、「 $\lambda \nabla g$ 」がゼロベクトルしか作れないため、 $\nabla f = (1, 0)$ をどう頑張っても表現できない。ラグランジュ条件の導出は「制約

曲線が最適点の近くでなめらかな曲線をなす」ことを $\nabla g \neq \mathbf{0}$ (陰関数定理の条件) で担保していた — その前提が崩れると、真の最適点が条件を満たさないまま候補リストから漏れる。

(3) 実務手順: 等式制約つき問題の候補リストは (i) ラグランジュ系の解、(ii) 制約上で $\nabla g = \mathbf{0}$ となる点 (正則性の破れ: 本問の原点タイプ)、(iii) 実行可能集合に境界・端点があればそれら — の和集合とし、全候補で f を評価して比較する。(i) だけで済ませるのは、(2) のような例で静かに間違える。

ポイント

(1) の場合分け「 $y(1 - \lambda) = 0$ 」型は頻出パターンで、**積 = 0 はすべての枝を検討** (片方だけ追って候補を落とすのが定番ミス)。(2) の正則性条件は、第16章の KKT 条件では「制約想定 (constraint qualification)」として一般化されます — 有名な必要条件たちには、いつも小さな前提の但し書きがある。**定理は前提込みで1セット**: 院試の証明問題でも研究でも、この習慣が事故を防ぎます。

第16章

不等式制約とKKT条件 — 解答解説

「縛られているか、いないか」を数式で判定する

解 16.1 ★ 有効か、無効か

方針

まず制約を忘れて解き、実行可能ならそれが答え(無効)。ダメなら境界に張りついて解く(有効)。相補性はその記録簿。

解答

(1) 無制約の最小点は $x = 2$ 。 $2 \leq 3$ で実行可能なので、これがそのまま答え(最小値 0)。

制約は無効: $g(2) = -1 < 0$ (内側) で、 $\mu = 0$ 。相補性 $\mu g = 0 \cdot (-1) = 0$ 成立。

(2) $x = 2$ は $2 \leq 1$ に反する。制約を有効($x = 1$)として停留性 $2(x - 2) + \mu = 0$ に $x = 1$ を代入: $-2 + \mu = 0$ 、 $\mu = 2 > 0$ 。最小値は $f(1) = 1$ 。相補性 $\mu g = 2 \cdot 0 = 0$ 成立(今度は $g = 0$ 側がゼロを担当)。

ポイント

相補性 $\mu g = 0$ は「 μ と g の少なくとも一方はゼロ」— (1) では $\mu = 0$ (制約は仕事をしていない)、(2) では $g = 0$ (制約が現場で働く)。上限を b とした値関数は $V(b) = (b - 2)^2$ ($b < 2$) なので、 $V'(1) = -2 = -\mu$ 。したがって上限 1 を $1 + \varepsilon$ に緩めると、最小値は 1 次近似で 2ε だけ減少する。乗数と感度の符号は、制約を $g = x - b \leq 0$ と書いたことに依存する。

解 16.2 ★ KKT条件を1問通して

解答

無制約最小点 $(0, 0)$ は制約 $x + y \geq 1$ を満たさないため、この点が実行不可能である。

問題全体は実行可能であり、たとえば $(1, 0)$ が制約を満たす。

$g = 1 - x - y \leq 0$ とすると、停留性から $2x - \mu = 0, 2y - \mu = 0$ 。有効制約 $x + y = 1$ と合わせて $x = y = 1/2, \mu = 1$ 。

主実行可能性、双対実行可能性、停留性、相補性をすべて満たす。目的は凸、制約はアフィンなので、この点が大域的最小点で、最小値は $1/2$ 。

解 16.3 ★★ $\mu \geq 0$ はニセ解の検出器

方針

同じ「境界に張りつける」計算を、正しい状況とニセの状況で実行し、符号だけが真偽を言い当てることを見る。

解答

(1) $x = 1$ で $f'(1) = -2$: f を下げたければ x を増やす ($x \rightarrow 2$) しかないが、それは実行可能領域 $x \leq 1$ の外。内側 (x を減らす向き) はすべて上り坂 — 境界が本当に最適を「堰き止めて」いる。停留性 $f' + \mu g' = 0$ は $-2 + \mu = 0, \mu = 2 > 0$: $-f'(1) = 2 = \mu \cdot g'(1)$ で、下りたい方向 $-\nabla f$ が外向き法線 $\nabla g = +1$ の正の倍数 — 幾何と符号が一致している。

(2) 停留性 $2(x + 2) + \mu = 0$ に $x = 1$ を代入すると $6 + \mu = 0, \mu = -6 < 0$ 。実際、 $f'(1) = 6 > 0$ だから x を減らす (内側へ入る) と f は減る — 境界に張りつく理由が

なく、真の解は内点 $x = -2$ (このとき制約は無効、 $\mu = 0$)。 $\mu < 0$ は「 $-\nabla f$ が内向き = 実行可能領域の中にまだ下り坂がある = この境界点是最適でない」というシグナルであり、KKT の符号条件はこのニセ解を機械的に棄却するフィルタとして働く。

(3) 一般化: 有効な境界解では、 f の最急降下方向 $-\nabla f$ がちょうど $\mu \nabla g (\mu \geq 0)$ — つまり **実行可能領域の外向き法線と同じ側** を向く。「これ以上下るには柵を越えるしかない」状態こそが制約つき最適性であり、 μ はその柵に押しつけられている力の大きさ(感度)である。

ポイント

等式制約(第15章)では柵の「両側」が壁なので λ の符号は問われず、不等式では片側だけが壁なので向きの検査 $\mu \geq 0$ が加わる — 2つの章の違いはこの1点に集約されます。力学のアナロジー(床の上の球: 床からの垂直抗力は押す向きにしか働かない $\mu \geq 0$ 、接しているときだけ働く $\mu g = 0$)で覚えると、KKT は「つり合いの条件」として一生忘れません。

解 16.4 ★★ 解いてみて、ダメなら境界へ

方針

手順 (i)(ii)(iii) を型どおりに。最後は初等幾何で答え合わせ。

解答

(i) 無制約最小は $(3, 2)$ 。 $3 + 2 = 5 > 2$ で実行不能 — 制約は有効。

(ii) 停留性 $\left(2(x-3), 2(y-2)\right) + \mu(1, 1) = (0, 0)$ より $2(x-3) = 2(y-2) = -\mu$ 、すなわち $x-3 = y-2$ 。 $x+y=2$ と連立して $x = \frac{3}{2}, y = \frac{1}{2}$ 。

(iii) $\mu = -2(x-3) = -2 \cdot \left(-\frac{3}{2}\right) = 3 > 0$ — 合格。最小値は

$$f\left(\frac{3}{2}, \frac{1}{2}\right) = \left(\frac{3}{2} - 3\right)^2 + \left(\frac{1}{2} - 2\right)^2 = \frac{9}{4} + \frac{9}{4} = \frac{9}{2}$$

検算:点 $(3, 2)$ と直線 $x + y - 2 = 0$ の距離は $\frac{|3 + 2 - 2|}{\sqrt{2}} = \frac{3}{\sqrt{2}}$ 、その2乗は $\frac{9}{2}$ — 一致。(凸問題なので、この KKT 点が大域的最小である。)

ポイント

この「まず自由に、ダメなら射影」は、解の構造としても正しい:凸集合への射影では、無制約最適点から実行可能集合へ最短距離で落とした点が答えになります(本問はまさに直線への射影)。停留性の式 $x - 3 = y - 2$ は「移動ベクトル $(x - 3, y - 2)$ が法線 $(1, 1)$ に平行」 — 垂線の条件が KKT から自動で出てきた、と読めます。

解 16.5 ★★ 箱制約への射影 = clip 関数

解答

$(3, -1)$ の $[0, 1]^2$ へのユークリッド射影は、各成分を区間に切り詰めた $(1, 0)$ 。KKT 乗数は上側の x 制約に 4、下側の y 制約に 2、残りは 0 となる。

軸に平行な箱では、目的と制約が座標ごとに分離するため、ベクトル射影は各成分の clip と一致する。

これは射影勾配法でパラメータを箱へ戻す操作の理論である。勾配そのものの値やノルムを切る「勾配クリッピング」や、強化学習で出力行動を切る「行動クリッピング」は別の操作・目的を持ち、同一の最適化問題とは限らない。

解 16.6 ★★ 等式と不等式の混在

方針

等式はいつでも帳簿に載せ(λ は符号自由)、不等式だけ有効/無効の判断と符号検査をする — 2種類の乗数の扱いの違いを1問で。

解答

(1) 等式だけなら問15.3型の計算で $(1, 1)$ (原点から直線 $x + y = 2$ への垂線の足)。しかし $1 \geq \frac{3}{2}$ は偽 — 不等式に反するので、この点は使えない。

(2) 不等式を有効($x = \frac{3}{2}$)として、停留条件

$$\frac{\partial \mathcal{L}}{\partial x} = 2x - \lambda - \mu = 0, \quad \frac{\partial \mathcal{L}}{\partial y} = 2y - \lambda = 0$$

と制約 $x + y = 2, x = \frac{3}{2}$ を連立する。 $x = \frac{3}{2}$ から $y = \frac{1}{2}$ 、第2式から $\lambda = 2y = 1$ 、第1式から $\mu = 2x - \lambda = 3 - 1 = 2 > 0$ — 符号検査合格。最小値は $\frac{9}{4} + \frac{1}{4} = \frac{5}{2}$ 。
(凸問題ゆえ大域的最小。)等式は「面の上から出られない」両側の壁なので、押しつけられる向きに制限がなく λ は正負どちらでもよい。不等式は片側だけの壁で、壁が支えられる力は一方向 — だから $\mu \geq 0$ の片側条件になる。

ポイント

解 $\left(\frac{3}{2}, \frac{1}{2}\right)$ は「等式の直線上を、不等式が許す端まで $(1, 1)$ に近づいた点」— 制約たちの綱引きの均衡として絵が描けます。実務のソルバー(SQP や内点法)も、内部ではまさに「等式は常時アクティブ、不等式は有効集合を推定して符号で検証」というこの手続きを高速化して回しています。手計算の型がそのままアルゴリズムの設計図です。

解 16.7 ★★★ 有効集合の総当たり — 唯一の生き残りを探す

方針

4ケースを機械的に検討。各ケースで「解けるか → 主実行可能か → 乗数の符号は」と3段の関門を通す。

解答

ケースA(両方無効、 $\mu_1 = \mu_2 = 0$):停留性は無制約条件 $\nabla f = 0$ となり $(2, 1)$ 。しかし $g_1 = 2 + 1 - 2 = 1 > 0$ — 主実行可能性違反で棄却。

ケースB(g_1 のみ有効):停留性 $(2(x - 2) + \mu_1, 2(y - 1) + \mu_1) = (0, 0)$ より $x - 2 = y - 1$ 、これと $x + y = 2$ から $x = \frac{3}{2}, y = \frac{1}{2}, \mu_1 = -2(x - 2) = 1$ 。関門検査: $y = \frac{1}{2} \geq 0$ (主実行可能)✓、 $\mu_1 = 1 \geq 0$ ✓、相補性は $\mu_1 g_1 = 1 \cdot 0 = 0, \mu_2 g_2 = 0 \cdot (-\frac{1}{2}) = 0$ ✓ — 全条件成立。

ケースC(g_2 のみ有効、 $y = 0$):停留性 $2(x - 2) = 0, 2(y - 1) - \mu_2 = 0$ より $x = 2, \mu_2 = 2(0 - 1) = -2 < 0$ — 符号違反で棄却($y = 0$ の壁から内側 $y > 0$ へ入れば f が下がる、というシグナル)。

ケースD(両方有効、 $x + y = 2$ かつ $y = 0$ 、すなわち $(2, 0)$):停留性 $2(x - 2) + \mu_1 = 0$ より $\mu_1 = 0, 2(y - 1) + \mu_1 - \mu_2 = 0$ より $\mu_2 = -2 < 0$ — 棄却。

生き残りはケースBのみ: $(\frac{3}{2}, \frac{1}{2}), f = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$ 。棄却された境界点 $(2, 0)$ の $f = 1$ より確かに小さい。目的は凸・制約はアフィンなので、KKT を満たすケースBの点は大域的最小である。

ポイント

有効集合の総当りは 2^m 通り — 小さな m なら手計算の確実な王道ですが、指数爆発するので大規模では使えません。実用ソルバーは (a) 有効集合を賢く更新しながら渡り歩く有効集合法、(b) 相補性 $\mu g = 0$ を $\mu g = \tau \rightarrow 0$ となめらかに緩めて境界を避けて進む内点法の二大路線で回避します。本問の手作業は、その両方の「1反復」を人力で体験したことに相当します。

解 16.8 ★★★ 注水定理 — 通信路への電力配分

方針

最大化を最小化(負号)に直して KKT を書けば、停留条件が「限界効用の均等化」、相補性が「水位に届かない器は空」を自動で語り出す。

解答

(1) $\min -\sum_i \log(n_i + p_i)$ s.t. $\sum p_i = P$ (乗数 λ)、 $-p_i \leq 0$ (乗数 $\mu_i \geq 0$)。停留条件:

$$-\frac{1}{n_i + p_i} + \lambda - \mu_i = 0 \quad (i = 1, 2)$$

$p_i > 0$ の通信路では相補性から $\mu_i = 0$ 、よって $\frac{1}{n_i + p_i} = \lambda$: 電力をもらっている通信路の限界効用はすべて共通で、 $n_i + p_i = \frac{1}{\lambda} = w$ (共通水位)。 $p_i = 0$ の通信路では $\mu_i = \lambda - \frac{1}{n_i} \geq 0$ 、すなわち $n_i \geq w$: 底(雑音)が水位より高い器には水が入らない。まとめて

$$p_i = \max(0, w - n_i)$$

— 底の高さ n_i の凸凹の器に、総量 P の水を注いだときの水面、という注水の絵になる(w は $\sum_i \max(0, w - n_i) = P$ から決まる)。

(2) 両方に注ぐ仮定では $(w - 1) + (w - 4) = 1$ より $w = 3$ 、しかし $p_2 = 3 - 4 = -1 < 0$ で破綻。そこで $p_2 = 0$ 、 $p_1 = P = 1$ 、水位は $w = n_1 + p_1 = 2$ 。乗数: $\lambda = \frac{1}{1+1} = \frac{1}{2}$ 、 $\mu_2 = \lambda - \frac{1}{n_2} = \frac{1}{2} - \frac{1}{4} = \frac{1}{4} \geq 0$ — KKT 成立。電力が乏しいときは全量を良い通信路へ。

(3) $P = 4$: $2w - 5 = 4$ より $w = \frac{9}{2}$ 、 $p = \left(\frac{7}{2}, \frac{1}{2}\right)$ (両方 ≥ 0 で整合)。限界効用は $\frac{1}{1+3.5} = \frac{1}{4.5} = \frac{2}{9} = \frac{1}{4+0.5}$ で共通 — 均等化が成立。1変数化 $p_2 = P - p_1$

の数値最大化でも $p_1^* = 3.5$ (検証済み、 $P = 1$ では端点 $p_1^* = 1$)。水位の絵: 水が少ない
 うち底の低い器(良い通信路)だけが濡れ、水位が悪い通信路の底 $n_2 = 4$ を越えた瞬間
 からそちらにもこぼれ始める — P に関する**閾値挙動**(本問では $w = 4$ 、すなわち $P = 3$
 が分水嶺)が、相補性の場合分けそのものとして現れている。

ポイント

注水定理は情報理論(並列ガウス通信路の容量達成配分・OFDM のビット割当て)の看板定
 理で、「KKT を書いたら物理的な絵(水)が出てきた」という理論の美しさの見本です。骨格は
限界効用の均等化 — 経済学の資源配分、機械学習の予算配分(どのデータ・どの層に計算
 を割くか)まで同じ原理が貫きます。凹目的+線形制約なので KKT は十分条件でもあり、この
 配分が大域的最適であることまで保証つき — 第12章(凹凸)・第15章(乗数)・本章(相補性)の
 三位一体の到達点です。

第17章

双対性 — 解答解説

下から支える影の問題

解 17.1 ★ 双対関数を作ってみる

方針

双対関数の計算は「乗数を定数だと思って、 x の無制約最小化を解く」だけ。出てきた q を今度は乗数の関数として最大化する — 2段の入れ子。

解答

(1) $\mathcal{L} = x^2 + \mu(1 - x)$ は x の凸2次関数。 $\frac{\partial \mathcal{L}}{\partial x} = 2x - \mu = 0$ より $x = \frac{\mu}{2}$ で最小。
代入して

$$q(\mu) = \frac{\mu^2}{4} + \mu\left(1 - \frac{\mu}{2}\right) = \mu - \frac{\mu^2}{4}$$

(2) $q'(\mu) = 1 - \frac{\mu}{2} = 0$ より $\mu^* = 2 (\geq 0 \text{ を満たす})$ 、 $d^* = q(2) = 2 - 1 = 1$ 。主問題は $x \geq 1$ で x^2 が増加だから $x^* = 1$ 、 $p^* = 1$ 。よって $p^* = d^* = 1$ — ギャップ0の強双対(目的が凸・制約がアフィンで、 $x = 2$ のような厳密実行可能点があるのでスレーター条件も成立)。

(3) 同じ主問題に KKT を直接当てると、制約は有効($x^* = 1$)で、停留性 $\nabla f + \mu \nabla g = 2x - \mu = 0$ に $x = 1$ を代入して $\mu = 2 (\geq 0 \text{ で相補性 } \mu g(x^*) = 2 \cdot 0 = 0 \text{ も成立})$ 。双対で得た $\mu^* = 2$ とぴったり一致する — 双対問題の最適解 μ^* は KKT の乗数と同

一物である。KKT では「連立の未知数」だった μ が、双対では「最大化すべき変数」に昇格した、という視点の転換がこの章の主題である。

ポイント

$q(\mu) = \mu - \frac{\mu^2}{4}$ のグラフ(上に凸の放物線)を描くと、頂点 $(2, 1)$ がちょうど p^* に触れ、それ以外の μ では下に潜っている — 「下界の族の中で一番よい下界を選ぶ」双対問題の絵がそのまま見えます。罰金 μ の読み: 小さすぎると制約破りが得(下界が緩む)、大きすぎると過剰に臆病(これも緩む)、最適な罰金率でちょうど本音の値に届く。

解 17.2 ★ 弱双対の証明 — 2行で出る不朽の不等式

方針

符号の勘定だけ: 実行可能なら $h = 0$ (消える)、 $g \leq 0$ に $\mu \geq 0$ を掛ければ ≤ 0 (罰金項は目的を下げる方向にしか働かない)。

解答

(1) $\mathbf{x}$ が実行可能なら $h_j(\mathbf{x}) = 0$ より $\lambda_j h_j = 0$ 、また $g_i(\mathbf{x}) \leq 0$ と $\mu_i \geq 0$ より $\mu_i g_i(\mathbf{x}) \leq 0$ 。よって

$$\mathcal{L}(\mathbf{x}, \lambda, \mu) = f(\mathbf{x}) + \underbrace{\sum_j \lambda_j h_j}_{=0} + \underbrace{\sum_i \mu_i g_i}_{\leq 0} \leq f(\mathbf{x})$$

(2) $q(\lambda, \mu) = \inf_{\mathbf{x}} \mathcal{L} \leq \mathcal{L}(\mathbf{x}, \lambda, \mu) \leq f(\mathbf{x})$ がすべての実行可能な $\mathbf{x}$ について成り立つので、右辺の下限をとって $q(\lambda, \mu) \leq p^*$ 。(証明終 — 本当に2行である。)

(3) $q(0) = 0, q(1) = 1 - \frac{1}{4} = \frac{3}{4}, q(3) = 3 - \frac{9}{4} = \frac{3}{4}$ — いずれも $p^* = 1$ 以下。
 μ を1つ選んで $q(\mu)$ を計算するたびに、「最適値は $q(\mu)$ 以上」という反論不能の証明書が発行される(証明書の中身は (1)(2) の2行)。

ポイント

弱双対は**無条件**で成り立つのが最大の美点です(凸性・微分可能性・正則性、何も要らない)。
 実務での使われ方: 反復ソルバーは主側の実行可能解 $f(\mathbf{x}_k)$ (上界) と双対側の $q(\mu_k)$ (下界) を同時に持ち、差(ギャップ)が ε 未満になったら「最適値まであと ε 以内」という**品質保証**つきで停止できる。問11.1(3) の「達成不能な最小を待ち続ける」問題への、理論が与えた実装解です。

解 17.3 ★★ 等式制約の双対による下界

解答

内側の最小化では $x = y = \lambda/2$ なので、 $q(\lambda) = 2\lambda - \lambda^2/2$ 。

これを最大化すると $\lambda^* = 2, d^* = 2$ 。主問題の解 $(1, 1)$ の値も 2 で強双対が成り立つ。

たとえば $q(1) = 3/2$ は主最適値の有効な下界である。

乗数を変えることで下界の族を系統的に生成し、その中で最良の証明書を選ぶのが双対最大化である。

解 17.4 ★★ 双対関数は常に凹だが、常に容易とは限らない

解答

固定した主変数に対するラグランジュ関数は乗数のアフィン関数であり、その各点下限である q は凹関数となる。

例では $\mathcal{L} = (\mu - 1)x^2 - \mu$ 。 $\mu < 1$ なら下に非有界で $q = -\infty$ 。 $\mu > 1$ なら $x = 0$ が唯一の最小点で $q = -\mu$ 。 $\mu = 1$ では $\mathcal{L} = -1$ が定数なので、すべての x が内側最小化の解である。双対最適値は -1 で主最適値と一致する。

凹性は重要な構造だが、 q の評価や劣勾配の取得が難しいことはあり得る。従って、主問題が難しいだけで下界が常に多項式時間で計算できるとは結論できない。実際に容易かどうかは、内側問題の構造、表現、精度モデル、利用できるオラクルに依存する。

解 17.5 ★★ 線形計画の双対 — 献立問題

解答

主側では $(2, 2), (6, 0), (0, 4)$ のコストがそれぞれ 10, 12, 12 なので、 $p^* = 10$ 。

双対実行可能領域の頂点は $(0, 0), (1, 1), (2, 0), (0, 3/2)$ 。目的値は順に 0, 10, 8, 9 なので、 $d^* = 10$ 。原点も頂点だが最適ではない。

最適点では主・双対の対応する制約がすべて等号で、相補性と整合する。栄養の最低必要量を増やすのは制約の厳格化で、最低コストは局所的に乗数だけ増える。必要量を減らして緩和すれば、最低コストは同じ乗数だけ下がる。

解 17.6 ★★ 等号の連鎖 — 強双対から相補性が転がり出る

解答

(1) 最初の等号は強双対と双対関数の定義による。 $\inf_{\mathbf{x}} \mathcal{L} \leq \mathcal{L}(\mathbf{x}^*, \boldsymbol{\mu}^*)$ は下限の定義による。最後は主実行可能性と双対実行可能性から $\mu_i^* g_i(\mathbf{x}^*) \leq 0$ であるため成立する。

(2) 不等式鎖の両端が強双対により一致するので、途中の不等号はすべて等号になる。従って $\sum_i \mu_i^* g_i(\mathbf{x}^*) = 0$ 。各項は非正なので、すべての項が 0、すなわち各 i について $\mu_i^* g_i(\mathbf{x}^*) = 0$ となる。

(3) また $q(\boldsymbol{\mu}^*) = \mathcal{L}(\mathbf{x}^*, \boldsymbol{\mu}^*)$ は、 $\mathbf{x}^*$ が内側問題の大域的最小点であることを示す。変数領域が開集合でラグランジュ関数が微分可能なら、1階必要条件から $\nabla f(\mathbf{x}^*) + \sum_i \mu_i^* \nabla g_i(\mathbf{x}^*) = \mathbf{0}$ 。境界や追加の定義域制約がある場合は、単純な勾配ゼロではなく対応する最適性条件が必要である。

(4) 問17.1では $f(1) = 1, \mathcal{L}(1, 2) = 1 + 2(1 - 1) = 1, q(2) = 1$ で三者が一致し、相補性も $2 \cdot (1 - 1) = 0$ と確認できる。

解 17.7 ★★★ 最小ノルム解の双対 — 問15.3を裏から見る

解答

内側最小化から $\mathbf{x} = \lambda \mathbf{a}/2, q(\lambda) = \lambda - 5\lambda^2/4$ 。最大化すると $\lambda^* = 2/5, d^* = 1/5$ で、主解 $(1/5, 2/5)$ と一致する。

一般に双対変数の数は制約数に対応するが、それが主変数数より少ないとは限らない。どちらを解く方が有利かは両者の次元と構造による。

SVM の双対変数は訓練例数に対応し、特徴次元より多い場合もある。双対形式の重要な利点は、データが内積として現れ、カーネルで置き換えられる点である。

解 17.8 ★★★ 最大エントロピーの双対 = log-sum-exp

方針

停留条件から分布の形(指数型)が出て、残る未知数は乗数 β だけ — その β を決める方程式が「対数分配関数の微分 = 平均」。数値まで下ろして主双対の値の一致を見届ける。

解答

$$(1) \mathcal{L} = -\sum p_i \log p_i + \alpha \left(\sum p_i - 1 \right) + \beta \left(\sum p_i x_i - m \right). \frac{\partial \mathcal{L}}{\partial p_i} = -\log p_i - 1 + \alpha + \beta x_i = 0 \text{ より}$$

$$p_i = e^{\alpha-1} e^{\beta x_i} \propto e^{\beta x_i}$$

正規化定数を $Z(\beta) = \sum_i e^{\beta x_i} = e^{-\beta} + 1 + e^{\beta}$ として $p_i = \frac{e^{\beta x_i}}{Z}$ — ボルツマン分布 (指数型分布族)。問15.6(制約が正規化のみ $\rightarrow$ 一様分布)に平均制約を1本足すと、指数の傾き β が1つ生えた、という構図である。

$$(2) A(\beta) = \log Z(\beta) \text{ とおくと}$$

$$A'(\beta) = \frac{Z'(\beta)}{Z(\beta)} = \frac{\sum_i x_i e^{\beta x_i}}{Z(\beta)} = \sum_i p_i x_i$$

— 対数分配関数の微分は、ちょうど分布 p のもとでの平均。よって平均制約は $A'(\beta) = m = \frac{1}{2}$ 。 $s = e^{\beta}$ とおくと $A' = \frac{s - 1/s}{1/s + 1 + s} = \frac{s^2 - 1}{1 + s + s^2} = \frac{1}{2}$ 、整理して $2s^2 - 2 = 1 + s + s^2$ 、すなわち

$$s^2 - s - 3 = 0 \quad \therefore s = \frac{1 + \sqrt{13}}{2} \approx 2.303, \quad \beta^* = \log s \approx 0.834$$

分布は $p = \frac{1}{Z} \left(\frac{1}{s}, 1, s \right) \approx (0.116, 0.268, 0.616)$ ($Z = \frac{1}{s} + 1 + s \approx 3.737$)。

平均の検算: $-0.116 + 0.616 = 0.500$ — 制約成立(記号的にも $\frac{s-1/s}{Z} = \frac{1}{2}$ が $s^2 - s$

— $3 = 0$ から厳密に従うことを検証済み)。

(3) 数値計算(検証済み)で

$$H(p^*) = - \sum p_i \log p_i = 0.9013 \dots,$$

$$A(\beta^*) - \beta^* m = \log Z - \frac{1}{2} \log s = 0.9013 \dots$$

— 両者は小数第10位を超えて一致する。すなわち**主問題(平均制約つきエントロピー最大化)の最適値 = 双対問題 $\min_{\beta} [A(\beta) - \beta m]$ の最適値**。本問では目的が凹、制約がアフィンで、平均 $1/2$ を満たす全成分正の分布(たとえば $(0.1, 0.3, 0.6)$)も存在するため、強双対を適用できる。この $\max_p / \min_{\beta}$ の対は**ルジャンドル変換**の関係で、「エントロピーと log-sum-exp(対数分配関数)は互いの変換」— 問8.8・12.8 で個別に調べた log-sum-exp が、実は最大エントロピーの影だったことが分かる。

ポイント

本問で本書の伏線が一斉に回収されました: log-sum-exp のヘッセ行列(問8.8)は $A''(\beta) = \text{分散} \geq 0$ (凸性: 問12.8)、その勾配は**平均**(本問 (2))、そして凹凸のペア(エントロピー $\leftrightarrow A$)を双対性が橋渡しする。「微分すると統計量が出てくる母関数」という見方は、確率統計のモーメント母関数・キュムラントへ直結します — 『確率統計』の教科書で A に再会したとき、この問題を思い出してください。

第18章

機械学習と最適化 — 解答解説

SGD・適応学習率・損失設計・正則化の総合演習

解 18.1 ★ 経験損失と勾配の分解

方針

微分の線形性そのもの — だが、この1行が SGD という一大産業の土台になる。

解答

各標本の勾配は $\nabla \ell_i = (2(wx_i + b - y_i)x_i, 2(wx_i + b - y_i))$ 。微分は和・定数倍と交換するので

$$\nabla L = \nabla \left(\frac{1}{3} \sum_i \ell_i \right) = \frac{1}{3} \sum_i \nabla \ell_i$$

— 全勾配は標本勾配の平均である(検証では記号のまま恒等式として確認済み)。全データ n 個の代わりに、大きさ B のミニバッチでこの平均を推定すれば、1歩の標本あたり計算量は全勾配のおよそ B/n (単一標本の SGD なら $1/n$) になる。実際の処理時間は並列化やメモリアクセスにも左右される。

ポイント

損失が「標本ごとの損失の和(平均)」という形であること — 加法性 — は当たり前に見えて本質的な構造です。この形だからこそ勾配が分解でき、SGD・分散計算・並列化(データ並列:各GPUが部分和を計算して平均)がすべて成立する。目的関数を設計するとき(第11章)、加法性を保つことは計算資源の設計でもあります。

解 18.2 ★ SGD は当てずっぽうではない — 不偏性

方針

具体的な3つのベクトルの平均を取り、「一様サンプルの期待値 = 平均」という期待値の定義に立ち返る。

解答

$(w, b) = (1, 1)$ での残差は $r_i = wx_i + b - y_i$: $r_1 = 1 + 1 - 2 = 0$, $r_2 = 2 + 1 - 3 = 0$, $r_3 = 3 + 1 - 5 = -1$ 。標本勾配 $\nabla \ell_i = (2r_i x_i, 2r_i)$ は

$$\nabla \ell_1 = (0, 0), \quad \nabla \ell_2 = (0, 0), \quad \nabla \ell_3 = (-6, -2)$$

一様ランダムな I に対して

$$E[\nabla \ell_I] = \frac{1}{3} \left[(0, 0) + (0, 0) + (-6, -2) \right] = \left(-2, -\frac{2}{3} \right) = \nabla L(1, 1)$$

— 一致(不偏)。一般の証明は1行: I が一様なら $E[\nabla \ell_I] = \sum_{i=1}^n \frac{1}{n} \nabla \ell_i = \nabla L$ (期待値の定義がそのまま平均の定義)。

ポイント

本例は不偏性の含意を鮮やかに見せます: 3回に2回は勾配 $(0, 0)$ を引いて**1ミリも動かない**。それでも「平均すれば」正しい方向 — SGD の1歩は信用できないが、歩みの合計は信用できる、という確率論的な信頼の形です。第13章の降下補題ベースの証明は、期待値をとる操作を挟むだけでほぼそのまま SGD 版に拡張されます(期待値の線形性が糊)。「不偏だがばらつく推定量を、たくさん平均して使う」— モンテカルロ法(問10.7)と同じ思想がここでも背骨です。

解 18.3 ★★ ばらつきはバッチで割れる

解答

$E[g] = -2, E[g^2] = 12$ なので $\text{Var}(g) = 12 - 4 = 8$ 。

独立な復元抽出の平均では、分散の加法性から $\text{Var}(\bar{g}) = B^{-2} \cdot B \cdot 8 = 8/B$ 。

非復元抽出では有限母集団修正 $(n - B)/(n - 1)$ が加わるため、 $n = 3, B = 2$ では $8 \cdot (1)/(2 \cdot 2) = 2$ 、 $B = 3$ では 0 となる。

解 18.4 ★★ ノイズ床と学習率減衰

解答

独立性と零平均から交差項が消え、 $m_{k+1} = (1 - \eta)^2 m_k + \eta^2 \sigma^2$ 。 $0 < \eta < 2$ での不動点は $m^* = \eta \sigma^2 / (2 - \eta)$ 。

$\eta_k = 1/(k + 1)$ では $(k + 1)x_{k+1} = kx_k - \xi_k$ 。望遠鏡和から

$$x_K = -\frac{1}{K} \sum_{k=0}^{K-1} \xi_k, \quad E[x_K^2] = \frac{\sigma^2}{K}.$$

$\sigma = 1, K = 5000$ なら正確には $1/5000 = 2 \times 10^{-4}$ 。この例は学習率減衰の基本機構を示すが、一般の非凸・非定常な確率的最適化へ数値をそのまま移せるわけではない。

解 18.5 ★★ 対角前処理と Adam の違い

解答

$\nabla f(1, 1) = (1, 9)$ なので、 $(1, 1) - \text{diag}(1, 1/9)(1, 9) = (0, 0)$ 。

ここでの D は既知の対角ヘッセ行列の厳密な逆である。対角が安価に得られるなら保存・適用は $O(n)$ だが、一般の関数で対角成分を求めるコストまで常に $O(n)$ とは限らない。

Adam の v_i は勾配の二次モーメントで、ヘッセ行列の対角成分そのものではない。座標ごとの更新尺度を調整する効果はあるが、条件数を 1 にする保証や、学習率・ノイズに対する無条件の頑健性はない。

解 18.6 ★★ 0-1損失と凸代理

解答

0-1損失は $m = 0$ 以外で局所的に定数で、通常の勾配情報を与えない。

$m \leq 0$ ではヒンジ損失は $1 - m \geq 1$ 、底2のロジスティック損失は $\log_2(1 + e^{-m}) \geq 1$ 。 $m > 0$ では0-1損失が 0 で、両代理損失は非負だから、どちらも上界である。

ヒンジ損失はアフィン関数の最大として凸。ロジスティック損失について

$$\ell''_{\log}(m) = \frac{e^m}{(\ln 2)(1 + e^m)^2} = \frac{\sigma(m)(1 - \sigma(m))}{\ln 2} > 0.$$

自然対数版なら係数 $1/\ln 2$ は付かないが、底2版では必要である。

解 18.7 ★★★ GD・SGD の再現実験

解答

指定手順での最小値は $L_{min} = 0.08962277$ 。1エポックと50エポックの値は、GD が 1.93600389, 0.09164897、 $B = 1$ が 0.09889409, 0.09240632、 $B = 16$ が 0.34009847, 0.09052234 となる。

同じデータ接触量でも更新回数が異なるため、序盤の進み方は大きく変わる。終盤には、確率的勾配の揺らぎ、バッチサイズ、学習率、有限エポックでまだ残る最適化誤差が同時に影響する。

この表は指定した線形回帰・シード・固定学習率での結果である。小バッチが常に序盤最良、大バッチが常に終盤最良という一般定理ではない。バッチと学習率の線形スケーリングも、最適化領域・ウォームアップ・並列効率などの条件を伴う経験則として扱う。

解 18.8 ★★★★★ 正則化と汎化の再現実験

解答

学習時の目的関数は、問題文どおり $\|X\mathbf{w} - \mathbf{y}\|^2 + \lambda\|\mathbf{w}\|^2$ (残差平方和と罰則の和) である。したがって $\lambda > 0$ では正規方程式 $(X^\top X + \lambda I)\mathbf{w} = X^\top \mathbf{y}$ を解く。評価時だけ、罰則を除いた残差の平均を MSE として報告する。

指定手順では、 $\lambda = 0$ の訓練・テストMSEと最大係数は

0.001901, 0.032257, 23.092944。 $\lambda = 0.01$ では 0.012015, 0.020111, 2.904166、 $\lambda = 1$ では 0.157840, 0.147712, 0.975314。

正則化なしでは高次多項式の係数が大きくなり、訓練点の雑音まで追う。中程度の正則化は係数を縮め、表示した3候補ではテスト誤差を下げる。強すぎる正則化は過小適合を起こす。

$\lambda = 0.01$ が最小なのは表示した3候補の中だけである。また、このテスト集合を見て λ を選べば評価漏洩になる。実際の選択は検証集合または交差検証で行い、テスト集合は最終評価に残す。

第19章

ε-δ論法 — 解答解説

「限りなく近づく」を仕様書に書き直す

解 19.1 ★ ε-N の読み方と最初の証明

方針

定義を「先手・後手のゲーム」として読み、証明を「応答 $N(\varepsilon)$ の構成+検証」の2部構成で書く型を作る。

解答

(1) ゲームの言い換え: **挑戦者が先手**で、好きな許容誤差 $\varepsilon > 0$ を突きつける。**応答者が後手**で、番号 N を返す。そのあと挑戦者は $n \geq N$ の範囲から好きな n を選んで検査し、 $|a_n - L| < \varepsilon$ が破れていれば挑戦者の勝ち。「収束する」とは、**応答者に必勝戦略があること**。 N は ε を見てから返すので $N = N(\varepsilon)$ と依存してよい — 量子子の順序「 $\forall \varepsilon$ (先) $\rightarrow \exists N$ (後)」がそのまま手番と依存関係を定めている。逆に n は N より後に選ばれるので、 N は n に依存できない(すべての $n \geq N$ を一括で引き受ける)。

(2) **構成**: 与えられた $\varepsilon > 0$ に対し $N = \left\lceil \frac{1}{\varepsilon} \right\rceil + 1$ と応答する。**検証**: $n \geq N$ なる任意の n について、 $N > \frac{1}{\varepsilon}$ だから

$$\left| \frac{1}{n} - 0 \right| = \frac{1}{n} \leq \frac{1}{N} < \varepsilon$$

よって定義の条件が成り立ち、 $\lim_{n \rightarrow \infty} \frac{1}{n} = 0$ 。(証明終)。 $\varepsilon = 0.01$ なら $N = \lceil 100 \rceil + 1 = 101$:101番以降の項はすべて 0.01 未満(数値検証済み)。

ポイント

証明の型は常に2部構成 — (i) 応答の構成(N や δ の式を書く)、(ii) 検証(その応答で条件が成り立つことを不等式で確かめる)。答案では「 $\varepsilon > 0$ を任意にとる。 $N = \dots$ とおく。 $n \geq N$ とすると…」という書き出しが定石です。なお N は「うまく動く1つ」を挙げればよく、最小である必要はありません(+1 の遊びはそのための保険)。

解 19.2 ★ ε-δ の型 — 1次関数で素振り

方針

目標量 $|f(x) - L|$ を $|x - a|$ の式に変形してから δ を逆算する — 「後ろから設計して、前から清書する」。

解答

$$(1) |(3x + 1) - 7| = |3x - 6| = 3|x - 2|.$$

(2) 清書: $\varepsilon > 0$ を任意にとる。 $\delta = \frac{\varepsilon}{3} > 0$ とおく。 $0 < |x - 2| < \delta$ を満たす任意の x に対して

$$|(3x + 1) - 7| = 3|x - 2| < 3\delta = 3 \cdot \frac{\varepsilon}{3} = \varepsilon$$

よって定義により $\lim_{x \rightarrow 2} (3x + 1) = 7$ 。(証明終)

(3) 同じ計算で $|f(x) - f(a)| = |c| |x - a|$ なので $\delta = \frac{\varepsilon}{|c|}$ が通用する。傾き $|c|$ は「入力のずれが出力のずれに化けるときの増幅率」であり、急な関数ほど同じ ε に対して小さな δ (厳しい入力管理) が必要。

ポイント

設計(下書き)では $|f(x) - L| < \varepsilon$ から逆向きに δ を割り出し、清書では δ を先に宣言して順方向に不等式を流す — 下書きと清書で向きが逆になるのが ε - δ 答案の作法です。逆算過程を答案に書く必要はありませんが、頭の中では必ずそちらが先です。

解 19.3 ★★ min をとる技 — 2次関数の ε - δ

方針

増幅率が場所に依存するときは、先に「作業エリア」を $|x - a| \leq 1$ に限定して増幅率に上限をつけ、 δ は $\min(\text{エリア制限}, \text{誤差要求})$ で応答する。

解答

(1) $|x^2 - 9| = |x - 3| |x + 3|$ 。1次関数と違い、増幅率にあたる因子 $|x + 3|$ が x とともに動く — x が大きい側では同じ $|x - 3|$ でも誤差が大きく増幅されるため、 $\delta = \varepsilon / (\text{定数})$ の形が直には作れない。

(2) 清書: $\varepsilon > 0$ を任意にとる。 $\delta = \min\left(1, \frac{\varepsilon}{7}\right) > 0$ とおく。 $0 < |x - 3| < \delta$ を満たす任意の x について、まず $|x - 3| < \delta \leq 1$ より $2 < x < 4$ 、したがって $|x + 3| < 7$ 。ゆえに

$$|x^2 - 9| = |x - 3| |x + 3| < \delta \cdot 7 \leq \frac{\varepsilon}{7} \cdot 7 = \varepsilon$$

よって $\lim_{x \rightarrow 3} x^2 = 9$ 。(証明終)($\varepsilon = 0.5, 3, 10$ の各場合について数値でも検証済み。)

(3) $\varepsilon = 100$ で $\delta = \frac{100}{7} \approx 14.3$ だけを使うと、たとえば $x = 17$ が $|x - 3| < \delta$ を満たすのに $|x^2 - 9| = 280 > 100$ — エリア制限を外した瞬間、増幅率 $|x + 3|$ (この x では 20) が上限 7 を突き破り、検証の不等式が崩れる。 $\min$ の第1引数 1 は「増幅率の見積もり $|x + 3| \leq 7$ が有効な作業エリアを保証する」役割を担っている。

ポイント

「まず $\delta \leq 1$ と決め打ちして局所の増幅率を見積もり、 $\min(1, \varepsilon/K)$ で応答」— 多項式・積・合成の ε - δ 証明のほぼすべてがこの型の反復です。数値 1 に意味はなく (0.5 でも 2 でもよい: 上限の 7 が変わるだけ)、「有界な作業エリアを先に確保する」という発想が本体。これは問19.5の「増幅率が有界なら一様連続」への布石でもあります。

解 19.4 ★★ 否定命題 — 「収束しない」を証明する

方針

否定は機械的に ($\forall \leftrightarrow \exists$ 反転 + 末尾条件の否定)。証明ではこちらが ε を選ぶ先手に回り、どの N が来ても反例の項を差し出す。

解答

(1) 元の命題「任意の $\varepsilon > 0$ に対し、ある N が存在して、 $n \geq N$ なるすべての n で $|a_n - L| < \varepsilon$ 」の否定は、量化子を順に反転して:「ある $\varepsilon > 0$ が存在して、どの N に対しても、 $n \geq N$ かつ $|a_n - L| \geq \varepsilon$ を満たす n が存在する」。手番も逆転する: 今度は「収束しない」ことを示す側が ε を先に固定でき、 N は相手 (任意) に渡す。

(2) $\varepsilon = \frac{1}{2}$ と選ぶ。任意の実数 L について、恒等式 $(1 - L) + (1 + L) = 2$ (L が消える) と三角不等式から

$$2 = |(1 - L) + (1 + L)| \leq |1 - L| + |1 + L| = |1 - L| + |-1 - L|$$

よって $\max(|1 - L|, |-1 - L|) \geq 1 > \frac{1}{2}$ 。すなわち、 $a_n = 1$ (偶数番) と $a_n = -1$ (奇数番) の少なくとも一方は L から $\frac{1}{2}$ より遠い。任意の N が与えられたら、遠い側の値をとる番号 $n \geq N$ (偶数番か奇数番かは N 以降に必ず両方ある) を差し出せば $|a_n - L| \geq 1 > \frac{1}{2} = \varepsilon$ 。よって $(-1)^n$ はどの L にも収束しない。(証明終)

(3) 証明のどこにも L の場合分けがない: 三角不等式が「2点 1 と -1 の距離 2 は、どんな L を経由しても縮まない」ことを一括で保証し、すべての L が同時に倒れた (格子 $L \in [-3, 3]$ の数値検証とも整合)。「反例候補が2つの値を往復する → 2値間の距離の半分未満の ε を選ぶ」は振動列の発散証明の定石である。

ポイント

否定命題の作成はド・モルガン則の練習であると同時に、「示したい主張に応じて自分の手番 (何を選べるか) が変わる」ことの体得です: 収束の証明では δ, N を構成する側、発散の証明では ε と反例を構成する側。院試で「一様連続でないことを示せ」型が頻出するのは、この手番の切り替えができるかを見るためです (次問がまさにそれ)。

解 19.5 ★★ 量子子の順序が命 — 連続 vs 一様連続

方針

2つの定義を1文字ずつ突き合わせ、 δ の依存先の違いに還元する。反証は問19.4と同じく「こちらが ε の先手」。

解答

(1) 並べて書く:

各点連続: 任意の点 a に対し、任意の $\varepsilon > 0$ に対し、ある $\delta > 0$ が存在して、 $|x - a| < \delta$ なるすべての x で $|f(x) - f(a)| < \varepsilon$ 。— δ は a と ε の後に出るので $\delta = \delta(a, \varepsilon)$: 場所ごとに別注の δ でよい。

一様連続: 任意の $\varepsilon > 0$ に対し、ある $\delta > 0$ が存在して、 $|x - y| < \delta$ なるすべての組 x, y で $|f(x) - f(y)| < \varepsilon$ 。— δ は場所の量化 ($\forall x, y$) より前に出るので $\delta = \delta(\varepsilon)$: 全域共通の δ が要る。違いは「 $\exists \delta$ 」が場所の「 $\forall$ 」の後か先か、その順序だけである (一様連続 $\Rightarrow$ 各点連続は明らか。逆は一般に不成立 — 次で反例)。

(2) 一様連続の否定は「ある $\varepsilon > 0$ が存在して、どの $\delta > 0$ に対しても、 $|x - y| < \delta$ かつ $|f(x) - f(y)| \geq \varepsilon$ なる組 x, y が存在する」。 $\varepsilon = 1$ と選ぶ。任意の $\delta > 0$ に対し、 $a = \frac{2}{\delta}$ 、 $x = a$ 、 $y = a + \frac{\delta}{2}$ とおくと $|x - y| = \frac{\delta}{2} < \delta$ だが

$$|x^2 - y^2| = (x + y)|y - x| = \left(2a + \frac{\delta}{2}\right) \frac{\delta}{2} = a\delta + \frac{\delta^2}{4} = 2 + \frac{\delta^2}{4} > 1 = \varepsilon$$

(検証済み: $\delta = 0.1, 0.01, 0.001$ のいずれでもギャップ > 1)。どの δ にも遠方で反例が作れるので、 x^2 は $\mathbb{R}$ 上で一様連続でない。(証明終) — 各点では $\delta(a, \varepsilon) \approx \frac{\varepsilon}{2|a| + 1}$ が取れて連続だが、 $|a| \rightarrow \infty$ で $\delta \rightarrow 0$: 共通の δ が枯渇するのが不成立の正体である。

(3) $[0, 1]$ 上では増幅率が $|x + y| \leq 2$ と有界なので $|x^2 - y^2| \leq 2|x - y|$ (5000組で数値検証済み)。よって $\delta = \frac{\varepsilon}{2}$ がどの場所でも通用し、一様連続。違いの核心は**増幅率(傾き)の有界性**: 定義域が有界閉区間なら連続関数の「暴れ」は閉じ込められる、というのがハイネ・カントールの定理の内容である (広義積分の存在議論や、第5章の「連続なら積分可能」の背後でもこの定理が働いている)。

ポイント

「 $\forall \exists$ 」と「 $\exists \forall$ 」の違いは、日常文なら「誰にでも(それぞれ)恋人がいる」と「全員共通の恋人がいる」の違い — 後者が圧倒的に強い主張です。プログラミングの型でいえば $\delta : \varepsilon \mapsto \delta(\varepsilon)$

と $\delta : (a, \varepsilon) \mapsto \delta(a, \varepsilon)$ のシグネチャの違い。**量子子の順序 = 関数の引数リスト**という読み替えは、情報系の読者にとって最強の暗記法だと思います。

解 19.6 ★★ ε/2 論法 — 証明の定番部品

方針

予算 ε を部品に配る($\varepsilon/2$ ずつ) → 各部品から δ_i をもらう → **min** で応答 → 三角不等式で合算 — 4手の定型。

解答

(1) $\varepsilon > 0$ を任意にとる。 f の a での連続性を誤差 $\frac{\varepsilon}{2}$ に対して使い、ある $\delta_1 > 0$ をとる:

$|x - a| < \delta_1$ なら $|f(x) - f(a)| < \frac{\varepsilon}{2}$ 。同様に g から $\delta_2 > 0$ をとる。 δ

$= \min(\delta_1, \delta_2) > 0$ と応答する。 $|x - a| < \delta$ なる任意の x に対し、三角不等式より

$$|(f + g)(x) - (f + g)(a)| \leq |f(x) - f(a)| + |g(x) - g(a)| < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon$$

よって $f + g$ は a で連続。(証明終)

(2) $\varepsilon > 0$ を任意にとる。 f の連続性から $\delta > 0$ をとる: $|x - a| < \delta$ なら $|f(x) - f(a)| < \varepsilon$ 。このとき逆三角不等式より

$$||f(x)| - |f(a)|| \leq |f(x) - f(a)| < \varepsilon$$

— $|f|$ の誤差は f の誤差を決して上回らない(絶対値は距離を縮めることはあっても広げない「1-リプシッツ」な操作:問19.7)ので、同じ δ がそのまま通用する。(証明終)

(3) 部品が k 個なら予算を $\frac{\varepsilon}{k}$ ずつ配り、 $\delta = \min(\delta_1, \dots, \delta_k)$ で応答すれば、合算は k

・ $\frac{\varepsilon}{k} = \varepsilon$ に収まる(配分は均等でなくてもよい — 合計が ε 以下なら任意の割り振りで成立し、実際、扱いにくい部品に厚めに配る証明もよくある)。

ポイント

$\varepsilon/2$ 論法は「誤差バジェットの配分」というエンジニアリングの言葉に直訳できます: システム全体の許容誤差を、部品(測定・量子化・演算)ごとに割り振って各部品の仕様を決める — まさに同じ設計手順です。証明が書けること = 誤差予算表が書けること。第I部の極限計算の裏で暗黙に使っていた「和の極限 = 極限の和」も、この $\varepsilon/2$ 論法(数列版)が正体でした — 直感で使った規則に、最後に領収書が発行された格好です。

解 19.7 ★★★ リプシッツ連続と数値誤差

解答

$K > 0$ なら $\delta = \varepsilon/K$ と取れば、 $|f(x) - f(y)| \leq K|x - y| < \varepsilon$ 。 $K = 0$ なら全ての2点で値が同じなので、任意の正の δ でよい。

この不等式は、入力誤差を ε/K 未満にすれば出力誤差を ε 未満に抑えられるという仕様になる。ただしこれは数学的な関数値の摂動評価であり、演算手順の丸め誤差は別途解析が必要である。

今回確認した Python の binary64 環境では、 $\cos(10^{-8})$ が 1.0 に丸められ、素朴な差は 0 となった。等価式 $2 \sin^2(x/2)$ は約 5×10^{-17} を保つ。この具体的な丸め結果は処理系依存だが、近い数の減算が相対精度を失いやすいという原理は一般的である。

解 19.8 ★★★ 定義から定理へ

解答

収束 $a_n \rightarrow L$ に $\varepsilon = 1$ を使うと、ある N 以降で $|a_n| < |L| + 1$ 。 $N = 1$ なら $M = |L| + 1$ 。 $N > 1$ なら $M = \max(|a_1|, \dots, |a_{N-1}|, |L| + 1)$ とすれば全項を抑え

られる。

$a_n \rightarrow L$ と $c_n \rightarrow L$ から得る番号を N_1, N_2 とし、 $N = \max(N_1, N_2)$ と取る。 $n \geq N$

では $L - \varepsilon < a_n \leq b_n \leq c_n < L + \varepsilon$ なので $b_n \rightarrow L$ 。

$-1/n \leq \sin n/n \leq 1/n$ と両端の収束から、はさみうちにより $\sin n/n \rightarrow 0$ 。

『情報系のための微分積分・最適化 解答解説集』全19章・159問。姉妹編『問題集』とセットで学習してください。

Copyright © 2026 情報系のための数学 問題集シリーズ. All Rights Reserved.