

解答解説集

大学基礎から大学院入試への橋渡し — 全18章・154問の詳解

本書は『問題集』の姉妹編です。問題番号は完全に対応しています(問 3.4 の解説は 解 3.4)。

PDF版 2026-09-03 生成

目次

第1章 確率の基礎 解 1.1～1.9

第2章 条件付き確率とベイズの定理 解 2.1～2.10

第3章 離散型確率変数 解 3.1～3.10

第4章 連続型確率変数 解 4.1～4.10

第5章 多次元確率変数 解 5.1～5.9

第6章 期待値の技法 解 6.1～6.9

第7章 大数の法則と中心極限定理 解 7.1～7.9

第8章 記述統計と標本分布 解 8.1～8.8

第9章 点推定 解 9.1～9.9

第10章 区間推定 解 10.1～10.7

第11章 仮説検定 解 11.1～11.10

第12章 回帰分析 解 12.1～12.8

第13章 ベイズ統計入門 解 13.1～13.8

第14章 マルコフ連鎖とポアソン過程 解 14.1～14.9

第15章 状態推定とカルマンフィルタ 解 15.1～15.8

第17章 信頼性工学の確率モデル 解 17.1～17.7

第18章 測度論的確率論への入口 解 18.1～18.7

解説の読み方

各解説は次の3段構成です。

- **方針** — 解き始める前の見取り図。詰まったときは、まずここだけを読んでもう一度自力で挑戦してください(段階的ヒントとして使えます)。
- **解答** — 答案として書ける形の完全な解。途中計算も省略せずに示します。
- **ポイント** — その問題が教えてくれる本質、よくある誤り、先の章や画像処理・車載システムなど応用とのつながり。

読んで「わかった」で止めず、翌日、何も見ずにノートへ再現できて初めて身についたと判定してください。証明問題は、論理の流れを自分の言葉で言い直せるかが基準です。

第1章

確率の基礎 — 解答解説

標本空間・事象・数え上げ

解 1.1 ★ 標本空間と事象

方針

確率の第一歩は「起こりうる結果を全部書き出す」こと。3回の各回に H/T の2通りがあるから、積の法則で 2^3 通り。

解答

(1) $\Omega = \{HHH, HHT, HTH, THH, HTT, THT, TTH, TTT\}$, $|\Omega| = 2^3 = 8$ 。

(2) $A = \{HHT, HTH, THH\}$ (表2回・裏1回の並び)。

(3) 各結果が等確率 $1/8$ なので

$$P(A) = \frac{|A|}{|\Omega|} = \frac{3}{8}$$

ポイント

確率の計算は「数える」ことから始まります。 $|A| = 3$ は「3回のうち表になる2回を選ぶ」 $\binom{3}{2}$ と読みます — この見方を n 回に一般化したものが**二項分布**(第3章)です。列挙が効くのは小さい問題だけで、以後は順列・組合せ、さらに分布という「数え上げの完成品」を使っていきます。

解 1.2 ★ 順列と組合せ

方針

定義どおり計算する。「同時に引く」=順序を区別しない=組合せ。

解答

$$(1) {}_5C_2 = \frac{5 \cdot 4}{2 \cdot 1} = 10, {}_6P_3 = 6 \cdot 5 \cdot 4 = 120, {}_8C_3 = \frac{8 \cdot 7 \cdot 6}{3 \cdot 2 \cdot 1} = 56.$$

(2) 引き方の総数は $\binom{52}{2} = 1326$ 、2枚ともハートは $\binom{13}{2} = 78$ 通り。よって

$$P = \frac{\binom{13}{2}}{\binom{52}{2}} = \frac{78}{1326} = \frac{1}{17} \approx 0.0588$$

ポイント

分子と分母で「数え方(順序の扱い)」を揃えることが鉄則です。順序を区別して数えても

$$\frac{13 \cdot 12}{52 \cdot 51} = \frac{1}{17} \text{ と同じ答えになります — 揃えずに混ぜるのが最頻出ミス。なお } \frac{13}{52} \cdot \frac{12}{51}$$

と読めば、これは次章の**乗法定理**(条件付き確率の積)そのものです。

解 1.3 ★ 余事象

方針

「少なくとも一方」は、余事象「1つも6が出ない」の方が数えやすい。

解答

(a) 余事象「どちらも6でない」は $5 \times 5 = 25$ 通りで確率 $25/36$ 。よって

$$P = 1 - \frac{25}{36} = \frac{11}{36} \approx 0.306$$

(b) 直接数える:1個目が6は6通り、2個目が6は6通り、両方6の $(6, 6)$ を二重に数えているので $6 + 6 - 1 = 11$ 通り。 $P = 11/36$ で一致。

ポイント

「少なくとも1つ → 余事象」は本書で繰り返し使う定石です(問1.7、問2.9、問3.7 …)。また (b) の「重複を引く」は加法定理・包除原理(問1.4、1.6)の最小例になっています。同じ答えを2通りで出す習慣は、最良の検算法でもあります。

解 1.4 ★ 加法定理

方針

ハートと絵札は排反でない(ハートの絵札がある)。加法定理で重複分を引く。

解答

$$P(\text{ハート}) = \frac{13}{52}, P(\text{絵札}) = \frac{12}{52}, P(\text{ハートの絵札}) = \frac{3}{52}。よって$$

$$P = \frac{13}{52} + \frac{12}{52} - \frac{3}{52} = \frac{22}{52} = \frac{11}{26} \approx 0.423$$

ポイント

「足しすぎた分を戻す」のが加法定理の心。排反($A \cap B = \emptyset$)のときだけ単純な足し算になります。3つ以上の集合への一般化が包除原理(問1.6)です。

解 1.5 ★★ 誕生日問題

方針

「一致する組がある」の余事象「全員の誕生日が異なる」を数える。365人を超える場合は鳩の巣原理を使う。

解答

(1) $1 \leq n \leq 365$ のとき、全員の誕生日が異なる確率は

$$\prod_{j=0}^{n-1} \frac{365-j}{365} = \frac{365!}{(365-n)! 365^n}$$

したがって $p_n = 1 - \frac{365!}{(365-n)! 365^n}$ 。一方、 $n \geq 366$ なら少なくとも2人が同じ日に割り当てられるので $p_n = 1$ である。

(2) $n = 23$ のとき、全員異なる確率は約0.4927であり、

$$p_{23} \approx 1 - 0.4927 = 0.5073 > \frac{1}{2}$$

($n = 22$ では $p_{22} \approx 0.476$ であり、23人が初めて0.5を超える。)

(3) 比較されるのは特定の1組ではなく、全体の $\binom{n}{2}$ 組である。この組数が人数の2乗のオーダーで増えるため、人数が365よりはるかに少なくても、どこかの組で一致しやすい。

ポイント

情報系ではハッシュ衝突の見積りとして重要である。 m 通りへ独立かつ一様に割り当てる同じモデルでは、およそ $1.18\sqrt{m}$ 個で衝突確率が50%に達する。これはバースデー攻撃の基本的な見積りでもある。

解 1.6 ★★ 包除原理

方針

2, 3, 5 の倍数の集合を A, B, C とし、3集合の包除原理。 k の倍数の個数は $\lfloor 100/k \rfloor$ 。

解答

$|A| = 50, |B| = 33, |C| = 20$ 。共通部分は最小公倍数の倍数で、 $|A \cap B| = \lfloor 100/6 \rfloor = 16, |A \cap C| = \lfloor 100/10 \rfloor = 10, |B \cap C| = \lfloor 100/15 \rfloor = 6, |A \cap B \cap C| = \lfloor 100/30 \rfloor = 3$ 。包除原理より

$$|A \cup B \cup C| = 50 + 33 + 20 - 16 - 10 - 6 + 3 = 74$$

よって $P = \frac{74}{100} = 0.74$ 。

ポイント

包除原理は「重複を引き、引きすぎたら足し戻す」を繰り返す原理で、一般形は $P(\bigcup A_i) = \sum P(A_i) - \sum P(A_i \cap A_j) + \dots$ 。エラトステネスの篩や、数え上げアルゴリズムの計算量解析にも現れる情報系の基本道具です。問1.9で確率の花形の使い方を見ます。

解 1.7 ★★ 抜き取り検査

方針

「少なくとも1個 → 余事象」。余事象は「4個とも良品」で、良品9個から4個選ぶ組合せ。

解答

$$P(4\text{個とも良品}) = \frac{\binom{9}{4}}{\binom{12}{4}} = \frac{126}{495} = \frac{14}{55}$$

よって

$$P(\text{少なくとも1個不良}) = 1 - \frac{14}{55} = \frac{41}{55} \approx 0.745$$

ポイント

逆から読むと、25%(3/12)もの不良率のロットでも、4個の抜き取りでは約 $14/55 \approx 25\%$ の確率で「全部良品」に見えて見逃します。「何個抜き取れば、どの程度の不良率を、どの確率で検出できるか」を設計する枠組みが、第10・11章の推定・検定(そして問10.7の実証試験)につながります。

解 1.8 ★★★ 公理からの導出

方針

使ってよいのは公理 (i)～(iii) だけ。**排反な分割**を作って (iii) を適用するのが唯一の武器。

解答

(1) $A_1 = \Omega, A_i = \emptyset (i \geq 2)$ とすると、これらは互いに排反で和集合は Ω 。公理 (ii), (iii) より

$$1 = P(\Omega) = P(\Omega) + \sum_{i=2}^{\infty} P(\emptyset) = 1 + \sum_{i=2}^{\infty} P(\emptyset)$$

各項は非負なので、この和が0となるには $P(\emptyset) = 0$ でなければならない。これで有限個の排反事象についても、残りを $\emptyset$ で埋めれば (iii) が使える(有限加法性)。

(2) $A \subseteq B$ のとき $B = A \cup (B \setminus A)$ は排反な分解なので

$$P(B) = P(A) + P(B \setminus A) \geq P(A) \quad (\because P(B \setminus A) \geq 0)$$

(3) $A \cup B = A \cup (B \setminus A)$ (排反)、 $B = (A \cap B) \cup (B \setminus A)$ (排反)より

$$P(A \cup B) = P(A) + P(B \setminus A), \quad P(B \setminus A) = P(B) - P(A \cap B)$$

代入して $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ 。

ポイント

高校で「公式」だったものが、3つの公理から導かれる「定理」に変わりました。**最小限の約束事からすべてを導く**この構図は、線形代数のベクトル空間の公理と同じ発想です。公理 (iii) がわざわざ「可算個(無限列)」の和を許している理由は、第18章(測度論への入口)で明らかになります(問18.2)。

解 1.9 ★★★ 完全順列(モンマル問題)

方針

「どれかが正しく入る」 $\bigcup A_i$ を包除原理で計算し、余事象を取る。対称性から、 k 個の特定の手紙がすべて正しい確率は共通。

解答

(1) 特定の k 通($A_{i_1} \cap \cdots \cap A_{i_k}$) がすべて正しい入れ方は、残り $n - k$ 通が自由なので $(n - k)!$ 通り。よってその確率は $\frac{(n - k)!}{n!}$ 。包除原理より

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k-1} \binom{n}{k} \frac{(n - k)!}{n!} = \sum_{k=1}^n \frac{(-1)^{k-1}}{k!}$$

$\left(\binom{n}{k} \frac{(n - k)!}{n!} = \frac{1}{k!}\right)$ 。余事象を取って

$$p_n = 1 - \sum_{k=1}^n \frac{(-1)^{k-1}}{k!} = \sum_{k=0}^n \frac{(-1)^k}{k!}$$

(2) $p_4 = 1 - 1 + \frac{1}{2} - \frac{1}{6} + \frac{1}{24} = \frac{9}{24} = \frac{3}{8} = 0.375$ 。

(3) $e^x = \sum x^k/k!$ に $x = -1$ を代入した形なので

$$\lim_{n \rightarrow \infty} p_n = e^{-1} \approx 0.368$$

ポイント

n によらずほぼ 37% で一定 — 「1000通なら1通くらい当たりそう」という直感を裏切る美しい結果です。これは「ランダムな置換に不動点がない確率」であり、シャッフルの検定や暗号でのランダム置換の解析に現れます。確率の問題に e が自然に顔を出す最初の例で、第3章のポアソン分布($e^{-\lambda}$)で再会します。

第2章

条件付き確率とベイズの定理 — 解答解説

情報で確率を更新する

解 2.1 ★ 条件付き確率の定義

方針

条件付けとは「世界を B に縮める」こと。和が8になる結果だけを新しい標本空間とみなす。

解答

和が8となるのは(順序対で)(2, 6), (3, 5), (4, 4), (5, 3), (6, 2) の5通り。このうち6を含むのは (2, 6), (6, 2) の2通り。よって

$$P(6\text{を含む} \mid \text{和} = 8) = \frac{2}{5}$$

定義に沿って書けば $\frac{P(6\text{を含む} \cap \text{和}8)}{P(\text{和}8)} = \frac{2/36}{5/36} = \frac{2}{5}$ 。

ポイント

情報を得ると分母(考える世界)が変わる — これが条件付き確率の全てです。(4, 4) を「1通り」と数えるのは誤り: 標本空間は順序対で作ってこそ各結果が等確率になります(2個のサイコロは区別がなくても、確率的には区別して数える)。

解 2.2 ★ 乗法定理

方針

「1個目が赤」×「1個目が赤だったもとで2個目も赤」。非復元抽出は条件付き確率の積で書くのが基本形。

解答

$$P = \frac{5}{8} \times \frac{4}{7} = \frac{20}{56} = \frac{5}{14} \approx 0.357$$

ポイント

実は「2個目が赤」の(条件なしの)確率も $5/8$ です — 1個目の結果で場合分けして全確率の公式で確かめられます($\frac{5}{8} \cdot \frac{4}{7} + \frac{3}{8} \cdot \frac{5}{7} = \frac{35}{56} = \frac{5}{8}$)。「順番が後でも、情報がなければ確率は同じ」という対称性は、くじ引きの公平性の根拠です。

解 2.3 ★ 独立性の判定

方針

独立性の判定方法は、定義 $P(A \cap B) = P(A)P(B)$ を確かめること以外にない。

解答

$$P(A) = \frac{1}{2}, P(B) = \frac{4}{6} = \frac{2}{3}, A \cap B = \{2, 4\} \text{ より } P(A \cap B) = \frac{2}{6} = \frac{1}{3}.$$

$$P(A)P(B) = \frac{1}{2} \cdot \frac{2}{3} = \frac{1}{3} = P(A \cap B) \Rightarrow A \text{ と } B \text{ は独立}$$

一方 $P(C) = \frac{1}{2}, A \cap C = \{2\}$ より $P(A \cap C) = \frac{1}{6} \neq \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$ 。よって A と C は独立でない(従属)。

ポイント

同じサイコロの事象でも独立になりうる、という直感に反する例です。 $B = \{1, 2, 3, 4\}$ を知っても偶数の割合は $2/4 = 1/2$ のまま ($P(A | B) = P(A)$) — 独立とは「情報として役に立たない」ことの数学的表現です。「物理的に無関係」と「確率的に独立」は別概念で、判定は必ず計算で行います。

解 2.4 ★ 全確率の公式

方針

どちらの工場製かで場合分け=全確率の公式。樹形図を描くと構造が見える。

解答

$$P(\text{不良}) = 0.6 \times 0.01 + 0.4 \times 0.03 = 0.006 + 0.012 = 0.018$$

ポイント

「排反で全体を覆う分割 $\{B_i\}$ を作り、条件付き確率で重み付き平均する」— 複雑な確率を計算する最重要パターンです。分割の条件(排反・網羅)を満たさない場合分けは二重計上や数え漏れを生みます。

解 2.5 ★★ ベイズの定理

方針

ベイズの定理。分母(不良品である確率)は問2.4で計算済み。

解答

生産シェア(事前確率)では40%の工場Bが、「不良品である」という情報を得た後(事後確率)は $2/3 \approx 67\%$ に跳ね上がった。不良率が高い工場ほど「不良品の出どころ」として疑わしくなる、という直感が定量化されている。

ポイント

事前確率 0.4 → 事後確率 $2/3$ という**更新**こそがベイズの定理の役割です。「原因 → 結果」の確率(不良率)しか分からなくても、「結果 → 原因」の確率が計算できる。この1ステップを繰り返し適用する体系がベイズ統計(第13章)です。

解 2.6 ★★ 歩行者検出と基準率

方針

H =歩行者あり、 $+$ =警報。求めるのは $P(H \mid +)$ 。分母は全確率の公式で「真の警報+誤警報」。

解答

$P(H) = 0.001$ 、 $P(+ \mid H) = 0.99$ 、 $P(+ \mid H^c) = 0.02$ より

$$P(+) = 0.001 \times 0.99 + 0.999 \times 0.02 = 0.00099 + 0.01998 = 0.02097$$

$$P(H \mid +) = \frac{0.00099}{0.02097} \approx 0.047$$

警報が出ても、本当に歩行者がいる確率は約 **4.7%** — 警報の95%以上は誤報である。感度99%・誤警報率2%という高性能でも、歩行者が写るフレームが千に1つと「まれ」であるため、誤警報の絶対数(0.999×0.02)が真の警報(0.001×0.99)を圧倒してしまう。

ポイント

これが**基準率の誤り(base rate fallacy)**です。まれな事象の検出では、(a) 誤警報率を桁で下げる、(b) 事前確率を上げる(検出対象領域の絞り込み・トラッキングによる文脈利用)、(c) 独

立性の高い複数センサの統合(第15章)が定石になります。医療スクリーニングで「陽性でも慌てず再検査」と言われるのも同じ構造です。

解 2.7 ★★ 冗長系と独立性

方針

独立なら確率は積。「少なくとも一方」は余事象。(3) は独立の仮定そのものを疑う。

解答

$$(1) 10^{-3} \times 10^{-3} = 10^{-6}。$$

$$(2) 1 - 10^{-6} = 0.999999。$$

(3) よくない。問題文では電源喪失を個別故障とは別の共通原因としている。電源喪失(確率 10^{-4})が起これば両系統が同時に機能を失うので、

$$P(\text{両系統故障}) \geq 10^{-4} \gg 10^{-6}$$

となり、(1) の見積もりは100倍以上甘い。共通原因があると故障は**独立でなくなり**、「掛け算」による楽観的評価は成立しない。

ポイント

確率計算で最も危険な誤りが「**従属なものを独立と仮定して掛け算する**」ことです。冗長設計の本質は系統数を増やすことではなく、電源分離・異種冗長(カメラ+レーダーのような原理の異なるセンサ)などで**独立性を確保すること** — 第17章(信頼性工学)で共通原因故障として定量的に扱います。

解 2.8 ★★ モンティ・ホール問題

方針

「司会者がどのドアを開けたか」も確率的な情報。賞品の位置を仮説とし、観測「ドア3が開いた」の尤度 $P(\text{開3} \mid \text{賞} = i)$ を仮説ごとに比べる。

解答

事前確率は $P(\text{賞} = i) = \frac{1}{3}$ 。司会者の行動ルールから

$$P(\text{開3} \mid \text{賞1}) = \frac{1}{2}, \quad P(\text{開3} \mid \text{賞2}) = 1, \quad P(\text{開3} \mid \text{賞3}) = 0$$

全確率の公式で $P(\text{開3}) = \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \frac{1}{2}$ 。ベイズの定理より

$$P(\text{賞1} \mid \text{開3}) = \frac{\frac{1}{3} \cdot \frac{1}{2}}{\frac{1}{2}} = \frac{1}{3}, \quad P(\text{賞2} \mid \text{開3}) = \frac{\frac{1}{3} \cdot 1}{\frac{1}{2}} = \frac{2}{3}$$

よって変更すれば勝率 $2/3$ 、変更しなければ $1/3$ 。変更すべき。

ポイント

「残り2つだから五分五分」が誤りなのは、司会者の行動が賞の位置に**依存した**情報だからです。仮説によって尤度が違う($1/2$ 対 1)ことが情報の正体。もし司会者が中身を知らずランダムに開けてたまたまハズレだった、という設定なら答えは $1/2$ になります — データが同じでも、生成のしくみが違えば結論が変わる。統計モデリングの核心的教訓です。

解 2.9 ★★★★ RANSACの反復回数

方針

(1) は問題文で指定した独立近似の下で確率を掛ける。(2) は「 N 回とも失敗」の余事象を使う。

解答

(1) 1点がインライアである確率は0.5なので、4点すべてがインライアである確率は

$$w = (0.5)^4 = 0.0625$$

(2) 各試行も独立とするため、 N 回とも失敗する確率は $(1 - w)^N = (0.9375)^N$ 。したがって

$$1 - (0.9375)^N \geq 0.99 \iff N \geq \frac{\ln 0.01}{\ln 0.9375} \approx 71.4$$

よって必要な最小回数は **72回**。

ポイント

全対応点が有限で、インライアがちょうど I 個、総数が M 個であり、1回の試行内では重複なしに4点を選ぶなら、厳密な成功確率は $\binom{I}{4} / \binom{M}{4}$ である。本問の $(I/M)^4$ は、母集団が十分大きい場合などに用いる標準近似である。

解 2.10



反復送信とMAP復号

方針

(1) 多数決が誤る=3ビット中2ビット以上誤る。(2) 送信0と送信1を仮説としてベイズの定理。

解答

(1) 誤りビット数が2以上となる確率:

$$p_e = \binom{3}{2} p^2 (1 - p) + p^3 = 3(0.1)^2(0.9) + (0.1)^3 = 0.027 + 0.001 = 0.028$$

1ビット送信の誤り率 0.1 が 0.028 に改善する。

(2) 尤度は $P(001 | 0) = 0.9 \times 0.9 \times 0.1 = 0.081$ 、 $P(001 | 1) = 0.1 \times 0.1 \times 0.9 = 0.009$ 。事前が等確率なので

$$P(0 | 001) = \frac{0.081}{0.081 + 0.009} = 0.9$$

(3) 事後確率が大い方(ここでは0)を選ぶのが **MAP復号**(maximum a posteriori)。事前が等確率で通信路が対称なら、尤度の大小は「一致ビット数」の大小と同値になるため、MAP復号=多数決。どの位置が食い違ったかによらず「0が2票」なら事後確率は常に0.9になる。

ポイント

繰り返し符号は最も素朴な誤り訂正符号で、信頼性(誤り率 $0.1 \rightarrow 0.028$)を冗長性(伝送レート $1/3$)で買うトレードオフを体現しています。「事後確率最大の仮説を選ぶ」MAP判定は、ベイズ識別(問13.8)・状態推定(第15章)まで一貫して現れる、不確かさ下の意思決定の基本原理です。

第3章

離散型確率変数 — 解答解説

数えられる不確かさと代表的な分布

解 3.1 ★ PMFと期待値・分散

方針

最大値は「両方が k 以下」で押さえるのが定石: $P(M \leq k) = (k/6)^2$. PMFは差分で出す。

解答

$$(1) P(M \leq k) = P(X_1 \leq k)P(X_2 \leq k) = \left(\frac{k}{6}\right)^2 \text{ より}$$

$$P(M = k) = \frac{k^2 - (k-1)^2}{36} = \frac{2k-1}{36} \quad (k = 1, \dots, 6)$$

$$(2) E[M] = \frac{1}{36} \sum_{k=1}^6 k(2k-1) \\ = \frac{1 \cdot 1 + 2 \cdot 3 + 3 \cdot 5 + 4 \cdot 7 + 5 \cdot 9 + 6 \cdot 11}{36} = \frac{161}{36} \approx 4.47.$$

$$(3) E[M^2] = \frac{1}{36} \sum k^2(2k-1) = \frac{791}{36} \text{ より}$$

$$V[M] = \frac{791}{36} - \left(\frac{161}{36}\right)^2 = \frac{2555}{1296} \approx 1.97$$

ポイント

「最大値・最小値の分布はCDF(累積)の積で求める」— この手筋は一様分布の最尤推定(問9.6)で主役になります。期待値4.47がサイコロ1個の平均3.5より大きいのは、大きい方だけを拾うから。分散は必ず $E[X^2] - (E[X])^2$ の形で計算量を減らしましょう。

解 3.2 ★ 期待値と分散の計算

方針

定義どおり重み付き平均。分散は $E[X^2] - (E[X])^2$ 。

解答

(1) $E[X] = 0 \times 0.7 + 100 \times 0.2 + 500 \times 0.1 = 70$ 円。

$E[X^2] = 100^2 \times 0.2 + 500^2 \times 0.1 = 2000 + 25000 = 27000$ より

$$V[X] = 27000 - 70^2 = 22100, \quad \sigma = \sqrt{22100} \approx 148.7 \text{ 円}$$

(2) 期待値の線形性より $E[Y] = E[X] - 100 = -30$ 円。

ポイント

標準偏差(約149円)が平均(70円)の2倍以上 — 当たりが「まれで大きい」分布は散らばりが支配的で、期待値だけでは分布の姿は見えません(問3.10でこの限界を突き詰めます)。参加者側の期待利益が負(-30円)であることは、胴元側の期待利益が正であることと表裏一体です。

解 3.3 ★ 線形変換

方針

公式 $E[aX + b] = aE[X] + b$ 、 $V[aX + b] = a^2V[X]$ を適用。

解答

$$E[Y] = 2 \times 50 - 30 = 70, \quad V[Y] = 2^2 \times 100 = 400, \quad \sigma_Y = 20$$

ポイント

平行移動 b は散らばりに無関係、倍率 a は分散に2乗で効く(標準偏差には $|a|$ 倍)。単位換算・ゲイン調整・正規化はすべてこの公式の応用で、第4章の標準化 $Z = (X - \mu)/\sigma$ (平均0・分散1にする変換)がその代表です。

解 3.4 ★ 二項分布

方針

「独立な n 回の成否の合計」を見たら二項分布 $B(10, 0.05)$ 。

解答

$$(1) P(X = 1) = \binom{10}{1} (0.05)(0.95)^9 \approx 10 \times 0.05 \times 0.6302 \approx 0.315.$$

$$(2) P(X = 0) = (0.95)^{10} \approx 0.599.$$

$$(3) E[X] = np = 10 \times 0.05 = 0.5.$$

ポイント

「まず誤らない」ように見えて、1個以上誤る確率は約4割($1 - 0.599$)もあります — パケットにチェックサムや誤り訂正(問2.10)が必須な理由です。 $E[X] = np$ は、第6章の「指示変数の和」を使うと一瞬で導出できます。

解 3.5 ★ 幾何分布

方針

$X = k \Leftrightarrow$ 最初の $k - 1$ 回失敗して k 回目に成功。 $P(X > k)$ は「最初の k 回が全部失敗」。

解答

$$(1) P(X = 3) = (0.8)^2(0.2) = 0.128.$$

$$(2) E[X] = \frac{1}{p} = \frac{1}{0.2} = 5 \text{ 回}.$$

$$(3) P(X > 5) = (0.8)^5 = 0.328.$$

ポイント

$P(X > k) = (1 - p)^k$ というシンプルな裾の形が幾何分布の特長で、ここから無記憶性 $P(X > m + n \mid X > m) = P(X > n)$ が直ちに従います ($(1 - p)^{m+n} / (1 - p)^m = (1 - p)^n$)。「失敗続きだから次こそ当たる」は成り立ちません。連続版の無記憶性は指数分布(問4.6)です。なお平均 $1/p$ の導出は問6.2(MGF)でも確認します。

解 3.6 ★★ ポアソン分布

方針

「3件以上」は余事象で $P(0) + P(1) + P(2)$ を引く。

解答

$$(1) P(X = 0) = e^{-2} \approx 0.135.$$

$$(2) P(X \geq 3) = 1 - e^{-2} \left(1 + 2 + \frac{2^2}{2!} \right) = 1 - 5e^{-2} \approx 0.323.$$

ポイント

ポアソン分布は「単位時間(単位面積)あたりの発生数」の標準モデルで、 λ は平均であり**分散でもある**という強い性質を持ちます。なぜこの形になるのかは次問(大量×まれの極限)と第14章(ポアソン過程)で説明します。

解 3.7 ★★ ポアソン近似(イメージセンサ)

方針

厳密には二項分布である。試行回数が大きく、各試行の成功確率が小さく、平均 np が適度な大きさなのでポアソン近似を用いる。

解答

(1) $X \sim B(10^6, 2 \times 10^{-6})$ 。ここで $np = 2$ なので $X \approx \text{Po}(2)$ と近似する。

(2)

$$P(X \geq 1) \approx 1 - e^{-2} = 0.8646647 \dots$$

(3) 問題文の表示精度では厳密値と一致しており、この事象の確率を求める用途には非常に精度が高い。大きな二項係数を直接扱わずに済むことも利点である。

ポイント

独立なベルヌーイ変数の和に対するポアソン近似には、近似誤差を各成功確率の2乗和(本問では $np^2 = 4 \times 10^{-6}$)で評価する定理がある。ただし「 n と p がこの値なら常に十分」とする単一の規則はなく、必要精度と対象事象に応じて厳密値または誤差評価も確認する。

解 3.8 ★★ ショットノイズ

方針

階乗を消すため $E[X]$ と $E[X(X-1)]$ を計算する — ポアソンの計算の定石。

解答

(1)

$$E[X] = \sum_{k=1}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

$$E[X(X-1)] = \sum_{k=2}^{\infty} k(k-1) e^{-\lambda} \frac{\lambda^k}{k!} = \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} = \lambda^2$$

よって $E[X^2] = E[X(X-1)] + E[X] = \lambda^2 + \lambda$, $V[X] = \lambda^2 + \lambda - \lambda^2 = \lambda$ 。

(2) $SN = \frac{\lambda}{\sqrt{\lambda}} = \sqrt{\lambda}$ 。 $\lambda = 100$ のとき $SN = 10$ 。

(3) $\sqrt{4\lambda} = 2\sqrt{\lambda}$ より、光量を **4倍** にすればよい。

ポイント

光子の到来はポアソンのなので、ノイズの標準偏差 $\sqrt{\lambda}$ は物理的に避けられません(ショットノイズ限界)。「SN比は明るさの平方根でしか上がらない」— 暗所撮影がざらつく根本理由です。ISO感度を上げても λ は増えないため改善せず、露光を伸ばす・画素を束ねる・フレームを平均する(問7.7)ことだけが λ を増やします。

解 3.9 ★★★ 二項分布の最頻値

方針

階乗を含むPMFは「隣との比」を取ると劇的に簡単になる。比が1を超える範囲=増加区間。

解答

まず $0 < p < 1$ とする。このとき

$$r_k = \frac{P(X = k)}{P(X = k - 1)} = \frac{\binom{n}{k}}{\binom{n}{k-1}} \cdot \frac{p}{1-p} = \frac{n-k+1}{k} \cdot \frac{p}{1-p}$$

$$r_k \geq 1 \iff (n-k+1)p \geq k(1-p) \iff k \leq (n+1)p$$

よってPMFは $k \leq (n+1)p$ の範囲で非減少となり、その後は減少する。したがって最頻値は $k^* = \lfloor (n+1)p \rfloor$ ($(n+1)p$ が整数のときは $(n+1)p - 1$ と $(n+1)p$ の2点で最大)。端点では、 $p = 0$ なら $P(X = 0) = 1$ なので最頻値は0、 $p = 1$ なら $P(X = n) = 1$ なので最頻値は n である。

$n = 20, p = 0.3$: $(n+1)p = 6.3$ より最頻値は 6。(実際 $P(5) = 0.179, P(6) = 0.192, P(7) = 0.164$ 。)

ポイント

最頻値 $\approx np \approx$ 平均、つまり二項分布は平均付近に一山を持つ形です。「隣接比を取る」技は理論だけでなく数値計算でも重要: $P(X = k)$ を漸化式 $P(k) = r_k P(k-1)$ で順に求めれば、巨大な二項係数や p^k のアンダーフローを避けられます。

解 3.10 ★★

サンクトペテルブルクのパラドックス

方針

初めて表が出る回数を K とすると、 $P(K = k) = 2^{-k}$ である。

解答

(1) 賞金を $X = 2^K$ とすれば、非負確率変数の期待値は

$$E[X] = \sum_{k=1}^{\infty} 2^k 2^{-k} = \sum_{k=1}^{\infty} 1 = +\infty$$

したがって期待値は有限ではなく、 X は可積分でない。「期待値が存在しない」ではなく、拡張された意味で期待値は $+\infty$ である。

(2) 巨額賞金の確率は急速に小さく、1回だけの意思決定では資産制約・破産リスク・金額に対する効用の逓減などを無視できない。また胴元の支払能力にも限界がある。例えば賞金を $Y = \min(2^K, 2^{30})$ と明確に上限設定すると、

$$E[Y] = \sum_{k=1}^{29} 1 + 2^{30} P(K \geq 30) = 29 + 2 = 31$$

となり、有限の31円である。結論は「期待値を捨てる」ことではなく、実際の支払規則と意思決定者の効用・制約をモデルへ含める必要がある、ということである。

ポイント

有限な通常の期待値を使うには $E[|X|] < \infty$ が必要である。非負確率変数では期待値を $[0, +\infty]$ の値として常に定義でき、本問はその値が無限大になる例である。

第4章

連続型確率変数 — 解答解説

密度で測る不確かさと正規分布

解 4.1 ★ 密度関数の基本

方針

全積分=1 から c を決める。 F を先に作れば区間の確率は引き算で済む。

解答

$$(1) \int_0^2 cx \, dx = 2c = 1 \text{ より } c = \frac{1}{2}。$$

$$(2) 0 \leq x \leq 2 \text{ で } F(x) = \int_0^x \frac{t}{2} \, dt = \frac{x^2}{4} (x < 0 \text{ で } 0, x > 2 \text{ で } 1)。$$

$$(3) P(X \leq 1) = F(1) = \frac{1}{4}。$$

$$(4) E[X] = \int_0^2 x \cdot \frac{x}{2} \, dx = \left[\frac{x^3}{6} \right]_0^2 = \frac{4}{3}, E[X^2] = \int_0^2 \frac{x^3}{2} \, dx = \left[\frac{x^4}{8} \right]_0^2 = 2。$$

よって

$$V[X] = 2 - \left(\frac{4}{3} \right)^2 = \frac{2}{9}$$

ポイント

密度の値そのものは確率ではありません($f(2) = 1$ でも、密度は1を超えてもよい)。**確率は面積**です。「規格化 → CDF → 確率とモーメント」という手順は連続分布の基本動作で、以後何度も繰り返します。

解 4.2 ★ 一様分布

方針

一様分布の確率は区間の長さの比。(3) は条件付き確率の定義。

解答

$$(1) \frac{5-3}{10} = 0.2。$$

$$(2) E[X] = 5 \text{ 分}, V[X] = \frac{10^2}{12} = \frac{25}{3} \approx 8.33。$$

$$(3) P(X > 8 \mid X > 5) = \frac{P(X > 8)}{P(X > 5)} = \frac{0.2}{0.5} = 0.4。$$

ポイント

条件なしで「3分以上待つ」確率は $P(X > 3) = 0.7$ ですが、5分待った後にさらに3分待つ確率は 0.4 に下がっています — 一様分布では「待った分だけゴールが近づく」。次問の指数分布(無記憶:待っても状況が変わらない)との対比が、分布の個性を際立たせます。

解 4.3 ★ 指数分布

方針

平均 $= 1/\lambda$ 。裾の確率は $P(X > x) = e^{-\lambda x}$ が最速。

解答

$$(1) E[X] = \frac{1}{\lambda} = 1000 \text{ より } \lambda = 0.001 \text{ (毎時)}。$$

$$(2) P(X > 2000) = e^{-0.001 \times 2000} = e^{-2} \approx 0.135。$$

$$(3) P(X \leq 500) = 1 - e^{-0.5} \approx 0.393。$$

ポイント

指数分布のパラメータには「レート λ 」(本書)と「平均 $\theta = 1/\lambda$ 」の2流儀があり、ソフトウェアでも混在します(NumPy の `exponential` は平均を渡す)。式を書く前に定義を確認する癖をつけましょう。 $P(X > x) = e^{-\lambda x}$ (信頼度関数)は第17章の主役です。

解 4.4 ★ 標準正規分布

方針

対称性 $\Phi(-z) = 1 - \Phi(z)$ を使う。

解答

$$(1) P(Z \leq 1.5) = \Phi(1.5) = 0.9332。$$

$$(2) P(|Z| \leq 1.96) = 2\Phi(1.96) - 1 = 2 \times 0.9750 - 1 = 0.9500。$$

(3) 与えられた表の値を用いると

$$P(-1 < Z < 2) = 0.9772 - (1 - 0.8413) = 0.9772 - 0.1587 = 0.8185$$

ポイント

表の値は丸められているため、最終結果もその精度に合わせる。両側95%に対応する1.96と、片側95%に対応する約1.645は、区間推定と検定で繰り返し使う。

解 4.5 ★ 標準化

方針

$Z = (X - 120)/15$ で標準化する。

解答

$$(1) P(X > 150) = P(Z > 2) = 1 - 0.9772 = 0.0228.$$

(2) 問題文で与えられた丸め値をそのまま使うと、

$$P(90 < X < 150) = P(-2 < Z < 2) = 2 \times 0.9772 - 1 = 0.9544$$

である。より多くの桁を持つ標準正規分布の値を使えば約0.9545となる。

(3) 上側1%点が $z_{0.01} = 2.326$ なので、

$$x = 120 + 2.326 \times 15 = 154.89 \approx 154.9$$

ポイント

途中で丸めた表の値から、表より細かい桁を作らないことが大切である。標準化は、平均を原点、標準偏差を単位として測り直す操作である。

解 4.6 ★★ 無記憶性

方針

裾の確率 $P(X > x) = e^{-\lambda x}$ を条件付き確率の定義に入れるだけ。指数法則が鍵。

解答

(1) $\{X > s + t\} \subseteq \{X > s\}$ に注意して

$$P(X > s + t \mid X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t)$$

(2) 「 s 時間使った部品の残り寿命の分布は、新品の寿命の分布と同じ」— 使っても古びないというモデルであり、経年劣化のない偶発故障だけを表す。ブレーキパッドやベアリングのように摩耗・疲労で壊れる部品では、使用時間とともに故障しやすくなる(故障率が増加する)た

め指数分布は不適切で、ワイブル分布など故障率が時間変化するモデル(第17章)を使うべきである。

ポイント

非負で非退化な寿命分布が、すべての $s, t \geq 0$ について無記憶性を満たすなら指数分布になり、正の整数値で同様の性質を満たす非退化な分布なら本書の規約の幾何分布になります(特徴づけ定理)。逆に言えば、この意味で「無記憶とみなせる現象」のモデルは指数分布に決まります。この性質は第14章のポアソン過程(到着間隔が指数分布)の心臓部でもあります。

解 4.7 ★★ 中央値と平均

方針

中央値は $F(m) = 1/2$ を解く。平均は与えられている。

解答

$$(1) 1 - e^{-\lambda m} = \frac{1}{2} \iff m = \frac{\ln 2}{\lambda} = 1000 \ln 2 \approx 693 \text{ 時間。}$$

$$(2) F(1000) = 1 - e^{-1} \approx 0.632。$$

(3) 指数分布は右に長い裾を引き、少数の長寿命個体が平均を引き上げる。そのため平均(1000時間)は中央値(693時間)より大きくなり、「平均寿命の時点ですでに63%が故障している」ことになる。

ポイント

カタログの MTTF(平均寿命)を「その時間までは大体もつ」と読むのは危険です。歪んだ分布では平均・中央値・最頻値(指数分布では0!)がすべて異なります — どの代表値で語るべきかは目的次第で、この視点は第8章(記述統計)で一般化します。

解 4.8 ★★ 逆関数法(乱数生成)

方針

$Y \leq y$ を U の条件へ変換する。 $U = 0$ は起こらないため対数は確率1で定義される。

解答

$y \geq 0$ に対し、

$$P(Y \leq y) = P(U \geq e^{-\lambda y}) = 1 - e^{-\lambda y}$$

となる。 $y < 0$ ではこの確率は0なので、これは $\text{Exp}(\lambda)$ の分布関数と一致する。

したがって、一様乱数 U を生成して $-\lambda^{-1} \ln U$ に変換すれば指数乱数を得る。ただし実装では0を返さない一様乱数の仕様を確認するか、0を安全に除外する。

ポイント

一般に連続で狭義単調な分布関数 F なら、 $F^{-1}(U)$ は分布関数 F に従う。一般化逆関数を使えば、より広い場合にも拡張できる。

解 4.9 ★★★ ガウス積分

方針

1次元では原始関数が書けない。2乗して2次元にし、極座標 $dx dy = r dr d\theta$ で解く。

解答

(1) 被積分関数が非負なので、Tonelliの定理により反復積分と2重積分の同一視および積分順序の交換が正当化される。したがって

$$I^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(x^2+y^2)/2} dx dy = \int_0^{2\pi} \int_0^{\infty} e^{-r^2/2} r dr d\theta = 2\pi \left[-e^{-r^2/2} \right]_0^{\infty} =$$

$I > 0$ なので $I = \sqrt{2\pi}$ 。

(2) よって $\int \varphi(z) dz = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1$ 。 $E[Z] = \int z\varphi(z) dz = 0$ (奇関数の対称積分; 絶対可積分なので正当)。分散は部分積分で

$$\begin{aligned} E[Z^2] &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z \cdot ze^{-z^2/2} dz \\ &= \frac{1}{\sqrt{2\pi}} \left(\left[-ze^{-z^2/2} \right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-z^2/2} dz \right) = \frac{0 + \sqrt{2\pi}}{\sqrt{2\pi}} = 1 \end{aligned}$$

ポイント

正規分布に 2π が現れる理由はこの極座標変換にあります。「1次元で困ったら2次元化して回す」技は、レイリー分布(問5.9)・ボックス=ミュラー法と同根で、院試でも頻出です。ここで確立した $E = 0, V = 1$ と標準化(問4.5)を合わせれば、一般の $N(\mu, \sigma^2)$ の平均・分散も直ちに従います。

解 4.10 ★★★ 非単調変換

方針

$Y = Z^2$ は単調でないので公式は使えない。CDF $F_Y(y) = P(Z^2 \leq y)$ を書き下してから微分する。

解答

(1) $y > 0$ に対して

$$F_Y(y) = P(-\sqrt{y} \leq Z \leq \sqrt{y}) = \Phi(\sqrt{y}) - \Phi(-\sqrt{y}) = 2\Phi(\sqrt{y}) - 1$$

両辺を y で微分して ($\Phi' = \varphi$, 合成関数の微分)

$$f_Y(y) = 2\varphi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{y}} \cdot \frac{1}{\sqrt{2\pi}} e^{-y/2} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}$$

$$(2) E[Y] = E[Z^2] = V[Z] + (E[Z])^2 = 1 + 0 = 1.$$

ポイント

非単調変換では「±両側から寄与が来る」ため、CDF経由が安全です。密度は $y \rightarrow 0$ で発散しますが積分は有限(可積分) — 密度が1を超えたり発散したりしてよい、の極端な例です。この $\chi^2(1)$ 分布は、第8章で「分散の推定量の分布」 $\chi^2(n-1)$ の構成要素として統計学の主役になります。

第5章

多次元確率変数 — 解答解説

同時分布・共分散・相関

解 5.1 ★ 同時分布表

方針

周辺分布は行・列の合計。条件付きは「その列だけを切り出して規格化」。独立性は積の形になるか全マスで確認。

解答

(1) $P(X = 0) = 0.1 + 0.2 + 0.1 = 0.4$, $P(X = 1) = 0.6$. $P(Y = 0) = 0.2$, $P(Y = 1) = 0.4$, $P(Y = 2) = 0.4$.

(2) $P(X = 1 \mid Y = 2) = \frac{P(X = 1, Y = 2)}{P(Y = 2)} = \frac{0.3}{0.4} = 0.75$.

(3) たとえば $P(X = 0, Y = 0) = 0.1$ だが $P(X = 0)P(Y = 0) = 0.4 \times 0.2 = 0.08 \neq 0.1$. よって独立でない。

ポイント

独立性の判定は「1マスでも崩れたら従属」— 反例1つで十分です(逆に独立を示すには全マスの確認が必要)。周辺分布だけからは同時分布は復元できません: 同じ周辺を持つ従属な分布は無数にあります。「関係」の情報は同時分布にしか入っていない、というのがこの章の主題です。

解 5.2 ★ 共分散と相関係数

方針

$E[XY]$ は全組合せについて xy と確率を掛けて足す。

解答

$E[X] = 0.6$ 、 $E[Y] = 1.2$ 、 $E[XY] = 0.8$ なので、

$$\text{Cov}[X, Y] = 0.8 - 0.6 \times 1.2 = 0.08$$

また $V[X] = 0.24$ 、 $V[Y] = 0.56$ より、

$$\rho = \frac{0.08}{\sqrt{0.24 \times 0.56}} \approx 0.218$$

ポイント

相関係数は平行移動と正の尺度変更では不変である。一般に $a, c \neq 0$ に対し、 $\text{Corr}(aX + b, cY + d) = \text{sgn}(ac) \text{Corr}(X, Y)$ であり、片方だけを負の倍率で反転すると相関の符号も反転する。

解 5.3 ★ 連続型の同時密度

方針

周辺化は「消したい変数で積分」。(3) は領域 $\{x + y \leq 1\}$ 上の2重積分。

解答

$$(1) \int_0^1 \int_0^1 (x + y) dx dy = \int_0^1 \left(\frac{1}{2} + y \right) dy = \frac{1}{2} + \frac{1}{2} = 1.$$

$$(2) f_X(x) = \int_0^1 (x+y) dy = x + \frac{1}{2} (0 \leq x \leq 1).$$

(3)

$$\begin{aligned} P(X+Y \leq 1) &= \int_0^1 \int_0^{1-x} (x+y) dy dx = \int_0^1 \left(x(1-x) + \frac{(1-x)^2}{2} \right) dx \\ &= \int_0^1 \frac{1-x^2}{2} dx = \frac{1}{2} - \frac{1}{6} = \frac{1}{3} \end{aligned}$$

ポイント

連続の同時分布では「領域の上の体積」が確率です。積分範囲(この場合は三角形領域)を図で描いてから立式する習慣が、計算ミスを大きく減らします。なお $f(x, y) = x + y \neq f_X(x)f_Y(y) = (x + \frac{1}{2})(y + \frac{1}{2})$ なので X, Y は独立でないことも読み取れます。

解 5.4 ★★ 無相関だが独立でない例

方針

対称性から奇数次モーメントが0になることを使う。独立性は具体的な事象で反証する。

解答

(1) $E[X] = E[X^3] = 0$ なので、

$$\text{Cov}[X, Y] = E[X^3] - E[X]E[X^2] = 0$$

(2) $A = \{X > 1/2\}, B = \{Y > 1/4\} = \{|X| > 1/2\}$ とすると、 $P(A) = 1/4$ 、 $P(B) = 1/2$ 、 $P(A \cap B) = 1/4$ である。これは $P(A)P(B) = 1/8$ と異なるので独立でない。

(3) 相関係数が捉えるのは線形な関係であり、0でも非線形な依存が残る。

ポイント

散布図や、より一般的な依存尺度も併用する。本問のように連続な X から $Y = X^2$ が誤差なく決まる理想化モデルでは、同時分布は低次元の曲線上に集中し、連続変数としての相互情報量は単に正というだけでなく $+\infty$ になる。量子化や観測雑音を入れれば有限値となる。

解 5.5 ★★ 相関するセンサの平均

方針

$\text{Cov}[X, Y] = \rho\sigma^2$ を和の分散公式へ代入する。

解答

(1)

$$V\left[\frac{X+Y}{2}\right] = \frac{1}{4} (2\sigma^2 + 2\rho\sigma^2) = \frac{\sigma^2(1+\rho)}{2}$$

(2) $\sigma^2 = 4, \rho = 0.5$ なので分散は3。

(3) $\rho = 0$ なら分散は $\sigma^2/2$ 、 $\rho = 1$ なら σ^2 である。したがって元の各センサより分散が小さくなるのは $\rho < 1$ のときで、負の相関なら低減効果はさらに大きい。 $\rho = 0$ は無相関を意味するだけで、一般には独立性まで保証しない。

ポイント

2台の平均で必要なのはこの分散式であり、独立性そのものではない。ただし台数を増やした平均や分布全体を論じる場合には、全ての共分散構造やより強い仮定が必要になる。共通原因による正の相関が大きいほど平均化の効果は弱い。

解 5.6 ★★ 畳み込み(一様和)

方針

$f_Z(z) = \int f_X(x)f_Y(z-x)dx$ 。被積分関数が1になるのは $0 \leq x \leq 1$ かつ $0 \leq z - x \leq 1$ のとき — 積分区間を z の場合分けで決める。

解答

$f_X = f_Y = 1$ (区間 $[0, 1]$)なので、 $f_Z(z)$ は条件 $\max(0, z-1) \leq x \leq \min(1, z)$ を満たす区間の長さに等しい。

$0 \leq z \leq 1$ のとき: $x \in [0, z]$ で $f_Z(z) = z$ 。

$1 \leq z \leq 2$ のとき: $x \in [z-1, 1]$ で $f_Z(z) = 2 - z$ 。

$$f_Z(z) = \begin{cases} z & (0 \leq z \leq 1) \\ 2 - z & (1 \leq z \leq 2) \\ 0 & (\text{その他}) \end{cases}$$

グラフは $z = 1$ を頂点とする三角形(三角分布)。

ポイント

平らな分布を2つ足すと三角形 — 足すたびに滑らかで釣鐘型に近づいていきます(3つ足すと区分2次曲線)。これが中心極限定理(第7章)を目で見た姿です。画像処理では「ボックスフィルタを2回かける=三角フィルタ」という平滑化の常識に対応します(畳み込みはフィルタリングと同じ演算!)

解 5.7 ★★ ポアソン分布の再生性

方針

離散版の畳み込み $P(X + Y = n) = \sum_{k=0}^n P(X = k)P(Y = n - k)$ を書いて、二項定理でまとめる。

解答

$$\begin{aligned} P(X + Y = n) &= \sum_{k=0}^n e^{-\lambda} \frac{\lambda^k}{k!} \cdot e^{-\mu} \frac{\mu^{n-k}}{(n-k)!} \\ &= \frac{e^{-(\lambda+\mu)}}{n!} \sum_{k=0}^n \binom{n}{k} \lambda^k \mu^{n-k} = \frac{e^{-(\lambda+\mu)} (\lambda + \mu)^n}{n!} \end{aligned}$$

(途中、 $\frac{1}{k!(n-k)!} = \frac{1}{n!} \binom{n}{k}$ と二項定理を使った。)これは $\text{Po}(\lambda + \mu)$ の確率関数である。

ポイント

「足しても同じ族に留まる」性質を**再生性**と呼び、ポアソン・正規・二項(同じ p)・ガンマ(同じレート)が持ちます。2台のカメラの光子数の合算、2本の通信路のイベント数の合算がまたポアソンになる、という実務上も便利な性質です。第6章ではMGFを使うと、この証明が1行になることを見ます(問6.6・6.7)。

解 5.8 ★★★★ 2変量正規の条件付き分布

方針

指数部を y について平方完成すれば、「 y の正規密度 $\times x$ だけの因子」に分離できる。積分と条件付けの両方が一度に片づく。

解答

(1) $(y - \rho x)^2 + (1 - \rho^2)x^2 = y^2 - 2\rho xy + \rho^2 x^2 + x^2 - \rho^2 x^2 = x^2 - 2\rho xy + y^2$ 。成立。

(2) (1) より同時密度は

$$f(x, y) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \cdot \frac{1}{\sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{(y-\rho x)^2}{2(1-\rho^2)}\right)$$

と分解できる。第2因子は(x を固定すると)平均 ρx ・分散 $1 - \rho^2$ の正規密度なので、 y で積分すると1。よって

$$f_X(x) = \int f(x, y) dy = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

(3) $f(y | x) = \frac{f(x, y)}{f_X(x)}$ は上の分解の第2因子そのもの。すなわち

$$Y | X = x \sim N(\rho x, 1 - \rho^2)$$

ポイント

結論の読み方が重要です。(a) 条件付き期待値 $E[Y | X = x] = \rho x$ は x の1次式 — これが「回帰直線」の原型で、回帰(regression)という言葉の由来もこの設定にあります(第12章)。(b) 条件付き分散 $1 - \rho^2$ は x の値によらず一定で、 $|\rho|$ が大きいほど小さい — 「 X を知ることで Y の不確かさが ρ^2 の割合だけ削れる」。この2点は、最良予測(問6.9)・カルマンフィルタの更新式(第15章)として繰り返し再登場します。一般の $N(\mu_X, \sigma_X^2), N(\mu_Y, \sigma_Y^2)$ では $E[Y | X = x] = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X)$ 、 $V[Y | X = x] = \sigma_Y^2(1 - \rho^2)$ となります(標準化すれば本問に帰着)。

解 5.9 ★★★ レイリー分布

方針

独立性から同時密度は積。回転対称なので極座標が最適(問4.9と同じ技)。

解答

(1) 同時密度は $f(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$ 。極座標 $x = t \cos \theta$, $y = t \sin \theta$ ($dx dy = t dt d\theta$) で

$$\begin{aligned} F_R(r) &= \iint_{x^2 + y^2 \leq r^2} f(x, y) dx dy \\ &= \int_0^{2\pi} \int_0^r \frac{1}{2\pi\sigma^2} e^{-t^2/(2\sigma^2)} t dt d\theta = 1 - e^{-r^2/(2\sigma^2)} \end{aligned}$$

微分して $f_R(r) = \frac{r}{\sigma^2} e^{-r^2/(2\sigma^2)} (r \geq 0)$ 。

(2) 部分積分 ($u = r, dv = \frac{r}{\sigma^2} e^{-r^2/(2\sigma^2)} dr, v = -e^{-r^2/(2\sigma^2)}$) で

$$\begin{aligned} E[R] &= \int_0^\infty r f_R(r) dr = \left[-r e^{-r^2/(2\sigma^2)} \right]_0^\infty + \int_0^\infty e^{-r^2/(2\sigma^2)} dr \\ &= 0 + \frac{\sqrt{2\pi\sigma^2}}{2} = \sigma \sqrt{\frac{\pi}{2}} \end{aligned}$$

(最後の積分はガウス積分(問4.9)の半分。)

ポイント

「2次元等方ガウスノイズの大きさ」がレイリー分布 — 画像の勾配強度のノイズ、無線通信のフェージング振幅、風速の大きさなどのモデルとして頻出です。各成分の平均は0でも、大きさの平均は $\sigma\sqrt{\pi/2} \approx 1.25\sigma > 0$: ノイズは「向きを平均すると消えるが、大きさは残る」ことの定量化です。なお $R^2 = X^2 + Y^2$ は指数分布(自由度2のカイ二乗、問8.5)になり、第8章への伏線となります。

第6章

期待値の技法 — 解答解説

条件付き期待値とモーメント母関数

解 6.1 ★ 指示変数と線形性

方針

X を「各人が自分のものを受け取ったか」の指示変数の和に分解する。線形性は従属でも成り立つ。

解答

1_i = 「 i 番目の人が自分のプレゼントを受け取る」の指示変数とすると $X = 1_1 + \dots + 1_n$ 。一様な順列では各人が特定のプレゼントを受け取る確率は $1/n$ なので $E[1_i] = P(\text{自分のを受け取る}) = \frac{1}{n}$ 。線形性より

$$E[X] = \sum_{i=1}^n E[1_i] = n \cdot \frac{1}{n} = 1$$

ポイント

受け取り同士は明らかに従属(誰かが自分のを取れば他の人の状況が変わる)ですが、**線形性は従属でも使える** — ここが最大の武器です。問1.9では「1つも一致しない確率」を求めるのに包除原理という重装備が必要でしたが、「一致数の平均」だけなら1行で出る。難しい分布でも平均は簡単、という非対称性はアルゴリズムの期待計算量の解析(乱択クイックソートなど)で決定的に効きます。

解 6.2 ★ MGFの計算

方針

定義 $M(t) = E[e^{tX}] = \sum e^{tk}p(k)$ に入れる。ポアソンでは指数関数の級数にまとめる。

解答

$$(1) M(t) = e^{t \cdot 0}(1-p) + e^{t \cdot 1}p = 1-p+pe^t.$$

(2)

$$M(t) = \sum_{k=0}^{\infty} e^{tk} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}$$

$$(3) M'(t) = \lambda e^t e^{\lambda(e^t-1)} \text{ より } E[X] = M'(0) = \lambda.$$

$$M''(t) = (\lambda e^t + \lambda^2 e^{2t}) e^{\lambda(e^t-1)} \text{ より } E[X^2] = M''(0) = \lambda + \lambda^2. \text{ よって } V[X] = \lambda + \lambda^2 - \lambda^2 = \lambda.$$

ポイント

問3.8では級数の工夫($E[X(X-1)]$)が必要だった計算が、MGFなら「微分して0を代入」という機械的作業になります。母関数は「分布の情報をすべて1つの関数に詰め込んだ圧縮ファイル」で、モーメントの取り出し・和の分布・極限操作をすべて関数の操作に変換します。

解 6.3 ★ 全期待値の法則

方針

$N = n$ を固定すれば $X \mid N = n \sim B(n, 1/2)$ で $E[X \mid N = n] = n/2$ 。それを N について平均する。

解答

$E[X | N] = \frac{N}{2}$ なので、全期待値の法則より

$$E[X] = E\left[E[X | N]\right] = E\left[\frac{N}{2}\right] = \frac{1}{2} \cdot \frac{7}{2} = \frac{7}{4}$$

ポイント

「まず内側(コイン)を固定した N で解き、外側(サイコロ)で平均する」— 階層モデルの標準手順です。 $E[X | N]$ が N の関数(確率変数)である、という見方に慣れることがこの章の山場。以後、ベイズ統計の予測(第13章)やカルマンフィルタ(第15章)で常用します。

解 6.4 ★★ 全分散の法則

方針

$V[X | N] = N/4$ (二項分布の分散)、 $E[X | N] = N/2$ 。全分散の法則の2項に入れる。

解答

$$\begin{aligned} V[X] &= E\left[V[X | N]\right] + V\left[E[X | N]\right] = E\left[\frac{N}{4}\right] + V\left[\frac{N}{2}\right] \\ &= \frac{1}{4} \cdot \frac{7}{2} + \frac{1}{4} \cdot \frac{35}{12} = \frac{7}{8} + \frac{35}{48} = \frac{77}{48} \approx 1.60 \end{aligned}$$

ポイント

第1項(内側のばらつきの平均)はコイン投げ自体の運、第2項(平均のばらつき)は投げる回数が毎回違うことによる変動 — 不確かさが2つの源泉に**分解**されています。この分解は、大津の二値化(問8.7:クラス内分散+クラス間分散)や分散分析の考え方そのものです。

解 6.5 ★★ ランダムな個数の和(複合ポアソン)

方針

$N = n$ を固定すると普通の n 項の和。 $E[S | N] = N\mu$ 、 $V[S | N] = N\sigma^2$ を全期待値・全分散に入れる。

解答

(1) $E[S | N] = N\mu$ より $E[S] = E[N\mu] = \mu E[N] = \lambda\mu$ 。

(2) 独立性より $V[S | N] = N\sigma^2$ 。全分散の法則で

$$V[S] = E[N\sigma^2] + V[N\mu] = \sigma^2\lambda + \mu^2 V[N] = \lambda\sigma^2 + \lambda\mu^2 = \lambda(\sigma^2 + \mu^2)$$

(ポアソンでは $E[N] = V[N] = \lambda$ 。)

ポイント

$V[S]$ には「1件あたりのばらつき σ^2 」だけでなく「件数のゆらぎに μ^2 が乗った項」が入ります — 処理時間の平均 μ が大きいほど、件数変動が総時間を大きく揺らす。リアルタイムシステムの最悪時間見積もり、保険の総支払額(複合ポアソンモデル)、ネットワークの総トラフィックなど、「ランダム個数×ランダム量」の標準公式(ワルドの等式の拡張)です。

解 6.6 ★★ 正規分布のMGFと再生性

方針

e^{tx} × 正規密度の指数部をまとめて平方完成 — 「積分は正規密度の全積分=1に帰着させる」のが定石。

解答

(1)

$$M(t) = \int_{-\infty}^{\infty} e^{tx} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx$$

指数部は

$$tx - \frac{(x-\mu)^2}{2\sigma^2} = -\frac{(x - (\mu + \sigma^2 t))^2}{2\sigma^2} + \mu t + \frac{\sigma^2 t^2}{2}$$

(展開して確認できる。)よって

$$M(t) = e^{\mu t + \sigma^2 t^2 / 2} \int \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu - \sigma^2 t)^2}{2\sigma^2}\right) dx = e^{\mu t + \sigma^2 t^2 / 2}$$

(積分は平均 $\mu + \sigma^2 t$ の正規密度の全積分で1。)

(2) 独立性より

$$M_{X+Y}(t) = M_X(t)M_Y(t) = e^{\mu_1 t + \sigma_1^2 t^2 / 2} \cdot e^{\mu_2 t + \sigma_2^2 t^2 / 2} = e^{(\mu_1 + \mu_2)t + (\sigma_1^2 + \sigma_2^2)t^2 / 2}$$

これは $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ のMGF。MGFの一意性より $X + Y$ はこの正規分布に従う。

ポイント

畳み込み積分(第5章)を直接実行する代わりに、**関数の掛け算**で和の分布が決まる — これがMGFの主戦場です。「独立な正規の和は正規、平均も分散もそれぞれ足し算」はノイズ伝搬の計算やカルマンフィルタの予測ステップ(問15.5)で毎回使う基本定理になります。

解 6.7 ★★ MGFによる極限(二項→ポアソン)

方針

二項分布のMGFへ $p = \lambda/n$ を代入し、指数関数の基本極限を使う。

解答

(1) 任意の実数 t に対し、

$$M_{X_n}(t) = \left(1 + \frac{\lambda(e^t - 1)}{n}\right)^n \longrightarrow e^{\lambda(e^t - 1)}$$

右辺は $\text{Po}(\lambda)$ のMGFである。

(2) 各 M_{X_n} は実数全体で有限であり、極限も0の近傍で有限な確率分布のMGFである。したがってMGFの連続定理により、 X_n は $\text{Po}(\lambda)$ へ分布収束する。

ポイント

ここで使うのはMGFに対する連続定理である。特性関数に対するレヴィの連続性定理と混同しない。特性関数なら常に存在する一方、MGFを使う議論では0の近傍での存在条件が重要になる。

解 6.8 ★★★★★ クーポンコレクター問題

方針

「 $i - 1$ 種 $\rightarrow i$ 種」の各段階に分ければ、それぞれは幾何分布。全体はその和なので線形性で足す。

解答

(1) $i - 1$ 種持っているとき、新種が出る確率は $p_i = \frac{6 - (i - 1)}{6} = \frac{7 - i}{6}$ 。新種を引くまでの枚数 T_i は $\text{Ge}(p_i)$ に従い $E[T_i] = \frac{6}{7 - i}$ 。 $T = T_1 + \cdots + T_6$ と線形性より

$$\begin{aligned} E[T] &= \sum_{i=1}^6 \frac{6}{7 - i} = 6 \left(\frac{1}{6} + \frac{1}{5} + \frac{1}{4} + \frac{1}{3} + \frac{1}{2} + 1 \right) \\ &= 6H_6 = 6 \times \frac{49}{20} = 14.7 \text{ 枚} \end{aligned}$$

(2) 一般式 $E[T] = nH_n \approx n \ln n$ 。ランダム入力によるテストで全 n 分岐を踏むには、分岐数 n に対して $n \ln n$ のオーダーの試行が必要 — 特に「最後の1種(踏みにくい分岐)」に $E[T_n] = n$ 枚を要し、終盤ほど効率が落ちる。カバレッジの最後の数%が高くつく理由の確率的説明であり、狙い撃ちのテスト設計(directed testing)が必要になる根拠でもある。

ポイント

「段階に分けて幾何分布の和にする」分解は、待ち時間解析の常套手段です。分散も同様に $V[T] = \sum V[T_i]$ (各段階は独立) で計算でき、終盤の段階が分散の大半を占めることが分かります。ハッシュテーブルの全バケット充填、ガチャの完全収集など、応用範囲の広い名作問題です。

解 6.9 ★★★ 最良予測としての条件付き期待値

方針

$\hat{X} = E[X | Y]$ とおき、平方を展開する。仮定により全ての項は可積分である。

解答

$X - g(Y) = (X - \hat{X}) + (\hat{X} - g(Y))$ なので、

$$E[(X - g(Y))^2] = E[(X - \hat{X})^2] + E[(\hat{X} - g(Y))^2] + 2E[(X - \hat{X})(\hat{X} - g(Y))]$$

$\hat{X} - g(Y)$ は Y の可測関数だから、条件付き期待値の引き出し性により、

$$E[(X - \hat{X})(\hat{X} - g(Y)) | Y] = (\hat{X} - g(Y))E[X - \hat{X} | Y] = 0$$

したがって交差項は0であり、

$$E[(X - g(Y))^2] = E[(X - \hat{X})^2] + E[(\hat{X} - g(Y))^2] \geq E[(X - \hat{X})^2]$$

等号は $g(Y) = \hat{X}$ が確率1で成り立つとき、かつそのときに限る。よって条件付き期待値が平均二乗誤差を最小にする。

ポイント

これは L^2 空間における直交射影の定理である。二乗可積分性は単なる技術的飾りではなく、平均二乗誤差と内積を有限に扱うための条件である。

第7章

大数の法則と中心極限定理 — 解答解説

なぜ平均は信頼できるのか

解 7.1 ★ マルコフの不等式

方針

非負性と平均だけで裾を押さえるのがマルコフ。分布が分かればもちろん正確に計算できる — その差を体感する。

解答

$$(1) P(X \geq 200) \leq \frac{E[X]}{200} = \frac{50}{200} = 0.25。$$

(2) $P(X \geq 200) = e^{-200/50} = e^{-4} \approx 0.018$ 。上界 0.25 の1/10以下で、マルコフの評価はかなり緩い。

ポイント

マルコフの不等式は「非負・平均既知」という最小限の情報での**最悪ケース保証**です(実際、上界を達成する分布が存在するのでこれ以上は縮められない)。緩くても「分布の仮定なしに成り立つ」ことに価値があり、チェビシェフ(2次の情報を使用)・ヘフディング(有界性を使用)と、情報を足すほど鋭くなる不等式の階段の出発点です。

解 7.2 ★ チェビシェフの不等式

方針

$90 < X < 110$ は $|X - 100| < 10 = 2\sigma$ 。 $k = 2$ のチェビシェフ。

解答

$$(1) P(|X - 100| \geq 10) \leq \left(\frac{5}{10}\right)^2 = 0.25 \text{ より}$$

$$P(90 < X < 110) \geq 1 - 0.25 = 0.75$$

(2) 正規分布なら $P(|Z| < 2) = 0.9545$ 。チェビシェフの保証 0.75 は真の値よりだいぶ控えめだが、**どんな分布でも**(歪んでいても、裾が重くても)成り立つ。

ポイント

「 2σ 以内に75%以上、 3σ 以内に $8/9 \approx 89\%$ 以上」— 分布不問の普遍保証として覚える価値があります。正規分布の 95.45%・99.7% と並べて、「仮定が強いほど強い結論」という統計の基本構図を体で覚えましょう。チェビシェフの真の使い道は数値よりも、次問のように**極限定理の証明部品**になることです。

解 7.3 ★ 標本平均の平均と分散

方針

期待値は線形性、分散は独立性(共分散0)を使う。

解答

(1)

$$E[\bar{X}_n] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{n\mu}{n} = \mu$$

独立なので分散は加法的:

$$V[\bar{X}_n] = \frac{1}{n^2} \sum_{i=1}^n V[X_i] = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

$$(2) \sigma_{\bar{X}} = \frac{8}{\sqrt{64}} = 1.$$

ポイント

この2行の計算が第III部全体の心臓です。平均しても中心は動かず(不偏)、ばらつきは $1/n$ で縮む — ただし標準偏差では $1/\sqrt{n}$ 。「64回測って精度8倍」であって64倍ではない、という**平方根の壁**は、あらゆるサンプルサイズ設計に現れます。なお分散の加法性には独立(無相関で十分)が必要で、相関があると問5.5のように縮み方が鈍ります。

解 7.4 ★★ 大数の弱法則

方針

チェビシェフに $\bar{X}_n$ (平均 μ 、分散 σ^2/n)を入れるだけ。上界が $n \rightarrow \infty$ で0に落ちる。

解答

(1) チェビシェフの不等式を $\bar{X}_n$ に適用して

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{V[\bar{X}_n]}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

任意の $\varepsilon > 0$ でこれが成り立つので、 $\bar{X}_n$ は μ に確率収束する(大数の弱法則)。

$$(2) \frac{\sigma^2}{n\varepsilon^2} = \frac{100}{n} \leq 0.05 \text{ より } n \geq 2000.$$

ポイント

証明はチェビシェフ1行 — しかし意味は深く、「経験平均が真の平均を言い当てる」という**統計学の存在理由**そのものの保証です。(2) の $n = 2000$ は保証のための十分条件で、実際

にはCLTベース(問10.5)なら約400回で足ります。「確率収束」という収束概念の正確な意味と、より強い「概収束」(大数の強法則)との違いは第18章で扱います。

解 7.5 ★★ CLT(サイコロの和)

方針

和の平均・分散は n 倍。整数値の和なので $P(S \geq 380) = P(S \geq 379.5)$ と読み替えて標準化(連続修正)。

解答

$$(1) E[S] = 100 \times 3.5 = 350, V[S] = 100 \times \frac{35}{12} = \frac{875}{3} \approx 291.7, \sigma_S \approx 17.08.$$

(2)

$$\begin{aligned} P(S \geq 380) &= P(S \geq 379.5) \approx P\left(Z \geq \frac{379.5 - 350}{17.08}\right) \\ &= P(Z \geq 1.727) \approx 0.0421 \end{aligned}$$

厳密値 0.0420 とほぼ一致(小数第3位まで合う)。

ポイント

一様なサイコロの出目(平らな分布)でも、100個足せば釣鐘型に化ける — 元の分布の形を「忘れて」正規分布に向かうのがCLTの凄みです(問5.6の三角分布はその第一歩でした)。連続修正 ± 0.5 は「整数 k の確率を区間 $[k - 0.5, k + 0.5]$ の面積で受ける」補正で、 n が中程度のとき精度を目に見えて改善します。

解 7.6 ★★ 二項分布の正規近似

方針

$B(2500, 0.02) \approx N(50, 49)$ 。 $P(X \leq 40) = P(X \leq 40.5)$ と連続修正してから標準化。

解答

$$(1) E[X] = 2500 \times 0.02 = 50, \sigma = \sqrt{2500 \times 0.02 \times 0.98} = \sqrt{49} = 7.$$

(2)

$$\begin{aligned} P(X \leq 40) &\approx P\left(Z \leq \frac{40.5 - 50}{7}\right) \\ &= P(Z \leq -1.357) = 1 - \Phi(1.357) \approx 0.0874 \end{aligned}$$

厳密値 0.0839 と比べ、相対誤差4%程度の実用的な近似になっている。

ポイント

二項分布は「ベルヌーイの和」なのでCLTがそのまま適用できます。適用の目安は $np \geq 5$ かつ $n(1-p) \geq 5$ 程度(本問は $np = 50$ で余裕)。 p が小さく np も小さいときはポアソン近似(問3.7)、 np が大きければ正規近似 — 2つの近似の使い分けが整理できたことになります。ビット誤りの規格検証やA/Bテストの設計はこの計算の直接の応用です。

解 7.7 ★★ フレーム平均化

方針

ノイズの平均は標本平均そのもの。 $\sigma/\sqrt{n}$ を目標値以下にする。

解答

(1) 各フレームのノイズが独立(平均0、 $\sigma = 10$)なので、 n 枚平均後のノイズの標準偏差は $\frac{10}{\sqrt{n}}$ 。

$$(2) \frac{10}{\sqrt{n}} \leq 2 \iff \sqrt{n} \geq 5 \iff n \geq 25. \text{最小 } n = 25 \text{ 枚。}$$

(3) 信号(真値)は平均しても不変、ノイズの標準偏差は $1/\sqrt{n}$ 倍。よって SN比 = 信号/ノイズ標準偏差 は $\sqrt{n}$ 倍になる。

ポイント

天体写真のスタッキング、暗所撮影のマルチフレームNR、計測の多数回平均 — すべてこの1行の応用です。前提は「ノイズが独立・シーンが静止」:動きがあれば位置合わせ(レジストレーション、問16.7)が先に必要で、固定パターンノイズ(毎回同じずれ)は平均しても消えません(問5.5 の $\rho = 1$ の場合に相当)。ショットノイズ(問3.8)に対しても、 n 枚合算は実効的な λ を n 倍にするので同じ $\sqrt{n}$ 改善が成り立ちます。

解 7.8 ★★★★★ モンテカルロ法の精度設計

方針

命中は $\text{Ber}(p)$ 、 $\hat{p}$ はその標本平均。 $\hat{\pi} = 4\hat{p}$ の標準偏差は4倍。

解答

$$(1) \hat{p} \text{ はベルヌーイ標本の平均なので } \sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}.$$

$$(2) \sigma_{\hat{\pi}} = 4\sigma_{\hat{p}} = 4\sqrt{\frac{p(1-p)}{n}} \leq 0.01 \text{ を解いて}$$

$$n \geq \frac{16p(1-p)}{0.01^2} = \frac{16 \times 0.7854 \times 0.2146}{10^{-4}} = 26967.4944$$

したがって必要な最小整数は $n = 26968$ (約2.7万点)。

(3) 誤差(標準偏差)は $1/\sqrt{n}$ でしか縮まないなので、誤差を $1/10$ にするには n を 100 倍にする必要がある。

ポイント

独立標本による通常のモンテカルロ法では、標準誤差の**標本数に関する率** $O(1/\sqrt{n})$ は次元によらない。ただし定数(被積分関数の分散)は次元に依存し得る — この区別を保った上で、高次元積分では格子法より有利になる場合があります。一方で「精度1桁=コスト100倍」という遅さも本質的で、分散削減法(層化・重点サンプリングなど)の研究が生まれる動機になっています。 π の計算法としては非効率でも、「打って数える」だけで積分が推定できる汎用性が本体です。

解 7.9 ★★★ ヘフディングの不等式と精度評価

方針

不等式に数値を入れるだけだが、(3) の比較でチェビシェフとの**収束の速さの違い**(多項式 vs 指数)を見る。

解答

(1) $2e^{-2 \times 1000 \times 0.05^2} = 2e^{-5} \approx 0.0135$ 。すなわち観測誤り率は真の誤り率から ± 0.05 (± 5 パーセントポイント)以内に、確率98.6%以上で収まる。

(2) $2e^{-2n\varepsilon^2} \leq 0.05 \iff n \geq \frac{\ln(2/0.05)}{2\varepsilon^2} = \frac{\ln 40}{2 \times 0.0004} = \frac{3.689}{0.0008} \approx 4611.1$ 。よって $n = 4612$ 。

(3) チェビシェフでは $\frac{\sigma^2}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2} \leq 0.05$ より $n \geq \frac{1}{4 \times 0.05 \times 0.0004} = 12500$ 。ヘフディングの約2.7倍の標本が要る。差は信頼度を上げるほど開く: 上界 δ に対しチェビシェフは $n \propto 1/\delta$ (多項式)、ヘフディングは $n \propto \ln(1/\delta)$ (対数)で済むため、 $\delta = 10^{-6}$ のような高信頼保証では桁違いになる。

ポイント

「テスト精度 95.0% ± 何%?」に有限標本で答えるのがこの型の不等式で、機械学習理論 (PAC学習・汎化誤差上界)の土台です。指数型の裾評価(チェルノフ限界の一種)は、有界な変数の和が平均から大きく外れる確率が**指数的に小さい**ことを示します — CLTの「正規近似」を、近似でなく不等式として厳密化した道具と位置づけられます。証明(チェルノフ法: e^{tX} にマルコフを適用してMGFで最適化)は第6章の道具立てでできる良い演習です。

第8章

記述統計と標本分布 — 解答解説

データの要約と、統計量の確率分布

解 8.1 ★ 要約統計量と外れ値

方針

平均は合計÷個数。中央値は並べ替えて中央2つの平均($n = 8$ は偶数)。

解答

(1) 合計 $12 + 15 + 11 + 14 + 18 + 13 + 95 + 14 = 192$ より平均 $\bar{x} = 192/8 = 24$ ms。並べ替えると 11, 12, 13, 14, 14, 15, 18, 95 で、中央値は $\frac{14 + 14}{2} = 14$ ms。

(2) 8回中7回は11~18 msに収まっており、「典型」は**中央値14 ms**の方がよく表す。平均24 msは、たった1つの外れ値(95 ms:GCや再送などの突発)に引きずられた値で、どの測定値の代表にもなっていない。

ポイント

平均は外れ値1つで大きく動く(**頑健でない**)のに対し、中央値はほぼ動きません。応答時間のような右裾の長い量では、実務でも p50(中央値)・p95・p99 のパーセンタイルで語るのが標準です。ただし「外れ値を捨てる」のではなく、95 msが**なぜ**出たか(それ自体が重要な信号かもしれない)を調べるのが分析の作法です。

解 8.2 ★ 標本分散と不偏分散

方針

偏差の2乗和を作り、 n で割るか $n - 1$ で割るか。

解答

$\bar{x} = \frac{2 + 4 + 4 + 6 + 9}{5} = 5$ 。偏差は $-3, -1, -1, 1, 4$ 、2乗和は $9 + 1 + 1 + 1 + 16 = 28$ 。

$$s^2 = \frac{28}{5} = 5.6, \quad u^2 = \frac{28}{4} = 7$$

使い分け: 手元のデータ自体のばらつきの記述なら s^2 でもよいが、このデータを**母集団からの標本**とみなして母分散 σ^2 を推定するときは、偏りのない u^2 を使う(理由は問8.4)。

ポイント

用語と記号は書籍・ソフトで揺れます: NumPy の `var` は既定で n 割り (ddof=1 で $n - 1$ 割り)、Excel は VAR. P と VAR. S、電卓は σ_n と σ_{n-1} 。本書では一貫して「 s^2 : n 割り、 u^2 : $n - 1$ 割り」とします。**どちらの定義かを常に確認するのが実務の第一歩です。**

解 8.3 ★ 標本相関係数

方針

偏差積和 S_{xy} 、偏差2乗和 S_{xx}, S_{yy} を表で整理して計算。

解答

$\bar{x} = 3, \bar{y} = 5$ 。偏差は $x: -2, -1, 0, 1, 2, y: -3, -2, 0, 1, 4$ 。

$$S_{xy} = 6 + 2 + 0 + 1 + 8 = 17, \quad S_{xx} = 4 + 1 + 0 + 1 + 4 = 10, \\ S_{yy} = 9 + 4 + 0 + 1 + 16 = 30$$

$$r = \frac{17}{\sqrt{10 \times 30}} = \frac{17}{\sqrt{300}} \approx 0.981$$

非常に強い正の相関。

ポイント

r は第5章の相関係数 ρ の「データ版」で、 ± 1 に近いほど点が直線に載ることを意味します。

S_{xx}, S_{xy}, S_{yy} の3つの和は第12章(回帰分析)でそのまま主役になるので、この計算の型は体に入れておいてください。なお r が高くても因果関係は言えません(問12.6のポイントで再論)。

解 8.4 ★★ 不偏分散の不偏性

方針

$X_i - \bar{X} = (X_i - \mu) - (\bar{X} - \mu)$ と分解して展開。期待値では $E[(X_i - \mu)^2] = \sigma^2$ 、 $E[(\bar{X} - \mu)^2] = V[\bar{X}] = \sigma^2/n$ を使う。

解答

(1)

$$\begin{aligned} \sum (X_i - \bar{X})^2 &= \sum \left\{ (X_i - \mu) - (\bar{X} - \mu) \right\}^2 \\ &= \sum (X_i - \mu)^2 - 2(\bar{X} - \mu) \underbrace{\sum (X_i - \mu)}_{=n(\bar{X} - \mu)} + n(\bar{X} - \mu)^2 \\ &= \sum (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \end{aligned}$$

(2) 期待値を取ると

$$E\left[\sum (X_i - \bar{X})^2\right] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2$$

よって $E[U^2] = \frac{(n-1)\sigma^2}{n-1} = \sigma^2$ (不偏)、 $E[S^2] = \frac{n-1}{n}\sigma^2 < \sigma^2$ (過小評価)。

(3) 偏差を真の中心 μ からでなく、データに最も寄り添う点 $\bar{X}$ から測っているため、2乗和は必ず小さめに出る((1) の第2項がその縮み分)。縮む量は平均してちょうど「1個分」 σ^2 — 平均の推定に自由度を1つ使った、と言い換えられる。 $n-1$ で割るのはその補填である。

ポイント

恒等式 (1) は本書で最も働く式のひとつで、 χ^2 分布の自由度が $n-1$ になる理由(基本定理)も、回帰の平方和分解(問12.2)もこの型です。極端な例として $n=1$ では $\bar{X} = X_1$ で偏差2乗和は常に0 — 1点からばらつきは推定できない、という当然の事実が $n-1=0$ で割れない形に現れています。

解 8.5 ★★ カイ二乗分布の基本性質

方針

定義 $\chi^2(m) = Z_1^2 + \cdots + Z_m^2$ に、線形性と独立性を適用。(3) は問5.9のレイリー分布の結果の言い換え。

解答

(1) $E[Z_i^2] = V[Z_i] = 1$ より $E[\chi^2(m)] = \sum E[Z_i^2] = m$ 。

(2) $V[Z_i^2] = E[Z_i^4] - (E[Z_i^2])^2 = 3 - 1 = 2$ 。独立なので分散は加法的で $V[\chi^2(m)] = 2m$ 。

(3) $Z_1^2 + Z_2^2$ は、独立な $N(0, 1)$ 2成分の2乗和。問5.9($\sigma = 1$)より $P(Z_1^2 + Z_2^2 > y) = P(R > \sqrt{y}) = e^{-y/2}$ 。これはレート $1/2$ の指数分布の裾に等しいので $\chi^2(2)$

$= \text{Exp}(1/2)$ 。よって

$$P(\chi^2(2) > 5.991) = e^{-5.991/2} = e^{-2.9955} \approx 0.0500$$

ポイント

5.991 は $\chi^2(2)$ の上側5%点 $\chi^2_{0.05}(2)$ で、独立性の検定(問11.9)などで頻出の定数です。

「平均 m ・分散 $2m$ 」から、自由度が大きいくほど相対的ばらつき $\sqrt{2/m}$ が減り、 $\chi^2(m) \approx N(m, 2m)$ (CLT)と近づくことも読み取れます。 $\chi^2(m)$ は形状母数 $m/2$ 、レート母数 $1/2$ (尺度母数2)のガンマ分布であり、この同一視は第14章・第17章で生きてきます。

解 8.6 ★★ t分布 — なぜ裾が重いのか

方針

T を「標準正規 ÷ カイ二乗変数から作った独立な平方根」の形へ変形する。

解答

(1) 正規母集団の基本定理より、

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \quad W = \frac{(n-1)U^2}{\sigma^2} \sim \chi^2(n-1)$$

であり、 Z と W は独立である。したがって

$$T = \frac{Z}{\sqrt{W/(n-1)}} \sim t(n-1)$$

(2) 推定された分母 U は確率的に小さくなることもあり、そのとき比の絶対値が大きくなる。この追加の不確かさが正規分布より重い裾として現れる。

(3) $2.262 > 1.960$ なので、自由度9で正規分布の臨界値を代用すると信頼区間を狭く作り、検定では棄却しやすくなる。

ポイント

自由度が増えるとt分布は標準正規分布へ近づくが、「標本数30以上なら必ず正規で代用してよい」は便宜的な経験則にすぎない。例えば自由度29でも両側95%の臨界値は約2.045で、1.960とは一致しない。正規母集団で母分散が未知ならt分布が厳密なので、計算機が使える場面では標本数にかかわらずt分布を用いるのが自然である。

解 8.7 ★★★ 大津の二値化(分散の分解)

方針

各しきい値で w_0, μ_0, w_1, μ_1 を出して σ_B^2 に代入。確率は度数÷10。

解答

輝度の分布は $P(1) = 0.4, P(2) = 0.3, P(6) = 0.2, P(7) = 0.1$ 。全体平均 $\mu = 0.4 + 0.6 + 1.2 + 0.7 = 2.9$ 。

(1) 各 t で:

$$t = 1: w_0 = 0.4, \mu_0 = 1; w_1 = 0.6, \mu_1 = \frac{0.6 + 1.2 + 0.7}{0.6} = \frac{25}{6} \circ \sigma_B^2 = 0.24 \left(\frac{25}{6} - 1 \right)^2 \approx 2.41。$$

$$t = 2: w_0 = 0.7, \mu_0 = \frac{0.4 + 0.6}{0.7} = \frac{10}{7}; w_1 = 0.3, \mu_1 = \frac{1.2 + 0.7}{0.3} = \frac{19}{3}。$$

$$\sigma_B^2 = 0.21 \left(\frac{19}{3} - \frac{10}{7} \right)^2 \approx 5.05。$$

$$t = 6: w_0 = 0.9, \mu_0 = \frac{2.2}{0.9} \approx 2.44; w_1 = 0.1, \mu_1 = 7 \circ \sigma_B^2 = 0.09(7 - 2.44)^2 \approx 1.87。$$

よって指定された候補の中での最適しきい値は $t = 2$ (輝度2以下と6以上の間で切る): $\sigma_B^2 \approx 5.05$ 。なお、しきい値を任意の整数から選ぶなら、輝度3・4・5の画素がないため $t = 2, 3, 4, 5$ はすべて同じ分割を与え、いずれも最適である。ヒストグラムの2つの山の谷で切れており、直感とも一致する。

(2) $E[X^2] = 0.4 + 1.2 + 7.2 + 4.9 = 13.7$ より $\sigma^2 = 13.7 - 2.9^2 = 5.29$ 。 $\sigma_W^2 = 5.29 - 5.05 \approx 0.24$ 。

(3) クラスラベル C (0か1) を条件とする全分散の法則 $V[X] = E[V[X | C]] + V[E[X | C]]$ で、第1項がクラス内分散 σ_W^2 (各クラス内のばらつきの重み付き平均)、第2項がクラス間分散 σ_B^2 (クラス平均のばらつき)。よって $\sigma^2 = \sigma_W^2 + \sigma_B^2$ は恒等式であり、「クラス間分散の最大化」と「クラス内分散の最小化」は同じことになる。

ポイント

大津の方法 (Otsu, 1979) は今も画像二値化の第一選択で、その正体は第6章で学んだ**全分散の法則**の最適化でした。「よい分割=各クラスは締まり、クラス同士は離れる」という規準は、クラスターリング (k-means) や判別分析、分散分析 (ANOVA) と同じ思想です。実装では全しきい値の σ_B^2 を累積和で $O(L)$ に計算します。

解 8.8 ★★★ 標本分布の定理の運用

方針

基本定理に $\sigma^2 = 36$, $n = 9$ を代入するだけ。(2) は U^2 の不等式を χ^2 の不等式に翻訳する。

解答

(1) $\bar{X} \sim N\left(\mu, \frac{36}{9}\right) = N(\mu, 4)$ (標準偏差2)。

$$(2) \frac{(n-1)U^2}{\sigma^2} = \frac{8U^2}{36} \sim \chi^2(8) \text{ なので}$$

$$P(U^2 > 2\sigma^2) = P\left(\frac{8U^2}{36} > 16\right) = P(\chi^2(8) > 16) = 0.042$$

$$(3) T = \frac{\bar{X} - \mu}{U/\sqrt{9}} \sim t(8).$$

ポイント

(2) は「分散の推定は意外に暴れる」ことの定量化です: $n = 9$ でも、不偏分散が真の2倍を超える確率が4%もあります ($V[U^2] = 2\sigma^4/(n-1)$ と大きい)。平均の推定(標準偏差 $\sigma/\sqrt{n}$)より分散の推定はずっと多くの標本を要する — 第10章の分散の信頼区間(問10.6)が広く非対称になる伏線です。

第9章

点推定 — 解答解説

最尤法と推定量の良さ

解 9.1 ★ 推定量の比較

方針

期待値の線形性で不偏性、独立性で分散を計算。係数の2乗和が分散を決める。

解答

$$(1) E[T_1] = \frac{\mu + \mu}{2} = \mu, E[T_2] = \frac{\mu + 2\mu}{3} = \mu. \text{ともに不偏。}$$

(2)

$$V[T_1] = \frac{\sigma^2 + \sigma^2}{4} = \frac{\sigma^2}{2}, \quad V[T_2] = \frac{\sigma^2 + 4\sigma^2}{9} = \frac{5\sigma^2}{9}$$

$\sigma^2 > 0$ かつ $\frac{1}{2} < \frac{5}{9}$ なので、 T_1 (等重み平均)の方が分散が厳密に小さく望ましい。

ポイント

不偏推定量は無数にあり、その中で**分散が小さいものが良い** — これが比較の第一基準です。実は係数 $c_1 + c_2 = 1$ の制約下で $c_1^2 + c_2^2$ を最小にするのは等重み(コーシー・シュワルツ)で、同じ精度の観測は平等に混ぜるのが最適。観測ごとに精度が違う場合の最適重みは「精度(分散の逆数)比例」になり、これがセンサ融合(問15.2)の公式です。

解 9.2 ★ ベルヌーイのMLE

方針

内点では対数尤度を微分し、端のデータでは元の尤度を境界上で比較する。

解答

$0 < k < n$ では

$$\ell'(p) = \frac{k}{p} - \frac{n-k}{1-p} = 0 \iff \hat{p} = \frac{k}{n}$$

かつ2階微分は負なので一意な最大点である。 $k=0$ なら尤度 $(1-p)^n$ は $p=0$ で最大、 $k=n$ なら p^n は $p=1$ で最大である。よって全ての場合に $\hat{p} = k/n = \bar{X}$ 。

$$E[\hat{p}] = p, \quad V[\hat{p}] = \frac{p(1-p)}{n}$$

ポイント

対数尤度の微分式は $p=0, 1$ で使えない。最尤法では、停留点だけでなくパラメータ空間の境界も調べる。

解 9.3 ★ ポアソンのMLE

方針

観測の総和が正なら内点で微分し、総和が0なら尤度を境界まで調べる。

解答

$S = \sum_i x_i > 0$ のとき、

$$\ell(\lambda) = -n\lambda + S \ln \lambda + \text{const}, \quad \ell'(\lambda) = -n + \frac{S}{\lambda}$$

より $\hat{\lambda} = S/n = \bar{x}$ 。2階微分は負である。全観測が0なら尤度は $e^{-n\lambda}$ であり、 $\lambda \geq 0$ 上の最大点は境界 $\lambda = 0$ 。この場合も $\hat{\lambda} = \bar{x} = 0$ である。

ポイント

$\lambda = 0$ では分布が0へ退化する。対数にして微分する方法だけでは、この正しい境界解を見落とす。

解 9.4 ★★ 指数分布のMLE — 不偏でない例

方針

密度の積 $\lambda^n e^{-\lambda \sum x_i}$ の対数を微分。(2) は与えられた期待値を読むだけ。

解答

(1) $\sum x_i > 0$ という問題文の条件の下で、 $\ell(\lambda) = n \ln \lambda - \lambda \sum x_i$ 。

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum x_i = 0 \iff \hat{\lambda} = \frac{n}{\sum x_i} = \frac{1}{\bar{x}}$$

(2) $E[\hat{\lambda}] = \frac{n\lambda}{n-1} \neq \lambda$ なので不偏でない(平均して $\frac{n}{n-1}$ 倍だけ過大評価)。ただし $n \rightarrow \infty$ で $\frac{n}{n-1} \rightarrow 1$ となり偏りは消える(漸近不偏; 一致推定量でもある)。不偏修正版は

$$\hat{\lambda}^* = \frac{n-1}{n} \hat{\lambda} = \frac{n-1}{\sum x_i}$$

ポイント

全観測値が0という確率0の標本では、 $\ell(\lambda) = n \ln \lambda$ が $\lambda \rightarrow \infty$ で増え続けるため有限なMLEは存在しない。「逆数」という非線形変換が偏りの原因です: $E[1/\bar{X}] \neq 1/E[\bar{X}]$ (イエッセンの不等式で、凸関数 $1/x$ では $\geq$ 側にずれる)。MLEは一致性・漸近正規性という大標

本の良さを持つ一方、小標本では不偏と限らない — 故障率推定(第17章)のように n が小さい現場では、この偏りが無視できません。

解 9.5 ★★ 正規分布のMLE

方針

まず μ 、次に σ^2 で最大化する。非定数標本という仮定により残差平方和は正である。

解答

(1) 対数尤度は

$$\ell = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

であり、微分から

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s^2$$

を得る。

(2) $E[s^2] = (n-1)\sigma^2/n$ なので分散のMLEは下方へ偏る。不偏分散は $u^2 = ns^2/(n-1)$ である。

(3) 全観測値が同じ c なら $\mu = c$ とした残差平方和は0で、尤度は $(2\pi\sigma^2)^{-n/2} \cdot \sigma^2 \downarrow 0$ で無限大になるが、パラメータ空間には $\sigma^2 = 0$ が含まれない。したがって上限は達成されず、通常の正規密度モデル内にMLEは存在しない。

ポイント

公式を使う前に、最大値がパラメータ空間内で実際に達成されるかを確認する。退化分布を別モデルとして許すかどうかは、通常の正規密度モデルとは別の定義上の選択である。

解 9.6 ★★ 一様分布のMLE — 微分で出ない例

方針

尤度は θ の減少関数(定義域つき)。グラフの形で最大点を決める。最大値の分布は問3.1の「CDFの積」。

解答

(1) 各点の密度は $1/\theta (0 \leq x_i \leq \theta)$ なので

$$L(\theta) = \begin{cases} \theta^{-n} & (\theta \geq \max_i x_i) \\ 0 & (\theta < \max_i x_i) \end{cases}$$

θ^{-n} は減少関数なので、許される最小の θ 、すなわち $\hat{\theta} = \max_i x_i$ で最大になる。境界で最大となるため微分=0では求まらない。

(2) $F_M(m) = P(\text{全部} \leq m) = \left(\frac{m}{\theta}\right)^n (0 \leq m \leq \theta)$ 、 $f_M(m) = \frac{nm^{n-1}}{\theta^n}$ 。

$$E[M] = \int_0^\theta m \cdot \frac{nm^{n-1}}{\theta^n} dm = \frac{n}{n+1} \theta$$

(3) $E[M] < \theta$ なので不偏でない(最大値は必ず θ 以下だから当然、常に過小評価)。不偏修正版は

$$\hat{\theta}^* = \frac{n+1}{n} \max_i x_i$$

ポイント

全観測値が0という確率0の標本では、 $L(\theta) = \theta^{-n}$ が $\theta \downarrow 0$ で発散し、通常のパラメータ空間 $\theta > 0$ ではMLEが存在しない。「観測の最大値より少しだけ外側に真の端がある」— この $(n+1)/n$ 倍の補正は、第二次大戦で連合軍が捕獲戦車の製造番号からドイツの生産台数を見積もった「戦車問題」として有名です。パラメータが分布の台(サポート)を決めるモデル

では微分の議論(正則条件)が崩れる、という理論上も重要な例で、次問でその「異常な良さ」が現れます。

解 9.7 ★★★ モーメント法との対決

方針

$V[\bar{X}] = V[X]/n$ と、与えられた $V[M]$ に定数倍の2乗を掛けるだけ。オーダー比較が本題。

解答

$$(1) E[\tilde{\theta}] = 2E[\bar{X}] = 2 \cdot \frac{\theta}{2} = \theta (\text{不偏}). V[X] = \frac{\theta^2}{12} \text{ より}$$

$$V[\tilde{\theta}] = 4 \cdot \frac{\theta^2/12}{n} = \frac{\theta^2}{3n}$$

(2)

$$V[\hat{\theta}^*] = \left(\frac{n+1}{n}\right)^2 V[M] = \frac{(n+1)^2}{n^2} \cdot \frac{n\theta^2}{(n+1)^2(n+2)} = \frac{\theta^2}{n(n+2)}$$

(3) $V[\tilde{\theta}] = O(1/n)$ に対し $V[\hat{\theta}^*] = O(1/n^2)$ 。たとえば $n = 10$ で $\theta^2/30$ 対

$\theta^2/120$ と4倍、 $n = 100$ では34倍の差がつき、最大値ベースの推定が圧倒的に優れる。直感的には、 θ (分布の端)の情報は端の近くの観測に集中しており、平均 $\bar{X}$ はその情報をほとんど捨てているためである。

ポイント

通常の(正則な)モデルでは不偏推定量の分散は $1/n$ より速く落ちません(クラメール・ラオ下限、次問)。 $1/n^2$ という「限界超え」が起きたのは、台がパラメータに依存する**非正則モデル**で下限の前提が崩れているからです。モーメント法(積率を合わせる素朴な方法)は手軽ですが、情報を捨てることがある — 最尤法が標準とされる理由の好例です。

解 9.8 ★★★ フィッシャー情報量とクラメール・ラオ下限

方針

$0 < p < 1$ なのでスコアと2階微分は有限に扱え、通常の正則条件を適用できる。

解答

(1) スコアは $X/p - (1 - X)/(1 - p)$ なので、

$$I(p) = p \frac{1}{p^2} + (1 - p) \frac{1}{(1 - p)^2} = \frac{1}{p(1 - p)}$$

また対数尤度の2階微分を使っても、

$$-E \left[\frac{\partial^2}{\partial p^2} \log f(X; p) \right] = \frac{1}{p} + \frac{1}{1 - p} = \frac{1}{p(1 - p)}$$

となる。

(2) n 観測のクラメール・ラオ下限は $1/[nI(p)] = p(1 - p)/n$ 。これは $V[\bar{X}]$ と一致するため、 $\bar{X}$ はこの正則な内点モデルで有効である。

ポイント

$p = 0, 1$ では上の式が特異になり、通常の内点に対するクラメール・ラオの議論をそのまま適用できない。境界では $\bar{X}$ の分散自体は0である。

解 9.9 ★★★ 情報量の計算と漸近正規性

方針

1観測のスコアの分散を計算し、独立な n 観測では情報量が n 倍になることを使う。

解答

(1) 正規分布のスコアは $(X - \mu)/\sigma^2$ なので、

$$I(\mu) = \frac{E[(X - \mu)^2]}{\sigma^4} = \frac{1}{\sigma^2}$$

(2) ポアソン分布のスコアは $(X - \lambda)/\lambda$ なので、

$$I(\lambda) = \frac{V[X]}{\lambda^2} = \frac{1}{\lambda}$$

(3) 総情報量は $nI(\lambda) = n/\lambda$ 、クラメール・ラオ下限は λ/n である。実際、

$$V[\hat{\lambda}] = V[\bar{X}] = \frac{\lambda}{n}$$

なので下限を達成する。さらに中心極限定理(またはMLEの漸近正規性)から、 $\hat{\lambda}$ は漸近的に $N(\lambda, \lambda/n)$ に従う。絶対標準誤差は $\sqrt{\lambda/n}$ で λ とともに増えるが、相対標準誤差は $1/\sqrt{n\lambda}$ で、総期待カウント $n\lambda$ とともに減る。

ポイント

「1観測あたりのパラメータ情報量 $1/\lambda$ 」と「観測カウントのSN比」を混同しない。明るいほど絶対ゆらぎは大きいが、相対精度は改善する。

第10章

区間推定 — 解答解説

誤差を幅で保証する

解 10.1 ★ z区間(σ 既知)

方針

ピボット $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ を $\pm z_{0.025} = \pm 1.960$ で挟んで μ について解く。

解答

標準誤差は $\frac{\sigma}{\sqrt{n}} = \frac{5}{\sqrt{25}} = 1$ 。95%信頼区間は

$$102.4 \pm 1.960 \times 1 = (100.44, 104.36)$$

ポイント

構造は常に「推定値 $\pm$ 分位点 $\times$ 標準誤差」です。 $P(-1.96 \leq Z \leq 1.96) = 0.95$ というデータを取る前に成り立つ確率の式を、 μ を主語に書き換えたものが信頼区間 — この「書き換え」の出自を覚えておくと、次問の解釈問題が明快になります。

解 10.2 ★ 信頼区間の解釈

方針

確率変数はどれか(区間の端点)、定数はどれか(μ)を突き止める。

解答

正しいのは (2)。

(1) が誤りの理由:(頻度論の立場では) μ は未知だが**定数**であり、確定した区間 $(100.44, 104.36)$ が μ を含むか否かは(我々が知らないだけで)すでに決まっている。確率 95%を持つのは「 μ の居場所」ではなく、**データに応じて動く区間という手続きの方**である。取得前なら $P(\bar{X} - 1.96 \leq \mu \leq \bar{X} + 1.96) = 0.95$ は正しいが、数値を代入した後の文には確率は残らない。

(3) が誤りの理由:この区間は**母平均**の推定範囲であり、個々の測定値の散らばる範囲ではない。母集団の中央95%範囲は $\mu \pm 1.96\sigma = \mu \pm 9.8$ 。未知の μ を本問の標本で推定して次の1測定値を予測する95%予測区間なら、 $\bar{x} \pm 1.96\sigma\sqrt{1 + 1/n}$ を用いる。母集団割合を所定の信頼度で覆う許容区間は、さらに別の概念である。

ポイント

(1) の読み方(「真値がこの区間にある確率」)を正当化したければ、 μ 自体を確率変数として扱う**ベイズ統計**の信用区間(第13章)へ進むことになります。(3) の混同(平均の区間と個々の値の区間)は実務で最も多い誤読で、 $1/\sqrt{n}$ の縮みがあるかどうかで見分けられます。

解 10.3 ★★ t区間(σ 未知)

方針

σ 未知なので u で置き換え、分位点を $t_{0.025}(8)$ にする(問8.6)。

解答

標準誤差は $\frac{u}{\sqrt{n}} = \frac{3.6}{3} = 1.2$ 。95%信頼区間は

$$50.2 \pm 2.306 \times 1.2 = 50.2 \pm 2.77 = (47.43, 52.97) \text{ ms}$$

ポイント

もし誤って $z_{0.025} = 1.960$ を使うと 50.2 ± 2.35 と狭くなり、95%を名乗りながら実際の被覆率はそれ未満になります(過大申告)。「 σ を推定した分の追加の不確かさ」を t 分布の重い裾が引き受けている — n が小さいほど t 分位点は大きく、その分だけ謙虚に幅が広がります。

解 10.4 ★★ 母比率の信頼区間

方針

$\hat{p}$ はベルヌーイ平均。CLT(問7.6)で正規近似し、標準誤差に $\hat{p}$ を代入する。

解答

標準誤差は $\sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0.8 \times 0.2}{400}} = 0.02$ 。95%信頼区間は

$$0.8 \pm 1.960 \times 0.02 = 0.8 \pm 0.039 = (0.761, 0.839)$$

ポイント

「検出率80%」という報告は、 $n = 400$ では $\pm 4\%$ の幅を持っています。ベンチマークで80.0%と81.5%を比べて優劣を断じるのは、この幅の前では早計 — 差の議論は第11章の検定(問11.7)へ。なお $n\hat{p}$ や $n(1 - \hat{p})$ が小さいときは正規近似が崩れ、Wilson区間などの改良版が推奨されます(大標本では本問の形で十分)。

解 10.5 ★★ 標本サイズ的设计

方針

誤差幅 $E = z_{\alpha/2}\sigma/\sqrt{n}$ を目標以下にする不等式を n について解く。

解答

$$1.96 \times \frac{15}{\sqrt{n}} \leq 2 \iff \sqrt{n} \geq \frac{1.96 \times 15}{2} = 14.7 \iff n \geq 14.7^2 = 216.09$$

よって $n = 217$ (切り上げ)。

ポイント

実験の前に n を決める、が正しい順序です(取りながら「有意になるまで」続けるのは第11章で述べる禁じ手)。公式から:幅を半分にしたいければ n は4倍、精度1桁なら100倍 — 問7.8のモンテカルロと同じ「平方根の壁」です。 σ が未知なら予備実験・過去データ・保守的な上限で見積もります(比率なら $p(1-p) \leq 1/4$ を使う安全側の設計が定石)。

解 10.6 ★★★ 母分散の信頼区間

方針

ピボットを χ^2 の2.5%点と97.5%点で挟み、逆数を取って σ^2 について解く(不等号の向きが入れ替わる)。

解答

(1)

$$P\left(\chi_{0.975}^2(9) \leq \frac{(n-1)U^2}{\sigma^2} \leq \chi_{0.025}^2(9)\right) = 0.95$$

中辺の逆数を取り $(n-1)U^2$ を掛けると

$$P\left(\frac{(n-1)U^2}{\chi_{0.025}^2(9)} \leq \sigma^2 \leq \frac{(n-1)U^2}{\chi_{0.975}^2(9)}\right) = 0.95$$

(2) $(n-1)u^2 = 9 \times 8.4 = 75.6$ より

$$\left(\frac{75.6}{19.02}, \frac{75.6}{2.700}\right) = (3.97, 28.0)$$

(3) χ^2 分布自体が右に歪んでいて、分位点が中心 $m = 9$ に対して非対称(2.700 と 19.02)だから。さらに逆数を取る操作が非対称性を増幅し、区間は $u^2 = 8.4$ の右側に大きく伸びる。

ポイント

「分散はかなり大きい可能性を否定できない」— $n = 10$ では σ^2 が u^2 の3倍超まで区間に入ります(問8.8で見た分散推定の暴れやすさの裏返し)。ノイズ分散の仕様保証など分散そのものが対象のときは、平均の感覚(対称な 土)を持ち込まないよう注意が必要です。

解 10.7 ★★★ 片側信頼限界(無故障データ)

方針

故障率 λ のとき「総時間 T で故障0」の確率は $e^{-\lambda T}$ (ポアソン過程、第14章; 指数寿命の無故障とも読める)。これが5%を割るほど大きい λ は「データと両立しない」として除外する。

解答

(1) $e^{-\lambda T} \geq 0.05 \iff \lambda T \leq \ln 20 \iff \lambda \leq \frac{\ln 20}{T}$ 。よって95%上側信頼限界は

$$\lambda_U = \frac{\ln 20}{T} = \frac{2.996}{T} \approx \frac{3.0}{T}$$

(「故障0でも λ は $3/T$ までありうる」— 分子がほぼ3なので**3のルール**と呼ばれる。)

(2) $T = 10^4$ 時間なら $\lambda_U = 3.0 \times 10^{-4}$ /時間。

(3) 使い方:無故障の実績しかなくても「 $\lambda \leq 3/T$ (信頼度95%)」という定量的な上限の主張ができる。逆に、故障ゼロは「 $\lambda = 0$ 」の証明にはならない: $\lambda = 3/T$ でも無故障になる確率が5%あり、データはその可能性を否定できていない。目標の故障率 λ^* を95%で保証したければ $T \geq 3/\lambda^*$ の無故障試験が必要 — 保証したい水準の**3倍の総時間**が要る、と読める。

ポイント

「事故ゼロの走行実績から安全性をどこまで主張できるか」という自動運転の実証問題の骨格がこれです(問17.6で車載の数値に展開)。片側限界は「良い方は問わない、悪い方だけ抑えたい」安全評価の標準形。なお比率版の3のルール(n 回無事故なら $p \leq 3/n$)も同じ計算 $(1 - p)^n \geq 0.05$ から出ます。

第11章

仮説検定 — 解答解説

偶然と本物を切り分ける

解 11.1 ★ z検定

方針

σ 既知なのでz検定。両側5%の棄却域は $|Z| > 1.960$ 。

解答

$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{52.1 - 50}{6/\sqrt{36}} = \frac{2.1}{1} = 2.1$$

$|2.1| > 1.960$ なので H_0 を棄却:平均は変わったと判断できる(有意水準5%)。p値は

$$p = 2 P(Z \geq 2.1) = 2(1 - 0.9821) = 0.036$$

ポイント

論理は背理法の確率版:「 H_0 が正しいとすれば、 $|Z| \geq 2.1$ ほどの外れは3.6%しか起きない。それが起きた — ならば前提 H_0 を疑おう」。信頼区間との表裏も確認できます:95%区間 $52.1 \pm 1.96 = (50.14, 54.06)$ が 50 を含まないことと、両側5%で棄却されることは同値です。

解 11.2 ★ 2種類の過誤

方針

H_0 = 「いない」を基準に、棄却 = 警報、と対応づける。

解答

(1) 第1種の過誤(H_0 が真なのに棄却) = 歩行者がいないのに警報を出す「**誤報**」。第2種の過誤(H_1 が真なのに棄却しない) = 歩行者がいるのに警報を出さない「**見逃し**」。

(2) 警報のしきい値(検出スコアの棄却ライン)を上げれば誤報 α は減るが、そのぶん本物の歩行者もしきい値を越えにくくなり、見逃し β が増える。両者は同じしきい値の表と裏であり、片方だけを自由に下げることはできない。両方を同時に下げる正攻法は、判別に使う情報を増やす(標本サイズ・センサ性能・特徴量を改善して2つの分布の重なりを減らす)ことである。

ポイント

しきい値を動かしたときの(誤報率, 検出力)の軌跡が **ROC曲線**で、検出器の評価の標準言語です。どちらの過誤が重いかは応用で決まります: ブレーキの見逃しは事故に直結する一方、誤報が多すぎれば運転者が警報を信じなくなる(狼少年化) — 統計だけでなくシステム設計の問題であることも押さえておきましょう。

解 11.3 ★ 1標本t検定(片側)

方針

帰無仮説 $\mu \geq 250$ のうち、下側棄却域へ入る確率が最大になる境界 $\mu = 250$ でt統計量を較正する。

解答

境界での統計量は

$$T = \frac{248 - 250}{8/\sqrt{16}} = -1.0$$

棄却域は $T < -1.753$ である。 -1.0 は棄却域に入らないため、 $H_0 : \mu \geq 250$ を棄却できない。すなわち「母平均が250未満であると結論する十分な統計的証拠は得られなかった」。

これは規格を満たすことの証明ではない。規格適合を積極的に示す目的なら、仮説の向きや非劣性マージンを含む別の試験設計が必要である。

ポイント

単純帰無仮説 $\mu = 250$ とだけ書く計算は、複合帰無仮説を境界で較正する手順の省略形である。実務上の結論と仮説集合を一致させることが重要である。

解 11.4 ★★ p値の解釈

方針

p値の定義「 H_0 の下での条件付き確率」に照らして1つずつ判定。

解答

(1) 誤り。p値は $P(\text{極端なデータ} \mid H_0)$ であって $P(H_0 \mid \text{データ})$ ではない。条件の向きが逆(この2つを混同するのが最も有名な誤読; 逆向きを計算したければベイズの定理と事前確率が必要 — 第13章)。

(2) 正しい。これが定義そのもの。

(3) 正しい。 $p = 0.03 \leq 0.05$ なので5%では棄却、 $0.03 > 0.01$ なので1%では棄却しない。p値は「棄却できる最小の有意水準」と読める。

(4) 誤り。p値は「差の大きさ」と「標本サイズ」の合成である。巨大な n なら実質的に無意味な微差でも p は小さくなる。効果の重要性は、差の推定値と信頼区間(効果量)で別途報告すべ

きである。

ポイント

(4) は現代のデータ分析で特に重要です: n が数百万のログ解析では「すべてが有意」になりがちで、**統計的有意と実務的重要性は別**。また「有意になるまでデータを足す/多数の指標を試して有意なものだけ報告する」(p-hacking)は α の保証を壊します。検定は事前に設計した問いに対して使う道具です。

解 11.5 ★★ 検出力と標本サイズ

方針

棄却しきい値を数値にし、「真の分布 $N(52, \sigma^2/n)$ のもとでしきい値を超える確率」を計算する。

解答

(1) $n = 36: \sigma/\sqrt{n} = 1$ 、しきい値は $50 + 1.645 \times 1 = 51.645$ 。真値 $\mu = 52$ のとき

$$\begin{aligned}\text{検出力} &= P(\bar{X} > 51.645) = P\left(Z > \frac{51.645 - 52}{1}\right) \\ &= P(Z > -0.355) = \Phi(0.355) = 0.639\end{aligned}$$

(2) $n = 100: \sigma/\sqrt{n} = 0.6$ 、しきい値 50.987。

$$\text{検出力} = P\left(Z > \frac{50.987 - 52}{0.6}\right) = P(Z > -1.688) = \Phi(1.688) = 0.954$$

(3) 同じ真の差(+2)でも、 $n = 36$ では36%の確率で見逃す。「差を Δ 以上なら検出力80～90%で検出したい」という要求から n を逆算するのが実験計画の標準であり、検出力を考えずに「有意になりませんでした」と報告するのは、単に n 不足の可能性がある。

ポイント

検出力の一般式 $1 - \beta = \Phi\left(\frac{\Delta}{\sigma/\sqrt{n}} - z_\alpha\right)$ から、必要 n は $n = \left(\frac{(z_\alpha + z_\beta)\sigma}{\Delta}\right)^2$ 。A/Bテストの設計ツールの中身はこの式です。「検出したい最小の差 Δ 」を先に決めることが、目的の明確化にもなります。

解 11.6 ★★ 2標本t検定

方針

等分散仮定の下でプールした分散 s_p^2 を作り、差の標準誤差で割る。自由度は $n_A + n_B - 2 = 14$ 。

解答

$$s_p^2 = \frac{7 \times 30 + 7 \times 26}{14} = 28, \quad \text{se} = \sqrt{28 \left(\frac{1}{8} + \frac{1}{8} \right)} = \sqrt{7} = 2.646$$

$$T = \frac{120.5 - 115.3}{2.646} = \frac{5.2}{2.646} = 1.965$$

$|1.965| < 2.145 = t_{0.025}(14)$ なので、有意水準5%では H_0 (差なし)を棄却できない(p 値 ≈ 0.070)。

ポイント

5.2 msの差が観測されても「偶然の範囲を出ない」判定 — しかし $p = 0.07$ は「差の示唆はあるが証拠不十分」というグレーゾーンで、追試(標本追加)の価値がある水準です。実務では有意性だけでなく差の信頼区間 $5.2 \pm 2.145 \times 2.646 = (-0.5, 10.9)$ を添えると、判断材料が格段に増えます。等分散が怪しいときは Welch のt検定(自由度を補正)が既定の選択肢です。

解 11.7 ★★ 比率の検定

方針

標準誤差は帰無仮説の値 $p_0 = 0.85$ で計算する(H_0 の下での分布を使うため)。片側なので棄却域は $Z > 1.645$ 。

解答

$$Z = \frac{0.9 - 0.85}{\sqrt{0.85 \times 0.15/200}} = \frac{0.05}{0.02525} = 1.98$$

$1.98 > 1.645$ なので H_0 を棄却: 検出率は向上したと言える(有意水準5%)。p値は

$$p = P(Z \geq 1.98) = 1 - 0.9762 = 0.024$$

ポイント

問10.4(区間)では標準誤差に $\hat{p}$ を使いましたが、検定では「 H_0 が正しい世界」でのばらつき、すなわち p_0 を使うのが原則 — どの分布の下で確率を測っているかを常に意識してください。ベンチマーク間の比較(2標本の比率差)にはもう一段の公式がありますが、考え方は同じです。両側で見ると $p = 0.048$ とぎりぎりになる点も、片側/両側の事前決定の大切さを物語ります。

解 11.8 ★★ 適合度検定

方針

期待度数は $120/6 = 20$ ずつ。 $\chi^2 = \sum (O - E)^2/E$ 、自由度は $6 - 1 = 5$ 。

解答

$$\begin{aligned}\chi^2 &= \frac{(15-20)^2 + (25-20)^2 + (20-20)^2 + (15-20)^2}{20} \\ &= \frac{25 + 25 + 0 + 25 + 4 + 9}{20} = \frac{88}{20} = 4.4\end{aligned}$$

$4.4 < 11.07 = \chi_{0.05}^2(5)$ なので棄却できない:このデータから「サイコロが歪んでいる」とは言えない。

ポイント

$(O - E)^2/E$ の形は、各セルの度数がほぼポアソン(分散 $\approx$ 平均 $=E$)であることに由来する標準化です。自由度が1減るのは「合計が120に固定」という制約のため(問8.4の $n - 1$ と同じ理屈)。乱数生成器の一様性テスト、カテゴリ分布のモデル検証など、離散データの検定の基本形です(期待度数が5未満のセルが多いときは近似が崩れるので併合や正確検定を)。

解 11.9 ★★★ 独立性の検定

方針

期待度数=行和 $\times$ 列和 $\div$ 総数。自由度は $(2 - 1)(2 - 1) = 1$ 。

解答

(1) 分割表(行:天候、列:異常/正常):観測は 晴れ (8, 192)、雨 (18, 82)。行和は200と100、列和は26と274、総数300。独立なら

$$\begin{aligned}E_{\text{晴,異}} &= \frac{200 \times 26}{300} = 17.33, & E_{\text{晴,正}} &= 182.67, \\ E_{\text{雨,異}} &= \frac{100 \times 26}{300} = 8.67, & E_{\text{雨,正}} &= 91.33\end{aligned}$$

(2)

$$\chi^2 = \frac{(8 - 17.33)^2}{17.33} + \frac{(192 - 182.67)^2}{182.67} + \frac{(18 - 8.67)^2}{8.67} + \frac{(82 - 91.33)^2}{91.33} \\ \approx 5.02 + 0.48 + 10.05 + 0.95 = 16.51$$

$16.51 > 3.841 = \chi_{0.05}^2(1)$ なので独立性を**棄却**:天候と異常発生には関連があると言える(p値 $\approx 4.8 \times 10^{-5}$)。異常率は晴れ4%に対し雨18%で、雨天時に集中している。

ポイント

期待度数の式は「独立なら $P(\text{雨} \cap \text{異常}) = P(\text{雨})P(\text{異常})$ 」(第2章)の度数版です。関連が示せても**因果や機構は別問題**(雨そのものか、暗さか、路面反射か)で、次の調査の仮説を与えるのが検定の役割。車載データ解析では、こうした層別(天候・時間帯・場所)との関連探索が異常解析の常套手段です。

解 11.10 ★★★ ネイマン・ピアソンの補題

方針

両仮説とも分布が完全に決まる(単純仮説)。尤度比を書き、単調変換で $\bar{x}$ の条件に落とす。

解答

(1)

$$\frac{L_1}{L_0} = \frac{\prod \exp\left(-\frac{(x_i-1)^2}{2}\right)}{\prod \exp\left(-\frac{x_i^2}{2}\right)} = \exp\left(\sum x_i - \frac{n}{2}\right) = \exp\left(n\bar{x} - \frac{n}{2}\right)$$

これは $\bar{x}$ の増加関数なので、「尤度比が大きいとき棄却」は「 $\bar{x} > c$ で棄却」と同値。ネイマン・ピアソンの補題により、この形が与えられた α の下で検出力最大(最強力)である。

(2) H_0 の下で $\bar{X} \sim N(0, 1/25)$ (標準偏差 0.2)。 $P(\bar{X} > c) = 0.05$ より

$$c = 1.645 \times 0.2 = 0.329$$

(3) H_1 の下で $\bar{X} \sim N(1, 0.04)$ 。

$$\begin{aligned} \text{検出力} &= P(\bar{X} > 0.329) = P\left(Z > \frac{0.329 - 1}{0.2}\right) \\ &= P(Z > -3.355) = \Phi(3.355) = 0.9996 \end{aligned}$$

ポイント

「まず誤報率 α を固定し、その制約下で検出力を最大化する — 単純仮説対単純仮説の最適解は尤度比のしきい値判定」。これがネイマン・ピアソン流の設計思想で、レーダーのCFAR検出、通信の信号検出、そしてMAP復号(問2.10)ともつながる、**検出理論の背骨**です。z検定・t検定も、対応する正規モデルや片側・不偏性など適切な条件下で最強力性を持つ場合がありますが、あらゆる対立仮説に対して一律に最強力というわけではありません。しきい値を動かして得られる $(\alpha, 1 - \beta)$ の軌跡がROC曲線です。

第12章

回帰分析 — 解答解説

最小二乗法と統計的推測

解 12.1 ★ 最小二乗直線

方針

偏差の表を作って S_{xx}, S_{xy} を集計 — 問8.3と同じ型。

解答

$\bar{x} = 3, \bar{y} = \frac{1.8 + 3.2 + 3.9 + 5.1 + 6.0}{5} = 4.0$ 。偏差は $x: -2, -1, 0, 1, 2, y: -2.2, -0.8, -0.1, 1.1, 2.0$ 。

$$S_{xx} = 4 + 1 + 0 + 1 + 4 = 10, \quad S_{xy} = 4.4 + 0.8 + 0 + 1.1 + 4.0 = 10.3$$

$$\hat{\beta}_1 = \frac{10.3}{10} = 1.03, \quad \hat{\beta}_0 = 4.0 - 1.03 \times 3 = 0.91$$

回帰直線は $\hat{y} = 0.91 + 1.03x$ 。

ポイント

回帰直線は必ず重心 $(\bar{x}, \bar{y})$ を通ります ($\hat{\beta}_0$ の式そのもの)。最小二乗の意味は「残差2乗和 $\sum (y_i - \beta_0 - \beta_1 x_i)^2$ の最小化」で、偏微分=0 から上の公式が出ます — そしてこれは誤差が正規なら最尤推定でもある(問9.5のポイント)、という二重の正当化を持ちます。

解 12.2 ★ 決定係数

方針

S_{yy} を集計し、公式 $SSE = S_{yy} - \hat{\beta}_1 S_{xy}$ で残差2乗和を出す。

解答

$$\begin{aligned} S_{yy} &= 2.2^2 + 0.8^2 + 0.1^2 + 1.1^2 + 2.0^2 \\ &= 4.84 + 0.64 + 0.01 + 1.21 + 4.00 = 10.7 \end{aligned}$$

$$SSE = 10.7 - 1.03 \times 10.3 = 10.7 - 10.609 = 0.091$$

$$R^2 = 1 - \frac{0.091}{10.7} \approx 0.9915$$

この標本内では、 y の平均との差の2乗和のうち約99.2%を当てはめた直線が占め、残差平方和は約0.8% — 当てはまりは極めて良い。ただし、これは因果的な「説明」を意味しない。

ポイント

分解 $S_{yy} = SSR + SSE$ (説明された変動+残差変動) は、問8.4・8.7で見た「2乗和の直交分解」の回帰版です。 R^2 は便利ですが万能ではありません: 非線形関係の見逃し、外れ値による見かけの上下(問12.8)があるため、必ず散布図と残差プロットを見るのが分析の作法です。

解 12.3 ★★ 傾きの推定量の性質

方針

S_{xy} の $\bar{Y}$ を含む項が消えることを使って $\hat{\beta}_1$ を Y_i の線形結合に直す。あとは線形性と独立性。

解答

(1) $\sum (x_i - \bar{x}) = 0$ より $\sum (x_i - \bar{x})\bar{Y} = 0$ 。よって

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{S_{xx}} = \frac{\sum (x_i - \bar{x})Y_i}{S_{xx}} = \sum_i c_i Y_i, \quad c_i = \frac{x_i - \bar{x}}{S_{xx}}$$

(2) $E[Y_i] = \beta_0 + \beta_1 x_i$ と、 $\sum c_i = 0$ 、 $\sum c_i x_i = \frac{\sum (x_i - \bar{x})x_i}{S_{xx}} = \frac{S_{xx}}{S_{xx}} = 1$ を使うと

$$E[\hat{\beta}_1] = \sum c_i (\beta_0 + \beta_1 x_i) = \beta_0 \cdot 0 + \beta_1 \cdot 1 = \beta_1$$

(3) ε_i が独立(分散 σ^2)なので

$$V[\hat{\beta}_1] = \sum c_i^2 \sigma^2 = \sigma^2 \cdot \frac{\sum (x_i - \bar{x})^2}{S_{xx}^2} = \frac{\sigma^2}{S_{xx}}$$

S_{xx} (x の広がり)が大きいほど分散は小さい。同じ本数の測定でも、 x を端に広く配置するほど傾きは正確に決まる — 直線を「長い腕」で支えるイメージ。

ポイント

「推定量は観測の線形結合」という見方は、重回帰・カルマンフィルタまで貫く見通しです。(3)は**実験計画**の最重要原理:キャリブレーションで測定点を狭い範囲に密集させるのは損で、範囲の両端を厚くするのが傾き精度には最適です(ただしモデルの直線性の検証には中間点も必要、というトレードオフがあります)。

解 12.4 ★★ 傾きの検定と信頼区間

方針

$\hat{\sigma}^2 = \text{SSE}/(n - 2)$ (自由度は係数2つ分減る)。あとは t の型どおり。

解答

$$\hat{\sigma}^2 = \frac{0.091}{3} = 0.0303, \quad \text{se}(\hat{\beta}_1) = \sqrt{\frac{0.0303}{10}} = 0.0551$$

$$T = \frac{\hat{\beta}_1 - 0}{\text{se}(\hat{\beta}_1)} = \frac{1.03}{0.0551} = 18.7$$

$|18.7| \gg 3.182 = t_{0.025}(3)$ なので $H_0: \beta_1 = 0$ を強く棄却: この回帰モデルの下で傾きは0でなく、 x と y に線形な関連がある。これは単独では因果関係を意味しない。95%信頼区間は

$$1.03 \pm 3.182 \times 0.0551 = 1.03 \pm 0.175 = (0.85, 1.21)$$

ポイント

統計ソフトの回帰出力(係数・標準誤差・t値・p値)の中身がこの計算です。自由度 $n - 2$ は「平均と傾きの2パラメータをデータから推定した」ことの反映(問8.4の一般化)。 $n = 5$ と小さいため、 $R^2 = 0.99$ でも区間は $\pm 17\%$ と意外に広い — 当てはまりの良さと係数の精度は別物です。

解 12.5 ★★ 平均応答の区間と外挿

方針

点推定は直線に代入。標準誤差は $\hat{\sigma}\sqrt{1/n + (x_0 - \bar{x})^2/S_{xx}}$ 。

解答

点推定: $\hat{y}(6) = 0.91 + 1.03 \times 6 = 7.09$ 。標準誤差:

$$\text{se} = \hat{\sigma}\sqrt{\frac{1}{5} + \frac{(6 - 3)^2}{10}} = \sqrt{0.0303 \times 1.1} = 0.183$$

95%信頼区間: $7.09 \pm 3.182 \times 0.183 = 7.09 \pm 0.58 = (6.51, 7.67)$ 。

区間が広がる理由: $(x_0 - \bar{x})^2 / S_{xx}$ の項は**傾きの不確かさ**が x_0 までの距離に比例して増幅されることを表す(支点 $(\bar{x}, \bar{y})$ を中心に直線が「ぶれる」扇形を想像するとよい)。さらに外挿では、幅の拡大以前に「データ範囲外でも直線関係が続く」という**検証不能な仮定**に依存しており、モデルが範囲外で曲がっていれば区間ごと外れる。区間は「モデルが正しいとき」の保証でしかない。

ポイント

これは「平均応答(回帰直線の高さ)」の区間です。個々の新しい観測 Y を当てる**予測区間**は、これにノイズ1個分 $\hat{\sigma}^2$ を足した $\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$ を使い、ずっと広がります(問10.2(3)と同じ区別)。センサのレンジ外での校正式の使用が危険なのは、まさに外挿だからです。

解 12.6 ★★ 相関係数と回帰

方針

問8.3と同じ計算。 r^2 と問12.2の R^2 を突き合わせる。

解答

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \frac{10.3}{\sqrt{10 \times 10.7}} = \frac{10.3}{\sqrt{107}} \approx 0.9957$$

$r^2 \approx 0.9915 = R^2$ で一致。また

$$r \sqrt{\frac{S_{yy}}{S_{xx}}} = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \cdot \sqrt{\frac{S_{yy}}{S_{xx}}} = \frac{S_{xy}}{S_{xx}} = \hat{\beta}_1 \quad \checkmark$$

ポイント

単回帰では「相関の強さ」と「直線の説明力」は同じ情報です($R^2 = r^2$;重回帰では別物になります)。関係式 $\hat{\beta}_1 = r \frac{s_y}{s_x}$ は、両変数を標準化すると傾きが r そのものになることを意味し、 $|r| < 1$ ゆえ予測は常に平均側へ縮む — これが「平均への回帰(regression)」という語の由来です(問5.8の $E[Y | X = x] = \rho x$ のデータ版)。最後に注意: r が高くても因果は言えません。交絡(第3の変数)や逆向きの因果がありえます — 介入実験・因果推論は別の枠組みが必要です。

解 12.7 ★★★ 重回帰(正規方程式)

方針

X は 4×3 。 $X^T X$ 、 $X^T \mathbf{y}$ を作り、3元連立を消去法で解く。

解答

(1)

$$X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 3 & 2 \\ 1 & 4 & 2 \end{pmatrix}, \quad X^T X = \begin{pmatrix} 4 & 10 & 6 \\ 10 & 30 & 17 \\ 6 & 17 & 10 \end{pmatrix}, \quad X^T \mathbf{y} = \begin{pmatrix} 21 \\ 61 \\ 35 \end{pmatrix}$$

(2) 正規方程式 $X^T X \hat{\beta} = X^T \mathbf{y}$ を消去法で解く。第2式-第1式 $\times 2.5$: $5\beta_1 + 2\beta_2 = 8.5$ 。第3式-第1式 $\times 1.5$: $2\beta_1 + \beta_2 = 3.5$ 。後者から $\beta_2 = 3.5 - 2\beta_1$ を前者に代入して $\beta_1 = 1.5$ 、 $\beta_2 = 0.5$ 、第1式より $\beta_0 = 0.75$ 。

$$\hat{\beta} = (0.75, 1.5, 0.5)^T, \quad \hat{y} = 0.75 + 1.5x_1 + 0.5x_2$$

(3) 当てはめ値は 2.75, 4.25, 6.25, 7.75、残差は $e = (0.25, -0.25, -0.25, 0.25)$ 、 $SSE = 4 \times 0.0625 = 0.25$ 。直交性:

$$\begin{aligned} \mathbf{1}^T e &= 0, & \mathbf{x}_1^T e &= 0.25 - 0.5 - 0.75 + 1 = 0, \\ \mathbf{x}_2^T e &= 0.25 - 0.25 - 0.5 + 0.5 = 0 \checkmark \end{aligned}$$

ポイント

正規方程式は $X^T(\mathbf{y} - X\hat{\boldsymbol{\beta}}) = \mathbf{0}$ 、すなわち「残差は説明変数の張る空間と直交する」という条件そのもの — 最小二乗=正射影(姉妹編・線形代数の主題)です。統計側の結果もそのまま拡張され、 $V[\hat{\boldsymbol{\beta}}] = \sigma^2(X^T X)^{-1}$ 、各係数の t 検定は自由度 $n - p - 1$ で行います。説明変数同士が強く相関すると $X^T X$ が特異に近づき係数が暴れる(多重共線性)ことも、行列の言葉で理解できます。

解 12.8 ★★★ 外れ値の影響とロバスト化

方針

$\bar{y}$ と S_{xy} だけ再計算(S_{xx} は不変)。変化の大きさを見る。

解答

(1) 新しい $\bar{y} = \frac{1.8 + 3.2 + 3.9 + 5.1 + 12.0}{5} = 5.2$ 。偏差積和は

$$\begin{aligned} S_{xy} &= (-2)(-3.4) + (-1)(-2.0) + 0 + (1)(-0.1) + (2)(6.8) \\ &= 6.8 + 2.0 - 0.1 + 13.6 = 22.3 \end{aligned}$$

$$\hat{\beta}_1 = \frac{22.3}{10} = 2.23, \quad \hat{\beta}_0 = 5.2 - 2.23 \times 3 = -1.49$$

傾きは 1.03 $\rightarrow$ 2.23 と2倍以上、切片は 0.91 $\rightarrow$ -1.49 と符号まで反転。たった1点で直線が別物になった。

(2) 二乗損失は大きな残差に2乗で重い罰を課すため、直線は外れ値を「なだめる」方向へ強く引き寄せられる。しかも $x_5 = 5$ は x の端で $c_5 = (x_5 - \bar{x})/S_{xx}$ が最大 — 端の点はこの支点から遠い力点のように傾きへの影響力(レバレッジ)が大きい。端の外れ値は最悪の組み合わせである。

(3) 対策:(a) 残差の大きい点の重みを落とす**ロバスト回帰**(Huber損失、最小絶対偏差など — 中央値が平均より頑健なこと(問8.1)の回帰版)。(b) **RANSAC**(問2.9):少数点でモデルを仮組みし、賛同する点(インライア)の多いモデルを採る。外れ値率が50%でも、インライアが同じモデルを支持し、十分な独立反復を行うなどの条件下では、高い確率で正しい候補を得られる。画像の対応点あてはめの標準手法だが、無条件の成功保証ではない。いずれも「外れ値を検出して原因を調べる」姿勢とセットで使う。

ポイント

最小二乗の最適性(ガウス・マルコフ、正規なら最尤)は「誤差がおとなしい」仮定の上の話で、仮定が壊れたときの**もろさ**と表裏一体です。実データ(特徴点マッチング、センサログ)には外れ値がしばしば混ざる — 「まず頑健に当て、残差で外れ値を診断し、必要なら精密に再推定」という2段構えが実務の型です。

第13章

ベイズ統計入門 — 解答解説

事前知識とデータの融合

解 13.1 ★ 離散パラメータのベイズ更新

方針

仮説は2つ(公正/細工)。第2章のベイズの定理そのもの — ただし「仮説」がパラメータの値になっている。

解答

尤度は $P(\text{HHH} \mid \text{細工}) = 0.8^3 = 0.512$ 、 $P(\text{HHH} \mid \text{公正}) = 0.5^3 = 0.125$ 。事前は各 0.5 なので

$$P(\text{細工} \mid \text{HHH}) = \frac{0.5 \times 0.512}{0.5 \times 0.512 + 0.5 \times 0.125} = \frac{0.512}{0.637} \approx 0.804$$

ポイント

3回の表で信念が 50% → 80% へ動きました。パラメータ推論とは「パラメータの値を仮説群とみなしたベイズの定理」にすぎない — 本章の全問がこの1行の変奏です。値の候補を2個から連続体に増やしたものが次問以降の連続パラメータの更新になります。

解 13.2 ★ ベータ-ベルヌーイの更新

方針

事後 $\propto$ 事前 $\times$ 尤度 の指数を足すだけ: $\theta^{a-1}(1-\theta)^{b-1} \times \theta^7(1-\theta)^3$ 。

解答

(1)

$$\pi(\theta \mid \text{データ}) \propto \theta^{1-1}(1-\theta)^{1-1} \cdot \theta^7(1-\theta)^3 = \theta^{8-1}(1-\theta)^{4-1}$$

よって事後分布は $\text{Beta}(8, 4)$ 。

(2) 事後平均 $\frac{8}{8+4} = \frac{2}{3} \approx 0.667$ 。MAP(最頻値)は $\frac{8-1}{8+4-2} = \frac{7}{10} = 0.7$ 。

(3) MAPの 0.7 は最尤推定 $k/n = 0.7$ と一致(一様事前ではMAP=MLE)。事後平均 $\frac{k+1}{n+2}$ は「成功と失敗を1回ずつ水増しした」形で、 n が小さいとき極端な値を避ける: たとえば $n=3$ 全成功でも 1 でなく $4/5$ と見積もり、「まだ失敗を見ていないだけかもしれない」慎重さを持つ。 $n \rightarrow \infty$ では k/n に一致し、データが事前を圧倒する。

ポイント

ラプラス平滑化は自然言語処理(未出現単語に確率0を与えない)やクリック率推定の定番技法で、その正体は**一様事前のベイズ事後平均**でした。「事前=擬似的な観測 a 回成功・ b 回失敗」という読み方(擬似カウント)は、共役事前分布の直感的理解として万能です。

解 13.3 ★★ 逐次更新

方針

1観測ごとに a (成功)か b (失敗)を1増やす。順番に追うだけ。

解答

$$\text{Beta}(2, 2) \xrightarrow{1} \text{Beta}(3, 2) \xrightarrow{1} \text{Beta}(4, 2) \xrightarrow{0} \text{Beta}(4, 3) \xrightarrow{1} \text{Beta}(5, 3)$$

最終事後は $\text{Beta}(5, 3)$ 、事後平均 $\frac{5}{8} = 0.625$ 。まとめて更新しても、成功3・失敗1を足して $\text{Beta}(2 + 3, 2 + 1) = \text{Beta}(5, 3)$ — 一致する。

ポイント

「今日の事後は明日の事前」— 逐次更新と一括更新が一致するのは、観測が条件付き独立だからです(尤度が積に分解)。ストリーミングデータをパラメータ2個 (a, b) だけ持って処理できる、というオンライン学習の原型で、カルマンフィルタ(第15章)の「予測→更新」ループの静的版とも言えます。順番を入れ替えても結果が同じ点も確認しておきましょう。

解 13.4 ★★ 正規-正規の更新(1観測)

方針

要点欄の公式:精度(分散の逆数)を足し、精度重み付き平均を取る。

解答

$$\frac{1}{\tau_1^2} = \frac{1}{16} + \frac{1}{9} = \frac{9 + 16}{144} = \frac{25}{144} \Rightarrow \tau_1^2 = \frac{144}{25} = 5.76$$

$$\mu_1 = \tau_1^2 \left(\frac{50}{16} + \frac{58}{9} \right) = \frac{144}{25} \cdot \frac{450 + 928}{144} = \frac{1378}{25} = 55.12$$

よって事後分布は $N(55.12, 5.76)$ 。事後平均は、事前平均50(精度 $1/16$)と観測58(精度 $1/9$)を精度の比 $9 : 16$ で重み付けした内分点になっている(観測の方が精密なので観測寄り)。

ポイント

正規×正規の指数部の平方完成(問6.6と同じ計算)から出るこの公式は、**本書後半で最も再利用される式**です。事後分散 5.76 は事前 16 よりも観測ノイズ 9 よりも小さい — 情報は合わせると必ず増える(精度の加算)。問15.2ではこれがそのまま「センサ融合」、問15.3では「カルマンフィルタの更新ステップ」になります。

解 13.5 ★★ 正規-正規の更新(n観測)

方針

$\bar{X} \sim N(\mu, \sigma^2/n)$ なので、「分散 $9/9 = 1$ の観測が1個」とみなして同じ公式へ。

解答

$$\frac{1}{\tau_1^2} = \frac{1}{16} + \frac{9}{9} = \frac{1}{16} + 1 = \frac{17}{16} \quad \Rightarrow \quad \tau_1^2 = \frac{16}{17} \approx 0.941$$

$$\mu_1 = \tau_1^2 \left(\frac{50}{16} + \frac{9 \times 58}{9} \right) = \frac{16}{17} (3.125 + 58) = \frac{16 \times 61.125}{17} \approx 57.53$$

事後は $N(57.53, 0.941)$ 。1観測のとき(55.12)より事後平均は観測側の58へ大きく寄り、事後分散は $5.76 \rightarrow 0.94$ と急減した。この固定分散の正規-正規モデルでは、 n が増えるほど事前の重みは相対的に薄れ、事後平均は $\bar{x}$ に近づき、事後分散は σ^2/n と同じオーダーになる。

ポイント

「事前 vs データ」の綱引きの重みは精度 $1/\tau_0^2$ 対 n/σ^2 。1観測の精度 $1/\sigma^2$ を単位にすると、事前精度は**擬似観測** σ^2/τ_0^2 個分(本問では $9/16 \approx 0.56$ 個分)に相当します。この正則な共役モデルでは、データが十分に増えると事前の影響が相対的に消えることを式から直接確認できます。

解 13.6 ★★ MAP推定と正則化(縮小推定)

方針

問13.5の公式に $\mu_0 = 0$ を入れる。等価性は「事後密度の対数 $=-(2乗和+罰則)/定数$ 」を見る。

解答

(1) 事後は正規なので MAP=事後平均。 $\mu_0 = 0$ を代入して

$$\hat{\mu}_{\text{MAP}} = \frac{\frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} = \frac{n\tau^2}{n\tau^2 + \sigma^2} \bar{x}$$

$$(2) \frac{4 \times 1}{4 \times 1 + 4} \times 10 = \frac{4}{8} \times 10 = 5.$$

(3) 係数 $\frac{n\tau^2}{n\tau^2 + \sigma^2} < 1$ なので、推定値は $\bar{x} = 10$ を事前平均0の方向へ縮めた値(縮小推定)。また対数事後は

$$\ln \pi(\mu | x) = -\frac{1}{2\sigma^2} \sum (x_i - \mu)^2 - \frac{\mu^2}{2\tau^2} + \text{const}$$

なので、MAP は $\min_{\mu} \left\{ \sum (x_i - \mu)^2 + \frac{\sigma^2}{\tau^2} \mu^2 \right\}$ と等価 — 二乗罰則(L2正則化)付き最小二乗であり、罰則の強さ $\lambda = \sigma^2/\tau^2$ は「事前の自信」(τ^2 小=強い正則化)に対応する。

ポイント

リッジ回帰・重み減衰(weight decay)は「係数はそう大きくないはず」という正規事前のMAP推定だった — 機械学習の正則化にベイズの解釈を与える古典的な対応です(L1正則化はラプラス事前に対応)。少データで推定が暴れるのを事前で抑える、という思想は、次章以降のフィルタリングでも一貫しています。

解 13.7 ★★★ 事後予測分布

方針

予測は「パラメータを事後分布で平均する」：全期待値・全分散(第6章)の出番。

解答

(1)

$$P(\tilde{X} = 1 \mid \text{データ}) = \int_0^1 \theta \pi(\theta \mid \text{データ}) d\theta = E[\theta \mid \text{データ}] = \frac{8}{12} = \frac{2}{3}$$

(2) $\tilde{X} = \mu + \varepsilon$ で、 $\mu \sim N(55.12, 5.76)$ (事後)と $\varepsilon \sim N(0, 9)$ は独立。独立な正規の和(問6.6)より

$$\tilde{X} \mid \text{データ} \sim N(55.12, 5.76 + 9) = N(55.12, 14.76)$$

予測分散 14.76 は、パラメータの不確かさ 5.76 と観測ノイズ 9 の和に分解される(全分散の法則: $V[\tilde{X}] = E[V[\tilde{X} \mid \mu]] + V[E[\tilde{X} \mid \mu]] = 9 + 5.76$)。

ポイント

「点推定を代入して予測する」(分散9だけ)と比べ、ベイズ予測は**推定の不確かさまで込みで幅を出す** — 誠実な予測区間の作り方です。機械学習で言う認識論的不確かさ(データ不足由来、5.76)と偶然的不確かさ(ノイズ由来、9)の分解がここに現れています。(1) の形(事後平均が予測確率)は、ラプラス平滑化の予測としての読み直しでもあります。

解 13.8 ★★★ ベイズ識別(2クラス)

方針

$\pi_1 f_1(x) > \pi_0 f_0(x)$ の対数を取り、 x について解く。等分散ガウスなので判定は1次(しきい値)になる。

解答

(1) C_1 と判定する条件は $\pi_1 f_1(x) > \pi_0 f_0(x)$ 。対数を取り、共通因子を消すと

$$\begin{aligned} -\frac{(x-140)^2}{2 \cdot 400} + \ln 0.1 &> -\frac{(x-100)^2}{2 \cdot 400} + \ln 0.9 \\ \frac{(x-100)^2 - (x-140)^2}{800} &> \ln 9 \iff \frac{80x - 9600}{800} > \ln 9 \\ \iff x &> 120 + 10 \ln 9 \approx 142.0 \end{aligned}$$

$$\text{すなわち } x^* = \frac{100 + 140}{2} + \frac{\sigma^2}{\mu_1 - \mu_0} \ln \frac{\pi_0}{\pi_1} = 120 + 10 \ln 9.$$

(2) 誤り率は「背景なのに $x > x^*$ 」+「歩行者なのに $x \leq x^*$ 」:

$$P(\text{誤り}) = 0.9 P\left(Z > \frac{142.0 - 100}{20}\right) + 0.1 P\left(Z \leq \frac{142.0 - 140}{20}\right)$$

$$= 0.9 (1 - \Phi(2.099)) + 0.1 \Phi(0.0986) = 0.9 \times 0.0179 + 0.1 \times 0.5393 \approx 0.07$$

(3) 事前確率が 9 : 1 で背景に偏っているため、判定は「よほど強い証拠がなければ多数派(背景)」に傾く — しきい値は2つの山の中点120から $10 \ln 9 \approx 22$ だけ歩行者側へ移動する。誤って歩行者と言う機会損失(0.9の重み)を抑えるのが全体誤り率最小の戦略だからである。

ポイント

これはガウス分布を仮定した2クラス判別(LDAの1次元版)で、MAP判定=ベイズ最適(誤り率最小)という事実は問2.10・11.10と同じ原理です。ただし歩行者検出では見逃し(重み0.1側の誤り)のコストが桁違いに重い — 誤り率でなく期待損失を最小化するなら、損失比をしきい

値の $\ln$ 項に足すだけで拡張できます(コスト考慮のベイズ決定)。事前確率がしきい値を動かす構図は、基準率の誤り(問2.6)の裏面でもあります。

第14章

マルコフ連鎖とポアソン過程 — 解答解説

時間とともに変わる確率

解 14.1 ★ 遷移行列と多段遷移

方針

2段遷移確率は P^2 の成分。経路(良好→良好→良好、良好→混雑→良好)で場合分けしても同じ。

解答

$$P^2 = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix} \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix} = \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix}$$

求める確率は $(P^2)_{11} = 0.8 \times 0.8 + 0.2 \times 0.4 = 0.72$ 。

ポイント

成分計算 $\sum_k P_{1k}P_{k1}$ は「中継状態で場合分けする全確率の公式」であり、行列積がその帳簿づけを自動化しています(チャップマン・コルモゴロフの等式)。「 n 歩後= P^n 」という翻訳により、確率過程の時間発展が線形代数(固有値・対角化)の問題になる — これが本章の最大の仕掛けです。

解 14.2 ★ 定常分布

方針

$\pi P = \pi$ と $\pi_1 + \pi_2 = 1$ の連立。

解答

$$\pi_1 = 0.8\pi_1 + 0.4\pi_2 \iff 0.2\pi_1 = 0.4\pi_2 \iff \pi_1 = 2\pi_2. \text{和が1より}$$

$$\pi = \left(\frac{2}{3}, \frac{1}{3} \right)$$

意味:初期状態がどちらでも、長時間運用すれば「良好でいる時間の割合」は $2/3$ に近づく (この連鎖は既約・非周期なので収束が保証される)。流入と流出が釣り合う配分、とも読める: $0.2\pi_1 = 0.4\pi_2$ はまさに「良好→混雑の流量=混雑→良好の流量」。

ポイント

定常分布には3つの顔があります:(a) 釣り合いの方程式の解、(b) 長時間平均(エルゴード性)、(c) P^T の固有値1の固有ベクトル。実際 P^2 の行(0.72,0.28)と(0.56,0.44)がすでに $(2/3, 1/3) \approx (0.67, 0.33)$ へ近づきつつあることを確認できます。収束の速さは固有値の第2位(ここでは 0.4)が支配します — 姉妹編・線形代数のべき乗の話がそのまま使えます。

解 14.3 ★★ 劣化モデル(3状態)

方針

初期分布 $\pi_0 = (1, 0, 0)$ に P を2回掛ける。

解答

1周期後: $\pi_1 = (0.9, 0.1, 0)$ 。2周期後:

$$\begin{aligned}\pi_2 &= \pi_1 P = (0.9 \times 0.9, 0.9 \times 0.1 + 0.1 \times 0.8, 0.1 \times 0.2) \\ &= (0.81, 0.17, 0.02)\end{aligned}$$

2周期後には、81%が正常、17%が劣化、2%がすでに故障している。

ポイント

「正常→劣化→故障」の一方向モデルは、信頼性工学の多状態劣化モデルの最小例です。故障状態は一度入ると出られない**吸収状態**(行が $(0, 0, 1)$)で、時間とともに確率が故障へ吸い込まれていく。予知保全(劣化段階での交換)の価値を定量化する土台であり、平均余命の計算が次問です。

解 14.4 ★★ 平均吸収時間

方針

「1歩進んで、行き先から先の平均を足す」1段階解析。未知数は $h_{\text{正}}, h_{\text{劣}}$ の2つ、故障では0。

解答

劣化から: $h_{\text{劣}} = 1 + 0.8 h_{\text{劣}} + 0.2 \times 0 \iff 0.2 h_{\text{劣}} = 1 \iff h_{\text{劣}} = 5$ 。

正常から: $h_{\text{正}} = 1 + 0.9 h_{\text{正}} + 0.1 h_{\text{劣}} \iff 0.1 h_{\text{正}} = 1 + 0.5 \iff h_{\text{正}} = 15$ 。

新品からの平均寿命は15周期(うち、正常滞在の平均 $1/0.1 = 10$ 周期+劣化滞在の平均 $1/0.2 = 5$ 周期、と分解しても確かめられる)。

ポイント

1段階解析(first-step analysis)は「期待値を条件付けで漸化式にする」全期待値の法則(第6章)の応用で、平均到達時間・吸収確率・期待コストを同じ型で解けます。各状態の滞在時間が幾何分布(平均 $1/p$ 、問3.5)になっている点にも注目 — 離散版の「無記憶な滞在」です。

解 14.5 ★★ ランダムウォークとPageRank

方針

状態順をA, B, Cとして遷移行列を書き、定常方程式を解く。

解答

(1)

$$P = \begin{pmatrix} 0 & 1/2 & 1/2 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$

(2) $\pi P = \pi$ と成分和1から、 $\pi = (0.4, 0.2, 0.4)$ 。この単純なランダム閲覧モデルでは、長時間の滞在割合をリンク構造に基づく重要度と読む。

(3) 転置すれば $P^T \pi^T = \pi^T$ であり、列ベクトル π^T は固有値1の固有ベクトルである。

ポイント

実用的なPageRankではテレポーテーションを混ぜ、ダングリングノードや閉じたクラスへ対処する。減衰係数として0.85は歴史的・説明用によく挙げられる値だが、普遍的な現在値や必須の既定値ではなく、実装・目的に応じて設定される。

解 14.6 ★★ ポアソン過程の2つの顔

方針

計数は $N(3) \sim \text{Po}(6)$ 、間隔は $\text{Exp}(2)$ 。(3) は「イベント0個」 $\Leftrightarrow$ 「最初の到着がまだ」。

解答

(1) $N(3) \sim \text{Po}(\lambda t) = \text{Po}(6)$ 。

$$P(N(3) \leq 3) = e^{-6} \left(1 + 6 + \frac{36}{2} + \frac{216}{6} \right) = 61e^{-6} \approx 0.151$$

(2) 間隔 $T \sim \text{Exp}(2)$ より $P(T > 1) = e^{-2} \approx 0.135$ 。

(3) 「時刻 t までイベントが0個」と「最初の到着時刻 T_1 が t より後」は同じ事象なので

$$P(T_1 > t) = P(N(t) = 0) = e^{-\lambda t}$$

右辺はポアソン分布の $k = 0$ 項、左辺は指数分布の裾 — 計数がポアソンであることと間隔が指数であることは、同じ過程の表と裏である。

ポイント

この対応 $\{N(t) = 0\} = \{T_1 > t\}$ は、2つの分布を結ぶ蝶番として何度でも使います。定常・独立増分を持ち、短時間に2件以上が起こる確率を高次の微小量とする単純計数過程など、標準的な仮定を課すとポアソン過程が特徴づけられます。LiDARやSPADセンサの光子計数、ネットワークのパケット到着の一次モデルとして標準的です。

解 14.7 ★★★ 間引き(thinning)

方針

各イベントを独立にコイン(確率0.1)で残す=間引き。残った列もポアソン過程で、強度が $p\lambda$ 。

解答

物体由来イベントは強度 $0.1 \times 2 = 0.2$ /秒のポアソン過程になる(間引きの性質)。10秒間の物体由来イベント数は $\text{Po}(0.2 \times 10) = \text{Po}(2)$ に従い、

$$P(0\text{件}) = e^{-2} \approx 0.135$$

簡単な確認: 区間内の総数 $N \sim \text{Po}(20)$ 、各イベントが物体由来かは独立な $\text{Ber}(0.1)$ なので、物体由来数は「ポアソン個のベルヌーイの和」— そのPMFを計算すると $\text{Po}(2)$ に一致する(複合分布の計算、問6.5の設定)。

ポイント

間引き(および逆の重ね合わせ)の閉性は、ポアソン過程の実務価値の核心です: 検出確率 p のフィルタを通して「ポアソン過程のまま、強度だけ $p\lambda$ に」なるので、モデルの形が壊れません。クラス別のイベント分解(車由来・歩行者由来・ノイズ由来)を独立なポアソン過程の和として扱う根拠でもあります。

解 14.8 ★★★★★ 重ね合わせと競争

方針

合流=重ね合わせ。次のイベントは2つの指数時計の「早い方」で、最小は $\text{Exp}(\lambda_1 + \lambda_2)$ 。

解答

(1) 独立なポアソン過程の重ね合わせなので、強度 $\lambda_1 + \lambda_2 = 4$ /秒のポアソン過程。

$$(2) P(\text{レーダーが先}) = \frac{\lambda_2}{\lambda_1 + \lambda_2} = \frac{3}{4}。$$

$$(\text{導出: } P(T_2 < T_1) = \int_0^\infty \lambda_2 e^{-\lambda_2 t} e^{-\lambda_1 t} dt = \frac{\lambda_2}{\lambda_1 + \lambda_2}。)$$

(3) $\min(T_1, T_2)$ の裾は $P(\min > t) = e^{-\lambda_1 t} e^{-\lambda_2 t} = e^{-4t}$ なので $\min \sim \text{Exp}(4)$ 、平均は $\frac{1}{4} = 0.25$ 秒。

ポイント

「複数の指数時計の競争」は、並列システムの最初の故障(第17章)、複数サーバの最初の応答、化学反応のギレスピー法など至る所に現れる基本モチーフです。強度が「速さ」、強度比が

「勝率」という素直な対応も覚えやすい。センサ統合の文脈では、イベント駆動の処理レート設計(平均0.25秒に1回のイベントを捌く)につながります。

解 14.9 ★★★ 隠れマルコフモデルの1ステップ

方針

観測でベイズ更新し、その事後分布を遷移モデルで1歩予測する。

解答

(1)

$$P(\text{湿} \mid \text{検知}) = \frac{0.2 \times 0.8}{0.2 \times 0.8 + 0.8 \times 0.1} = \frac{2}{3}$$

(2) 事後分布は(乾, 湿) = (1/3, 2/3) なので、

$$P(\text{次が湿}) = \frac{1}{3} \times 0.1 + \frac{2}{3} \times 0.7 = 0.5$$

(3) HMMもカルマンフィルタも、「状態モデルで予測し、観測尤度で更新する」というベイズフィルタの共通骨格を持つ。

ポイント

違いは単に「離散か連続か」だけではない。典型的な有限状態HMMは離散状態と一般のカテゴリ観測モデルを扱い、標準カルマンフィルタは連続状態・線形遷移・線形観測・ガウス雑音という仮定により、平均と共分散だけで厳密な更新を閉じた形で行える。状態空間、遷移・観測モデル、分布仮定を区別して比較する。

第15章

状態推定とカルマンフィルタ — 解答解説

ノイズの中から状態を追いかける

解 15.1 ★ 逐次平均はフィルタである

方針

 $\bar{y}_n$ の定義を $\bar{y}_{n-1}$ で書き直すだけ。形を更新式と見比べる。

解答

$$\bar{y}_n = \frac{(n-1)\bar{y}_{n-1} + y_n}{n} = \bar{y}_{n-1} + \frac{1}{n}(y_n - \bar{y}_{n-1})$$

これは「現在の推定 $\bar{y}_{n-1}$ に、イノベーション $y_n - \bar{y}_{n-1}$ をゲイン $K_n = 1/n$ で足し込む」更新式そのもの。問題文のように別の情報を持つ事前を使わず最初の観測から平均を始めると、 $n-1$ 個の平均の誤差分散は $R/(n-1)$ 。これは観測1個の分散 R より次第に小さくなるので、新しい1個を信じる度合いも下がる。実際 $K = \frac{P^-}{P^- + R}$

$$= \frac{R/(n-1)}{R/(n-1) + R} = \frac{1}{n} \text{ と、カルマンゲインの式から同じ値が出る。}$$

ポイント

「平均を取る」というもっとも素朴な操作が、静止状態($Q = 0$)のカルマンフィルタの特別な場合でした。逆に言えばKFは、状態が動く($Q > 0$)ときに「古い情報を適度に忘れる平均」を自動設計する装置です。逐次形は全データの保持が不要で、組み込み実装の基本形でもあります。

解 15.2 ★ 2センサの融合

方針

精度(分散の逆数)で重み付け — 問13.4の公式で「事前」をレーダー、「観測」をLiDARと読めばよい。

解答

$$\hat{x} = \frac{y_1/R_1 + y_2/R_2}{1/R_1 + 1/R_2} = \frac{10.0/4 + 10.6/1}{1/4 + 1} = \frac{2.5 + 10.6}{1.25} = 10.48 \text{ m}$$

$$V = \left(\frac{1}{4} + 1 \right)^{-1} = 0.8$$

重みは $1/4 : 1 = 1 : 4$ でLiDARが4倍信頼され、推定値10.48はLiDARの10.6寄り。融合後の分散0.8は、**単独最良のLiDAR(1)**よりもさらに小さい — 精度の低いレーダーでも情報は足しになる。

ポイント

「精度は加算される」 $1/V = 1/R_1 + 1/R_2$ がセンサフュージョンの基本原理です(問9.1の最適重みの一般形)。前提は誤差の**独立性**:相関があれば効果は問5.5のとおり目減りし、共通バイアス(外部パラメータのずれ等)は融合では消えません。原理の異なるセンサを組み合わせる工学的理由がここにもあります。

解 15.3 ★★ スカラーKFを2ステップ回す

方針

「予測: $P^- = P + Q(a=1)$ → 更新: $K, \hat{x}, P$ 」を2周する。分数で正確に。

解答

時刻1: 予測 $\hat{x}^- = 0, P^- = 10 + 1 = 11$ 。

$$K_1 = \frac{11}{11 + 2} = \frac{11}{13} \approx 0.846$$

$$\hat{x}_1 = 0 + \frac{11}{13}(3.0 - 0) = \frac{33}{13} \approx 2.538,$$

$$P_1 = \left(1 - \frac{11}{13}\right) \times 11 = \frac{22}{13} \approx 1.692$$

時刻2: 予測 $\hat{x}^- = \hat{x}_1, P^- = \frac{22}{13} + 1 = \frac{35}{13} \approx 2.692$ 。

$$K_2 = \frac{35/13}{35/13 + 2} = \frac{35}{61} \approx 0.574$$

$$\hat{x}_2 = \frac{33}{13} + \frac{35}{61} \left(3.6 - \frac{33}{13}\right) \approx 2.538 + 0.574 \times 1.062 \approx 3.148,$$

$$P_2 = \left(1 - \frac{35}{61}\right) \frac{35}{13} = \frac{70}{61} \approx 1.148$$

ポイント

数値の物語を読みましょう: 初期の無知($P_0 = 10$)ゆえ最初は観測を強く信じ($K_1 = 0.85$)、1回の観測で分散は $10 \rightarrow 1.7$ と激減。2周目は信念が育ったのでゲインが下がり(0.57)、推定は予測と観測の中間に落ち着く。分散は予測で $+Q$ 増え、更新で $(1 - K)$ 倍に減る — この収支が定常値(問15.6)へ向かいます。

解 15.4 ★★ カルマンゲインの意味

方針

$K = P^- / (P^- + R)$ の極限を読む。

解答

- (1) $P^- \gg R$ (予測が観測よりずっと不確か) のとき $K \rightarrow 1$: 更新は $\hat{x} \approx y$, すなわち観測をほぼ丸ごと採用する。初期化直後や長い観測断の後がこの状態。
- (2) $P^- \ll R$ (予測の方がずっと確か) のとき $K \rightarrow 0$: 観測をほぼ無視し、 $\hat{x} \approx \hat{x}^-$ 。ノイズだらけのセンサに信念を荒らされない。
- (3) $K_1 = 0.85 \rightarrow K_2 = 0.57$: 最初は無知ゆえ観測重視、学ぶにつれ予測(蓄積した情報)の比重が増えた — ゲインは「予測と観測の信頼度の配分比」を毎時刻自動調整するダイヤルである。

ポイント

ゲインの式は融合公式(問15.2)の k 側の重み $\frac{1/R}{1/P^- + 1/R} = \frac{P^-}{P^- + R}$ と同一 — 更新とは「予測という名のセンサ」と「実センサ」の融合です。実務では、イノベーション $y - \hat{x}^-$ が $S = P^- + R$ に照らして大きすぎる観測を棄却する(外れ値ゲート、問12.8の思想)など、この枠組みの上に安全装置を足します。

解 15.5 ★★ 観測が来ないとき

方針

更新なしで予測 $P \leftarrow a^2 P + Q$ を5回。 $a = 1$ なら等差、 $|a| < 1$ なら等比の混合。

解答

$a = 1$ なら $P \leftarrow P + Q$ の繰り返しで、5周期後は

$$P = 1 + 5 \times 0.5 = 3.5$$

一般に $a = 1$ (ランダムウォーク) かつ $Q > 0$ では分散は Q ずつ線形に増え続け、上限がない — 観測断が長引くほど推定は際限なく劣化する。一方 $|a| < 1$ (平衡点へ戻る減衰系) では $P \leftarrow a^2 P + Q$ は不動点 $\frac{Q}{1-a^2}$ に収束する。初期値が不動点より大きければ分散は減り、小さければ増えるため、「予測では常に分散が増える」とは限らない。

ポイント

GPS断(トンネル・ビル陰)でのデッドレコニングの誤差成長がまさにこの計算です。線形成長といっても標準偏差では $\sqrt{Qt}$ — ランダムウォークの $\sqrt{t}$ 拡散(第7章の $\sqrt{n}$) が再登場しています。復帰後の最初の観測では P^- が大きい分ゲインが跳ね上がり、素早く引き戻される(問15.4 (1))ところまでがワンセットの挙動です。

解 15.6 ★★★ 定常ゲイン(リカッチ方程式)

方針

予測と更新を1本の漸化式に合成し、不動点 $P_t = P_{t-1} = P_\infty$ を解く。

解答

$$(1) P^- = P_{t-1} + Q, \text{更新後 } P_t = (1-K)P^- = \frac{R}{P^- + R}P^- \text{ より}$$

$$P_t = \frac{(P_{t-1} + Q)R}{P_{t-1} + Q + R}$$

$$(2) P_\infty(P_\infty + Q + R) = (P_\infty + Q)R \text{ を展開して } P_\infty^2 + QP_\infty - QR = 0. Q = 1, R = 2 \text{ で } P_\infty^2 + P_\infty - 2 = 0, \text{ 正の解は}$$

$$P_\infty = \frac{-1 + \sqrt{1+8}}{2} = 1$$

$$(3) P_\infty^- = P_\infty + Q = 2 \text{ より}$$

$$K_{\infty} = \frac{2}{2+2} = 0.5$$

問15.3では $K_1 = 0.846 \rightarrow K_2 = 0.574$ と、確かに 0.5 へ向かって減衰している。

ポイント

「予測で増える分」と「更新で減る分」が釣り合う点が定常分散で、この不動点方程式が(離散代数)リカッチ方程式の最小例です。定常ゲインは初期値によらず決まるので、計算資源の乏しい組み込みでは K_{∞} を事前計算して固定する設計(α - β フィルタ)も定番。KFと最適制御(LQR)が同じリカッチ方程式で結ばれている、という双対性は制御理論への入口です。

解 15.7 ★★★ 2次元KF — 見ていない速度が直る

方針

行列版の式に代入して丁寧に。 $H = (1 \ 0)$ なので S はスカラー、 K は 2×1 。

解答

(1) $\hat{\mathbf{x}}^- = F(0, 1)^T = (1, 1)^T$ (位置は速度分進む)。

$$P^- = FP_0F^T + Q = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 0.5 \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 1 & 1.5 \end{pmatrix}$$

(位置の分散は $2 + 1 = 3$ に増え、位置と速度に相関1が生まれた:速度が大きめなら位置も進みすぎているはず、という結びつき。)

(2) $S = HP^-H^T + R = P_{11}^- + R = 3 + 1 = 4$ 。

$$K = P^-H^TS^{-1} = \frac{1}{4} \begin{pmatrix} 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.75 \\ 0.25 \end{pmatrix}$$

(3) イノベーションは $y_1 - H\hat{\mathbf{x}}^- = 1.4 - 1 = 0.4$ 。

$$\hat{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + 0.4 \begin{pmatrix} 0.75 \\ 0.25 \end{pmatrix} = \begin{pmatrix} 1.3 \\ 1.1 \end{pmatrix}, \quad P = (I - KH)P^- = \begin{pmatrix} 0.75 & 0.25 \\ 0.25 & 1.25 \end{pmatrix}$$

観測したのは位置だけなのに、速度の推定も $1 \rightarrow 1.1$ に修正された。理由は P^- の非対角成分(相関)にある:「予測より位置が進んでいた(+0.4)」という証拠は、相関を通じて「速度も想定よりやや大きい」ことを示唆する。ゲインの第2成分 $K_2 = P_{21}^-/S = 0.25$ がその換算係数で、相関が0ならこの成分は0になり速度は動かない。

ポイント

「見えない成分は、相関を介して観測から学ぶ」— これが多次元KFの真価です。位置観測だけから速度・加速度・ジャイロバイアスまで推定できる(可観測性が満たす限り)のはこの仕組みで、GPS+IMU統合やトラッキング(位置観測から速度を推定して次を予測)の核心です。条件付き分布 $N(\rho x, 1 - \rho^2)$ (問5.8)の「相関があるほど情報が流れる」がベクトルで動いている、と読めます。

解 15.8 ★★★ 3つの顔の同値性

方針

問題文の独立性・不偏性と正の分散を使い、3つを別々に解く。

解答

(1) **ベイズ**: 事後平均は精度重み付き平均であり、

$$E[x | y] = \frac{R\hat{x}^- + P^-y}{P^- + R} = \hat{x}^- + \frac{P^-}{P^- + R}(y - \hat{x}^-)$$

(2) **最小分散**: 事前誤差と観測雑音が無相関なので、線形推定量の誤差分散は

$$f(k) = (1 - k)^2 P^- + k^2 R$$

である。 $f'(k) = 0$ から $k = P^- / (P^- + R)$ 。独立性を仮定しなければ交差共分散項が加わり、この式は一般には成り立たない。

(3) **正則化つき最小二乗**: 目的関数の微分を0とすると、

$$x \left(\frac{1}{P^-} + \frac{1}{R} \right) = \frac{\hat{x}^-}{P^-} + \frac{y}{R}$$

となり、(1) と同じ解を得る。したがって3つとも $K = P^- / (P^- + R)$ の更新式に一致する。

ポイント

ベイズ解としての一致には正規モデルが、最良線形不偏推定としての一致には2次モーメントと無相関性が、二乗目的関数との一致には指定された重みが効いている。「同じ式」になっても、それぞれの最適性を保証する仮定は区別しておく。

第16章

情報理論の基礎 — 解答解説

不確かさを情報量で測る

解 16.1 ★ エントロピーの計算

方針

定義 $H = -\sum p \log_2 p$ に代入するだけ。

解答

(1)

$$\begin{aligned} h(0.9) &= -0.9 \log_2 0.9 - 0.1 \log_2 0.1 = 0.9 \times 0.152 + 0.1 \times 3.322 \\ &= 0.137 + 0.332 = 0.469 \text{ ビット} \end{aligned}$$

(2) 公正なコイン: $h(0.5) = 1$ ビット。4値一様: $H = \log_2 4 = 2$ ビット。

(3) $0.469 < 1 < 2$ 。表が9割と分かっているコインは「ほぼ予想がつく」ので不確かさが小さく、結果を知って得られる情報も平均的に少ない。選択肢が多く等確率なほど不確かさは大きい。

ポイント

$-\log_2 p$ は「確率 p の事象が起きたと知ったときの驚き(ビット)」で、エントロピーはその平均です。まれな事象ほど情報が大きい(問1.5のまれな一致、問2.6の警報)という直感が、対数で定量化されました。 $h(p)$ のグラフ($p = 1/2$ で山)は本章で3回登場する主役関数です。

解 16.2 ★ エントロピーと符号長

方針

各記号の $-\log_2 p$ がちょうど整数になる分布 — 符号長をそれに合わせると平均が H に一致する。

解答

(1)

$$H = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 0.5 + 0.5 + 0.375 + 0.375 = 1.75 \text{ ビット}$$

(2) 平均符号長 $\bar{L} = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.75$ ビット。 $\bar{L} = H$ で一致(固定長なら2ビット必要なところを0.25ビット節約)。

(3) 情報源符号化定理により、どんな一意復号可能な符号でも平均長は H 未満にできない。よって H は「この情報源を平均何ビットで表せるか」の理論限界であり、本問の符号(ハフマン符号)はそれを達成している。頻出記号に短い符号を割り当てる、という圧縮の原理が数式で保証された形である。

ポイント

各確率が $2^{-\ell}$ 型のときは限界ぴったりに達成でき、一般の分布でもハフマン符号で $H \leq \bar{L} < H + 1$ 、ブロック化や算術符号で限界に迫れます。ZIP・PNG・JPEGのエントロピー符号段はこの理論の実装であり、「画像のエントロピー」を測ることが圧縮率の見積もりになる — 確率分布が工学量に直結する好例です。

解 16.3 ★★ KLダイバージェンス

方針

定義に代入。 $\log$ の中身は「真/モデル」の比。

解答

$$\begin{aligned} D(p \parallel q) &= 0.5 \log_2 \frac{0.5}{0.9} + 0.5 \log_2 \frac{0.5}{0.1} \\ &= 0.5(-0.848) + 0.5(2.322) = 0.737 \text{ ビット} \end{aligned}$$

$$\begin{aligned} D(q \parallel p) &= 0.9 \log_2 \frac{0.9}{0.5} + 0.1 \log_2 \frac{0.1}{0.5} \\ &= 0.9(0.848) + 0.1(-2.322) = 0.531 \text{ ビット} \end{aligned}$$

$0.737 \neq 0.531$ で非対称。 $D(p \parallel q)$ は「真実は p なのに q を信じて符号化・予測したときの平均的な損(余分なビット数)」。 p では半々に起こる事象の片方を q が確率0.1としか見ていないため、その事象が起こるたび大きく驚かされ、損が大きい。 $D(q \parallel p)$ は役割を入れ替えた損で、別の量である。

ポイント

KLは「距離」と呼ばれがちですが、対称性も三角不等式も満たしません。どちら向きを使うかで最適化の性格も変わります(機械学習では $D(\text{真} \parallel \text{モデル})$ の最小化=最尤が基本、変分推論では逆向きも使う)。「モデルが小さい確率を割り当てた事象が実際に起こると大損」という非対称の感覚は、まれな事象のモデリング(問2.6)の重要性ともつながります。

解 16.4 ★★ ギブスの不等式

方針

まず0確率を含む場合を分ける。その後、 $\ln x \leq x - 1$ を適用する。

解答

ある点で $p(x) > 0$ かつ $q(x) = 0$ なら、定義により $D(p\|q) = +\infty$ であり結論は直ちに成り立つ。以下、そのような点はないとする。

$S = \{x : p(x) > 0\}$ 上で $\ln(q(x)/p(x)) \leq q(x)/p(x) - 1$ だから、

$$-D(p\|q) \ln 2 \leq \sum_{x \in S} (q(x) - p(x)) \leq 1 - 1 = 0$$

よって $D(p\|q) \geq 0$ 。等号には、 S 上で $q(x) = p(x)$ かつ S 外へ q の確率質量がないことが必要十分で、すなわち $p = q$ である。

m 点上の一様分布 u を使うと、

$$0 \leq D(p\|u) = \log_2 m - H(p)$$

なので $H(p) \leq \log_2 m$ 、等号は一様分布のときに限る。

ポイント

$\ln x$ は凹関数であり、そのグラフが $x = 1$ における接線 $x - 1$ 以下にあることが、使った不等式の幾何学的意味である。

解 16.5 ★★ クロスエントロピー損失

方針

1標本の損失は正解確率の $-\log_2$ 。(2) は問16.3の値を使って分解を数値検算。

解答

(1) $-\log_2 0.7 = 0.515$ ビット。 $-\log_2 0.99 = 0.014$ (自信を持って正解:損失ほぼ0)、
 $-\log_2 0.5 = 1$ (当てずっぽう:1ビットの損)。正解確率が低いほど損失は急増する($\rightarrow 0$ で

→ ∞ :「絶対違う」と断言して外すと無限の罰)。

(2)

$$H(p, q) = -0.5 \log_2 0.9 - 0.5 \log_2 0.1 = 0.5(0.152) + 0.5(3.322) = 1.737 \text{ ビット}$$

一方 $H(p) + D(p \parallel q) = 1 + 0.737 = 1.737$ で一致。

(3) 分解 $H(p, q) = H(p) + D(p \parallel q)$ の第1項 $H(p)$ はデータ固有の不確かさでモデルによらない。よって q についてクロスエントロピーを最小化することは $D(p \parallel q)$ の最小化 (モデルを真の分布へ近づけること) と同じ。さらに、経験分布に対するクロスエントロピーは $-\frac{1}{n} \sum \log_2 q(x_i)$ 、すなわち**負の対数尤度**(の定数倍)なので、その最小化は最尤推定(第9章)と一致する。

ポイント

ニューラルネット分類器の標準損失は、「モデル分布と真の分布のKLを、標本を通して最小化=最尤法」の実装でした。第9章(最尤)と第16章(情報量)がここで握手します。損失の値にも意味があり、 $\log_2$ 換算で「1標本あたり平均何ビット外しているか」と読めます($\ln$ を使う実装なら nat 単位)。

解 16.6 ★★★★★ 二元対称通信路の容量

方針

入力等確率のときの $I(X; Y)$ を計算する(BSCでは等確率入力最適)。

解答

(1) $C = 1 - h(0.1) = 1 - 0.469 = 0.531$ ビット/使用。

(2) 入力 X を等確率とする。対称性より出力も $P(Y = 0) = P(Y = 1) = \frac{1}{2}$ (例: $P(Y = 0) = \frac{1}{2}(1 - p) + \frac{1}{2}p = \frac{1}{2}$)なので $H(Y) = 1$ 。また X を固定すると Y は「確率 p

で反転」だけが残る不確かさなので、どちらの x でも $H(Y | X = x) = h(p)$ 、ゆえに $H(Y | X) = h(p)$ 。したがって

$$I(X; Y) = H(Y) - H(Y | X) = 1 - h(p)$$

入力分布の中でこれが最大($H(Y) \leq 1$ の上限を達成)なので容量は $C = 1 - h(p)$ 。

(3) シャノンの定理は「レート $< C = 0.531$ なら、十分長い符号で誤り率をいくらでも小さくできる。 $> C$ は不可能」と主張する。問2.10の3回繰り返し符号はレート $1/3 \approx 0.333 < C$ だが誤り率は0.028止まりで、繰り返しを増やすとレートが0に向かってしまう。定理は「レートを0.53近くに保ったまま誤りをほぼ0にできる符号が存在する」と言っており、現代のLDPC符号・ポーラ符号(5G等で実用)がそれをほぼ達成している。素朴な冗長化と情報理論的限界のギャップを埋めたのが符号理論の歴史である。

ポイント

$I(X; Y) = H(Y) - H(Y | X)$ は「出力の不確かさのうち、入力を知っても残る分(ノイズ由来 $h(p)$)を引いた、通信で運べた正味の情報」という読みです。 $p = 1/2$ で $C = 0$ (完全なコイン投げ通信路は何も運べない)、 $p = 0$ または 1 で $C = 1$ (確定反転は復号できるので無害)という両端の値も、この式の健全性チェックとして確認する価値があります。

解 16.7 ★★★ 相互情報量と画像レジストレーション

方針

周辺分布を求め、4つの組について定義へ代入する。

解答

(1) 両周辺分布は $(0.5, 0.5)$ なので、

$$I(X; Y) = 0.8 \log_2 1.6 + 0.2 \log_2 0.4 \approx 0.278$$

ビット

(2) 独立なら同時確率と周辺確率の積が一致するため $I(X; Y) = 0$ 。

(3) 正しく対応した位置では一方の輝度が他方について情報を持つため、相互情報量が大きくなりやすい。位置がずれて対応が壊れると独立に近づくので、相互情報量を位置合わせの目的関数にできる。相関係数は線形関係の尺度だが、相互情報量は非線形・非単調な統計的依存も捉えられる。

ポイント

単なる符号反転 $Y = -X$ は相関係数が -1 となる完全な線形関係であり、相関が「破綻する」例ではない。相関が0でも依存する例としては $Y = X^2$ のような対称な非線形関係が適切である。実画像では相互情報量の推定法、補間、重なり領域にも結果が依存するため、最大化だけで自動的に正解が保証されるわけではない。

第17章

信頼性工学の確率モデル — 解答解説

故障率・冗長設計・安全の定量化

解 17.1 ★ FITとMTTF

方針

1 FIT = 10^{-9} /時間。一定故障率なので指数分布の公式で。

解答

(1) $\lambda = 100 \times 10^{-9} = 10^{-7}$ /時間。MTTF = $1/\lambda = 10^7$ 時間(約1140年)。

(2) $P(T \leq 8760) = 1 - e^{-10^{-7} \times 8760} = 1 - e^{-0.000876} \approx 8.76 \times 10^{-4}$ (約0.088%)。

(3) $10^5 \times 8.76 \times 10^{-4} \approx 88$ 台。

ポイント

MTTF「1140年」は個体が千年もつという意味ではなく、**大集団での故障ペースの逆数**です(問4.7の平均の読み違いに注意)。実際、10万台では年間約88台の故障が期待され、個体ではまれでも母数が大きいと無視できません(問3.7の「大量×まれ」)。 $\lambda t \ll 1$ では $1 - e^{-\lambda t} \approx \lambda t$ の近似が便利で、(2) はほぼ $10^{-7} \times 8760$ です。

解 17.2 ★ 直列系

方針

直列=全員生存の積。指数分布なら指数部が足し算=故障率の加算。

解答

(1)

$$R_{\text{sys}}(t) = e^{-\lambda_1 t} e^{-\lambda_2 t} e^{-\lambda_3 t} = e^{-(\lambda_1 + \lambda_2 + \lambda_3)t}$$

より故障率は加算されて $100 + 50 + 50 = 200 \text{ FIT}$ 。

(2) $\lambda = 2 \times 10^{-7} / \text{時間}$ 、 $R(8760) = e^{-2 \times 10^{-7} \times 8760} = e^{-0.00175} \approx 0.99825$ 。

(3) $\text{MTTF} = 1/\lambda = 5 \times 10^6 \text{ 時間}$ 。

ポイント

「故障率はFITのまま足せる」— 部品表から系全体の故障率を積み上げる**故障率予測**の基本操作です(独立性が前提;共通原因は問2.7)。直列系は「最弱リンク」で決まり、部品点数が増えるほど故障率は線形に悪化する。だからこそ重要機能には次問の冗長化を投じます。なお $\min$ の分布が $\text{Exp}(\sum \lambda_i)$ になる話(問14.8)と同じ数学です。

解 17.3 ★★ 並列冗長と多数決(TMR)

方針

並列は全滅の余事象、TMRは正常系統数が2以上となる二項確率で求める。

解答

(1) $1 - (1 - 0.99)^2 = 0.9999$ 。

(2)

$$R_{\text{TMR}} = \binom{3}{2} R^2 (1 - R) + R^3 = 3R^2 - 2R^3$$

$R = 0.99$ では0.999702。

(3)

$$R_{\text{TMR}} - R = R(1 - R)(2R - 1)$$

したがって、 $0 \leq R \leq 1$ でTMRが単一系より厳密に有利なのは $1/2 < R < 1$ 。 $R = 0, 1/2, 1$ では等しく、 $0 < R < 1/2$ ではTMRの方が低い。

ポイント

$R = 1$ では単一系もTMRも完全なので、厳密な改善はない。また独立性、同一信頼度、完全な投票器という仮定が必要であり、共通原因故障や投票器故障を含めると式は変わる。

解 17.4 ★★ ワイブル分布とB10寿命

方針

信頼度を時間について解き、対数信頼度を微分する。

解答

(1)

$$t_{B10} = 10^4 \sqrt{-\ln 0.9} \approx 3.24 \times 10^3$$

時間

(2)

$$\lambda(t) = -\frac{d}{dt} \ln R(t) = \frac{m}{\eta} \left(\frac{t}{\eta} \right)^{m-1}$$

(3) $m < 1$ なら減少故障率、 $m = 1$ なら一定故障率、 $m > 1$ なら増加故障率である。これらは順に初期故障期・偶発故障期・摩耗故障期の局所モデルとして使える。

ポイント

固定した1つの形状母数では故障率は単調減少・一定・単調増加のいずれかであり、減少してから一定となり、さらに増加する完全なバスタブ曲線を1本で表すことはできない。全期間を扱うには区分モデル、混合モデル、競合リスクなど別の構成が必要になる。

解 17.5 ★★ コールドスタンバイ

方針

主系の故障→予備の故障、と「一定レート λ のイベント」が2回起こって初めてシステム故障。

時刻 t までのイベント数は $Po(\lambda t)$ 。

解答

(1) 主系稼働中も(切替後の)予備稼働中も、故障は常にレート λ で起こる。よって「時刻 t までの故障イベント数 $N(t)$ 」は強度 λ のポアソン過程に従い、システムが生きている $\Leftrightarrow N(t) \leq 1$ 。

$$R(t) = P(N(t) \leq 1) = e^{-\lambda t} + \lambda t e^{-\lambda t} = e^{-\lambda t}(1 + \lambda t)$$

(2) $\lambda t = 1$ なので $R_{\text{cold}} = 2e^{-1} \approx 0.736$ 。ホットスタンバイは $R_{\text{hot}} = 2e^{-1} - e^{-2} \approx 0.600$ 。コールドの方が13ポイント以上高い(待機中は消耗しないため)。

(3) MTTFは、コールドが「寿命2本分」で $2/\lambda$ 、ホットは $\int_0^\infty (2e^{-\lambda t} - e^{-2\lambda t}) dt = \frac{2}{\lambda} - \frac{1}{2\lambda} = \frac{1.5}{\lambda}$ 。コールドが優れるが、実際には切替の検知・起動が失敗する確率や待機中の潜在故障があり、理想値どおりにはならない。切替機構の信頼性と故障検知率(診断カバレージ)込みで評価するのが実務である。

ポイント

「 k 個目の故障までの時間=指数の和=ガンマ分布(アーラン分布)」で、 $R(t)$ がポアソンの累積で書けるのはポアソン過程の計数と間隔の双対(問14.6)そのものです。コールド(温存)対ホット(即応)の選択は、切替時間・検知能力・消耗のトレードオフ — ブレーキの機械バックアップ、電源の二重化など、車載設計の定番論点です。

解 17.6 ★★★ 安全目標の実証に必要な走行時間

方針

無故障観測の片側95%上限 $\lambda_U = \ln 20/T$ を目標値以下にする。

解答

(1)

$$T \geq \frac{\ln 20}{10^{-8}} \approx 2.996 \times 10^8$$

時間

「厳密に $\lambda < 10^{-8}$ 」を上限值そのものと区別するなら、右辺より大きい試験時間が必要である。

(2) 1台年あたり500時間なら約 5.99×10^5 台年である。例えば1万台なら約60年、10万台なら約6年に相当する。

(3) 直接の無故障走行試験だけでは、必要資源が目標故障率の逆数で増大する。加速試験、部品・サブシステム試験、設計解析、プロセス保証、診断、シミュレーションなど、適用条件と不確かさを明示した複数の証拠を組み合わせる必要がある。

ポイント

冗長系を評価するとき、2系統の故障率 λ_1, λ_2 を単純に掛けた $\lambda_1 \lambda_2$ は単位が時間の逆数の2乗であり、システム故障率ではない。任務時間 τ を固定し、各系の任務中故障確率が小さ

く $q_i \approx \lambda_i \tau$ 、かつ独立で「両方が任務中に故障すると危険」という明示的モデルなら、危険事象の任務確率を $q_1 q_2$ と近似できる。連続運用の等価故障率は修復、順序、待機状態、共通原因などを含む状態モデルやフォールトツリーから別途導く。

解 17.7 ★★★ 可用性と年間停止時間

方針

稼働と修復のサイクルで「動いている時間の割合」。冗長版は不稼働率の2乗。

解答

(1)

$$A = \frac{1000}{1000 + 2} = 0.99800 \quad (\text{不稼働率 } 1 - A \approx 2.0 \times 10^{-3})$$

年間停止時間 = $8760 \times (1 - A) \approx 17.5$ 時間。

(2) 不稼働率 $(1 - A)^2 \approx (2.0 \times 10^{-3})^2 = 4.0 \times 10^{-6}$ 。年間停止は $8760 \times 4.0 \times 10^{-6} \approx 0.035$ 時間 ≈ 2.1 分。1台の17.5時間から劇的に改善する(いわゆる「9の数」で二九(99%台)から五九(99.999%台)へ)。

(3) $1 - A = \frac{\text{MTTR}}{\text{MTTF} + \text{MTTR}} \approx \frac{\text{MTTR}}{\text{MTTF}}$ (MTTR $\ll$ MTTF のとき)。不稼働率は近似的に比 MTTR/MTTF で決まるので、MTTFを2倍にするのもMTTRを半分にするのも同じ効果である。実際、 $A(M, r) = M/(M + r)$ とおけば $A(2M, r) = A(M, r/2)$ であり、この2つの改善の同等性は近似によらず厳密に成り立つ。壊れにくくする(信頼性)だけでなく、**早く直す**(保守性:検知・診断・交換の速さ)が同格の設計変数である。

ポイント

可用性は「修復系」の中心指標で、データセンターのSLA(99.9%=年8.8時間、99.999%=年5.3分)の言葉です。(2) の2乗則は独立修復の近似で、修復要員の共有や共通原因で崩れま

す(ここでも問2.7)。信頼性(壊れない)・保守性(すぐ直る)・安全性(壊れ方が危なくない)は別の軸 — 3つを区別して要求を書くことが、システム設計の出発点になります。

第18章

測度論的確率論への入口 — 解答解説

厳密さはなぜ必要か

解 18.1 ★ σ -加法族の構成

方針

全体集合、補集合、可算和について閉じているかを確認する。

解答

(1) $\{\emptyset, \Omega\}$: (i) $\Omega \in \{\emptyset, \Omega\}$. (ii) $\Omega^c = \emptyset, \emptyset^c = \Omega$ がともに含まれるので補集合で閉じる。
 (iii) 族の要素は $\emptyset$ と Ω しかないから、可算個をどう選んで和をとっても、全て $\emptyset$ なら $\emptyset$ 、一つでも Ω を含めば Ω となり、結果は常にこの族に含まれる。よって (i)~(iii) を満たし σ -加法族であり、任意の σ -加法族は Ω と (その補集合としての) $\emptyset$ を必ず含むから、 $\{\emptyset, \Omega\}$ は最小の σ -加法族である。

2^Ω : (i) $\Omega \subseteq \Omega$ より $\Omega \in 2^\Omega$. (ii) Ω の任意の部分集合 A について、補集合 $A^c = \Omega \setminus A$ もまた Ω の部分集合だから 2^Ω に含まれる。(iii) Ω の部分集合を可算個集めた和もまた Ω の部分集合だから 2^Ω に含まれる。よって 2^Ω は σ -加法族であり、 Ω 上のどの σ -加法族もその元は Ω の部分集合 (すなわち 2^Ω の元) なので、 2^Ω は最大の σ -加法族である。

(2)

$$\sigma(\{1, 2\}) = \{\emptyset, \{1, 2\}, \{3, 4\}, \Omega\}$$

(3) σ -加法族ではない。例えば $\{1, 2\}$ の補集合 $\{3, 4\}$ が含まれていない。

ポイント

実数上で全ての部分集合を可測にし、区間の長さで積分する平行移動不変・可算加法的な測度を保つことはできない。その障害を示す標準例は**ヴィタリ集合**のような非可測集合である。バナッハ＝タルスキーのパラドックスも非可測集合を利用するが、1次元の確率測度で σ -加法族が必要な理由を説明する直接の例としてはヴィタリ集合が適切である。

解 18.2 ★ 測度の連続性と「いつかは起こる」

方針

増大列を「年輪」 $B_n = A_n \setminus A_{n-1}$ に切り分けると排反になり、可算加法性が使える。

解答

(1) $B_1 = A_1, B_n = A_n \setminus A_{n-1} (n \geq 2)$ は互いに排反で、 $\bigcup_{k=1}^n B_k = A_n, \bigcup_k B_k = \bigcup_n A_n$ 。可算加法性より

$$P\left(\bigcup_n A_n\right) = \sum_{k=1}^{\infty} P(B_k) = \lim_{n \rightarrow \infty} \sum_{k=1}^n P(B_k) = \lim_{n \rightarrow \infty} P(A_n)$$

(2) A_n は増大列で $P(A_n) = 1 - (1-p)^n$ 。「いつかは成功」 $= \bigcup_n A_n$ なので、(1) より

$$P\left(\bigcup_n A_n\right) = \lim_n \left(1 - (1-p)^n\right) = 1$$

ポイント

「極限と確率の順序交換」を正当化するのが連続性で、その源は公理の**可算**加法性です(有限加法性だけでは証明できない)。第1章で「なぜ公理 (iii) は無限列まで許すのか」と伏線を張った答えがこれ:無限の時間・無限の試行に関する主張(いつかは/無限回/収束する)を扱

のための装備でした。幾何分布の $P(X < \infty) = 1$ が、いま初めて定理として着地しています。

解 18.3 ★★ 可算集合の確率は0

方針

1点を小区間で挟んで $\varepsilon \rightarrow 0$ 。可算集合は「確率0の和(可算個)」。

解答

(1) 任意の $\varepsilon > 0$ で $\{X = c\} \subseteq \{c - \varepsilon < X \leq c + \varepsilon\}$ 。後者と一様分布の台 $[0, 1]$ との共通部分の長さは高々 2ε だから、 $P(X = c) \leq 2\varepsilon$ 。 ε は任意に小さくできるので $P(X = c) = 0$ 。

(2) 有理数は可算なので $\mathbb{Q} \cap [0, 1] = \{q_1, q_2, \dots\}$ と番号づけできる。可算加法性(と(1))より

$$P(X \in \mathbb{Q} \cap [0, 1]) = \sum_{k=1}^{\infty} P(X = q_k) = \sum_{k=1}^{\infty} 0 = 0$$

(3) $[0, 1]$ は**非可算**なので、「全体=各点の和」という分解は可算加法性の適用範囲外である。確率0の点を可算個集めても0のままだが、非可算個集めることについて公理は何も約束していない — だから「各点0・全体1」は矛盾しない。連続分布の確率は点の足し算ではなく、長さ(測度)で測るものである。

ポイント

「一様乱数がぴったり有理数になる確率は0」— 稠密に(どこにでも)ある集合でも測度は0になりうる、という直感の更新です。さらに驚くべきことに、非可算でも測度0の集合(カントール集合)が存在します。「ほとんど確実に(almost surely)=確率1で」という言い回しは、こうした測度0の例外集合を許す表現で、次問以降の収束概念で主役になります。

解 18.4 ★★ 分布収束 $\neq$ 確率収束

方針

対称性で分布は不変。一方、実現値の差 $|X_n - X| = 2|X|$ は全然小さくない。

解答

(1) 標準正規は対称なので $-X \sim N(0, 1)$ 。よってすべての n で X_n のCDFは Φ そのもの — 一定数列として当然 Φ に収束するから、 X_n は X に分布収束する。

(2) $|X_n - X| = |-2X| = 2|X|$ より

$$P(|X_n - X| > \varepsilon) = P\left(|X| > \frac{\varepsilon}{2}\right) = 2\left(1 - \Phi\left(\frac{\varepsilon}{2}\right)\right) > 0$$

これは n によらない正の定数で、0に収束しない。よって確率収束しない。

(3) 分布収束は「分布の形が近づく」ことしか要求せず、 X_n と X の実現値が近いことは全く含意しない(本問では常に符号が逆!)。CLT(第7章)が与えるのはこの弱い意味の収束であり、「 $\bar{X}_n$ の値が標準正規変数 Z の値に近づく」と読むのは誤り — 「標準化した平均 $(\bar{X}_n - \mu)/(\sigma/\sqrt{n})$ の分布が標準正規分布に近づく」が正しい読みである。

ポイント

収束概念の強弱: 概収束 $\Rightarrow$ 確率収束 $\Rightarrow$ 分布収束 (逆は不成立; 本問が後段の反例、次問が前段の反例)。用途で使い分けます — 近似計算の正当化には分布収束(CLT)で十分、推定量の一致性は確率収束(大数の弱法則)、アルゴリズムの軌道1本の挙動には概収束(強法則)。「どの意味で収束か」を言えることが、大学院の確率の第一関門です。

解 18.5 ★★★★ タイプライター列

方針

各区間の幅は0へ縮むが、各点は世代ごとに繰り返し踏まれる。

解答

(1) 第 k 世代の各区間の確率は 2^{-k} 。 $n \rightarrow \infty$ なら対応する世代も無限大へ進むので、任意の $0 < \varepsilon < 1$ に対し、

$$P(|X_n| > \varepsilon) = P(X_n = 1) = 2^{-k} \rightarrow 0$$

よって0へ確率収束する。

(2) 各世代の区間の和集合は $[0, 1]$ なので、任意の点は各世代で少なくとも1回踏まれる。二進分割の端点は2区間に入る場合があるが、結論は変わらない。一方、世代 $k \geq 2$ には4本以上の区間があり、固定した点を含まない区間もあるため、値0も各世代で現れる。したがって各点で0と1が無限回現れ、点ごとの数列は0へ収束しない。ゆえに概収束しない。

ポイント

閉区間を使う定義では「各世代でちょうど1回」とは限らない。確率0の端点の重複は確率収束には影響しないが、点ごとの主張では明示的に処理する必要がある。

解 18.6 ★★★★ ボレル・カンテリの補題

方針

「無限個起こる」=「どのNから先にも起こる」を集合で書き、裾の和で押さえる。

解答

(1) $C = \{A_n \text{ が無限個起こる}\} = \bigcap_{N \geq 1} \bigcup_{n \geq N} A_n$. $U_N = \bigcup_{n \geq N} A_n$ は減少列で $C = \bigcap_N U_N$. 測度の連続性(減少版)と劣加法性より

$$P(C) = \lim_{N \rightarrow \infty} P(U_N) \leq \lim_{N \rightarrow \infty} \sum_{n \geq N} P(A_n) = 0$$

(最後は収束級数の裾が0に向かうこと。)よって $P(C) = 0$.

(2) 任意の $\varepsilon > 0$ に対し $A_n = \{|X_n - X| > \varepsilon\}$ とおくと $\sum P(A_n) \leq \sum C/n^2 < \infty$. 補題より、確率1で A_n は有限個しか起こらない — すなわちある番号から先ずっと $|X_n - X| \leq \varepsilon$. これが $\varepsilon = 1, \frac{1}{2}, \frac{1}{3}, \dots$ (可算個)すべてで成り立つ事象も確率1(確率0の例外の可算和は確率0)なので、確率1で $X_n \rightarrow X$: 概収束する。問18.5の列は $\sum P(X_n \neq 0) = \infty$ (各世代の和が1)なので、この十分条件を満たさない — 実際に概収束しなかったことと整合する。

ポイント

ボレル・カンテリは「失敗確率の和が有限なら、失敗はいつか止む(確率1)」という、**概収束を作るほぼ唯一の初等的な道具**です。ヘフディングの不等式(問7.9)の指数的な裾 $2e^{-2n\varepsilon^2}$ は和が収束するので、経験平均は概収束する — 大数の**強法則**がこのルートで(有界の場合に)証明できます。第7章の弱法則(確率収束)との違いが、ここでようやく言葉になりました。

解 18.7 ★★★ 特性関数とCLTの証明スケッチ

方針

独立和を特性関数の積へ変換し、原点付近の2次展開を使う。

解答

(1) $|e^{itX}| = 1$ なので特性関数は全ての確率分布で存在する。MGFは0を含むどの開区間でも有限にならない分布があるため、この普遍性が特性関数の利点である。ただし、特性関数列の任意の点ごとの極限が自動的に分布収束を与えるわけではない。レヴィの連続性定理では、極限関数が0で連続であることが必要であり、そのとき極限は確率分布の特性関数になる。

(2) 有限な2次モーメントと $E[X] = 0, E[X^2] = 1$ から、 $s \rightarrow 0$ で

$$\varphi_X(s) = 1 - \frac{s^2}{2} + o(s^2)$$

である。独立性と尺度変換より、固定した t に対して

$$\varphi_{S_n}(t) = \left(\varphi_X \left(\frac{t}{\sqrt{n}} \right) \right)^n = \left(1 - \frac{t^2}{2n} + o(n^{-1}) \right)^n \rightarrow e^{-t^2/2}$$

極限は標準正規分布の特性関数であり、特に0で連続である。したがってレヴィの連続性定理により S_n は標準正規分布へ分布収束する。

ポイント

レヴィの定理の連続性条件は技術的な飾りではない。例えば確率質量が無限遠へ逃げる列では、特性関数が各点で収束して見えても、その極限が特性関数にならない場合がある。本問では極限を既知の標準正規の特性関数と同定できるため条件を満たす。

『情報系のための確率・統計 解答解説集』全18章・154問。姉妹編『問題集』とセットで学習してください。

Copyright © 2026 情報系のための数学 問題集シリーズ. All Rights Reserved.